

Asistencia inteligente para la inferencia del rol de usuario en trabajos colaborativos soportados por computadora

Tesis de Grado de la Carrera de Ingeniería en Sistemas de la
Universidad del Centro de la Provincia de Buenos Aires



Directores: Ing. Berdun Franco
Dr. Armentano Marcelo

Alumnos: Colacci Joaquín
D'Achilli Franco

1. Introducción	3
1.2 Motivación	4
1.3 Propuesta	4
1.4 Resumen	6
2. Marco Teórico y conceptual	8
2.1 Teoría de roles de equipo de Belbin	8
2.2 Minería de datos	15
2.2.1 Redes Bayesianas	17
2.3 Aprendizaje de máquina	19
2.4 Modelado de usuario	20
2.5 Procesamiento de Lenguaje Natural	21
2.6 Plataformas de trabajo compartido	22
2.7 Trabajos relacionados	23
2.8 Resumen	27
3. Desarrollo de la propuesta	29
3.1. Estructura de la herramienta a implementar	29
3.2. Consideraciones especiales a tener en cuenta	30
3.3. Enfoques de clasificación de chats propuesto	31
3.3.1 Enfoque directo	33
3.3.2 Enfoque en fases	34
3.3.3 Enfoque en fases cascada	37
3.4 Resumen	38
4. Diseño e implementación de la herramienta propuesta	40
4.1. Requerimientos funcionales y restricciones de diseño	40
4.2 Diseño de la solución	42
4.3 Escenarios de calidad	44
4.3.1 Usabilidad	44
4.3.2 Fiabilidad	46
4.3.3 Precisión	46
4.3.4 Performance	47
4.3.5 Portabilidad	53
4.3.6 Modificabilidad	53
4.4 Persistencia de los datos	54
4.5 Resumen	54
5. Diseño e implementación de la aplicación de análisis de datos	55
5.1 Requisitos funcionales y atributos de calidad	56
5.2 Decisiones de diseño	58
5.2.1 Capa de presentación	58
5.2.2 Capa de Negocio	60
5.3 Atributos de calidad	60
5.3.1 Usabilidad	60
5.3.2 Performance	66

5.3.3 Portabilidad	77
5.3.4 Disponibilidad	78
5.3.4 Escalabilidad	78
5.4 Persistencia de datos	79
5.5 Resumen	81
6. Descripción del experimento	82
6.1. Configuración	82
6.1.1 Roles sociales	85
6.1.2 Roles De Acción	87
6.1.3 Roles Mentales	88
6.2. Resultados de experimentación con técnicas de aprendizaje de máquina	90
6.2.1 Análisis general clasificadores	91
6.2.2 Análisis individual clasificadores entrenamiento directo	96
6.2.3 Análisis individual clasificadores entrenamiento fases	99
6.2.3 Análisis individual clasificadores con filtros entrenamiento directo	102
6.2.4 Análisis individual clasificadores con filtros entrenamiento fases	105
6.2.5 Análisis colectivo de clasificadores con filtros y entrenamiento fases	109
6.3 Aplicación y evaluación de la herramienta resultante	112
6.4 Análisis de métricas de usuarios	116
6.5 Resumen	119
7. Conclusiones	120
7.1 Limitaciones	122
7.2 Trabajos futuros	122
7.3 Implicancias	123
8. Anexos	125
8.1 Relación Teoría de Roles de Belbin con modelos IPA y SYMLOG	125
8.2 Freeling	127
8.3 Weka	128
8.4 Equipo de trabajo	129
9. Documentación de las herramientas	132
9.1. Herramienta de entrenamiento	132
9.1.1 Requisitos e instalación	132
9.1.2 Manual de uso	132
9.2. Herramienta de predicción	138
9.2.1 Requisitos e instalación	138
9.2.2 Manual de uso	141
Referencias	148

1. Introducción

Las organizaciones hoy en día cuentan con la necesidad de formar equipos de trabajo donde sus integrantes se complementan para llegar a lograr los objetivos pactados. Conformar grupos balanceados requiere conocer los roles que cumple cada participante, mediante el análisis de las características que tienen en común, y así también de las diferencias existentes entre ellos, en base al estudio de distintos aspectos de sus conductas.

Cuando se habla de trabajar en equipo no se hace referencia exclusivamente a la unión de esfuerzos, también se refiere a la unión de beneficios. Para trabajar en equipo es indispensable la identificación y unificación de objetivos, así como el complemento e integración de habilidades y esfuerzos. Las tareas individuales dentro del trabajo en equipo son esenciales, aunque deben estar orientadas a la consecución de los objetivos del proyecto y se debe procurar evitar la duplicación de esfuerzos y la interferencia mutua.

Entre las características más importantes de los integrantes de un equipo se encuentra el rol que cada uno de ellos cumple en el grupo. Uno de los principales investigadores de los roles de equipo es Meredith Belbin (Belbin, 1993), que los define como la tendencia de un individuo a comportarse, contribuir e interrelacionarse con otros de una determinada manera. Según dice Belbin “Un equipo no es un conjunto de personas adscritas a determinados puestos de trabajo, sino una congregación de personas donde cada uno de ellos desempeña un rol que es comprendido por el resto de miembros. Los miembros de un equipo negocian entre sí el reparto de roles y desempeñan de manera más eficaz aquellos que les son más naturales”.

Partiendo de esto, en este trabajo, se va a realizar el estudio de individuos de distintos grupos en un contexto de trabajo colaborativo en un entorno virtual (Google Docs, Hangouts), donde los mismos cooperan entre sí para alcanzar los objetivos pactados (Glinz, 2005). Cuando grupos de estudiantes aprenden de manera colaborativa usando la computadora para comunicarse y colaborar, se está en presencia de un escenario de Aprendizaje Colaborativo Soportado por Computadora (ACSC) (Hoadley, Christopher, 1999), donde la transmisión de información se realiza a velocidades mucho mayores con respecto a otros medios, lo cual le aporta gran dinámica y eficacia a las interacciones entre sus miembros. Existen estudios que se han dedicado a determinar si el uso de estas herramientas puede conllevar una mejora de rendimiento en actividades colaborativas. En “Google Docs in an Out-of-Class Collaborative Writing Activity” (Zhou et al., 2012) se analiza de forma comparativa el rendimiento en una tarea asignada de dos grupos, uno utilizando Google Docs y otro no; se concluye que el uso de esta herramienta tiene buena recepción por parte de los alumnos, que muestran una tendencia general a adoptarla una vez introducida. Los estudiantes escribieron ensayos más largos y eran capaces de trabajar en la escritura colaborativa de manera más eficiente cuando utilizaban Google Docs. Brodahl et al. (2011) analiza características de estudiantes que utilizan aplicaciones de escritura en línea, concluyendo que los estudiantes con alta competencia y actitud positiva hacia lo digital obtienen resultados más positivos.

A su vez, con estos medios, se puede recolectar gran cantidad de información, que representada y organizada correctamente, pueden contribuir a la detección de los roles a los que el individuo mejor se adapta, y a la formación de grupos a partir de la eficaz distribución de los mismos.

Para poder analizar la dinámica entre alumnos, se precisa contar primero con una caracterización de cada interacción como demostración de ciertas conductas. Algunos trabajos encontraron relaciones entre la demostración de ciertas conductas como expresiones características de algunos roles, empleando otros modelos de dinámica de grupos (Bales, 1950)(Beck et al., 2005). Estas caracterizaciones van a ser la base del enfoque propuesto, el cual será de utilidad para la rápida detección de roles de equipo, y para la materialización de herramientas de formación de futuros grupos.

1.2 Motivación

Conformar grupos de trabajo balanceados requiere saber qué conductas en común tienen los individuos así como las diferencias existentes entre ellos, para poder detectar los roles que cumple cada uno en base a sus conductas colaborativas.

Se entiende que un grupo posee desbalance de roles cuando está formado por individuos con características similares tendiendo a desempeñar las mismas funciones, provocando como resultado conflictos en el trabajo colaborativo. Por ejemplo, en un grupo conformado solo por personas dotadas con la capacidad de solucionar problemas difíciles, es muy probable que los mismos compitan uno con el otro, invirtiendo gran parte del tiempo en debates, sin convencerse entre ellos. Todo este tipo de conflictos provocados por desbalance de roles son los que se busca evitar con el uso de la herramienta a desarrollar en este trabajo.

Por otra parte, debido a que la labor de análisis de las interacciones por parte de una persona a cargo (líder de proyecto, profesor, etc) insume tiempo y esfuerzos significativos, la existencia de una herramienta puede simplificarlo de forma considerable. Esto va a permitirle al encargado focalizarse en la resolución de los conflictos que pudieran surgir en un grupo desbalanceado, los cuales evitan que los participantes desempeñen los diferentes roles que permiten realizar un trabajo coordinado y exitoso.

Además, la herramienta va a permitir eliminar las encuestas y consultas a los integrantes de grupo las cuales ayudan a obtener un punto de vista de cada uno de acuerdo a la opinión del resto del grupo, ya que esta información se va a detectar mediante técnicas de Inteligencia Artificial.

Con el tiempo, la investigación desarrollada en el área de Inteligencia Artificial ha proporcionado sistemas y técnicas perspicaces capaces de simular el comportamiento de un ser humano en un campo específico. En trabajos relacionados se pudo observar la modelización de perfiles de usuario y la clasificación de sus conductas, a partir de las interacciones de los mismos. Estos perfiles son de suma importancia para la detección de roles y la formación de grupos, mejorando la performance de cada uno de los integrantes y del entorno.

1.3 Propuesta

La propuesta de este trabajo consiste en el desarrollo de enfoques para la inferencia de roles de equipo, basado en una clasificación a partir de los Roles de Belbin, para lo que se aplicarán técnicas de aprendizaje de máquina, una rama de Inteligencia Artificial.

Esta propuesta está basada en el objetivo general del trabajo, el cual consiste en desarrollar una herramienta que provea la asistencia para la detección de los roles. Adicionalmente, mediante el análisis de las demostraciones de cada alumno en base a la teoría de Belbin, realizar la formación automática de grupos eficientes.

El entorno de trabajo colaborativo elegido para desarrollar este trabajo son diferentes aplicaciones dentro de la plataforma de Google. Dentro de estas se encuentra Hangouts, una herramienta de comunicación que los usuarios utilizarán para comunicarse y discutir sobre la tarea a realizar, y Google Docs, que es un editor de texto que permite trabajar de forma simultánea entre diferentes usuarios impulsando la colaboración entre los mismos de forma online.

Por un lado se va a recolectar información de distintas sesiones de chat de los grupos, mediante el análisis de las conversaciones. Por otro, previo a comenzar a trabajar colaborativamente, se completarán encuestas del modelo de análisis de trabajo SYMLOG, que propone una clasificación de factores claves de personalidad que impactan en el desempeño grupal y un conjunto de herramientas para medirlos, cuyo resultado indica la presencia de ciertos rasgos que resultan relevantes para el desempeño grupal, y pueden ser relacionados directamente con los Roles de Belbin. Esta relación va a permitir tener una vista inicial de los roles, auto percibidos por el propio usuario.

Toda esta información recolectada va a ser analizada mediante técnicas de inteligencia artificial, aplicando estrategias para lograr un enfoque que permita clasificar roles de usuario eficientemente.

Para cumplir con los objetivos se deberán desarrollar en el trabajo las siguientes funcionalidades:

- Entrenamiento: En esta etapa se aplicará Aprendizaje de Máquina sobre un dataset pre-procesado, para que la herramienta sea entrenada.
- Clasificación: Luego del entrenamiento se procederá a la clasificación de un conjunto de datos de entrada no clasificados, utilizando herramientas de Aprendizaje de Máquina.
- Análisis de las conversaciones: Se analizará la información recolectada de los chats a partir de la herramienta entrenada.
- Generación de resultados: Se generarán archivos con los resultados del análisis de los datos obtenidos de la clasificación de las conversaciones y los roles de los alumnos.
- Asistencia: Se asistirá al administrador mediante la formación de grupos automáticamente con los resultados obtenidos.

En la Figura 1.1 se puede observar un bosquejo de la herramienta a desarrollar. Los alumnos participan de distintos trabajos y conversan mediante el chat de Hangouts, cuyas conversaciones se almacenan. Estos a su vez llenan cuestionarios, tanto de autopercepción como de percepción de sus compañeros de grupo. Tanto los chats almacenados como los cuestionarios van a utilizarse para el entrenamiento de los clasificadores, procesándolos para lograr una entrada apta para la inferencia de los roles de usuario. Con los roles obtenidos se va a proveer asistencia, mediante la formación automática de grupos de trabajo.




Figura 1.1 Esquema de plan de trabajo

En base a las actividades descritas, se puede dividir el trabajo en dos etapas:

Diseño e implementación de la herramienta: Se debe definir la herramienta para clasificar las conversaciones de los alumnos. La misma proveerá facilidades al profesor para cargar los archivos obtenidos, para clasificarlos y analizarlos. También recibirá un archivo para que se entrene utilizado Aprendizaje de Máquina, y permitirá la elección de distintos algoritmos de aprendizaje (clasificadores). Las actividades a llevar a cabo en esta etapa son:

- Estudio de diferentes clasificadores provistos por WEKA - TENSOR FLOW.
- Estudio de la herramienta de procesamiento de lenguaje natural FreeLing.
- Diseño e implementación de la solución.

Análisis de los datos recabados: Teniendo como base los estudios realizados por Belbin, se analizará cada grupo de alumnos para detectar la existencia de riesgos de desbalance de roles. A partir de los datos analizados también se podrán crear grupos optimizados (de tamaño configurable) con los alumnos involucrados en el análisis. Para esto vamos a contar con las siguientes actividades:

- Análisis de los grupos.
- Definición de grupos según distintos tamaños.

Diseño e implementación de la herramienta de administración: Se debe definir la herramienta para administrar la información y obtener a partir de una entrada los diferentes roles. La misma proveerá facilidades para el ingreso de la entrada y la lectura de la salida. También contará con la opción de formar grupos de trabajo a partir de los resultados. Las actividades a desarrollar son:

- Estudio de diferentes arquitecturas para el desarrollo de interfaces de usuario.
- Estudios de frameworks para el desarrollo de interfaces de usuario.
- Implementación de la solución.

1.4 Resumen

Conformar grupos balanceados requiere conocer los roles que cumple cada participante, mediante el análisis de las características que tienen en común, y así también de las diferencias existentes entre ellos, en base al estudio de distintos aspectos de sus conductas.

Entre las características más importantes de los integrantes de un equipo se encuentra el rol. Uno de los principales investigadores de los roles de equipo es Meredith Belbin, que los define como la tendencia de un individuo a comportarse, contribuir e interrelacionarse con otros de una determinada manera.

En este trabajo, se va a realizar el estudio de individuos de distintos grupos en un contexto de trabajo colaborativo en un entorno virtual (Google Docs, Hangouts), donde los mismos cooperan entre sí para alcanzar los objetivos pactados. Inferir los roles de usuario va a permitir lograr obtener grupos equilibrados de trabajo, con una alta efectividad en el desarrollo de sus actividades. Además, se van a reducir conflictos colaborativos, reduciendo la carga de intervenciones por parte de la persona a cargo.

Debido a que la labor de análisis de las interacciones por parte de una persona a cargo insume tiempo y esfuerzos significativos, la existencia de una herramienta puede simplificarlo de forma considerable. Esto va a permitirle al encargado focalizarse en la resolución de los conflictos que pudieran surgir en un grupo desbalanceado, los cuales evitan que los participantes desempeñen los diferentes roles que permiten realizar un trabajo coordinado y exitoso.

Además, la herramienta va a permitir eliminar las encuestas y consultas a los integrantes de grupo las cuales ayudan a obtener un punto de vista de cada uno de acuerdo a la opinión del resto del grupo, ya que esta información se va a detectar mediante Inteligencia Artificial.

Para la organización de este trabajo se va a comenzar con el Marco Teórico, donde se van a presentar los conceptos teóricos más importantes. Una vez que lector logre una idea acerca hacia donde apunta el trabajo, se va a presentar el desarrollo de la herramienta propuesta, explicando las decisiones tomadas y los enfoques que se van a implementar.

Luego se va a desarrollar el diseño e implementación tanto de la herramienta de entrenamiento, como la aplicación de análisis, donde se va a poder inferir roles a partir de distintas entradas. Seguido a esto, se va a describir el experimento realizado, mediante la presentación de los resultados obtenidos en el entrenamiento de los modelos.

Para finalizar, se va a realizar una conclusión sobre el trabajo desarrollado, analizando si se cumplieron los objetivos, se van a proponer trabajos futuros relacionados al actual, y se van a extender algunos conceptos relevantes para el informe en Anexos.

Comenzando con la organización, en el próximo capítulo se van a presentar los conceptos teóricos más importantes, junto con antecedentes de trabajos relacionados, con el objetivo de lograr un entendimiento del tema de investigación.

2. Marco Teórico y conceptual

En este capítulo se describen los conceptos teóricos más relevantes necesarios para comprender el trabajo realizado, para orientar al lector en el dominio en el que se encuentra el mismo, es decir los roles de usuario y la Inteligencia Artificial. A su vez, se presentan trabajos relacionados a ese dominio, realizando comparaciones y analizando puntos en común.

2.1 Teoría de roles de equipo de Belbin

El trabajo de Meredith Belbin (Belbin, 1993) ha proporcionado una clara visión de las relaciones internas del grupo y la clarificación de los roles necesarios para que el equipo o grupo trabajen efectivamente.

El Dr. Belbin fue invitado a participar en un experimento desarrollado en un curso organizado por la Administrative Staff College de Henley, Oxon. Para el estudio se estableció como premisa que el éxito de los equipos debería estar vinculado al intelecto, pero se encontró que no era el intelecto sino el equilibrio lo que permitió que un equipo tuviese éxito y que la compatibilidad entre las aptitudes personales y el hecho de tomar esta diversidad como una fortaleza podían favorecer la formación de un buen equipo de trabajo. A raíz de este estudio, el Dr. Belbin definió *Rol de Equipo* como “una tendencia a comportarse, contribuir y relacionarse con los demás de una determinada manera” y estableció, junto a su equipo, ocho “Roles de Equipo” a los que posteriormente él añadió uno más basado en el conocimiento especialista.

Según el Dr. Belbin, “un equipo no es un conjunto de personas adscritas a determinados puestos de trabajo, sino una congregación de personas donde cada uno de ellos desempeña un rol que es comprendido por el resto de miembros. Los miembros de un equipo negocian entre sí el reparto de roles y desempeñan de manera más eficaz aquellos que les son más naturales”. Además establece que conociendo las fortalezas y debilidades de cada integrante es posible asignar roles (de entre los 9 que contempla) a cada uno de ellos, con el fin de construir equipos de alto rendimiento, explotando las cualidades de cada uno de ellos.

Belbin sugirió también que mientras que las conductas de un individuo de un equipo pueden ser infinitas, el rango de conductas útiles que realizan una contribución efectiva al equipo es finito.

Los roles definidos por Belbin se dividen en tres grandes grupos:

- **Sociales:** los que se encargaban de la cohesión, coordinación y contacto del grupo con el exterior.
- **Mentales:** los que tenían el expertise, la visión crítica y la creatividad para hacer una tarea.
- **De Acción:** los que se ocupaban de pasar a la acción, llevar a cabo y finalizar una tarea.

En las siguientes tablas se puede observar que roles pertenecen a cada grupo, junto con sus características, puntos fuertes y puntos débiles:

Social

Coordinador	- Controlados, tranquilos y seguros. - El rasgo que distingue a los coordinadores es su habilidad para hacer que otros trabajen en dirección hacia metas compartidas. - Maduros, confiados delegan fácilmente. - En las relaciones interpersonales son rápidos para descubrir talentos individuales y utilizarlos para lograr los objetivos del grupo. - Los coordinadores no son necesariamente los miembros que tienen el mayor conocimiento en un equipo. Sin embargo tienen una perspectiva amplia y generalmente se les respeta. FUNCIÓN: - Son hábiles para hacerse cargo de un equipo, cuyos miembros tengan diversidad de habilidades y características personales. - Su rendimiento es mayor cuando tratan con colegas de rango parecido. - Su lema podría ser “consulta con control” y generalmente creen manejar los problemas con tranquilidad. - Los Coordinadores tienden a enfrentarse con los Impulsores debido a sus diferentes estilos de gestión. PUNTOS FUERTES: agradecen a todos las posibles aportaciones, sin perder de vista su objetivo. PUNTOS DÉBILES: Se le puede percibir como manipulador. Se descarga de trabajo que se le ha asignado y por ello en opinión de otros tal vez deleguen “demasiado”.
Colaborador	- Perceptivo y diplomático. - Son los miembros que más apoyan a los compañeros de equipo. - Son sociables y se preocupan por los otros. - Tienen una gran capacidad para adaptarse a diferentes situaciones y personas. - Buenos oyentes y generalmente muy aceptados por el equipo. - No funcionan muy bien bajo presión o en situaciones que implican confrontación. FUNCIÓN: - Son muy efectivos previniendo problemas interpersonales dentro de un equipo. - No le gusta las fricciones, intentará evitarlas. - Las habilidades diplomáticas de un Colaborador se convierten puntos fuertes, especialmente con un rol directivo en que puedan aparecer conflictos. - Los Colaboradores directivos no son vistos como una amenaza por nadie. Por ello, pueden ser considerados como los preferidos para ocupar

	posiciones de mando. - Tienen un efecto lubricante en los equipos. PUNTOS FUERTES: tienen habilidad para responder a las personas. También ante situaciones de alto contenido social y para promover el espíritu de equipo. PUNTOS DÉBILES: Son indecisos en momentos de crisis.
Investigador	- Extrovertidos, entusiastas, curiosos, comunicativos. - Buenos comunicadores dentro y fuera de la organización. Negociadores naturales, dados a explorar nuevas oportunidades y desarrollar contactos. - Aunque no sean necesarias, aportan gran cantidad de ideas originales. - Son rápidos para captar las ideas e otros y adaptarlas. - Son hábiles para averiguar lo que está disponible y lo que puede hacerse. - Generalmente tienen una buena aceptación debido a su naturaleza extrovertida. - Tienen una personalidad relajada con un fuerte sentido de la observación y una predisposición a ver las posibilidades de algo nuevo. Sin embargo, a menos que se les estimule, su entusiasmo rápidamente desvanece. FUNCIÓN: - Son rápidos para iniciar y explorar oportunidades, tienen habilidad para pensar sobre la marcha y aprovechar la información de otros. - Son los mejores para iniciar contactos externos, para hallar recursos fuera del grupo y llevar cualquier tipo de negociación en la que puedan estar implicados. PUNTOS FUERTES: capacidad para encontrar gente útil y localizar ideas y oportunidades. Son una gran fuente de vitalidad. PUNTOS DÉBILES: Demasiado optimista. Pierde el interés una vez pasado el entusiasmo inicial.

Tabla 2.1 Roles sociales

Mental

Cerebro	- Individualistas, heterodoxos y algo distantes. - Son innovadores y pueden ser muy creativos. - Generalmente prefieren actuar por sí mismos, a distancia de los otros miembros del equipo, usando su imaginación y a menudo trabajan de un modo poco convencional. - Tienden a ser introvertidos y reaccionan fuertemente a la crítica y a la alabanza. Sus ideas pueden ser a menudo radicales y suelen carecer de orientación práctica. - Son independientes, inteligentes y originales y pueden tener dificultad para comunicarse. FUNCIÓN: - Su principal función en el grupo es generar nuevas propuestas y resolver problemas complejos. Se necesitan en los estadios iniciales de un proyecto o cuando el proyecto está fallando. Pueden ser creadores de empresas o lanzadores de nuevos servicios o productos. - Demasiados en una organización, puede ser contraproducente porque tienden a pasar el tiempo
Especialista	- Resuelto, dinámico, entregado. - Son individuos entregados a su trabajo que se enorgullecen de tener y desarrollar habilidades técnicas y conocimientos especializados. - Sus prioridades son mantener niveles profesionales y progresos en su propia actividad. Mientras que muestran gran orgullo en su propio trabajo, generalmente, muestran falta de interés por el trabajo de otros e incluso por las personas mismas. - Eventualmente, el especialista se convierte en el experto por su compromiso, decisión y aptitudes. FUNCIONES: - Aporta habilidades y conocimientos muy específicos. PUNTOS FUERTES: proporcionan conocimientos o habilidades técnicas en situaciones difíciles. PUNTOS DÉBILES: Contribuye sólo en áreas específicas. Se extiende en tecnicismos.
Monitor evaluador	- Serio, estratégico y perspicaz. - Lentos para decidir. - Prefieren pensar las cosas con una gran dosis de pensamiento crítico. - Generalmente los Monitores-Evaluadores tienen gran capacidad para hacer ponderaciones teniendo en cuenta todas las variedades. - Suelen dar muy buenos consejos. FUNCIÓN: - Se sienten cómodos analizando los problemas. - Evalúan las ideas y sugerencias.

	- Son muy buenos analizando los pros y contras. - El resto del equipo los percibe por lo general como secos, aburridos e incluso excesivamente críticos. - Generalmente, los Monitores-Evaluadores son clave en puestos de planificación y estrategia y obtienen buenos resultados en puestos de alto nivel donde un número relativamente pequeño de decisiones generan grandes resultados. PUNTOS FUERTES: tienen mucho juicio y discreción. Analiza todas las opciones y juzga con precisión. PUNTOS DÉBILES: Les falta inspiración o habilidad para motivar a otros. Puede ser excesivamente crítico.
--	--

Tabla 2.2. Roles mentales

De Acción

Implementador	- Práctico, fiable, eficiente. - Transforma las ideas en acciones y organiza el trabajo que debe hacerse. - Organizados, disfrutan con lo reglado, con lo rutinario. Auto-disciplinado. - Apoyan el trabajo duro y abordan problemas de manera sistemática. FUNCIÓN: - Son útiles por su confianza y capacidad práctica. - Tienen éxito porque tienen un sentido de lo que es útil y práctico. - Los implementadores hacen lo que necesite hacer, independientemente que les guste o no la tarea. - Pueden llegar a cargos de alta dirección gracias a su eficacia a la hora de abordar todo tipo de tareas. PUNTOS FUERTES: Habilidad para organizar, sentido común práctico, trabajo duro y autodisciplina. PUNTOS DÉBILES: Falta de flexibilidad. Resistencia a ideas no contrastadas.
Impulsor	- Dinámicos, extrovertidos. - Muy motivados, con mucha energía y gran necesidad de logro. - Son agresivos, con gran empuje. - Les gustan los desafíos, conducir y empujar a otros a la acción y ganar. - Si aparecen los obstáculos, los sobrepasan, pero pueden ser tercos y responder de forma primaria a desilusiones o frustraciones. - Los Impulsores son manipuladores y, a veces, provocan la confrontación. FUNCIONES: - Son buenos directivos porque generan acción y se crecen ante la presión. - Son buenos resaltando la labor de equipo y son muy útiles en grupos donde las complicaciones políticas ralentizan los asuntos. - Les gusta hacer los cambios necesarios y no les importa tomar decisiones impopulares. - Intentan imponer algún modelo de actuación en los grupos de trabajo. PUNTOS FUERTES: tienen empuje para desafiar la inercia, la ineficacia o la complacencia. PUNTOS DÉBILES: Son propensos a la provocación e impaciencia. Tienen tendencia a herir los sentimientos de los otros.
Finalizador	- Esmerado, concienzudo, ansioso. - Tienen una gran capacidad para dar continuidad a las tareas.

	- Presta atención al detalle. - Raramente comienzan lo que no pueden terminar. - Están motivados por cierta ansiedad interna, aunque aparentemente pueden parecer imperturbables. - Son introvertidos, no necesitan estímulo externo o incentivos. - A los Finalizador le disgusta el despiste. - Son reacios a delegar. Prefieren realizar todas las tareas ellos mismos. FUNCIONES: - Son valiosos donde las tareas demandan mucha concentración y gran exactitud. - Aportan un sentido de urgencia al equipo y son buenos cumpliendo los programas, en el plazo comprometido. - En dirección sobresalen por los altos estándares a los que aspiran y por su preocupación por la precisión y atención al detalle. PUNTOS FUERTES: capacidad para cumplir sus promesas y trabajar con altos niveles de exigencia. PUNTOS DÉBILES: tendencia a preocuparse por las pequeñas cosas. Son intransigentes para pasar por alto detalles. Reacio a delegar.
--	--

Tabla 2.3 Roles de acción.

Belbin además afirmó que estos roles de equipo eran vitales para la efectividad del desempeño de los equipos, e identificó cinco principios que subyacen a tal desempeño (Aritzeta et al., 2003):

- Cada miembro contribuye al logro de los objetivos del equipo a través del desempeño, tanto funcional (determinado por su conocimiento o habilidad profesional) como del Rol de equipo (determinado por sus patrones característicos de interacción en el equipo).
- El equipo necesita de un equilibrio óptimo entre el Rol funcional y el Rol de equipo. En este equilibrio influyen los objetivos y las tareas que los miembros desempeñan.
- Se promueve la efectividad del equipo en la medida en que los miembros del equipo reconozcan las necesidades y potencialidades del equipo y se auto-ajusten a ellas, tanto en lo referido a los roles funcionales como a los Roles de equipo.
- Ciertas cualidades personales se adecuan a ciertos roles mientras reducen la probabilidad de que puedan adoptar otros roles.
- Un equipo puede desplegar sus recursos técnicos de forma excelente solo cuando existe un rango mínimo de Roles de equipo que asegure un trabajo de equipo suficiente.

Belbin mantiene que es fácil prever qué equipos tendrán éxito y qué equipos fallarán.

Hay dos importantes aportes en el análisis de Belbin:

1. El reconocimiento de que las fortalezas humanas, generalmente traen debilidades.

2. Con la combinación de estos roles, se tiene una gran probabilidad de obtener un equipo de éxito, con respecto a otras alternativas. Pues es posible que algunos equipos alcancen una productividad complementaria, mientras que otros probablemente entran en una competición intra-grupo.

2.2 Minería de datos

La revolución digital ha hecho posible que la información digitalizada sea fácil de capturar, procesar, almacenar, distribuir, y transmitir. Con el importante progreso en informática y en las tecnologías relacionadas y la expansión de su uso en diferentes aspectos de la vida, se continúa recogiendo y almacenando gran cantidad de información.

La minería de datos nació con la idea de aprovechar dos cosas: la gran cantidad de datos que se almacena, y la potencia de las nuevas computadoras para realizar operaciones de análisis sobre esos datos. El data mining permite encontrar información escondida en los datos que no siempre resulta aparente, ya que, dado el gigantesco volumen de datos existentes, gran parte de ese volumen nunca será analizado. La minería de datos es un proceso de identificación de información relevante extraída de grandes volúmenes de datos, con el objetivo de descubrir patrones y tendencias estructurando la información obtenida de un modo comprensible para su posterior utilización (Agrawal et al., 1996).

La minería de datos surge a principios de los años ochenta cuando la Administración de Hacienda de Estados Unidos desarrolló un programa de investigación para detectar fraudes en la declaración y evasión de impuestos, mediante lógica difusa, redes neuronales y técnicas de reconocimiento de patrones. Sin embargo, su expansión se produce hasta la década de los noventa, principalmente debido a:

- El incremento en la potencia de procesamiento de las computadoras, así como en la capacidad de almacenamiento.
- El crecimiento de la cantidad de datos almacenados, el cual se ve favorecido no solo por el abaratamiento de los discos y sistemas de almacenamiento masivo, sino también por la automatización de trabajos y técnicas de acopio de datos (observación con nuevas tecnologías, entrevistas más prácticas, encuestas, chats, etc).
- La aparición de nuevos métodos y técnicas de aprendizaje y almacenamiento de datos, como las redes neuronales, la Inteligencia Artificial y el surgimiento del almacén de datos (Vallejo Ballesteros et al., 2018).

Un proceso típico de minería de datos consta de los pasos generales presentados en la Figura 2.1:




Figura 2.1. Proceso de minería de datos (Witten et al., 1999).

1. Selección del conjunto de datos, tanto en lo que se refiere a las variables objetivo (aquellas que se quiere predecir, calcular o inferir), como a las variables independientes (las que sirven para hacer el cálculo o proceso), como posiblemente al muestreo de los registros disponibles.
2. Análisis de las propiedades de los datos, en especial los histogramas, diagramas de dispersión, presencia de valores atípicos y ausencia de datos (valores nulos).
3. Transformación del conjunto de datos de entrada, se realizará de diversas formas en función del análisis previo, con el objetivo de prepararlo para aplicar la técnica de minería de datos que mejor se adapte a los datos y al problema, a este paso también se le conoce como preprocesamiento de los datos.
4. Seleccionar y aplicar la técnica de minería de datos, se construye el modelo predictivo, de clasificación o segmentación.
5. Extracción de conocimiento, mediante una técnica de minería de datos, se obtiene un modelo de conocimiento, que representa patrones de comportamiento observados en los valores de las variables del problema o relaciones de asociación entre dichas variables. También pueden usarse varias técnicas a la vez para generar distintos modelos, aunque generalmente cada técnica obliga a un preprocesado diferente de los datos.
6. Interpretación y evaluación de datos, una vez obtenido el modelo, se debe proceder a su validación comprobando que las conclusiones que arroja son válidas y suficientemente satisfactorias. En el caso de haber obtenido varios modelos mediante el uso de distintas técnicas, se deben comparar los modelos en busca de aquel que se ajuste mejor al problema. Si ninguno de los modelos alcanza los resultados esperados, debe alterarse alguno de los pasos anteriores para generar nuevos modelos.

Si el modelo final no superará esta evaluación el proceso se podría repetir desde el principio o, si el *experto* lo considera oportuno, a partir de cualquiera de los pasos anteriores. Esta retroalimentación se podrá repetir cuantas veces se considere necesario hasta obtener un modelo válido.

La minería de datos tiene como objetivo analizar los datos desde todas las perspectivas estratégicas. En el presente trabajo se va a extraer información de diferentes chats de grupos de trabajo y encuestas, con el fin de transformarla en información útil y conocimiento, y poder inferir roles de equipo, siguiendo los pasos del proceso típico de este campo, concluyendo con una evaluación final de los resultados.

Para finalizar, en la tabla 2.1 se muestra una lista de las principales técnicas de minería de datos (Weiss et al., 1998)(Molina López et al., 2006), desarrollando Redes Bayesianas, ya que luego va a formar parte de las utilizadas en la herramienta.

Técnicas de Minería de Datos			
Técnicas	No supervisadas	Agrupamiento	Numérico
			Conceptual
			Probabilístico
		Asociación	A priori
		Predicción	Regresión
			Árboles de predicción
			Estimador de núcleos
	Supervisadas	Clasificación	Tabla de decisión
			Árboles de decisión
			Inducción de reglas
			Bayesianas
			Basada en ejemplos
			Redes neuronales

Tabla 2.1. Ejemplos de técnicas de minería de datos.

2.2.1 Redes Bayesianas

Las redes bayesianas son grafos dirigidos acíclicos cuyos nodos representan variables aleatorias en el sentido de Bayes: las mismas pueden ser cantidades observables, variables latentes, parámetros desconocidos o hipótesis. Las aristas representan dependencias condicionales; los nodos que no se encuentran conectados representan variables las cuales son condicionalmente independientes de las otras. Cada nodo tiene asociado una función de probabilidad que toma como entrada un conjunto particular de valores de las variables padres del nodo y devuelve la probabilidad de la variable representada por el nodo (Luis M. de Campos et al., 2004).

En el caso de este trabajo, se puede realizar la aplicación de la Regla de Bayes para predecir la probabilidad condicional de que un rol pertenezca a una clase $P(c_i | r_j)$ a partir de la probabilidad a priori de la clase en el conjunto de entrenamiento $P(c_i)$.

$$P(c_i | r_j) = \frac{P(c_i) P(r_j | c_i)}{P(r_j)}$$

Dado que la probabilidad de cada rol $P(d_j)$ no aporta información para la clasificación, el término suele omitirse. La probabilidad de un rol dada la clase suele asumirse como la probabilidad conjunta de los features analizados dada la clase y se calculan como:

$$P(r_j | c_i) = \prod_{t=1}^{|v|} P(f_t | c_i)$$

Adicionalmente, el modelo Naive Bayes Multinomial considera la frecuencia de aparición de cada feature en los roles x_t en vez de una ocurrencia binaria:

$$P(r_j | c_i) = \prod_{t=1}^{|v|} P(f_t | c_i)^{x_t}$$

El término $P(f_t | c_i)$ se calcula a partir del número de apariciones de cada feature f_t en una clase c_i pero para evitar el problema de las probabilidades 0 se usa la estimación de Laplace:

$$P(f_t | c_i) = \frac{1 + n(f_t | c_i)}{|v| + n(c_i)}$$

Donde $n(f_t | c_i)$ es el número de ocurrencias de f_t en c_i , $|v|$ es el tamaño del dataset y $n(c_i)$ es el conteo total del feature en c_i . De este modo, la clasificación se realiza buscando el rol que maximiza la función:

$$c^*(d) = \text{rolmax}_{c_i} P(c_i) \prod_{t=1}^{|v|} P(f_t | c_i)^{x_t}$$

2.3 Aprendizaje de máquina

La minería de datos utiliza en su análisis los métodos del aprendizaje automático. Este (del inglés, "Machine Learning") es un subcampo de las ciencias de la computación y una rama de la inteligencia artificial, cuyo objetivo es desarrollar técnicas que permitan que las computadoras aprendan (Jeria, 2007). De forma más concreta, se trata de crear algoritmos capaces de generalizar comportamientos y reconocer patrones a partir de una información suministrada en forma de ejemplos. Es, por lo tanto, un proceso de inducción del conocimiento, es decir, un método que permite obtener por generalización un enunciado general a partir de enunciados que describen casos particulares.

En muchas ocasiones el aprendizaje automático se solapa con la Minería de Datos, ya que las dos disciplinas están enfocadas en el análisis de datos. Sin embargo, el aprendizaje automático se centra más en el estudio de la complejidad computacional de los problemas desde el punto de vista práctico, no únicamente teórico.

A un nivel muy básico, se puede decir que una de las tareas del aprendizaje automático es intentar extraer conocimiento sobre algunas propiedades no observadas de un objeto basándose en las propiedades que sí han sido observadas, en pocas palabras, predecir comportamiento futuro a partir de lo que ha ocurrido en el pasado.

Hay un gran número de problemáticas que caen dentro de lo que llamamos aprendizaje automático. La principal diferencia entre ellos radica en el tipo de objetos que intentan predecir. Algunas clases habituales son regresión, clasificación, ranking, etc.

El aprendizaje automático tiene como resultado un modelo para resolver una tarea dada. Entre los modelos se distinguen

- Los modelos geométricos, contruidos en el espacio de instancias y que pueden tener una, dos o múltiples dimensiones. Si hay un borde de decisión lineal entre las clases, se dice que los datos son linealmente separables. Un límite de decisión lineal se define como $w \cdot x = t$, donde w es un vector perpendicular al límite de decisión, x es un punto arbitrario en el límite de decisión y t es el umbral de la decisión.
- Los modelos probabilísticos, que intentan determinar la distribución de probabilidades descriptora de la función que enlaza a los valores de las características con valores determinados. Uno de los conceptos claves para desarrollar modelos probabilísticos es la estadística bayesiana.
- Los modelos lógicos, que transforman y expresan las probabilidades en reglas organizadas en forma de árboles de decisión.

El aprendizaje automático además, puede clasificarse en Aprendizaje supervisado, no supervisado, o semi supervisado (Dubiau, 2013), dependiendo del tipo de salida que se produzca y de cómo se aborde el tratamiento de los ejemplos.

- Aprendizaje supervisado: se genera una función que establece una correspondencia entre las entradas y las salidas deseadas del sistema, donde la base de conocimientos está formada por ejemplos etiquetados a priori. Es decir, ejemplos de los que se conoce su clasificación correcta.

- Aprendizaje no supervisado: donde el proceso de modelado se lleva a cabo sobre un conjunto de ejemplos formados únicamente por entradas al sistema, sin conocer su clasificación correcta. Se busca que el sistema sea capaz de reconocer patrones para poder etiquetar las nuevas entradas.
- Aprendizaje semi supervisado: Este tipo de algoritmos combinan los dos algoritmos anteriores para poder clasificar de manera adecuada. Se tiene en cuenta los datos marcados y los no marcados.

En el actual trabajo se van a combinar distintas técnicas de aprendizaje automático para obtener el modelado de los usuarios.

2.4 Modelado de usuario

Las creencias y los deseos de un usuario se obtienen por medio del modelado de un usuario; a través se puede saber el estereotipo que tiene el mismo, los intereses sobre ciertos recursos y que recursos derivan otros intereses para un usuario. Un modelo de usuario es la representación de las características que tiene un usuario, y en base a éstas se podrán tomar decisiones en la interacción. (Fischer, 2001)

En otras palabras, un modelo de usuario es una colección y categorización de datos personales asociados a un usuario específico. Por lo tanto, es la base de cualquier cambio adaptativo en el comportamiento del sistema. Los datos incluidos en el modelo dependen del propósito de la aplicación y puede incluir información personal como el nombre o edad del usuario, sus intereses, sus habilidades y conocimientos, sus objetivos y planes, sus preferencias o datos sobre su comportamiento y sus interacciones con el sistema.

Hay diferentes patrones de diseño de modelos de usuario, aunque a menudo se suele usar una mezcla de ellos. (Johnson et al., 2005)

- Modelos de usuario estáticos: modelos de usuario estáticos son el tipo más básico. Una vez los datos principales han sido recopilados, normalmente no cambian, son estáticos. Los cambios en las preferencias de los usuarios no son registrados, y no se aplican algoritmos de aprendizaje para alterar el modelo.
- Modelos dinámicos de usuario: Los modelos de usuario dinámicos permiten una representación de los usuarios más actualizada. Cambios en sus intereses, su proceso de aprendizaje o sus interacciones con el sistema son registrados y ejercen influencia sobre los modelos del usuario. Los modelos pueden ser actualizados y toman las necesidades y objetivos del usuario actuales en cuenta.
- Modelos de usuario basados en estereotipos: Los modelos de usuario basados en estereotipos están basados en estadísticas demográficas. Los usuarios son clasificados en diferentes estereotipos basados en la información recopilada, entonces el sistema se adapta a este estereotipo. Por lo tanto, la aplicación puede adaptarse al usuario aunque no haya datos sobre un área concreta. Esto es así porque los estudios demográficos han mostrado que otros usuarios del mismo estereotipo tienen las mismas características. Como consecuencia, los modelos basados en estereotipos se basan principalmente en estadísticas y no toman en cuenta los atributos personales que podrían no encajar en el estereotipo. Sin embargo, permiten hacer predicciones sobre un usuario aunque haya poca información del mismo.

- Modelos de usuario altamente adaptativos: Los modelos de usuario altamente adaptativos intentan representar a un usuario particular y por lo tanto, permitir una gran adaptación del sistema. A diferencia de los modelos basados en estereotipos, no se basan en estadísticas demográficas, sino que intentan encontrar una solución específica para cada usuario. A pesar de que los usuarios pueden obtener un gran beneficio de estos sistemas, este tipo de modelos requieren recopilar una gran cantidad de información primero.

La información de los usuarios puede recopilarse de varias maneras. Hay tres métodos principales:

- Preguntar sobre hechos concretos mientras se interactúa con el sistema por primera vez: La mayoría de la información se recopila durante el proceso de registro. Mientras se registran, a los usuarios se les pide información como sus gustos o necesidades. A menudo las respuestas dadas pueden ser cambiadas más adelante.
- Aprender sobre las preferencias del usuario observando e interpretando sus interacciones con el sistema: En este caso, no se preguntan los datos personales ni las preferencias a los usuarios directamente, sino que esta información se deriva de su comportamiento mientras interactúa con el sistema. Cosas como las diferentes formas en las que el usuario completa tareas y sus intereses permiten realizar una inferencia sobre un usuario específico. La aplicación aprende de forma dinámica mientras observa estas interacciones. Diferentes algoritmos de aprendizaje automático pueden ser usados para complementar este método.
- Un enfoque híbrido en el que se pregunta sobre ciertos hechos y se altera el modelo de usuario a través de aprendizaje adaptativo (Montaner et al., 2003): Este enfoque es una mezcla de los anteriores. Los usuarios tienen que responder preguntas específicas. Después, sus interacciones con el sistema son observadas y la información derivada es usada para ajustar los modelos de usuario automáticamente.

En el actual trabajo, se va a utilizar un modelado de usuario basado en estereotipos, clasificando a los usuarios con diferentes roles, basados en la información recopilada de los chats. Además, se observa la presencia de esta técnica al momento de extraer la autopercepción de los alumnos, utilizando encuestas que detectan la presencia de ciertos rasgos distintos que resultan relevantes para el desempeño grupal.

2.5 Procesamiento de Lenguaje Natural

Una de las ramas más importantes de la Inteligencia Artificial es aquella orientada a facilitar la comunicación hombre-computadora por medio del lenguaje humano, o lenguaje natural. El Procesamiento del Lenguaje Natural (PLN) es la disciplina encargada de producir sistemas informáticos que posibiliten dicha comunicación. Las aplicaciones de PLN necesitan estudiar el lenguaje natural en profundidad y para esto utilizan distintos tipos de análisis (Cortez et al., 2014).

El estudio del lenguaje natural se estructura normalmente en los siguientes niveles:

- Análisis Morfológico: la morfología es la rama de la lingüística que se preocupa por la descripción de la estructura de las palabras y el proceso de formación de las mismas. La idea general es que los morfemas individuales pueden ser combinados para formar palabras.
- Sintáctico: la sintaxis, o construcción de oraciones, es el nivel más bajo en el cual el lenguaje humano es constantemente creativo. El conocimiento sintáctico es un componente básico

de cualquier sistema de PLN, ya que se encarga de reconocer las oraciones gramaticales y asignarles una estructura. El reconocimiento de la estructura de las oraciones por parte de la computadora es llevado a cabo por un algoritmo llamado parsing.

- Semántico: la semántica, o significado, es el nivel en el cual el lenguaje hace contacto con el mundo real. Se trata de la primera tarea del componente interpretativo, la cual consiste en asignar un significado a cada una de las oraciones analizadas independientemente del contexto. La semántica oracional es una parte imprescindible de cualquier sistema, ya que sin ella no podríamos asignar significado a las estructuras analizadas.
- Pragmático: se refiere al uso del lenguaje en el contexto. En general la pragmática incluye aspectos del conocimiento conceptual del mundo que van más allá de las condiciones reales literales de cada oración. Este conocimiento lo tienen en cuenta los hablantes cuando se comunican mediante una lengua. Les sirve para comprender mucha información sobreentendida pero no expresada explícitamente en las oraciones. Mientras la sintaxis y semántica estudia las oraciones, la pragmática estudia “las acciones del discurso” y las situaciones en las cuales el lenguaje es usado.

Cuando se analiza texto, el resultado del análisis generalmente se representa mediante anotaciones o etiquetas. Una operación de etiquetado o anotación se basa en un conjunto de etiquetas que representan las diversas categorías lingüísticas o extra-lingüísticas.

Las anotaciones pueden tener atributos, por ejemplo, un análisis que busca todos los nombres propios de personas en un texto (María, Pedro, etc.), podría etiquetar o anotar cada nombre y además, a cada anotación agregar un atributo que diga si el nombre es femenino o masculino. El hecho que las anotaciones tengan atributos permite representar otros tipos de análisis más complejos ya que una anotación puede tener a otras anotaciones como atributos.

2.6 Plataformas de trabajo compartido

Con los avances de la tecnología, se redujo notablemente la metodología de trabajos grupales presenciales, reemplazando por la comunicación mediante computadora, donde dos o más personas comparten sus conocimientos mediante distintas plataformas que permiten la ejecución en tiempo real de las actividades.

En el área del software existen plataformas que permiten trabajar colaborativamente en simultáneo. Desde hace varios años, Google ha puesto a disposición de sus usuarios, una serie de aplicaciones y servicios gratuitos que van orientados a la productividad, colaboración y comunicación basados en web. Entre éstos se encuentra Google Docs, un conjunto de aplicaciones que permite crear, almacenar y compartir documentos de texto, hojas de cálculo y presentaciones en línea, en las que se puede trabajar de manera simultánea y en tiempo real entre varios usuarios. La herramienta de Google Docs, incluye además una combinación de servicios integrados tales como el chat y el correo electrónico que permiten una mejor interacción y comunicación entre los usuarios. Cuando un usuario crea un documento en Google Docs puede compartirlo con más personas a las que puede asignarles privilegios de escritura o sólo lectura. La persona que crea el documento es denominada propietario o autor, las personas con quienes se comparte el documento se denominan: colaborador cuando se le otorguen privilegios de escritura y lector, cuando se le otorguen privilegios de sólo lectura.

Kieser y Ortiz-Golden (2009) refieren que la herramienta de Google Docs provee un mecanismo de monitoreo para ver la participación de los estudiantes y la forma en que plasman sus ideas en un

mismo documento. Al tener la disposición vía Internet del documento es más fácil accederlo desde la casa o desde cualquier lugar remoto. En el mismo sentido, Finholt y Teasley (1998) argumentan que la tecnología de hoy en día, permite la posibilidad de acceder a documentos por parte de múltiples miembros, tales como procesadores de textos, hojas de cálculo e incluso presentaciones compartidas. Google Docs, brinda precisamente un ejemplo de esta amalgama de herramientas de uso colaborativo. A diferencia de la tecnología Wiki, Google Docs ofrece la posibilidad de trabajo en tiempo real además de la asincronía, aspectos que aumentan la eficacia de la comunicación, y por ende, del aprovechamiento académico (Leigh Tharp, 2010).

Las principales ventajas del uso de software de colaboración son:

- La comunicación fluye más rápido y de manera más precisa.
- Permite hacer un mejor uso de los recursos humanos al facilitar la colaboración entre personas ubicadas en sitios remotos y con diferentes horarios de trabajo.
- Mejora la productividad al "obligar" a los participantes a colaborar de una manera más ordenada.
- Facilita los consensos y la toma de decisiones grupales mediante la automatización de estas actividades.
- Permite realizar una evaluación del proceso de colaboración mediante el análisis de las interacciones.

2.7 Trabajos relacionados

Existen trabajos pertenecientes al dominio de estudio de las dinámicas de grupo, con presencia y ausencia de herramientas tecnológicas como intermediarias, y que alentaron al actual trabajo.

Se observaron propuestas donde se realiza el análisis de conductas y características de distintos individuos para la detección de sus roles. En "Inferencia de roles de equipo a partir de conductas colaborativas" (Berdun et al., 2016), se realiza el estudio de grupos de alumnos en un entorno de trabajo colaborativo a partir de la herramienta Google Docs, coordinados por un profesor. A partir de las interacciones textuales, se presenta un conjunto de resultados experimentales de clasificación automática de texto libre a roles de equipo mediante conductas colaborativas, los cuales, basándose en un entorno dado y una clasificación de conductas a roles, pueden ser utilizados para materializar una herramienta que ayude a la detección automática de los mismos.

Algo similar se encuentra en "Aplicabilidad de la Teoría de los Roles de Equipo de Belbin: un estudio longitudinal comparativo con equipos de trabajo" (Aitor Arizteta et al., 2003), donde también se analizaron grupos de trabajo compuestos por alumnos. La muestra se tomó de 40 equipos pertenecientes a los últimos dos años de la carrera de psicología, con el objetivo de comprobar que en los grupos que muestran un equilibrio de Roles obtienen mejores resultados que en aquellos donde el equilibrio no existe. Estos grupos debían realizar dos tipos de tareas relacionadas a la carrera (dos tomas de datos). Solo 4 equipos se mantuvieron equilibrados durante las dos tomas, mientras que 17 se mantuvieron desequilibrados. La mejor puntuación en efectividad la obtuvieron los equipos equilibrados durante las dos tomas, mientras que los que inicialmente se mostraron equilibrados y luego no, fueron los que más bajo puntuaron. Este trabajo es una muestra clara de lo importante que es una herramienta que detecte los roles de equipo, para poder mantener equilibrados los grupos y obtener mejores resultados.

Albert Simón Mira (Mira, 2015) realizó el estudio de los roles de equipo en el sector de la auditoría contable, a través de informes Belbin realizados por empleados de una firma de Auditoría de Cuentas, para la búsqueda del equipo ideal a partir de los mismos. Otras investigaciones similares acerca de la influencia de los roles en los equipos de trabajo se pueden observar en “Análisis de Roles de Trabajo en Equipo: Un enfoque centrado en comportamientos” (Guasch, 2006), donde se estudia el trabajo en equipo y el impacto de los Roles en el mundo organizacional en general, a partir de distintos modelos que abordan los roles de equipo, destacándose el Modelo de Belbin.

Por otra parte, en “Influencia de estilos de aprendizaje y roles de equipo en el aprendizaje colaborativo soportado por computadoras” (Nicoletti et al., 2013), analizaron si el estilo de aprendizaje y los roles de equipo afectan el trabajo y el aprendizaje grupal. Este estudio lo realizaron en un entorno de aprendizaje colaborativo en un ambiente académico, aunque mediante reglas de asociación. Concluyeron en que se desempeñan de manera satisfactoria aquellos grupos heterogéneos respecto a los roles de equipo que manifiestan sus integrantes, tal como establece la propuesta de Belbin, como así también aquellos equipos con mayoría de roles de Coordinador podría tener resultados satisfactorios.

En estos contextos, se observó la falta de una herramienta que automatice la labor de las personas encargadas de la clasificación de los roles, por lo que se propone este trabajo para acelerar la caracterización de los perfiles de trabajo por medio de los roles de equipo, disminuyendo el alto consumo de recursos humano-temporal que requiere el proceso de supervisión y categorización de interacciones por parte de personas idóneas en el tema.

Desde otro ángulo, se encontraron trabajos donde se automatizan los procesos de caracterización de conductas a través de distintos enfoques. En “Building SYMLOG profiles with an online collaborative game” (Berdun et al., 2018), se construyen perfiles de usuario utilizando un juego colaborativo formado por acciones que fueron mapeadas al modelo SYMLOG, y a partir de las cuales se obtuvo la información sobre los perfiles de distintos usuarios, en la forma establecida en dicho modelo. En dicho trabajo se propone como trabajo futuro, la clasificación de interacciones textuales de los chats al modelo IPA para poder incorporarlas al perfil de los usuarios. Esta solución se puede observar en “Classification of collaborative behavior from free text interactions.” (Berdun et al., 2017), donde se recolectó información de los chats, y se los procesó mediante distintos modelos de Inteligencia Artificial para clasificar las conductas en las 12 categorías IPA, utilizando procesamiento directo y en fases. Estas fases están divididas en el clasificador del Área de la conducta, luego por el clasificador de la Reacción, y por último el clasificador de la Categoría. Los mejores resultados se obtuvieron con el procesamiento dividido en las tres fases, con buenos porcentajes de clasificación.

En estos dos últimos trabajos, se observa la extracción de información a partir de distintas estrategias (juegos y plataforma colaborativa). Además se cuenta con la presencia de la encuesta SYMLOG, presentada en la Tabla 2.2.

Ítem	Consigna	
1	U	Buscas éxito individual, prominencia personal y poder.
2	UP	Buscas popularidad y éxito social, ser querido y admirado.
3	UPF	Prefieres el trabajo en equipo activo dirigido a metas comunes, integridad organizacional.
4	UF	Buscas la eficiencia, administración imparcial estricta.
5	UNF	Buscas el refuerzo activo a la autoridad, repaso de reglas y regulaciones.
6	UN	Mantienes firmeza, obstinación y constancia para cumplir un objetivo, asertividad auto-orientada.
7	UNB	Eres vigoroso, individualista auto-orientado, pones resistencia a la autoridad.
8	UB	Buscas pasarla bien, renunciar a la tensión, un control relajante.
9	UPB	Buscas proteger a los miembros menos capaces, proveer ayuda cuando se necesita.
10	P	Buscas igualdad, participación democrática en la toma de decisión.
11	PF	Tienes un idealismo responsable, trabajo colaborativo.
12	F	Eres conservador, establecido, prefieres las formas "correctas" de hacer las cosas.
13	NF	Reprimas tus deseos individuales por las metas organizacionales.
14	N	Buscas la auto-protección, primero el interés personal, ser auto-suficiente.
15	NB	Rechazas los procedimientos establecidos, rechazas la conformidad.
16	B	Cambias a nuevos procedimientos, diferentes valores, creatividad.
17	PB	Buscas amistad, placer mutuo, recreación.
18	DP	Buscas confianza en la bondad de otros.
19	DPF	Trabajas con dedicación, confianza, eres leal al equipo
20	DF	Obedeces a la cadena de mando, eres complaciente con la autoridad.
21	DNF	Haces auto-sacrificio si es necesario para alcanzar las metas organizacionales.
22	DN	Tienes un rechazo pasivo a la popularidad.
23	DNB	Admites un error, dejas de esforzarte en defender trabajo mal hecho
24	DB	Tienes actitudes de no-cooperación pasiva con la autoridad.
25	DPB	Buscas satisfacción, te lo tomas con calma.
26	D	Renuncias a tus necesidades personales y deseos, pasividad.

Tabla 2.2. Encuesta SYMLOG.

La misma consta de 26 preguntas donde se evalúan las distintas combinaciones de valores positivos y negativos, 21 para cada una de las 3 dimensiones. El resultado de esta encuesta es un trinomio de valores numéricos, cada uno de ellos comprendido entre -18 y 18 (siendo éstos los valores mínimo y máximo de las 3 dimensiones); con estos 3 valores se puede ubicar al sujeto encuestado en el espacio tridimensional del modelo y caracterizarlo en función a dicha ubicación, de acuerdo con la Figura 2.2, obteniendo información valiosa sobre autopercepción de los roles de cada usuario, de gran utilidad para este trabajo.




Figura 2.2. Relación SYMLOG - Roles de Belbin (Beck, Dieter, and Rudolf Fisch ,2005)

Siguiendo bajo este contexto, en el trabajo presentado en (Serrano et al., 2017), se propone un enfoque para identificar a los usuarios conflictivos en una red social basado en la observación del comportamiento en grupos de interés de Facebook, utilizando SYMLOG. En este trabajo se destaca la formulación de los atributos SYMLOG a partir de las conductas IPA, donde se puede observar que los atributos que define IPA para la orientación de los mensajes, son abordados a través de la tercera dimensión de SYMLOG, que las reacciones Positivas y Negativas definen al usuario como Amistoso o No Amistoso, y que la dimensión de Estado, que abarca los atributos de Sumisión y Dominancia pueden interpretarse como el grado de y tipo de participación (Tabla 2.3).

Symlog	IPA
# Dominante	# Negativo + # Requiere
# Sumiso	# Positivo + # Responde
# Amistoso	# Positivo
# No Amistoso	# Negativo
# Tarea	# Requiere + # Responde
# Socioemocional	# Positivo + # Negativo

Tabla 2.3. Formulación de los atributos Symlog a partir de IPA.

Esta formulación es importante para el mapeo de este modelo con los Roles de Belbin, ya que transitivamente se puede relacionar las conductas IPA de cada mensaje de los chats con los Roles de Belbin.

Por último se presenta el trabajo encontrado que más se relaciona al actual. En J.M. Alberola et al. (2016) se desarrolló una herramienta para la formación de equipos en el aula. La herramienta busca recomendar equipos de alumnos a los docentes. Más concretamente, la herramienta toma como

ejes centrales de su funcionamiento la taxonomía de roles de Belbin, la evaluación/opinión de los alumnos sobre los roles predominantes de otros compañeros de equipo, y la generación automática de equipos. La misma funciona normalmente en un bucle de formación de equipos y posterior evaluación que permite formar equipos cada vez más diversos en base a los roles predominantes para cada uno de los alumnos. La diferencia existente de este trabajo con el realizado con parte de esta tesis, es que la información es extraída únicamente de las opiniones de los integrantes de los grupos, y no a partir del análisis de texto libre y el análisis de las conductas IPA y atributos SYMLOG.

2.8 Resumen

En este capítulo se desarrollaron los conceptos principales para el entendimiento del presente trabajo.

Inicialmente, se presentó la Teoría de Roles de Meredith Belbin, el cual ha proporcionado una clara visión de las relaciones internas del grupo y la clarificación de los roles necesarios para que el equipo o grupo trabajen efectivamente. A su vez se presentaron estos roles propuestos por Belbin, organizandolos de acuerdo a sus tipos (Social, Mental y de Acción), y analizando sus características, debilidades y fortalezas.

El proceso aplicado para la inferencia de los roles es la minería de datos, donde se aplican algoritmos y técnicas específicas con el objetivo de extraer patrones en grandes volúmenes de datos. Las técnicas de minería de datos se dividen en no supervisadas y supervisadas. Estas últimas son de interés en este trabajo, dentro de las cuales se encuentran las redes bayesianas. Las redes bayesianas se modelan como un grafo probabilístico que representa un conjunto de variables aleatorias y sus dependencias condicionales a través de un grafo acíclico dirigido, y las redes neuronales cuyo objetivo es resolver los problemas de la misma manera que el cerebro humano.

La minería de datos utiliza en su análisis los métodos del aprendizaje automático, el cual es un subcampo de las ciencias de la computación y una rama de la inteligencia artificial, cuyo objetivo es desarrollar técnicas que permitan que las computadoras aprendan. Teniendo en cuenta el tipo de información que se intenta descubrir en este trabajo, se decidió utilizar aprendizaje automático supervisado, donde la base de conocimiento está conformada por instancias etiquetadas inicialmente mediante la información recolectada. Estas instancias serán utilizadas en una etapa posterior para construir los modelos de clasificación.

Este modelo se va a utilizar para el modelado de usuario, que es una colección y categorización de datos personales asociados a un usuario específico. En el actual trabajo, se va a utilizar un modelado de usuario basado en estereotipos, clasificando a los usuarios con diferentes roles, basados en la información recopilada de los chats.

Una de las técnicas utilizadas en el proceso de minería de datos es el procesamiento de lenguaje natural, la cual es aquella orientada a facilitar la comunicación hombre-computadora por medio del lenguaje humano, o lenguaje natural. Esta técnica se aplica sobre chats extraídos de plataformas de trabajo compartido, donde dos o más personas comparten sus conocimientos mediante distintas plataformas que permiten la ejecución en tiempo real de las actividades.

Por último se presentaron distintos trabajos, pertenecientes al dominio de estudio de las dinámicas de grupo, con presencia y ausencia de herramientas tecnológicas como intermediarias, y que alentaron al actual trabajo.

En el próximo capítulo se presentará la solución propuesta, detallando las decisiones más importantes tomadas sobre la implementación, y los enfoques propuestos para la creación de los modelos.

3. Desarrollo de la propuesta

En este capítulo se desarrolla la propuesta que motiva al presente trabajo, detallando las principales decisiones de diseño que llevaron a la implementación del mismo. Se presentará la estructura de la herramienta, junto con detalles a tener en cuenta sobre la misma, y los enfoques propuestos para inferir los roles de usuario.

3.1. Estructura de la herramienta a implementar

La herramienta a implementar es una aplicación, la cual a partir de una entrada determinada pueda inferir los distintos Roles de Usuario, utilizando el modelo de Roles de Belbin. Se dividirá a la misma en dos partes, el entrenamiento y la predicción, siguiendo el proceso de minería de datos.

El dataset, como se dijo anteriormente, proviene del monitoreo y registro de interacciones entre estudiantes, en trabajos realizados colaborativamente en la plataforma Google Docs. Los alumnos, divididos en grupos de entre 5 y 6 personas cada uno, realizaron actividades que correspondían en escribir colaborativamente tres documentos con temáticas diferentes. Dentro de estos documentos, se encontraban diferentes incisos a realizar en forma colaborativa, donde para discutir acerca de cada uno de los ejercicios debían utilizar la plataforma de Hangouts para comunicarse, lo que permitió obtener las interacciones entre cada uno de ellos. A su vez, también se recolectaron datos de encuestas de autopercepción y de percepción de los compañeros. En este caso, las variables objetivo (que se quieren predecir) provienen del rol autopercebido, mientras que las variables independientes (las que sirven para hacer el cálculo) se obtienen a partir de los chats y de las percepciones de roles por parte de los compañeros.

Este conjunto de datos de entrada no estructurados serán pre procesados, con el objetivo de adaptarlos al problema en cuestión y obtener las variables independientes ayudarán a predecir la variable objetivo. A los chats se le aplicarán procesamiento de lenguaje natural utilizando la herramienta desarrollada en Berdun et al. (2017), la cual usa la herramienta de PLN Freeling. Se analizaron otras opciones de herramientas como Stanford NLP y Apache OpenNLP, pero Freeling es la única que provee un servicio completo para el idioma español, que es sobre el cual se realizará el análisis.

Los mensajes se procesarán aplicando tokenización, sentence splitting, análisis morfológico, etiquetado gramatical, reconocimiento de entidades nombradas y análisis gramatical entre otros:

- Tokenización: Convierte un texto plano en una lista de palabras, de acuerdo al conjunto de reglas que contiene el modelo.
- Sentence splitting: Detecta los signos de puntuación para separar las sentencias. Analiza la lista de palabras resultantes de tokenizar previamente el texto, mediante el método split, retornando una lista de sentencias.
- Etiquetado gramatical: Previo a realizar el etiquetado gramatical en Freeling se debe tokenizar, luego armar una lista de sentencias mediante el split, y por último realizar un análisis morfológico. Luego, al tener el análisis morfológico se puede analizar el texto para etiquetarlo gramaticalmente

- Reconocimiento de entidades nombradas: Al momento de clasificar las entidades nombradas Freeling cambia los tags obtenidos en el etiquetado gramatical por las etiquetas definidas de un modelo que distingue cuatro clases: Person (tag NP00SP0), Geographical location (NP00G00), Organization (NP00O00), and Others (NP00V00). Para realizar la clasificación previamente se debe tokenizar el texto, separar las sentencias y analizar morfológicamente como se explicó anteriormente.
- Análisis gramatical: El analizador gramatical de Freeling relaciona cada objeto de las sentencias con una categoría gramatical (adjetivo, sustantivo, verbo, etc). Previo a análisis se debe tokenizar, detectar las sentencias, realizar el análisis morfológico, etiquetar gramaticalmente y detectar las entidades nombradas.

Con esta herramienta, además, se obtienen las conductas colaborativas de cada mensaje de los chats, y a partir de las mismas se crean los indicadores SYMLOG, utilizando las fórmulas presentadas por Serrano et al. (2017). Esto tiene como objetivo relacionar las conductas obtenidas con los Roles de Belbin, utilizando el modelo SYMLOG como intermediario. Otra de las características extraídas de los mensajes es el momento de participación del integrante, dividiendo la conversación en tres etapas: el “setup” o introducción, el desarrollo, y la finalización, junto con la participación general en comparación con el resto de sus compañeros de grupo.

Para evitar los conflictos producidos entre grupos con cantidades dispares de mensajes, se normalizan todos los features dividiéndolos por la cantidad de interacciones del participante en el grupo, así como también el porcentaje de participación de cada uno se calcula dividiendo la cantidad de interacciones individual, por la cantidad de mensajes total del grupo. Por último, se recogen los roles asignados por los compañeros, los cuales van a ser utilizados como una variable independiente más, que va a aportar el contexto en el que se desempeñaron.

A este conjunto preprocesado de datos se aplicarán diferentes técnicas de aprendizaje de máquina, a partir de algoritmos para análisis de datos y modelado predictivo provistos por la herramienta Weka, como Bayes (Naive Bayes y Bayes Net), árboles (J48, REPTree, LMT), funciones (SMO), basados en reglas (Part, JRip, Decision Table), Lazy (KStar, Ibk) y meta (Logit Boost, Multiclass Classifier). Al utilizar la librería de aprendizaje de máquina WEKA, los datos de entrada a la herramienta sobre los que operan las técnicas implementadas, deben estar codificados en un formato específico, denominado Attribute-Relation File Format (extensión "arff").

Una vez aplicadas las distintas técnicas, se realiza la extracción del conocimiento, obteniendo los modelos que contienen los patrones de comportamiento observados en los valores de las variables en relación con los roles de usuario.

Con estos modelos, se realizará por último el modelado de los usuario a partir de distintas conversaciones. Para esto se implementará una interfaz de usuario que permita cargar un conjunto de chats de entrada mediante los cuales se van a calcular los roles. Esta interfaz va a contener además la funcionalidad de armar grupos de trabajo automáticamente en base a los cálculos realizados previamente.

3.2. Consideraciones especiales a tener en cuenta

Como se dijo previamente, el aprendizaje automático se puede clasificar en tres categorías, de acuerdo con la información que se puede proporcionar al algoritmo de aprendizaje: aprendizaje supervisado, aprendizaje no supervisado y aprendizaje semi-supervisado. El aprendizaje supervisado,

también conocido como clasificación, supone que los datos proporcionados al algoritmo de aprendizaje se han etiquetado manualmente con la categoría correcta. En otras palabras, la clase para cada ejemplo de entrenamiento se conoce con anticipación. Nuestro trabajo cae en este tipo de aprendizaje como un problema de clasificación: dada una conversación de un grupo, buscamos asignar a cada participante el rol más probable que representa.

Por otra parte, debido a que el preprocesamiento origina un registro por cada integrante del grupo con sus correspondientes características, el dataset con todos los chats de casi 40.000 mensajes se redujo a 542 registros. Por esta razón, se optó por utilizar la técnica de Cross Validation Folder de Weka en lugar de utilizar el proceso habitual de dividir el 66,66% de la entrada para el entrenamiento, y el 33,33% restante para clasificar y obtener el porcentaje de instancias clasificadas correctamente e incorrectamente. Esta técnica es una forma sistemática de ejecutar divisiones porcentuales repetidas. Divide el conjunto de datos según una cantidad n dada, y por cada parte se construye el clasificador con las $n-1$ partes, y se prueba con la restante. Esto lo repite n veces. Luego la precisión proviene del promedio de cada resultado obtenido sobre las diferentes particiones.

Por último, como se mencionó, la variable objetivo es extraída de la autopercepción del usuario. Uno de los planteos que se presentó era si utilizar este valor, o el valor inferido por sus compañeros que representaba mejor el contexto del grupo y de sus conductas colaborativas. Contar solo con la autopercepción iba a brindar una información global, sin importar el entorno en donde se desempeñaba la persona. A su vez, si se utilizaba solo el rol clasificado por sus compañeros, se notaba la ausencia de la autopercepción, ya que la precisión de la clasificación fue menor. Por esto se optó finalmente por utilizar ambos, el rol autopercebido como variable objetivo, otorgando más importancia, y el rol asignado por sus compañeros como variable independiente.

Se entrenarán modelos para predecir en primer lugar el rol de compañeros, logrando obtener una relación más directa de las conversaciones que tuvo cada participante de acuerdo al grupo, para luego utilizar ese valor para predecir el rol principal. Para ambos casos se va a contar con las mismas variables independientes, aplicando los mismos enfoques.

3.3. Enfoques de clasificación de chats propuesto

Para entrenar a los distintos clasificadores y realizar los análisis de los chats inicialmente se proponen dos enfoques, uno simple o directo y una mejora de este dividido en tres fases. Luego, a partir de este último, se propone otro enfoque en cascada, en el cual se va a entrenar un clasificador para cada subconjunto de tipo de rol.

Con el enfoque directo, se busca obtener el valor de la variable objetivo a partir del análisis directo de las diferentes características que se pueden obtener de los datasets. En cambio, con el enfoque en fases se busca realizar un “filtrado”, tomando previamente como variable objetivo los tipos de roles, para que una vez obtenidos los mismos sea menos probable que fallen los distintos algoritmos de clasificación al momento de calcular los roles, ya que solo tienen que decidir entre tres valores de clase.

Estos enfoques se van a aplicar tanto al procesamiento general como al procesamiento de grupo. En la Figura 3.1 se puede observar la estructura de la solución propuesta, modelos individuales por cada grupo que predicen el rol con el que los compañeros de grupo lo clasificarían en las encuestas, y luego un modelo general que utiliza el rol autodefinido para predecir qué rol le corresponde al participante según los atributos analizados y el rol que sus compañeros definieron.




Figura 3.1. Modelado de solución propuesta

Antes de detallar los enfoques propuestos, se van a presentar los features que poseen en común todos los entrenamientos, para luego dar a conocer aquellos que varían entre las distintas etapas y tipos de procesamiento:

- Conducta IPA: Este feature es uno de los más importantes, ya que permite la clasificación en categorías de las interacciones textuales ocurridas en el marco de las actividades colaborativas. Con esto se puede conocer cómo se desarrolló una determinada persona, y puede aportar información relevante al momento de inferir los roles, ya que un rol se define como una tendencia a comportarse.
- Reacción IPA: Este feature permite agrupar las conductas IPA en positiva, negativa, pregunta o respuesta, proveyendo una vista en conjunto de las mismas. Puede suceder que un rol no esté muy relacionado a una conducta pero sí a su reacción, por lo cual es un feature que debe estar presente.
- Área IPA: Este feature agrupa las reacciones IPA en socio-emocional o de tarea. Es la vista más general de modelo IPA, y permite un filtrado importante de los roles ya que va a existir una división entre aquellos que apuntan más a conductas sociales y los que apuntan a tareas.
- Etapa del chat: Conocer el porcentaje de participación de una persona en cada etapa del chat aporta gran utilidad a la inferencia de roles. Hay roles que participan mayormente en la introducción, otros en el desarrollo, y otros en la finalización.
- Atributos SYMLOG: Como se mencionó en Trabajos Relacionados de la sección Marco Teórico, se puede establecer una relación directa entre SYMLOG y los Roles de Belbin, ubicar al sujeto en el espacio tridimensional del modelo, por lo que es importante la presencia de este feature. Los atributos SYMLOG se calculan a partir de las conductas IPA, y los mismos son: dominante, sumiso, amistoso, no amistoso, socio-emocional y tarea.

- Participación: Analizar el porcentaje de participación aporta valiosa información a la inferencia de roles, ya que existen roles que son más cerrados a la comunicación, y trabajan por su cuenta, y otros que participan más socialmente, como es el caso de los roles sociales.

Una vez obtenida una visión general de las características a analizar se procede a presentar los enfoques propuestos.

3.3.1 Enfoque directo

En esta sección se presentará tanto el enfoque directo dirigido a los roles brindados por los grupos, como el entrenamiento del mismo tipo dirigido al rol general. Ambos procesos comparten el paso inicial, el cual consiste en extraer a partir de cada mensaje de los chats la conducta, área y reacción correspondiente.

Una vez obtenidas las características IPA, se calcula el promedio de las mismas para normalizar los valores, lo cual también permite solucionar un posible desbalance de mensajes entre los grupos. La estructura además está formada por la clase rol, como variable objetivo, extraída de las percepciones realizadas por los compañeros, en el caso del procesamiento de los grupos, o de la autopercepción en el caso general. En la misma se encuentran además el nombre y la fecha que van a ser excluidos luego del análisis, ya que el primero solo aporta información de la persona referida, y la fecha fue utilizada para calcular otra característica que contiene la entrada como es el momento de participación.

Por último, para completar los features presentados anteriormente, se encuentran el promedio de los atributos SYMLOG calculados a partir de los valores IPA, y el porcentaje de participación general en la actividad. Se obtiene un registro perteneciente a cada integrante de cada grupo.

En la Figura 3.2 se puede observar como queda formado el archivo encargado del entrenamiento directo:

```
@attribute class_rol {finalizador, impulsor, cerebro, colaborador, especialista, implementador, monitor, investigador, coordinador}
@attribute class_rol_companeros {finalizador, impulsor, cerebro, colaborador, especialista, implementador, monitor, investigador, coordinador}
------(Promedio conductas IPA)-----
@attribute C1 numeric
@attribute C2 numeric
@attribute C3 numeric
@attribute C4 numeric
@attribute C5 numeric
@attribute C6 numeric
@attribute C7 numeric
@attribute C8 numeric
@attribute C9 numeric
@attribute C10 numeric
@attribute C11 numeric
@attribute C12 numeric
------(Promedio reacciones IPA)-----
@attribute R1 numeric (positiva)
@attribute R2 numeric (negativa)
@attribute R3 numeric (pregunta)
@attribute R4 numeric (respuesta)
------(Promedio áreas IPA)-----
@attribute A1 numeric (socio-emocional)
@attribute A2 numeric (tarea)
------(Etapas del chat)-----
@attribute Horario1 numeric
@attribute Horario2 numeric
@attribute Horario3 numeric
------(Atributos SYMLOG)-----
@attribute dominante_symlog numeric
@attribute sumiso_symlog numeric
@attribute amistoso_symlog numeric
@attribute no_amistoso_symlog numeric
@attribute tarea_symlog numeric
@attribute socio_emocional_symlog numeric
------(Participación)-----
@attribute cant_mensajes numeric

colaborador,1,positiva,socio-emocional, 'Usuario', '2017-01-26 14:58:26',implementador,0.154639,0.010309,0.340206,0.041237,0.113402,0.28866,0.041237,
0.010309,0,0,0,0.505155,0,0.051546,0.443299,0.505155,0.494845,0.185567,0.793814,0.020619,0.051546,0.948454,0.505155,0,0.494845,0.505155,0.302181
```

Figura 3.2 . Estructura archivo ARFF entrenamiento directo

La única diferencia en la estructura entre el procesamiento de grupos y general, además del origen del valor de la variable objetivo, es que el análisis general contiene además el rol de los compañeros, que como se dijo anteriormente, brinda una visión del contexto en el que se desarrolló la actividad. Es decir, la estructura presentada en la figura anterior es similar para ambos casos, solo que el procesamiento de grupos no cuenta con el atributo *class_rol_companeros*.

3.3.2 Enfoque en fases

Este enfoque va a estar dividido en tres fases. Se considera como primera fase a la obtención de los indicadores IPA mediante el clasificador IPA, utilizados también en el entrenamiento directo (conducta, área y reacción) directamente de los mensajes. Luego para la segunda fase, se entrena el modelo con los indicadores obtenidos anteriormente para detectar el tipo del rol. Por último, con los indicadores IPA y el tipo de rol en conjunto, se entrena el tercer modelo para detectar el rol del participante. Este proceso puede observarse en la Figura 3.3, donde se encuentran graficadas las diferentes fases con sus entradas y salidas correspondientes:




Figura 3.3. Entrenamiento en fases.

El enfoque tiene una propuesta similar al directo, entrenar clasificadores por grupo para detectar los diferentes roles que los compañeros asignarían según el comportamiento del individuo, y por otro lado entrenar clasificadores para detectar el rol que le corresponde al mismo según el rol con el que lo definieron sus compañeros y las demás características analizadas, utilizando el rol autodefinido.

Primera fase

A partir del texto libre de los chats se busca obtener la conducta, área y reacción asociada a cada mensaje, de la misma forma que en el entrenamiento directo. Para esto se utiliza el clasificador IPA mencionado anteriormente, el cual recibe como entrada las diferentes conversaciones, y etiqueta cada mensaje con los atributos IPA.

Como esta herramienta realiza además el preprocesamiento del texto, como salida se obtiene el análisis realizado mediante Freeling, a partir de los cuales se predijeron los atributos IPA, como se observa en la Figura 3.4, los cuales no son de interés para la detección de los roles por lo que se descartan.

```
@relation chat

@attribute class_conducta {1,2,3,4,5,6,7,8,9,10,11,12}
@attribute class_reaccion {positiva,negativa,pregunta,respuesta}
@attribute class_area {socio-emocional,tarea}
@attribute nombre string
@attribute mensaje string
@attribute adjectives numeric
@attribute adverbs numeric
@attribute determinants numeric
@attribute names numeric
@attribute verbs numeric
@attribute pronouns numeric
@attribute conjunctions numeric
@attribute interjections numeric
@attribute prepositions numeric
@attribute punctuation numeric
@attribute numerals numeric
@attribute dates_times numeric

@data
6, respuesta, tarea, Juan, 'hola chico , para el que no poder ir a el ultima torr a de el materia , le enviá 0 uno lino sobre uno apunte de aprendizaje de maquina',
0,1,7,7,9,4,1,1,9,6,0,0
```

Figura 3.4. Estructura archivo ARFF fase 1.

La conducta, reacción y área van a ser los features de interés que se van a utilizar en las fases siguientes, calculando su promedio para luego calcular los atributos SYMLOG.

Segunda fase

En esta etapa se procesa la salida del clasificador utilizado en la primer fase, agregándole el atributo Tipo de rol. El mapeo del tipo de rol con la información obtenida en los datasets se toma del tipo de cada rol asignado por los compañeros y el autodefinido según el caso. Para los roles asignados como *Cerebro*, *Especialista* o *Monitor Evaluador*, se mapea el tipo de rol *Mental*; para *Colaborador*, *Coordinador* o *Investigador*, se mapea *Social*; y por último para *Impulsor*, *Implementador* o *Finalizador*, se mapea el tipo de rol *De Acción*.

Además, al igual que en el entrenamiento directo, se normalizan los atributos para armar el modelo que sirve para predecir el tipo de rol de acuerdo a las características analizadas, y se agrega el porcentaje de participación, el porcentaje de participación en cada etapa del chat, y los atributos SYMLOG.

Para observar la estructura del archivo de entrenamiento de la Fase 2 se presenta la Figura 3.5:

```
@attribute class_tipo_rol {social,mental,accion}
@attribute class_tipo_rol_companeros {social,mental,accion}
@attribute nombre string
@attribute fecha date 'yyyy-MM-dd HH:mm:ss'
------(Promedio conductas IPA)-----
@attribute C1 numeric
@attribute C2 numeric
@attribute C3 numeric
@attribute C4 numeric
@attribute C5 numeric
@attribute C6 numeric
@attribute C7 numeric
@attribute C8 numeric
@attribute C9 numeric
@attribute C10 numeric
@attribute C11 numeric
@attribute C12 numeric
------(Promedio reacciones IPA)-----
@attribute R1 numeric (positiva)
@attribute R2 numeric (negativa)
@attribute R3 numeric (pregunta)
@attribute R4 numeric (respuesta)
------(Promedio áreas IPA)-----
@attribute A1 numeric (socio-emocional)
@attribute A2 numeric (tarea)
------(Etapas del chat)-----
@attribute Horario1 numeric
@attribute Horario2 numeric
@attribute Horario3 numeric
------(Atributos SYMLOG)-----
@attribute dominante_symlog numeric
@attribute sumiso_symlog numeric
@attribute amistoso_symlog numeric
@attribute no_amistoso_symlog numeric
@attribute tarea_symlog numeric
@attribute socio_emocional_symlog numeric
------(Participación)-----
@attribute cant_mensajes numeric

social,1,positiva,socio-emocional,'UsuarioId','2017-01-26 14:58:26',accion,0.154639,0.010309,0.340206,0.041237,0.113402,0.28866,0.041237,
0.010309,0,0,0,0,0.505155,0,0.051546,0.443299,0.505155,0.494845,0.185567,0.793814,0.020619,0.051546,0.948454,0.505155,0,0.494845,0.505155,0.302181
```

Figura 3.5. Estructura archivo ARFF entrenamiento fase 2

Como se puede observar, esta cuenta con el atributo Tipo de Rol extraído de la percepción de los compañeros en el caso del entrenamiento de grupo, y de la autopercepción para la vista general. Luego se encuentran los promedios de los features comunes a todos los entrenamientos resumidos en un registro por cada participante de cada grupo.

Como diferencia entre los dos tipos de procesamiento cabe destacar que el atributo *class_tipo_rol_companeros* se utiliza solo para el general, el mismo no existe en el procesamiento de grupos, ya que ese dato forma parte de la clase principal *class_tipo_rol*.

Tercera fase

Esta última fase se entrenan los modelos agregando el rol correspondiente a cada usuario al tipo de rol analizado en la fase anterior.

En la Figura 3.6 se presenta la entrada para el entrenamiento de grupos de la fase 3:

```
@attribute class_rol {finalizador, impulsor, cerebro, colaborador, especialista, implementador, monitor, investigador, coordinador}
@attribute class_tipo_rol {social, mental, accion}
@attribute class_tipo_rol_companeros {social, mental, accion}
@attribute class_rol_companeros {finalizador, impulsor, cerebro, colaborador, especialista, implementador, monitor, investigador, coordinador}
@attribute nombre string
@attribute fecha date 'yyyy-MM-dd HH:mm:ss'
----- (Promedio conductas IPA) -----
@attribute C1 numeric
@attribute C2 numeric
@attribute C3 numeric
@attribute C4 numeric
@attribute C5 numeric
@attribute C6 numeric
@attribute C7 numeric
@attribute C8 numeric
@attribute C9 numeric
@attribute C10 numeric
@attribute C11 numeric
@attribute C12 numeric
----- (Promedio reacciones IPA) -----
@attribute R1 numeric (positiva)
@attribute R2 numeric (negativa)
@attribute R3 numeric (pregunta)
@attribute R4 numeric (respuesta)
----- (Promedio áreas IPA) -----
@attribute A1 numeric (socio-emocional)
@attribute A2 numeric (tarea)
----- (Etapas del chat) -----
@attribute Horario1 numeric
@attribute Horario2 numeric
@attribute Horario3 numeric
----- (Atributos SYMLOG) -----
@attribute dominante_symlog numeric
@attribute sumiso_symlog numeric
@attribute amistoso_symlog numeric
@attribute no_amistoso_symlog numeric
@attribute tarea_symlog numeric
@attribute socio_emocional_symlog numeric
----- (Participación) -----
@attribute cant_mensajes numeric

colaborador,social,1,positiva,socio-emocional,'Usuario', '2017-01-26 14:58:26',accion,implementador,0.154639,0.010309,0.340206,0.041237,0.113402,0.28866,0.041237,0.010309,0,0,0,0,0.505155,0,0.051546,0.443299,0.505155,0.494845,0.185567,0.793814,0.020619,0.051546,0.948454,0.505155,0,0.494845,0.505155,0.302181
```

Figura 3.6. Estructura archivo ARFF fase 3

En la misma se puede observar que al registro se le agrego el rol Implementador para el atributo *class_rol_companeros*, que pertenece a la percepción de los compañeros sobre el participante en cuestión, que ya contenía Acción como valor de clase del atributo *class_tipo_rol_companeros*. Lo mismo se realizó con el tipo de rol social, al cual se había calculado a partir del rol colaborador. Como se vino mencionando, los atributos de los compañeros únicamente forman parte de la estructura del archivo de procesamiento general.

Con esta propuesta de fases, se pretende mejorar al modelo de clasificación básico presentado en el enfoque directo, ya que el clasificador conociendo el tipo de rol, tiene más probabilidad de acertar el rol que pertenece al usuario en cuestión.

3.3.3 Enfoque en fases cascada

Este enfoque se propone con el objetivo de mejorar las precisiones del enfoque de fases. Como se puede observar en la Figura 3.7, su proceso es muy similar a este, con la diferencia de que en la última fase se entrena por separado un clasificador para cada Tipo de Rol calculado previamente en la Fase 2.




Figura 3.7. Enfoque en fases cascada.

Al seguir el mismo proceso, se utilizan los mismos conjuntos de datos que para el enfoque de fases, obteniendo la misma estructura para las entradas. Las dos primeras fases son similares al enfoque anterior, variando únicamente la última, que calcula los roles a partir de los tipos de rol. En este caso

se divide el dataset según cada subcategoría, es decir, si por ejemplo se desea entrenar al clasificador enfocándose en el tipo de rol Social, se eliminan los registros formados por los tipos de rol Mental y Acción. Entonces se obtiene un dataset que contiene solo las instancias del tipo de rol que se desea, por lo que el clasificador se va a enfocar en el mismo.

Con esto se logra que el clasificador realmente tenga que elegir entre solo tres valores de la clase rol, ya que son los únicos que va a conocer debido a que no hay otros presentes en el conjunto de datos (fueron descartados junto con el tipo de rol). El enfoque básico de fases, a pesar de que conoce las probabilidades de que un rol sea de un tipo determinado, tiene que decidir luego entre los 9 valores de clase, por lo que existen más posibilidades de fallo.

Al momento de utilizar estos clasificadores para predecir, se debe seguir el mismo proceso de dividir el dataset por cada tipo de rol, y utilizar aquel perteneciente al rol en cuestión, para luego por último unir los resultados.

3.4 Resumen

En este capítulo se presentó el desarrollo de la propuesta, donde se explicaron las decisiones tomadas, la estructura de la herramienta, el pre procesamiento de los datos, las herramientas utilizadas las consideraciones generales a tener en cuenta y los enfoques propuestos.

La herramienta a implementar es una aplicación, la cual a partir de una entrada determinada pueda inferir los distintos Roles de Usuario, a partir del modelo de Roles de Belbin. El dataset proviene del monitoreo y registro de interacciones entre estudiantes, en trabajos realizados colaborativamente en la plataforma Google Docs, y encuestas realizadas al comenzar y finalizar los mismos. Los mensajes se procesan a través de tokenización, sentence splitting, análisis morfológico, etiquetado gramatical, reconocimiento de entidades nombradas y análisis gramatical entre otros, utilizando la herramienta de procesamiento de lenguaje natural Freeling.

A partir de esto, se obtienen las conductas colaborativas de cada mensaje de los chats y mediante las mismas se crean los indicadores SYMLOG. Esto tiene como objetivo relacionar las conductas obtenidas con los Roles de Belbin, utilizando el modelo SYMLOG como intermediario. Otra de las características extraídas de los mensajes es el momento de participación del integrante, dividiendo la conversación en tres etapas: el setup o introducción, el desarrollo, y la finalización, junto con la participación general en comparación con el resto de sus compañeros de grupo.

Para evitar los conflictos producidos entre grupos con cantidades dispares de mensajes, se normalizan todos los features dividiéndolos por la cantidad de interacciones del participante en el grupo. Por último, se recogen los roles asignados por los compañeros, los cuales van a ser utilizados como una variable independiente más, que va a aportar el contexto en el que se desempeñaron.

A este conjunto preprocesado de datos se le va a aplicar diferentes técnicas de aprendizaje de máquina, a partir de diferentes algoritmos para análisis de datos y modelado predictivo provistos por la herramienta Weka, mediante un enfoque directo y otro en fases.

Con el enfoque directo, se busca obtener el valor de la variable objetivo a partir del análisis directo de las diferentes características que se pueden obtener a partir de los datasets. En cambio, con el enfoque en fases se mejorará este enfoque simple, tomando previamente como variable objetivo los tipos de roles, para que una vez obtenidos los mismos sea menos probable que fallen los distintos

algoritmos de clasificación al momento de calcular los roles, ya que solo tienen que decidir entre tres valores de clase.

Por último, se propone un enfoque que en la tercera fase cuente con un clasificador para cada tipo de rol. Este forma parte de una mejora al enfoque de fases, ya que se logra que el clasificador realmente tenga que elegir entre solo tres valores de la clase rol, ya que son los únicos que va a conocer debido a que no hay otros presentes en el conjunto de datos. Esto se debe a que el análisis se hace sobre solo un tipo de rol individualmente, y por lo tanto sobre los tres roles de este tipo, descartando momentáneamente el resto.

Con los modelos obtenidos, se va a realizar por último el modelado de los usuarios a partir de distintas conversaciones. Para esto se implementará una interfaz de usuario que permita conversaciones de entrada a partir de la cual se van a calcular los roles, y que se obtenga como salida estos roles inferidos de los participantes de cada grupo. Esta interfaz va a contener además la funcionalidad de armar grupos de trabajo automáticamente, en base a los cálculos realizados previamente.

En el próximo capítulo, previo a la implementación de esta interfaz de usuario, se va a presentar la implementación de la interfaz, mediante la cual se van a poder entrenar a los distintos clasificadores con las entradas que el usuario desee.

4. Diseño e implementación de la herramienta propuesta

En esta sección se va a detallar el diseño e implementación para entrenar a los clasificadores que se utilizan para percibir los Roles de Usuario. La misma cuenta con los distintos requisitos funcionales y atributos de calidad que se detectaron sobre la herramienta a desarrollar, diferentes diagramas para plasmar las decisiones de diseño, y escenarios de calidad.

4.1. Requerimientos funcionales y restricciones de diseño

Al pensar esta aplicación, se espera que el usuario pueda obtener modelos finales para poder aplicarlos en la predicción de roles de usuario. Estos a su vez, no deben tardar demasiado tiempo en crearse, por lo tanto, la cantidad de features a la hora de seleccionar debe ser correctamente estudiada para que no tenga gran impacto en la performance.

Analizando las distintas características que se esperan de la herramienta se obtuvieron los siguientes requerimientos funcionales

- La herramienta debe cumplir un propósito similar a un ETL (Extract, Transform and Load, en español Extraer, Transformar y Cargar).
- La herramienta debe ser capaz de crear múltiples modelos.
- La herramienta debe permitir la carga de archivos de entrenamiento.
- La herramienta debe permitir elegir entre distintos enfoques.
- La herramienta debe permitir la carga de diferentes encuestas.
- El usuario debe poder establecer relación entre las conversaciones y las encuestas para determinar qué encuesta pertenece a cada chat.
- La herramienta debe almacenar todos los resultados obtenidos.

Por otra parte, se detectaron los siguientes requisitos no funcionales y atributos de calidad:

- Usabilidad: El sistema debe permitir al usuario entrenar a los clasificadores de manera sencilla.
- Fiabilidad: El sistema debe ser capaz de funcionar sin fallas dentro de las condiciones normales.
- Precisión: Se debe buscar la mayor precisión en el modelo final y tratar de minimizar el overfitting.
- Modificabilidad: El sistema debe permitir el ingreso de nueva meta información y adaptarla para incorporar al proceso de detección de perfiles fácilmente.
- Performance: La creación de los modelos finales no deben demorar mucho tiempo en su creación, ni necesitar mucho consumo de memoria

- Portabilidad: La aplicación de entrenamiento debe poder usarse en cualquier sistema operativo.
- Persistencia de datos: Los archivos con las precisiones y los modelos deben poder almacenarse para que persistan con el tiempo.

Especificación de requerimientos

A continuación se describen de forma general los requerimientos de la aplicación mediante el diagrama de Casos de Uso de la Figura 4.1, los cuales serán detallados luego:




Figura 4.1. Casos de uso entrenamiento

1. **Cargar archivo entrenamiento:** Se le debe permitir al usuario cargar el archivo que contenga las conversaciones con las que desee entrenar los modelos. No debe existir límite de tamaño, ya que los mismos suelen pesar mucho.

2. **Cargar opciones entrenamiento:** El usuario debe poder elegir el tipo de entrenamiento que desee, ya sea en fases o directo. También debe poder permitir seleccionar el clasificador que desea entrenar.
3. **Cargar encuestas:** El usuario debe contar con la opción de cargar las encuestas que van a ser utilizadas para extraer el rol de autopercepción y el inferido por sus compañeros de grupo.
4. **Relacionar encuestas y conversaciones:** Debido a que se puede contar con numerosas conversaciones de diferentes trabajos, el usuario debe poder ingresar a qué contexto corresponde cada encuesta. Cuando se habla de contexto se refiere a algún identificador que contenga el nombre de la conversación, como por ejemplo TP1.
5. **Preprocesar entradas:** El usuario debe poder pre procesar un conjunto de entradas para utilizarlas en el entrenamiento, sin tener que demorar el procesamiento por cada clasificador que quiera entrenar.
6. **Cargar archivo preprocesado:** El usuario debe poder cargar un archivo ya procesado con los atributos esperados para realizar el entrenamiento de forma directa.
7. **Entrenar:** El usuario debe poder contar con la opción de entrenar al clasificador seleccionado. Una vez que termina el entrenamiento, el usuario debe poder observar los resultados, los cuales a su vez tienen que almacenarse automáticamente.

4.2 Diseño de la solución

La herramienta puede ser observada como un ETL, donde en primera etapa se realiza una extracción de los datos, obteniendo así la información de los chats, luego a esta se la preprocesa, se realizan diversos tipos de transformaciones, ya sea procesamiento de lenguaje natural, cálculo de conductas y normalización, y luego como último en la etapa de carga, que es en realidad es la creación del modelo final y no una carga a otra plataforma, donde esta ultima seria la diferencia con el proceso tradicional de ETL que se suele ver.

Para obtener una vista del diseño de la solución, se comienza desde el más alto nivel, por lo que la primera ilustración es sobre los componentes presentes en el desarrollo, representados en la Figura 4.2.




Figura 4.2. Diagrama de componentes

Dentro de los componentes principales, se encuentra el *Administrador*. Este no solo es aquel que se encarga de comunicar al resto de los componentes de realizar su tarea, sino que también es el encargado de la interfaz gráfica con el cual el usuario va a interactuar, por lo tanto, cada acción que el usuario realice va a impactar en alguno de los componentes restantes que será comunicado a través del mismo.

Luego se encuentran los entrenamientos, encargados de crear parte de los modelos, ya que dentro se encuentran los diferentes clasificadores que se entrenan y almacenan en sus respectivos archivos.

Antes de ser utilizados por estos entrenamientos, los conjuntos de datos pasan por los componentes de *Parser Entrenamiento* encargados de mapear la información de forma correcta para que sea entendida por los siguientes procesos, tales como el componente de *Organizador*, que se encargan de resumir la información reduciendo registros y a su vez agrega más información al conjunto de características del modelo.

Por último se encuentran los componentes *WekaRoles* y *Hangouts*, donde el primero contiene procedimientos relacionados a Weka y los roles, profundizado más adelante, mientras que *Hangouts* contiene diferentes estructuras y funciones para trabajar con los datos proporcionados por la plataforma y dejarlos sentados de una forma más sencilla de interpretar.

A su vez fuera de los componentes principales, se encuentra *IPA* utilizado para clasificar los mensajes, el cual a su vez utiliza *Freeling*, herramienta NLP que también es utilizada por los componentes principales y por último *Weka* que contiene todos los clasificadores, filtros y demás herramientas para el procesamiento de los datos y creación de efectivos modelos.

Una vez presentado el diseño de la solución, se va a detallar el cumplimiento de cada atributo de calidad a partir de distintos escenarios.

4.3 Escenarios de calidad

4.3.1 Usabilidad

Escenario de calidad 1. El usuario debe contar con una interfaz para poder ingresar archivos de entrenamiento, encuestas de usuario, y todo lo necesario para entrenar a los distintos clasificadores ofrecidos. Además debe poder visualizar los resultados del proceso.

- Fuente: Usuario.
- Estímulo: Entrenar a los clasificadores.
- Artefacto: Aplicación desarrollada.
- Ambiente: En tiempo de ejecución.
- Respuesta: El sistema debe contar con interfaz para el entrenamiento.
- Medida Rta: La interfaz no debe afectar a la performance del entrenamiento.

Para la carga de datos y el entrenamiento, se cuenta con la interfaz de usuario de la Figura 4.3.




Figura 4.3. Interfaz gráfica de la herramienta

Mediante la misma, el usuario puede cargar el archivo principal de entrenamiento, junto con los archivos auxiliares de las encuestas, tanto la de autopercepción de los participantes, como la de percepción del rol de los compañeros. A su vez, puede establecer la relación que tiene el nombre de la encuesta con los nombres de las conversaciones, para saber a qué conversación pertenece cada una, y puedan ser utilizadas correctamente, aportando a la precisión del entrenamiento. Con estos datos ya cargados el usuario cuenta con la opción de pre procesarlos, así quedan listos para entrenar, sin necesidad de realizarlo cada vez que deseen entrenar a un clasificador.

La herramienta permite también cargar un archivo preprocesado, en el caso de que el usuario ya cuente con uno que cumpla con los requisitos del entrenamiento, seleccionar del clasificador que

desea utilizar, y el tipo de procesamiento. También, se presenta en una vista los resultados obtenidos, los cuales son almacenados automáticamente.

Para ilustrar mejor este proceso, se presenta el Use Case Map de la Figura 4.4, donde se observa la presencia de los casos de uso especificados anteriormente, y las responsabilidades de cada componente.




Figura 4.4. UCM entrenamiento

En el mismo se puede observar el componente Administrador, que contiene la interfaz de usuario y es el encargado de la carga de las entradas y de las preferencias, comunicando a la misma con el entrenador, que se encarga de pre procesar toda esta información y luego entrenar al clasificador que se desea.

4.3.2 Fiabilidad

Escenario de calidad 2. El sistema debe permitir cargar archivos de gran tamaño sin fallar durante el proceso.

- Fuente: Usuario.
- Estímulo: Cargar archivo de entrenamiento.
- Artefacto: Aplicación desarrollada.
- Ambiente: En tiempo de ejecución.
- Respuesta: El sistema debe poder responder a la carga de archivos de gran tamaño.
- Medida Rta: Tiempo de carga del archivo.

Al momento de desarrollar la interfaz de entrenamiento, se contaba con las opciones de realizarlo mediante una aplicación web, o una interfaz más sencilla en Java. Esta última fue la implementada, debido a que la aplicación web debe enviar al servidor correspondiente el contenido del archivo completo, ya que por cuestiones de seguridad no se puede obtener la ruta del mismo. Entonces, como el entrenamiento trata de archivos de gran tamaño, lo más probable es que la carga falle, no permitiendo cumplir con la fiabilidad.

Desarrollando la interfaz en Java, se logró evitar estas fallas, ya que se puede obtener el path del archivo directamente, y ser cargado al momento que se requiera.

4.3.3 Precisión

Escenario de calidad 3. La herramienta debe lograr un cierto grado de precisión aceptable en el modelo a construir.

- Fuente: Externa o Interna.
- Estímulo: Entrenar.
- Artefacto: Aplicación desarrollada.
- Ambiente: En tiempo de ejecución.
- Respuesta: El sistema debe generar un modelo con buena precisión sobre los datos.
- Medida Rta: Porcentaje correctos de clasificación y Recall.

Para lograr el nivel de precisión pretendido en el trabajo, se propusieron los enfoques presentados en el capítulo anterior, los cuales mejoraron hasta obtener el enfoque de Fases en cascada, que con la aplicación de filtros logró porcentajes de aciertos elevados con respecto al resto, acercándose mucho a lo esperado.

El mismo, como se explicó anteriormente, cuenta con un clasificador para cada categoría, entrenado con un conjunto de datos en el cual se descartan los registros de los tipos de rol que no son de interés, dejando solo aquellos del tipo de rol en cuestión.

En la Figura 4.5 se presenta el flujo relacionado a esta funcionalidad en un diagrama de secuencia:




Figura 4.5. Diagrama de secuencia entrenamiento

En este caso, una vez obtenido el dataset parseado con la primer fase (atributos IPA) completa, el entrenamiento se realiza una vez para la fase 2, y luego tres veces para la fase 3, una para cada tipo de rol. Como se puede observar, una vez aplicados los filtros de resample y discretize, si se trata de la última fase, se remueve del dataset las instancias que no forman parte del tipo de rol que se desea analizar. Se envía como parámetro el dataset, junto con el índice del atributo tipo de rol, y los valores nominales que se deben quitar del mismo.

Una vez obtenido el dataset filtrado, se realiza el entrenamiento normal, almacenando los resultados (*guardarArchivo*) y los modelos (llamando a *write* de *Weka*) correspondientes para futuros usos.

4.3.4 Performance

Escenario de calidad 4. La herramienta debe performar en cierto grado de aceptación, dado que la creación de modelos no deba durar un largo plazo.

- Fuente: Externa o Interna.
- Estímulo: Entrenar.
- Artefacto: Aplicación desarrollada.
- Ambiente: En tiempo de ejecución.
- Respuesta: El sistema debe crear modelos con una buena performance.
- Medida Rta: Tiempo de entrenamiento.

Al trabajar con la creación de modelos, un aspecto no menor es la performance, ya que a medida que se va incrementando su complejidad, está muy posiblemente afecte tanto a la calidad como al rendimiento, y es aquí donde hay un trade-off. Es por esto, que el modelo recibe algunas limitaciones, ya que se podría agregar variables específicas con las cuales se mejoraría la precisión


pero aumentaría el grado de complejidad y en definitiva bajaría la performance, donde no se desea que el usuario demore días en crear el modelo y tenga que contar con un buen hardware para poder utilizar la herramienta.

Escenario de calidad 5. El entrenamiento no debe demorar al entrenar varios clasificadores de manera separada.

- Fuente: Usuario.
- Estímulo: Entrenar.
- Artefacto: Aplicación desarrollada.
- Ambiente: En tiempo de ejecución.
- Respuesta: El sistema debe entrenar a cada clasificador en un tiempo considerable.
- Medida Rta: Tiempo de entrenamiento.

El preprocesamiento es lo que más tiempo demanda en el proceso de entrenamiento. Debido a esto, se decidió separar la lógica de ambos, para que el usuario primero pre procese todas las entradas requeridas, y luego use el dataset generado para entrenar a cada clasificador que desee. Con esto se logra evitar que se deba pre procesar la entrada cada vez que se desee entrenar a un nuevo clasificador.

Para detallar este proceso, en el Diagrama de Clases de la Figura 4.6 se presenta de forma estática el



modelado del parseo del dataset, describiendo la funcionalidad de cada objeto:

Figura 4.6. Diagrama de clases parser en entrenamiento

- **IpaClassifier:** es el encargado de clasificar la entrada añadiendo la conducta IPA de cada mensaje, el área y la reacción.
- **WekaRoles:** contiene la funcionalidad relacionada a la inserción de atributos en los archivos ARFF, a la aplicación de filtros y a la carga de los clasificadores.
- **Organizador:** se encarga de organizar los archivos parciales obtenidos en el parser, obteniendo como salida un único archivo con el resumen de los anteriores. Con resumen se refiere a promedio de los atributos de interés.
- **Parser:** Clase abstracta debido a que contiene el método abstracto *saveRolArff*, el cual almacena el archivo de cada conversación, con posterior predicción de las conductas IPA y agregado de atributos según el enfoque que la herede. Contiene además el método *parseJson* que procesa el archivo de Hangouts que contiene las conversaciones para modelarlo según las necesidades de este trabajo.
- **DirectoParserEntrenamiento:** es el encargado de preparar los archivos para entrenar de forma directa, a partir del rol autodefinido.
- **GrupoDirectoParserEntrenamiento:** prepara los archivos para entrenar directo a partir del rol asignado por los compañeros.
- **FasesParserEntrenamiento:** es el encargado de parsear los archivos con el tipo de rol y el rol autodefinido.
- **GrupoFasesParserEntrenamiento:** prepara los archivos de acuerdo al tipo de rol y el rol definido por los compañeros de grupo.

En la Figura 4.7 se puede observar el flujo del proceso de mapeo del dataset, a través de un diagrama de secuencia:




Figura 4.7 . Diagrama de secuencia parseo dataset.

Este flujo es similar en todos los tipos de entrenamiento, es decir, ya sea directo, en fases, o general o de grupos siguen el mismo flujo. La diferencia radica en la manera en la que se obtiene el valor para la clase rol y tipo de rol según la etapa de entrenamiento.

Cuando se trata de el entrenamiento en grupos, el tipo de rol y el rol se obtienen a partir de procesar las salidas de las encuestas que los alumnos que forman parte del dataset respondieron sobre sus compañeros, definiendo un rol a cada uno. En cambio, en el entrenamiento general, estos atributos se obtienen de la salida de la encuesta SYMLOG de autopercepción, donde se mapean los resultados de la misma con los Roles de Belbin.

En lo que se refiere al organizador, una vez realizado el procesamiento del conjunto de datos disponibles, estos se encontraran distribuidos en diferentes carpetas, en donde cada grupo tendrá en un archivo toda la conversación transcurrida con los atributos IPA por mensaje, y lo que se desea es tener un resumen normalizando los datos para solucionar un posible problema de diferencia en la cantidad de mensajes por grupo. Esto a su vez permite un rápido insight del comportamiento de los individuos en el grupo, ya que el organizador se encarga de obtener nuevas variables e información a partir del conjunto de datos disponible, tales como el rango horario en el que mayor participación tuvo o cuál fue el promedio de comentarios realizados, en valores entre 0 y 1. A su vez, relaciona conductas IPA con SYMLOG, calculando los valores de estos atributos.

Como se puede observar en el diagrama de secuencia de la Figura 4.8, hay algunos metodos especificos para obtener determinados resultados dentro del conjunto de datos, para ello también se agregan nuevas columnas que son utilizadas posteriormente.




Figura 4.8. Diagrama de secuencia organizador

Dentro de la carpeta que se le entrega a un Organizador, deben estar todas las conversaciones de todos los grupos, ya que esta va a realizar un único resumen para todos los archivos. De esta forma se disponibilizar de un único archivo por tipo de pardeamiento con el cual se trabajará el modelo final.

Por otra parte, volviendo a la aplicación, se le otorga al usuario la opción de cargar un archivo pre procesado que haya descargado previamente para entrenar con el mismo de forma directa, ahorrando una considerable cantidad de tiempo, como se observa en la Figura 4.9.




Figura 4.9. Ingreso directo de archivos en aplicación.

4.3.5 Portabilidad

Escenario de calidad 6. El sistema debe funcionar correctamente en cualquier sistema operativo donde desee ejecutarlo.

- Fuente: Usuario.
- Estímulo: Correr la aplicación en otro sistema operativo diferente de Windows.
- Artefacto: Aplicación desarrollada.
- Ambiente: En tiempo de ejecución.
- Respuesta: El sistema debe funcionar con normalidad.
- Medida Rta: La portabilidad no debe afectar a la performance de la aplicación.

La aplicación de entrenamiento está desarrollada en Java, por lo que su ejecutable es un archivo JAR (Java ARchive), el cual se puede ejecutar en cualquier computadora de cualquier Sistema Operativo que contenga la máquina virtual de Java.

Otro de los inconvenientes que se presentaban para la portabilidad era la herramienta Freeling que se utiliza para el procesamiento de los textos. Esto se solucionó consultando previo a la carga de las librerías bajo que Sistema Operativo se está ejecutando la aplicación, así se realiza la carga de las dependencias correctas según el SO.

4.3.6 Modificabilidad

Escenario de calidad 6. El sistema debe proporcionar la posibilidad de modificarse fácilmente si se quieren agregar nuevos atributos.

- Fuente: Usuario.
- Estímulo: Cargar nueva información.
- Artefacto: Aplicación desarrollada.
- Ambiente: En tiempo de ejecución.
- Respuesta: El sistema debe mantener su performance a pesar de la nueva información.
- Medida Rta: Performance y posibilidad de escalar el conjunto de datos.

La aplicación se diseñó de tal forma que solo sea necesario modificar el pre procesamiento para agregar nueva información. En caso de querer adicionar atributos para inferir los roles, se debe contar con el dataset correspondiente del cual se puedan extraer los datos, modificar el header del archivo de entrenamiento para que lo reconozca, y agregar las variables al organizador de las carpetas para que calcule su promedio y pueda reducir la información a un solo registro por participante de cada grupo. Luego el entrenamiento y la predicción van a tomar automáticamente esos nuevos atributos, incorporándolos al análisis.

Además, al utilizar weka, se posee la posibilidad de utilizar algoritmos que escalan fácilmente, por ejemplo SGD. Este permite agregar nuevos atributos y continuar funcionando normalmente ante la falta de estos, debido a que reemplaza globalmente todos los valores perdidos y transforma los atributos nominales en valores binarios. Además normaliza todos los atributos, por lo que los

coeficientes en la salida se basan en los datos normalizados. Este algoritmo no fue usado en la solución, pero puede ser implementado en un escenario de modificabilidad.

4.4 Persistencia de los datos

A medida que se van generando las diferentes etapas del proceso, se van creando diferentes archivos ARFF que pueden ser consultados y analizados por el usuario. Esto permite a que previo a realizar un nuevo modelo, se pueda almacenar resultados parciales, ya que se encuentran cada uno separados por grupos de trabajo y etapa. Por lo tanto, en una generación completa de todos los modelos, se tendrá hasta seis conjuntos de datos disponibles para analizar previo a la creación del modelo final, otorgando la chance al usuario de comparar los diferentes conjuntos en una sola corrida del proceso.

Una vez que el usuario desee correr nuevamente este proceso con un nuevo conjunto de datos, los resultados previos serán reemplazados por el reciente resultado que se obtenga.

Los resultados se almacenan en el path en el que está corriendo el ejecutable. En *pathEjecutable/results*, se crean las carpetas presentadas en la Figura 4.10.

procesamientoDirecto	23/4/2018 6:48 p.	Carpeta de archivos
procesamientoFases	23/4/2018 6:43 p.	Carpeta de archivos
procesamientoFasesCompuesto	24/9/2018 7:22 p.	Carpeta de archivos
procesamientoGrupos	25/9/2018 6:23 p.	Carpeta de archivos
resample_discretize	15/8/2018 6:21 p.	Carpeta de archivos

Figura 4.10. Carpetas de resultados

La carpeta *procesamientoDirecto* contiene dentro los resultados de la clasificación, junto con el modelo formado para el clasificador entrenado con el proceso directo. La carpeta *procesamientoFases* presenta un contenido similar a la anterior para la Fase 2 y Fase 3. Dentro de la carpeta *procesamientoGrupos* se encuentran dos carpetas iguales a las anteriores para el enfoque de grupo, es decir una para el procesamiento directo, y la restante para el de fases. Por último, la carpeta *resample_discretize* posee las tres carpetas anteriores, pero con el resultado de aplicar los filtros de resample y discretize.

Por último se encuentra la carpeta *procesamientoFasesCompuesto*, la cual contiene los resultados y modelos de los tres clasificadores de la Fase 3 pertenecientes a cada tipo de rol. Esta carpeta también se encuentra dentro de *procesamientoGrupos*, y en *resample_discretize* con los resultados del aplicado de filtros.

4.5 Resumen

En esta sección, se presentó el diseño y la implementación de la herramienta de entrenamiento. Se presentaron los distintos requisitos funcionales y no funcionales detectados, junto con los atributos de calidad.

Para un mejor entendimiento de lo que realiza la herramienta se agregaron distintos diagramas UML, tanto estáticos como diagramas de clase, de componentes, y de caso de uso, como dinámicos, como diagramas de secuencia y mapa de caso de uso.

A su vez, se presentó la interfaz de usuario a partir de la cual los distintos administradores van a poder entrenar a los clasificadores. También, se desarrollaron distintos escenarios de calidad, para visualizar cómo se cumplen los atributos de calidad establecidos. Estos atributos de calidad son: usabilidad, fiabilidad, precisión, escalabilidad, performance y portabilidad.

La herramienta está desarrollada bajo el lenguaje JAVA, y va a estar formada por un parser, que va a transformar el dataset para que quede usable de acuerdo a las necesidades, un organizador, que va a resumir los archivos pre procesados para obtener un único archivo de entrenamiento de cada tipo con los features a analizar, y distintas clases que van a entrenar a la herramienta de forma directa o en fases, tanto en el contexto general como el de grupos.

En el próximo capítulo se va a seguir un proceso igual al actual, dando a conocer el diseño e implementación de la herramienta de predicción, donde se van a poder ingresar distintos chats a partir de los cuales se van a predecir los roles de los integrantes.

5. Diseño e implementación de la aplicación de análisis de datos

En este capítulo se presenta la implementación de la aplicación mediante la cual el administrador va a poder realizar el análisis de datos e inferencia de los roles, junto con las decisiones de diseño. Va a estar dividido en diferentes secciones, de acuerdo a las funcionalidades descritas, como lo son los requisitos funcionales y atributos de calidad, la arquitectura, y los distintos escenarios de calidad que cumplen con los atributos.

5.1 Requisitos funcionales y atributos de calidad

Con toda la información recabada acerca de la herramienta a desarrollar es posible definir los requisitos funcionales del sistema de análisis de datos, los cuales van a permitir concretar todos los servicios que la misma debe cumplir, junto con las relaciones de su operación e implementación.

Entre los requisitos detectados se encuentran:

- La herramienta debe permitir que los usuarios puedan cargar chats para analizar los grupos.
- La herramienta debe permitir a los usuarios visualizar los resultados de forma clara, y a su vez tener la posibilidad de poder ver detalles de los mismos.
- La herramienta debe permitir guardar los resultados para futuros análisis, es decir los datos deben persistir.
- La herramienta debe permitir armar grupos de forma automática a partir de una entrada de datos.
- La herramienta debe poder utilizarse sin la necesidad de instalación.

Por otra parte, se propone que la herramienta cumpla con los siguientes atributos de calidad, como características no funcionales deseables para el sistema:

- Performance: el tiempo que tarda el sistema en responder a un evento debe ser considerablemente corto, dentro de los parámetros de la herramienta, considerando que a veces se pueden procesar entradas de gran tamaño.
- Usabilidad: aunque en un principio la aplicación está pensada para ser utilizada en la Facultad, donde existen profesores que están familiarizados con el uso de la tecnología, la misma debe ser fácil de entender y usar, ya que su uso se puede extender a otras instituciones.
- Portabilidad: Se requiere que la aplicación pueda ejecutarse en diferentes plataformas, es decir, que el código fuente sea capaz de reutilizarse sin necesidad de retocar el código.
- Disponibilidad: El sistema debe mantenerse operativo cuando se lo necesite y debe poder recuperarse fácilmente.
- Extensibilidad: Se deben poder agregar nuevos servicios a la aplicación si así se requiere.

Especificación de requerimientos

A continuación se describen de forma general los requerimientos de la aplicación de análisis de datos a través del diagrama de Casos de Uso de la Figura 5.1, los cuales van a ser detallados luego:




Imagen 5.1. Diagrama de casos de uso aplicación de predicción.

1. **Cargar conversaciones:** El usuario debe poder cargar el archivo de conversaciones de Hangouts que desee para predecir los roles de las personas que forman parte del mismo.
2. **Modelar usuarios:** El usuario debe poder elegir la conversación que desea predecir, y solicitarle al sistema que efectúe el análisis, obteniendo los resultados de forma clara y con la información necesaria.
3. **Exportar:** El usuario debe poder almacenar los resultados para que los mismos persistan.
4. **Materializar datos intermedios:** El usuarios debe poder elegir que datos exportar. Debe poder almacenar tanto los roles resultantes, con los valores de los atributos analizados, como los grupos formados automáticamente.

5. **Armar grupos:** El usuario debe poder armar grupos de acuerdo a los roles calculados previamente de las conversaciones.
6. **Limpiar resultados:** El usuario debe tener permitido reutilizar todas las conversaciones para analizarlas con otro clasificador, o con otro enfoque. Para esto se debe contar con un botón que limpie los resultados de una conversación determinada.

5.2 Decisiones de diseño

En esta sección, se van a presentar las decisiones de diseño tomadas para que la aplicación pueda satisfacer los requisitos funcionales y los atributos de calidad presentados anteriormente.

De acuerdo a las características de la solución, se optó por diseñar una aplicación web con una arquitectura Cliente-Servidor. La misma está formada por dos capas, la Capa de Presentación formada por la interfaz con la que el usuario va a interactuar y la Capa de Negocio, la cual se va a encargar del todo el procesamiento que abarca la predicción de roles, como se puede observar en la Figura 5.2.




Figura 5.2. Arquitectura de la aplicación de análisis de datos

Esta decisión se tomó debido a la presencia de librerías como Freeling, herramienta de procesamiento de lenguaje natural que se utiliza para pre procesar los chats utilizados para la predicción. La misma es una librería de C++, pensada para correr bajo el sistema operativo Linux. En este caso se utiliza en el sistema operativo Windows, con el lenguaje de programación Java. Por esto, para la construcción e instalación de la librería, se deben seguir numerosos pasos y se requiere de varias dependencias externas, las cuales además varían según el sistema operativo.

Aplicando la arquitectura Cliente - Servidor, se logra evitar que los usuarios tengan que llevar a cabo toda la instalación de las librerías, ya que el Servidor va a suplir esta necesidad, debido a que contiene todo el entorno preparado para ser utilizado.

Por otra parte, se optó por una aplicación web debido a que hoy en día, con la presencia de numerosos frameworks, es mucho más sencillo desarrollar una aplicación de este tipo, antes que una interfaz de usuario con el idioma de programación JAVA, la cual era otra de las opciones.

5.2.1 Capa de presentación

Para realizar la interfaz de usuario se decidió emplear una tecnología Frontend que complemente y facilite el desarrollo. En un principio, se consideraron dos opciones: Angular 6 y ReactJs.

Angular es un framework para aplicaciones web desarrollado en TypeScript, de código abierto, mantenido por Google, que se utiliza para crear y mantener aplicaciones web de una sola página. Su

objetivo es aumentar las aplicaciones basadas en navegador con capacidad de Modelo Vista Controlador (MVC), en un esfuerzo para hacer que el desarrollo y las pruebas sean más fáciles.

La biblioteca lee el HTML que contiene atributos de las etiquetas personalizadas adicionales, entonces obedece a las directivas de los atributos personalizados, y une las piezas de entrada o salida de la página a un modelo representado por las variables estándar de JavaScript. Los valores de las variables de JavaScript se pueden configurar manualmente, o ser recuperados de recursos JSON estáticos o dinámicos.

Entre sus principales ventajas se tienen:

- **Generación de código:** Angular convierte tus plantillas en código altamente optimizado para las máquinas virtuales de JavaScript de hoy en día, ofreciendo todas las ventajas del código escrito a mano con la productividad de un framework.
- **Universal:** Ejecuta la primera vista de la aplicación en node.js, .NET, PHP, y otros servidores para renderizado de forma casi instantánea obteniendo solo HTML y CSS. También abre posibilidades para la optimización del SEO del sitio.
- **División del código:** Las aplicaciones de Angular se cargan rápidamente gracias al nuevo enrutador de componentes. Éste ofrece una división automática de códigos para que los usuarios sólo carguen el código necesario para procesar la vista que solicitan.

React por su parte es una biblioteca Javascript de código abierto para crear interfaces de usuario con el objetivo de animar al desarrollo de aplicaciones en una sola página. La misma intenta ayudar a los desarrolladores a construir aplicaciones que usan datos que cambian todo el tiempo. Su objetivo es ser sencillo, declarativo y fácil de combinar.

Entre sus ventajas se puede observar:

- **DOM propio:** React mantiene un virtual DOM propio, en lugar de confiar solamente en el DOM del navegador. Esto deja a la biblioteca determinar qué partes del DOM han cambiado comparando contenidos entre la versión nueva y la almacenada en el virtual DOM, y utilizando el resultado para determinar cómo actualizar eficientemente el DOM del navegador.
- **JSX:** JSX hace que sea fácil leer el código de tus componentes. También es realmente fácil ver el layout o cómo los componentes se combinan entre sí.
- **Desarrollo rápido y fluido:** Como React Native se compila con códigos reales y nativos, la forma en que funciona es perfectamente rápida y fluida.

Aunque no existen grandes diferencias entre ellas, esta última fue la elegida, debido a que es la más utilizada actualmente, ofrece grandes beneficios en performance debido a su DOM virtual (la cual se busca reducir debido a la complejidad de la Capa de Negocio), y promueve un flujo muy claro de datos y eventos, facilitando el desarrollo. Además, va a existir en la aplicación un continuo cambio de estados, lo que es fácil de manejar con este Framework, sumado a que sólo maneja la interfaz de usuario, que es lo para lo que se necesita.

Adicionalmente, existen varias librerías de componentes ya estilizados que son de gran ayuda para evitar tener que dedicar mucho tiempo a los estilos de la aplicación mediante CSS.

5.2.2 Capa de Negocio

Esta capa contiene toda la lógica utilizada para poder llevar a cabo la predicción de los roles. La misma está contenida en un Servicio Rest implementado en el lenguaje de programación Java. Esta arquitectura define una interface de comunicación entre cliente y servidor, separando completamente las responsabilidades entre ambas partes, y no mantienen estado asociado al cliente, permitiendo que cada petición que se realiza sea completamente independientes a la siguiente. Además, mantener un estado requiere memoria donde guardar todos los estados de todos los clientes, por lo que los servicios Rest son de gran ventaja para esto.

Al momento de elegir el servidor sobre el cual se iba a desplegar la aplicación se propusieron dos opciones, Apache Tomcat o Wildfly de JBoss. El primero no es un servidor de aplicaciones, exactamente es un contenedor, es decir solo ejecuta servlets, jsp y pojos (clases simples de java). En cambio Wildfly si lo es, se puede utilizar todo el arsenal completo del standard: JPA, EJB, JMS, etc.

Se terminó optando por este último debido a que es un servidor de aplicaciones Java de código abierto y multiplataforma, compatible con cualquier sistema operativo en el que se encuentre disponible la máquina virtual de Java. Este a su vez es fácil de configurar, pudiendo ser utilizado localmente, permitiendo realizar pruebas de forma sencilla. Además, ya trae incluido RestEasy dentro de sus librerías, lo cual permite desarrollar un servicio Rest sin configuraciones previas.

La funcionalidad del servicio se orientó a la predicción de los Roles de Usuario, separando la lógica del entrenamiento. De esta forma quedaron delimitadas dos partes de la solución al problema planteado: el entrenamiento de los clasificadores para la obtención de los modelos, y la predicción a partir de esos modelos.

5.3 Atributos de calidad

5.3.1 Usabilidad

Escenario de calidad 1. El usuario debe poder obtener fácilmente el archivo que contiene las conversaciones que desea procesar y poder realizar la carga del mismo.

- Fuente: Usuario.
- Estímulo: Cargar archivo de conversaciones.
- Artefacto: Aplicación desarrollada.
- Ambiente: En tiempo de ejecución.
- Respuesta: El sistema debe presentar la información de cómo obtener el archivo de conversaciones y permitir la carga del mismo.
- Medida de respuesta: Tiempo de carga del archivo.

La interacción del usuario con la aplicación comienza con una pantalla donde se puede cargar el primer archivo para comenzar a trabajar. Debido a que la herramienta de interés para proveer los chats es Hangouts, como entrada se aceptan solo archivos .json, ya que es la extensión con la que se obtienen las conversaciones de la misma.

La Figura 5.3 muestra esta pantalla inicial, que cuenta con una explicación y un link de redirección a la página de Google Takeout, de donde se pueden descargar todos los datos de la cuenta de Google, entre ellos, los chats de Hangouts.



CARGAR ARCHIVO

Como obtener el archivo Hangouts.json

Visita [Google Takeout](#), clickear "No seleccionar ninguno" y luego solo seleccionar la opción de Hangouts. Luego presione "Crear Archivo" con las opciones predefinidas, y luego de unos minutos recibirá un archivo zip con Hangouts.json dentro. Extraer el archivo y seleccionarlo desde "Cargar archivo". Tenga en cuenta que si el historial del chat es de gran tamaño podría demorar unos minutos su carga.

Figura 5.3. Pantalla inicial con tutorial para obtener el archivo de chats.

Una vez obtenido el chat, se puede cargar mediante el botón *Cargar Archivo*, presentado en la Figura 5.4.



CARGAR ARCHIVO

Como obtener el archivo Hangouts.json

Visita [Google Takeout](#), clickear "No seleccionar ninguno" y luego solo seleccionar la opción de Hangouts. Luego presione "Crear Archivo" con las opciones predefinidas, y luego de unos minutos recibirá un archivo zip con Hangouts.json dentro. Extraer el archivo y seleccionarlo desde "Cargar archivo". Tenga en cuenta que si el historial del chat es de gran tamaño podría demorar unos minutos su carga.




Figura 5.4. Carga de archivo.

Escenario de calidad 2. El sistema debe permitirle al usuario poder armar grupos de trabajo fácilmente, luego de haber inferido roles de algunas conversaciones.

- Fuente: Usuario.
- Estímulo: Armar grupos a partir de resultados.
- Artefacto: Aplicación desarrollada.
- Ambiente: En tiempo de ejecución.
- Respuesta: El sistema debe calcular grupos efectivos a partir de los roles obtenidos a partir de la predicción.
- Medida de respuesta: Tiempo de tardanza del armado de grupos.

La funcionalidad de Armar Grupos está disponible para el usuario una vez que proceso al menos tres conversaciones, ya que se considera que con ese número de participantes ya se está en condiciones de realizar una distribución en grupos. En la Figura 5.5 se muestra la aparición del botón una vez que se cumplen las condiciones.



Figura 5.5. Botón armar grupo

Una vez seleccionada la opción armar grupos, se presenta un diálogo donde el usuario debe determinar el tamaño que desea que los mismos posean, como se observa en la Figura 5.6.




Figura 5.6. Diálogo de tamaño de grupos.

Ya con la información necesaria disponible, se realiza un llamado al servicio que contiene el armado de grupos. En la implementación del mismo, se tuvo en cuenta que para que un equipo de trabajo funcione de manera óptima, debe contar con los 9 roles definidos por Meredith Belbin. Sin embargo, no es necesario que existan 9 personas diferentes, cada una cumpliendo un rol, cada persona puede tener dos o tres roles preferentes y desempeñarse según se requiera.

En este trabajo, para el armado de los grupos, se utiliza el rol predecido general como rol principal, y el rol predecido asignado por sus compañeros como rol secundario. Con estos datos, y a partir del tamaño ingresado por el usuario, se van a intentar formar grupos equilibrados, siguiendo el diagrama de flujo de la Figura 5.7.




Figura 5.7. Diagrama de flujo armar grupos.

Como se observa en el diagrama de flujo, se recorre la lista de participantes que se recibe como entrada, verificando si sus roles cumplen con los que aún se requieren para completar el grupo y equilibrarlo. Primero se verifica si ambos roles son requeridos, y luego cuando se terminó de iterar sobre la lista de personas, se reinicia el iterador para comprobar si al menos uno de los roles es necesario. Aquellos roles que coincidan con un faltante son retirados de la lista, para no volver a ser consultados.

Los grupos se van almacenando a medida que se llega al tamaño pactado por el usuario, o sino bien cuando los 9 roles de usuario son completados. Aquellos participantes que no pudieron ser colocados en ningún grupo, luego son reubicados en los grupos que aún no completaron el tamaño requerido.

Cuando se agrega un grupo a la lista, dentro el mismo se almacenan los integrantes, si esta completo o no, es decir si contiene todos los roles de Belbin, y en caso de que esto no suceda, la lista de roles faltantes para alertar al usuario. La estructura de la formación de grupos es presentada en la Figura 5.8 mediante un diagrama de clases.




Figura 5.8. Diagrama de clase armado de grupo

- **Integrante:** es la clase que representa a cada participante que forma parte del armado de los grupos. La misma contiene el rol principal y secundario, que son los que se utilizan para realizar la distribución en los distintos grupos, junto con el nombre para identificar a la persona.
- **Grupo:** es la clase que contiene la lista de sus integrantes, junto con la variable booleana *completo* que indica su estado, y los roles faltantes en caso de que sea necesario almacenarlos.
- **RolesGrupo:** es la clase que contiene la funcionalidad del armado de grupos, contenida en el método *armarGrupos*, el cual sigue lo detallado en el diagrama de flujo presentado anteriormente.

Una vez procesados los grupos, se presenta una lista con los resultados, tal como la de la Figura 5.9, en la cual se encuentra cada grupo detallando sus integrantes, y en caso de que no se hayan podido completar los 9 Roles de Belbin, se indica los faltantes.

Grupos	
Integrantes:	Usuario1 (colaborador, implementador), Usuario2 (finalizador, coordinador), Usuario3 (cerebro, impulsor), Usuario4 (especialista, monitor), Usuario5 (impulsor, investigador).
Integrantes:	Usuario6 (impulsor, implementador), Usuario7 (finalizador, coordinador), Usuario8 (especialista, monitor), Usuario9 (cerebro, implementador), Usuario10 (colaborador, monitor).
Roles faltantes:	investigador.
Integrantes:	Nicolas Rodriguez (finalizador, monitor), Joaquin Allende (coordinador, implementador), Matias Adrian Penabaz Puz (colaborador, impulsor), Juan Martin Varela (especialista, finalizador), Agustin Froberg (cerebro, monitor).
Roles faltantes:	investigador.
Integrantes:	mariano diandea@gmail.com (especialista, monitor), Franco Chero (cerebro, coordinador), Desconocido (finalizador, finalizador), Lucas Goyeneche (especialista, monitor), Lucas Olvera (monitor, monitor).
Roles faltantes:	implementador, colaborador, investigador, impulsor.
Integrantes:	Santiago Costa (especialista, monitor), Alan Hesse (coordinador, coordinador), Nicolas Laugas (cerebro, monitor), Lucas Goyeneche (especialista, monitor), Lucas Olvera (monitor, monitor).
Roles faltantes:	implementador, colaborador, finalizador, investigador, impulsor.

EXPORTAR CERRAR

Figura 5.9. Listado de grupos.

Para finalizar se brinda una vista adicional del flujo de Armar Grupo mediante el Use Case Map de la Figura 5.10:




Figura 5.10. Use Case Map armado de grupo

En el diagrama se observa claramente la responsabilidades de cada componente. El servidor se encarga de calcular los grupos, realizando lo explicado anteriormente, mientras que el cliente es el encargado de tomar la cantidad de integrantes que el usuario desea que tengan los grupos, presentar los resultados correspondientes, y exportar esos resultados en caso de que se desee.

5.3.2 Performance

Escenario de calidad 3. El tiempo de respuesta del procesamiento de las conversaciones ingresadas debe ser el menor dentro de lo posible

- Fuente: Usuario.
- Estímulo: Procesar conversaciones.
- Artefacto: Aplicación desarrollada.
- Ambiente: En tiempo de ejecución.
- Respuesta: El sistema debe presentar los roles predecidos.
- Medida de respuesta: El sistema debe brindar respuesta en menos de 20 segundos.

Una respuesta tan rápida es imposible de realizar si se envía a procesar el archivo completo y el mismo es de gran tamaño. Debido a esto, la carga del archivo se divide en conversaciones, de las cuales el usuario debe ir seleccionando aquellas que son de su interés para ser procesadas. En la Figura 5.11 se puede observar la lista de conversaciones cargadas, las cuales se deben procesar individualmente.

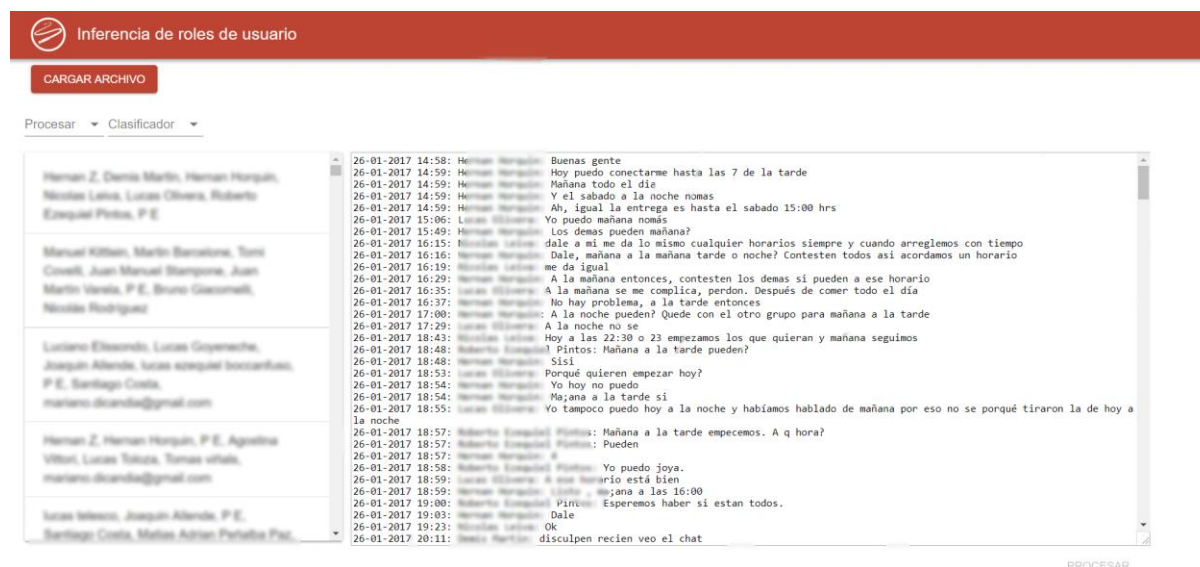


Figura 5.11. Pantalla inicial con conversación cargada

El usuario puede elegir entre el Procesamiento Directo, Procesamiento en Fases o el Procesamiento de Fases Compuesto de la entrada elegida. Al elegir procesar directo, debe seleccionar un clasificador de las opciones que se le proponen, en caso de optar por fases, cuenta con la obligación de elegir tres clasificadores distintos, uno para cada fase, por último, seleccionando el procesamiento compuesto, se requieren cinco clasificadores, uno para la primer y segunda fase, y tres para la último fase, uno para cada tipo de rol.

Una vez completado los filtros correspondientes, el usuario está en condiciones de procesar su entrada, llamando al servicio de predicción. El mismo contiene una estructura formada por una clase principal abstracta llamada *PredictorAbstracto*, de la cual extienden *Predictor* y *PredictorGrupo*. Esta estructura queda reflejada en el diagrama de clase de la Figura 5.12.




Figura 5.12. Diagrama de clases predicción

PredictorAbstracto engloba la utilización de clases que se encargan de preprocesar la entrada para luego poder ser procesada. Una de estas clases es *ParserPrediccion* la cual es la encargada de tomar la conversación de entrada, predecir su conducta IPA con su respectiva área y reacción, mediante la clase *IpaClassifier*, y agregarle a la salida los atributos de interés para ser procesado luego por *OrganizadorPrediccion*. Esta clase toma el archivo generado por el parser y su función es la de promediar las conductas, calcular los atributos SYMLOG, los momentos de participación y la participación general, obteniendo como salida el archivo arff final listo para ser predecido.

En el diagrama de secuencia de la Figura 5.13 se muestra el flujo perteneciente a la creación del archivo para predecir:




Figura 5.13. Diagrama de secuencia de creación de archivo para predecir

Las clases encargadas de la predicción son *Predictor* y *PredictorGrupo*, abstractas como su padre *PredictorAbstracto* debido a que contienen el método que adapta el archivo de predicción abstracto, que luego va a ser implementado por cada tipo de predicción para que lo defina según su necesidad.

Como se dijo anteriormente, el usuario puede elegir entre un procesamiento directo o en fases. Para comenzar a detallarlos, el diagrama de clase de la Figura 5.14 ilustra la estructura del tipo de predictor directo:

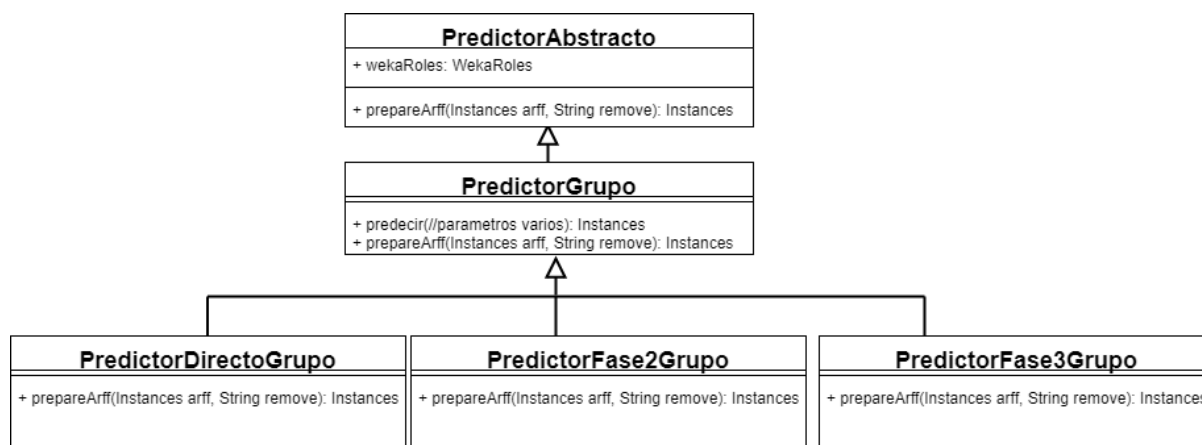


Figura 5.14. Diagrama de clases predicción grupos.

El predictor de grupos es el encargado de predecir qué rol le asignarían los compañeros de grupo según las características que presentó en ese contexto. Cada uno contiene su método *prepareArff*, el cual adapta la salida del Organizador para poder predecir.

Dentro de la predicción de grupos se encuentran:

- **PredictorDirectoGrupo:** El predictor directo de grupos utiliza los modelos entrenados por el entrenamiento directo en grupos para clasificar las instancias. El rol predicho va a formar parte del archivo de predicción del predictor directo general, ocupando el atributo *rol_companeros*.
- **PredictorFase2Grupo:** La primer fase del predictor en fases se considera la formada por el clasificador IPA, de la cual se obtienen los mensajes clasificados según su conducta. Luego de que se organiza la salida de esta, se inicia la fase 2, la cual predice el tipo de rol que los compañeros de grupo asignarían al sujeto en cuestión. Su resultado va a formar parte del archivo utilizado en la fase 2 general, como el atributo *tipo_rol_companeros*, y se va a utilizar como entrada de la fase 3 de grupos.
- **PredictorFase3Grupo:** Como se dijo anteriormente, este predictor toma como entrada la salida de la fase 2, y utilizando los modelos entrenados para este caso, predice el rol que los compañeros de grupo le asignarían a la persona según las características analizadas.

Luego se encuentran los predictores que se alimentan con la salida de los anteriores para realizar la predicción general del rol de equipo, presentados en el diagrama de clase de la Figura 5.15:




Figura 5.15. Diagrama de clases predicción general.

- **PredictorDirecto:** Este predictor es el encargado de inferir el rol de equipo mediante los modelos entrenados por el entrenador directo. El mismo toma como entrada el archivo organizado luego de ser clasificado por el clasificador IPA, sobre el cual realiza un procesamiento para luego utilizarlo en la predicción. Para esto, se utiliza el predictor directo de grupos, de donde se obtiene el valor del atributo *rol_companeros*. Una vez hecho esto, comienza la predicción obteniendo como resultado el rol final.
- **PredictorFase2:** Al igual que el predictor en fases de grupo, la primer fase está formada por el clasificador IPA a partir del cual se obtienen las conductas. Luego esas conductas, junto con el resultado de la predicción de la fase 2 de grupo que brinda el tipo de rol asignado por los compañeros, son utilizadas por este predictor que va a dar como salida un archivo con el tipo de rol general que se utiliza en la próxima fase.
- **PredictorFase3:** Este predictor con la salida de la fase 2, utiliza al predictor de la fase 3 en grupos para obtener el rol asignado por los compañeros que va a servir como uno de los features de esta etapa. Como resultado se obtiene el rol general predecido a través de los modelos entrenados para esta fase, que son los que más precisión lograron.

Para terminar de detallar la predicción, se presenta en diagramas de secuencia el flujo completo de la misma, tanto directa como en fases. Se comienza por el modelado de usuario directo, detallado en la Figura 5.16.




Figura 5.16. Diagrama de flujo predicción directa

En este diagrama quedó resumido lo explicado anteriormente. El predictor recibe el clasificador a utilizar junto con una entrada (conversación), la cual va a ser clasificada con las conductas IPA, su área IPA y reacción. Luego de esto, con la salida del clasificador IPA, se organizan los datos, promediando cada conducta, área y reacción, calculando los atributos SYMLOG, estableciendo los porcentajes de participación en cada momento del chat, y el de participación general. Por otra parte, le agrega el rol asignado por los compañeros de grupo, predecido por el predictor directo de grupos, obteniendo el archivo de predicción de la Figura 5.17.


```

1 @relation 'chat-weka.filters.unsupervised.attribute.Remove-R1-3,5-5'
2
3 @attribute class_rol {finalizador,impulsor,cerebro,colaborador,especialista,implementador,monitor,investigador,coordinador}
4 @attribute nombre string
5 -----Rol predecido por predictor directo de grupos-----
6 @attribute class_rol_companeros {finalizador,impulsor,cerebro,colaborador,especialista,implementador,monitor,investigador,coordinador}
7 -----Promedio conductas predecidas por clasificador IPA-----
8 @attribute C1 numeric
9 @attribute C2 numeric
10 @attribute C3 numeric
11 @attribute C4 numeric
12 @attribute C5 numeric
13 @attribute C6 numeric
14 @attribute C7 numeric
15 @attribute C8 numeric
16 @attribute C9 numeric
17 @attribute C10 numeric
18 @attribute C11 numeric
19 @attribute C12 numeric
20 -----Promedio reacciones predecidas por clasificador IPA-----
21 @attribute R1 numeric
22 @attribute R2 numeric
23 @attribute R3 numeric
24 @attribute R4 numeric
25 -----Promedio áreas predecidas por clasificador IPA-----
26 @attribute A1 numeric
27 @attribute A2 numeric
28 -----Porcentaje de participación en introducción-----
29 @attribute Horario1 numeric
30 -----Porcentaje de participación en desarrollo-----
31 @attribute Horario2 numeric
32 -----Porcentaje de participación en finalización-----
33 @attribute Horario3 numeric
34 -----Promedio de atributos SYMLOG-----
35 @attribute dominante_symlog numeric
36 @attribute sumiso_symlog numeric
37 @attribute amistoso_symlog numeric
38 @attribute no_amistoso_symlog numeric
39 @attribute tarea_symlog numeric
40 @attribute socio_emocional_symlog numeric
41 -----Participación general-----
42 @attribute cant_mensajes numeric
43
44 @data
45 ?,Usuario1,implementador,0.154639,0.010309,0.340206,0.041237,0.113402,0.28866,0.041237,0.010309,0,0,0,0.505155,0.051546,0.443299,
46 0.505155,0.494845,0.185567,0.793814,0.020619,0.051546,0.948454,0.505155,0,0.494845,0.505155,0.305031
47 ?,Usuario2,coordinador,0.023256,0.046512,0.162791,0.162791,0.116279,0.488372,0,0,0,0,0.232558,0,0.767442,0.232558,0.767442,
48 0.093023,0.906977,0,0,1,0.232558,0.767442,0.232558,0.13522
49 ?,Usuario3,impulsor,0.035714,0.107143,0.321429,0.0.107143,0.392857,0,0,0,0.035714,0,0.464286,0.035714,0.5,0.5,0.5,0.071429,
50 0.928571,0.035714,0.964286,0.464286,0.035714,0.5,0.5,0.08805
51 ?,Usuario4,implementador,0.091954,0.057471,0.471264,0.011494,0.057471,0.264368,0,0.011494,0.022989,0.011494,0.62069,0.034483,
52 0.011494,0.333333,0.655172,0.344828,0.068966,0.873563,0.057471,0.045977,0.954023,0.62069,0.034483,0.344828,0.655172,0.273585
53 ?,Usuario5,monitor,0.190476,0.047619,0.15873,0.142857,0.063492,0.301587,0,0.015873,0,0.063492,0.015873,0,0.396825,0.079365,0.015873,
54 0.507937,0.47619,0.52381,0.111111,0.857143,0.031746,0.095238,0.904762,0.396825,0.079365,0.52381,0.47619,0.198113

```

Figura 5.17. Estructura archivo ARFF predicción directa

Con este recurso sumado al clasificador, se obtiene la salida que consta de los roles predecidos de los participantes del grupo en cuestión.

Ahora se procede a presentar el flujo de la predicción en fases en la Figura 5.18:




Figura 5.18. Diagrama de secuencia predicción en fases

La predicción por fases comienza de forma similar a la directa, se reciben como entrada los clasificadores de cada fase junto con la conversación a predecir. A partir de esto, se clasifican los mensajes con sus conductas IPA, reacciones y acciones utilizando el clasificador de la fase 1, obteniendo luego los promedios de las mismas, los atributos SYMLOG calculados a partir de ellas y los porcentajes de participación.

Luego utilizando el archivo organizado, se obtiene el tipo de rol que le asignan los compañeros mediante el predictor de la fase 2 de grupo y a la vez se crea la instancia del predictor de la fase 3 de grupo, que luego va a ser utilizado para predecir los roles propuestos por los compañeros.

El tipo de rol obtenido como salida del predictor de grupo, va a completar el archivo de predicción de la Fase 2, a partir del cual se va a inferir el tipo de rol general. Este último va a pasar a formar parte de la entrada de la Fase 3, junto con el rol asignado por los compañeros (salida Fase 3 de grupo), dando como resultado un archivo ARFF con la estructura presentada en la Figura 5.19, mediante el cual finalmente se infieren los roles generales de cada participante.

```

1 @attribute class_rol {finalizador,impulsor,cerebro,colaborador,especialista,implementador,monitor,investigador,coordinador}
2 -----Tipo de rol prededido por fase 2-----
3 @attribute class_tipo_rol {social,mental,accion}
4 @attribute nombre string
5 -----Tipo de rol asignado por compañeros prededido por fase 2 de grupo-----
6 @attribute class_tipo_rol_companeros {social,mental,accion}
7 -----Rol asignado por compañeros prededido por fase 3 de grupo-----
8 @attribute class_rol_companeros {finalizador,impulsor,cerebro,colaborador,especialista,implementador,monitor,investigador,coordinador}
9 -----Promedio de conductas IPA prededido por fase 1-----
10 @attribute C1 numeric
11 @attribute C2 numeric
12 @attribute C3 numeric
13 @attribute C4 numeric
14 @attribute C5 numeric
15 @attribute C6 numeric
16 @attribute C7 numeric
17 @attribute C8 numeric
18 @attribute C9 numeric
19 @attribute C10 numeric
20 @attribute C11 numeric
21 @attribute C12 numeric
22 -----Promedio de reacciones IPA prededido por fase 1-----
23 @attribute R1 numeric
24 @attribute R2 numeric
25 @attribute R3 numeric
26 @attribute R4 numeric
27 -----Promedio de acciones IPA prededido por fase 1-----
28 @attribute A1 numeric
29 @attribute A2 numeric
30 -----Porcentaje de participación en introducción-----
31 @attribute Horario1 numeric
32 -----Porcentaje de participación en desarrollo-----
33 @attribute Horario2 numeric
34 -----Porcentaje de participación en finalización-----
35 @attribute Horario3 numeric
36 -----Atributos SYMLOG-----
37 @attribute dominante_symlog numeric
38 @attribute sumiso_symlog numeric
39 @attribute amistoso_symlog numeric
40 @attribute no_amistoso_symlog numeric
41 @attribute tarea_symlog numeric
42 @attribute socio_emocional_symlog numeric
43 -----Porcentaje de participación general-----
44 @attribute cant_mensajes numeric
45
46 @data
47 ?,social,Usuario1,accion,implementador,0.154639,0.010309,0.340206,0.041237,0.113402,0.28866,0.041237,0.010309,0,0,0,0.505155,0,
48 0.051546,0.443299,0.505155,0.494845,0.185567,0.793814,0.020619,0.051546,0.948454,0.505155,0,0.494845,0.505155,0.305031
49 ?,mental,Usuario2,accion,implementador,0.023256,0.046512,0.162791,0.162791,0.116279,0.488372,0,0,0,0,0,0.232558,0,0,0.767442,
50 0.232558,0.767442,0.093023,0.906977,0,0,1,0.232558,0,0.767442,0.232558,0.13522
51 ?,mental,Usuario3,accion,implementador,0.035714,0.107143,0.321429,0,0.107143,0.392857,0,0,0,0.035714,0,0,0.464286,0.035714,0,0.5,
52 0.5,0.5,0.071429,0.928571,0,0.035714,0.964286,0.464286,0.035714,0.5,0.5,0.08805
53 ?,social,Usuario4,social,colaborador,0.091954,0.057471,0.471264,0.011494,0.057471,0.264368,0,0.011494,0,0.022989,0.011494,
54 0,0.62069,0.034483,0.011494,0.333333,0.655172,0.344828,0.068966,0.873563,0.057471,0.045977,0.954023,0.62069,0.034483,0.344828,0.655172,0.273585
55 ?,social,Usuario5,social,colaborador,0.190476,0.047619,0.15873,0.142857,0.063492,0.301587,0,0.015873,0,0.063492,0.015873,0,0.396825,
56 0.079365,0.015873,0.507937,0.47619,0.52381,0.111111,0.857143,0.031746,0.095238,0.904762,0.396825,0.079365,0.52381,0.47619,0.198113

```

Figura 5.19. Estructura archivo ARFF predicción en fases.

La predicción por fases compuesta, en la cual se utiliza un clasificador por cada tipo de rol, sigue un flujo similar al presentado anteriormente para el procesamiento por fases simple. Como entrada cuenta con dos clasificadores adicionales, ya que en la última fase se requieren tres. Luego es similar en las primeras dos fases, pudiéndose observar algunas diferencias en la tercera, las cuales se presentan en el diagrama de flujo de la Figura 5.20.




Figura 5.20. Fase 3 procesamiento en Fases compuesto.

En el diagrama se puede observar que tanto para el procesamiento por grupos como para el general, en la última etapa se filtra previamente el dataset antes de predecirlo, dejando solo los registros pertenecientes al tipo de rol con el cual fue entrenado el clasificador en cuestión.

Cuando se trata del procesamiento por grupos, se combinan los resultados a medida que se va prediciendo, ya que los mismos deben ser agregados al dataset que luego se utiliza para el general. Entonces, se deben descartar de este los registros que se descartaron para predecir, para conocer a qué instancia pertenece cada rol de compañeros inferido. Luego una vez calculados los roles generales, se unen las instancias al finalizar, retornando el conjunto resultante.

Una vez obtenida la salida de la predicción de cualquiera de los enfoques, se presenta una lista de tarjetas con el desenlace del procesamiento, como la que se puede observar en la Figura 5.21, las cuales individualmente contienen el nombre del integrante, el rol predicho, y se puede extender para ver los detalles del análisis.

Resultados

	Usuario 1 Colaborador
	Usuario 2 Finalizador
	Usuario 3 Cerebro
	Usuario 4 Impulsor
	Usuario 5 Monitor

Figura 5.21. Lista de resultados

Dentro de los detalles se encuentran las características principales analizadas por los clasificadores presentadas en la Figura 5.22, como los atributos SYMLOG, el rol asignado por sus compañeros, los momentos de participación, y el porcentaje de participación en el chat, los cuales pueden ser de interés para la persona encargada de analizar los resultados.

Resultados

	Usuario 3 Cerebro
Rol asignado por compañeros: Impulsor Mensajes en introducción: 0.071429 Mensajes en desarrollo: 0.928571 Mensajes en finalización: 0 Dominante (SYMLOG): 0.035714 Sumiso (SYMLOG): 0.964286 Amistoso (SYMLOG): 0.464286 No amistoso (SYMLOG): 0.035714 Tarea (SYMLOG): 0.5 Socio emocional (SYMLOG): 0.5 Participación 0.08805	

Figura 5.22. Tarjeta de resultado extendida

A modo de resumen, se presenta el Use Case Map de la Figura 5.23, el cual brinda una visión extra del proceso de modelado de usuarios:




Figura 5.23. Use case map modelado de usuarios.

Como se puede observar, previo a modelar los usuarios se debe ingresar el archivo que contiene las conversaciones de Hangouts, seleccionar la conversación a predecir, y elegir las preferencias. Este último paso consta de optar por un procesamiento directo o en fases y por la selección del clasificador con el que se desea predecir. Una vez que se carga esta información se pueden modelar los usuarios, los cuales se pueden exportar o no según se desee.

5.3.3 Portabilidad

Escenario de calidad 4. Se desea que el sistema pueda ser utilizado en cualquier Sistema Operativo sin la necesidad de instalaciones previas.

- Fuente: Administrador.
- Estímulo: Utilizar la aplicación en varios SO.
- Artefacto: Aplicación desarrollada.
- Ambiente: En tiempo de ejecución.
- Respuesta: El sistema debe funcionar en cualquier SO donde desee ser utilizado.
- Medida de respuesta: El agregado de portabilidad no debe intervenir con el normal funcionamiento de la plataforma.

Para dar respuesta a este escenario, se diseñó a la Aplicación con una arquitectura Cliente Servidor, como se dijo anteriormente.

Reactjs, va a funcionar de igual manera en cualquier navegador de cualquier Sistema Operativo, incluyendo SO móviles. Por su parte, la presencia del Servidor va a permitir tener configuradas todas las librerías sin necesidad de tener que cargar sus dependencias de acuerdo a cada sistema operativo, va a estar todo centralizado en el mismo.

5.3.4 Disponibilidad

Escenario de calidad 4. Se desea que el sistema esté operativo cuando se lo necesite y que en caso de falla se pueda restaurar fácilmente.

- Fuente: Interna o externa.
- Estímulo: Defecto, respuesta incorrecta.
- Artefacto: Aplicación desarrollada.
- Ambiente: En tiempo de ejecución.
- Respuesta: El sistema debe detectar la falla, registrarla y volver a estar operativo.
- Medida de respuesta: Tiempo para reparar la falla.

La decisión de separar a las conversaciones para ser procesadas una a una también se tomó para evitar fallas que puedan alterar el correcto funcionamiento de la aplicación. Si se envía un archivo de gran tamaño (ya que no se puede enviar el path del mismo por cuestiones de seguridad), crece la probabilidad de que falle el sistema debido que se debe realizar la carga en el servidor y esto es muy costoso.

Por otra parte, la aplicación va a desplegarse en un contenedor Docker, el cual permite acelerar el tiempo promedio para la resolución de problemas. Esto se debe a que permite volver a desplegar fácilmente e implementar correcciones en la aplicación.

5.3.4 Escalabilidad

Escenario de calidad 5. Se desea agregar nuevos servicios a la aplicación, junto con una conexión a una base de datos.

- Fuente: Administrador.
- Estímulo: Agregar servicios.
- Artefacto: Aplicación desarrollada.

- Ambiente: En tiempo de compilación.
- Respuesta: El sistema debe continuar funcionando de forma similar a pesar del agregado de carga.
- Medida de respuesta: Tiempo de carga y respuesta.

Para dar respuesta a este escenario se cuenta con la arquitectura Cliente - Servidor. La estructura inherentemente modular facilita la integración de nuevas tecnologías y el crecimiento de la infraestructura computacional, favoreciendo así la escalabilidad de las soluciones. Se pueden agregar las capas que se deseen, como una capa de datos mediante una conexión a una base de datos, sin afectar el funcionamiento de la aplicación.

Los sistemas Cliente - Servidor pueden ser escalados horizontal o verticalmente. El escalado horizontal significa añadir o eliminar estaciones clientes con un ligero impacto en el rendimiento. A su vez, el escalado vertical significa la migración a un servidor más grande y rápida o la incorporación de nuevos servidores.

5.4 Persistencia de datos

Durante el desarrollo de la aplicación se analizó la forma en la que los datos iban a persistir. Se contaba con la opción de una Base de Datos, o de la descarga directa de los archivos con los resultados.

Se terminó optando por no levantar una Base de Datos, debido a que sólo se iba a utilizar para almacenar los resultados. Se consideró mejor la opción de que el usuario elija qué archivos quiere almacenar y en qué formato, de acuerdo al uso que le va aplicar a los datos.

Para satisfacer esto se diseñó la funcionalidades de exportar, como se puede observar en la Figura 5.24. Con esto se busca que el usuario pueda almacenar sus resultados para futuros análisis. Se cuenta con las opciones de exportar a un archivo con el formato *xlsx* (excel), o con el formato *arff* para poder ser reutilizado en la herramienta Weka.

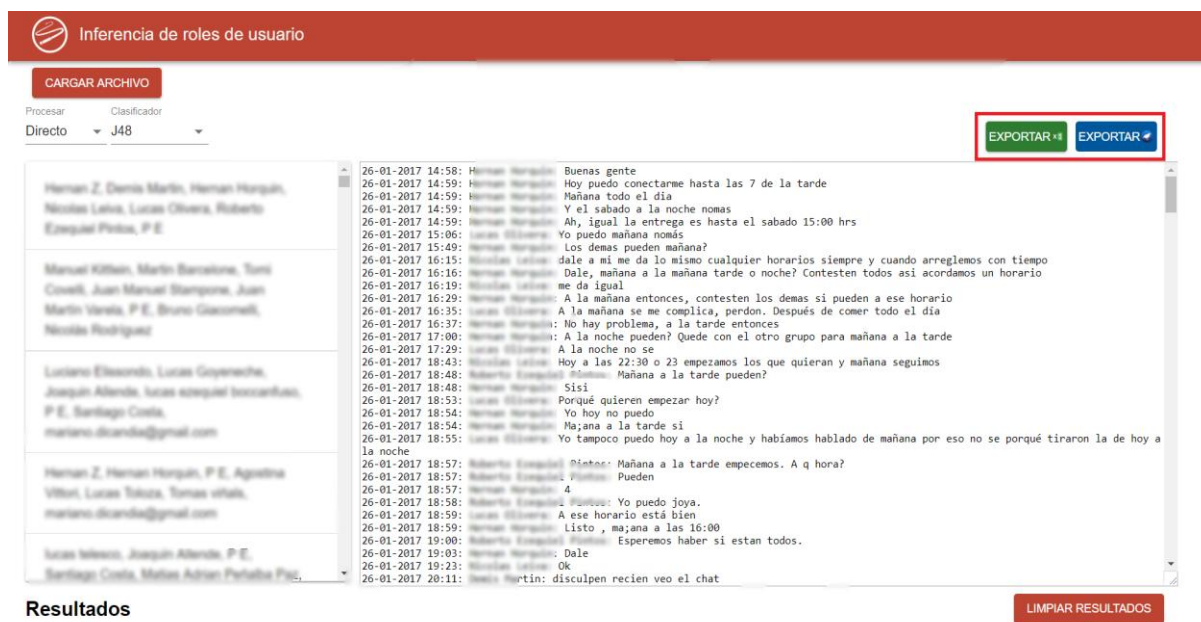


Figura 5.24. Botones para exportar resultados

Con la opción de Exportar a Excel, se descarga automáticamente un archivo XLSX como el de la Figura 5.25, el cual contiene como columnas un resumen de la información analizada (atributos SYMLOG y participación), junto con el nombre de cada participante, y los roles predecidos, tanto general como el asignado por sus compañeros.

	A	B	C	D	E	F	G	H	I	J	K	L	M
	Rol	Nombre	Rol Companeros	Participacion Intro	Participacion Desa	Participacion Fin	Dominante	Sumiso (SYM	Amistoso (SY	No-amistoso (SY	Tarea (SYMLOG	Socio-Emocional	Participacion
1	colaborador	Usuario1	implementador	0.185567	0.793814	0.020619	0.051546	0.948454	0.505155	0	0.494845	0.505155	0.305031
2	finalizador	Usuario2	coordinador	0.093023	0.906977	0	0	0.232558	0.232558	0	0.767442	0.232558	0.13522
3	cerebro	Usuario3	impulsor	0.071429	0.928571	0	0.035714	0.964286	0.464286	0.035714	0.5	0.5	0.08805
4	impulsor	Usuario4	implementador	0.068966	0.873563	0.057471	0.045977	0.954023	0.62069	0.034483	0.344828	0.655172	0.273585
5	monitor	Usuario5	monitor	0.111111	0.857143	0.031746	0.095238	0.904762	0.396825	0.079365	0.52381	0.47619	0.198113

Figura 5.25. Resultados exportados a Excel

Cuando se exporta el archivo ARFF, la información descargada es similar a la del archivo XLSX, con el agregado de los valores de los promedios de las conductas, áreas y reacciones IPA, de los cuales se obtuvieron los atributos SYMLOG, como se muestra en la Figura 5.26.

```
@relation 'chat-weka.filters.unsupervised.attribute.Remove-R1-3,5-5'

@attribute class_rol {finalizador,impulsor,cerebro,colaborador,especialista,implementador,monitor,investigador,coordinador}
@attribute nombre string
@attribute class_rol_companeros {finalizador,impulsor,cerebro,colaborador,especialista,implementador,monitor,investigador,coordinador}
@attribute C1 numeric
@attribute C2 numeric
@attribute C3 numeric
@attribute C4 numeric
@attribute C5 numeric
@attribute C6 numeric
@attribute C7 numeric
@attribute C8 numeric
@attribute C9 numeric
@attribute C10 numeric
@attribute C11 numeric
@attribute C12 numeric
@attribute R1 numeric
@attribute R2 numeric
@attribute R3 numeric
@attribute R4 numeric
@attribute A1 numeric
@attribute A2 numeric
@attribute Horario1 numeric
@attribute Horario2 numeric
@attribute Horario3 numeric
@attribute dominante_symlog numeric
@attribute sumiso_symlog numeric
@attribute amistoso_symlog numeric
@attribute no_amistoso_symlog numeric
@attribute tarea_symlog numeric
@attribute socio_emocional_symlog numeric
@attribute cant_mensajes numeric

@data
colaborador,'Usuario1',implementador,0.154639,0.010309,0.340206,0.041237,0.113402,0.28866,0.041237,0.010309,0,0,0,0.505155,0,0.051546,
0.443299,0.505155,0.494845,0.185567,0.793814,0.020619,0.051546,0.948454,0.505155,0,0.494845,0.505155,0.305031
finalizador,'Usuario2',coordinador,0.023256,0.046512,0.162791,0.162791,0.116279,0.488372,0,0,0,0.232558,0,0.767442,0.232558,
0.767442,0.093023,0.906977,0,0,1,0.232558,0.767442,0.232558,0.13522
cerebro,'Usuario3',impulsor,0.035714,0.107143,0.321429,0.107143,0.392857,0,0,0,0.035714,0,0.464286,0.035714,0.5,0.5,0.071429,
0.928571,0,0.035714,0.964286,0.464286,0.035714,0.5,0.5,0.08805
impulsor,'Usuario4',implementador,0.091954,0.057471,0.471264,0.011494,0.057471,0.264368,0,0.011494,0,0.022989,0.011494,0,0.62069,
0.034483,0.011494,0.333333,0.655172,0.344828,0.068966,0.873563,0.057471,0.045977,0.954023,0.62069,0.034483,0.344828,0.655172,0.273585
monitor,'Usuario5',monitor,0.190476,0.047619,0.15873,0.142857,0.063492,0.301587,0,0.015873,0,0.063492,0.015873,0,0.396825,0.079365,0.015873,0.507937,
0.47619,0.52381,0.111111,0.857143,0.031746,0.095238,0.904762,0.396825,0.079365,0.52381,0.47619,0.198113
```

Figura 5.26. Resultados exportados a formato arff

También, otro de los resultados que se pueden almacenar son los grupos armados por la herramienta. Los mismos se presentan en un archivo TXT con el formato de la Figura 5.27.

```

Grupo 1:
Integrantes: Usuario1 (colaborador, implementador), Usuario2 (finalizador, coordinador), Usuario3 (cerebro, impulsor),
Usuario4 (especialista, monitor), Usuario5 (impulsor, investigador).
-----
Grupo 2:
Integrantes: Usuario6 (impulsor, implementador), Usuario7 (finalizador, coordinador), Usuario8 (especialista, monitor),
Usuario9 (cerebro, implementador), Usuario10 (colaborador, monitor).
Roles faltantes: investigador.
-----

```

Figura 5.27. Grupos exportados.

5.5 Resumen

En este capítulo se detalló el diseño en implementación de la aplicación de análisis de datos, presentando los requisitos funcionales y atributos de calidad, los requerimientos detectados mediante diagramas de Caso de Uso y la arquitectura.

La aplicación es una aplicación web bajo una arquitectura Cliente-Servidor. La capa de presentación va a estar formada por una interfaz de usuario desarrollada con el framework React, mientras que el servicio que utiliza la misma va a estar desarrollado bajo el lenguaje Java, corriendo en un servidor Wildfly.

La misma cuenta con las funcionalidades de modelado de usuario, a partir de los tres enfoques propuestos, y armado de grupos automáticamente. Los resultados obtenidos pueden exportarse bajo el formato `xlsx` y `arff` en el caso del modelado de usuario, y `txt` en el caso de los grupos.

También se presentaron diferentes escenarios de calidad para demostrar el cumplimiento de los atributos de calidad y requisitos no funcionales detectados en un principio.

Una vez presentados los diseños e implementaciones tanto de la herramienta de entrenamiento (Capítulo 4), como la de la aplicación de modelado de usuario, se procede en el próximo capítulo a detallar el experimento seguido junto con los resultados obtenidos de las precisiones de los distintos clasificadores

6. Descripción del experimento

En esta sección se presenta una serie de análisis realizada sobre los atributos previo a presentar los resultados de las experimentaciones. Se realizaron dos tipos de experimentos, el primero con técnicas de aprendizaje de máquina obteniendo las precisiones de los clasificadores, y luego aplicando la herramienta en una situación real. Por último, se analizarán un conjunto de métricas de usuario para analizar el impacto de la aplicación.

6.1. Configuración

En esta etapa se procede a realizar una serie de análisis realizada sobre atributos específicos y diferentes patrones que se visualizan en los roles. Este análisis de los datos permite identificar su validez y aún más, tal como poder identificar no solo como los algoritmos juzgan y obtienen su decisión, sino para tener una visión y comprensión más profunda acerca de los datos y así poder proveer mayor información acerca de lo que se intenta predecir. Además, permite mejorar la precisión no a partir de decisiones no intuitivas, sino a partir de los datos, de la información que nos otorga, tomando en fin mejores decisiones.

A su vez, se muestran diferentes tipos de gráficos para que el lector obtenga una representación más sencilla de lo que la información dispone y se puedan analizar aspectos interesantes de los datos.

Como paso inicial se procedió a identificar la distribución de roles presente en el conjunto de datos (Figura 6.1), ya que ésta es la clase que se utiliza para clasificarlos.

Roles autopercebidos




Figura 6.1. Distribución de rol auto percibidos

Las encuestas de autopercepción arrojaron que entre los roles más identificados se destacan los coordinadores y colaboradores, representando casi el 40% del total. Por otra parte, los investigadores e impulsores son los roles que más escasean, representando solo un 4,5% de los recursos disponibles. Como se puede observar, no existe un balance en las ocurrencias de los mismos, existiendo aquellos que predominan alrededor de siete veces más que otros, provocando

en definitiva un desbalance general. Es así que aquellos roles con menos presencia necesitan ganar mayor peso para poder ser identificados correctamente.

Los desbalances afectan directamente al resultado, donde las clases que representan a los grupos más minoritarios en cantidad de repeticiones se ven afectadas en la clasificación, mientras que aquellos grupos mayoritarios tendrán posibilidades más altas de ser clasificados correctamente que el resto. Esto se da porque la precisión de los clasificadores se basa más en las clases comunes que en las que presentan menos ocurrencias, lo cual hace difícil una buena performance en estas últimas. De esta forma será necesario aplicar alguna técnica sobre los datos que permita obtener una mejor representación de aquellas minorías. Además, detallar la matriz de confusión luego de las clasificaciones permitirá observar más profundamente como el clasificador se ve afectado por estos casos.

Adicionalmente, si se observa la repetición de acuerdo al tipo de rol que posee el individuo presentada en la Figura 6.2, se obtiene otra visión diferente de la balanza, donde los roles sociales predominan sobre el resto con un 42% del total, seguidos por los mentales con un 32%, mientras que el resto se delega en aquellos roles del tipo acción como grupo minoritario, en el que se encuentran los implementadores, finalizadores e impulsores, este último unos de los roles menos auto percibidos.




Figura 6.2. Distribución en tipo de rol auto percibido.

En este caso, si se ve a los roles como conjunto se observa un mayor balance, mientras que si se trata a cada rol individualmente se detecta el desbalance.

Por otra parte, continuando con el análisis general, se procede a observar la distribución de los mensajes registrados. En la Figura 6.3 se muestra que el 40% de los mismos son provenientes de estos tipos de roles sociales, mientras que el restante proviene un 33% del mental y un 27% de aquellos perteneciente al de acción.

Cantidad de mensajes por tipo de rol




Figura 6.3. Cantidad de mensajes registrados por tipo de rol

Esto quizás era imaginable, ya que son los roles que más se comunican con sus compañeros de grupo a la hora de desarrollar un actividad. En total da una cantidad de casi 40.000 mensajes registrados a este tipo de rol.

Finalizando, en la Figura 6.4, se puede verificar que no siempre la percepción de los compañeros es la misma que el rol primario natural de la persona. Esto se puede dar ya que existen otros compañeros que ganaron en la predominancia de este rol y por lo tanto han tenido que adaptarse a otro rol o preferentemente a su rol secundario si es que tuvieron la oportunidad.

Tipo de rol asignado por compañeros




Figura 6.4. Promedio de percepción de los compañeros

En el caso de los roles sociales es el rol que muestra mayor correlación con lo autopercebido, un 41% frente al 32% de los roles mentales y 26% a los de acción. Esto significa que la presencia de un rol primario en un individuo, es muy posible que este lleve adelante un rol de ese mismo tipo en un trabajo grupal.

Para lograr una mejor identificación de cada rol individual y saber exactamente cuáles son aquellas features que tienen mayor impacto en la toma de decisiones, se decidió analizar cada uno de estos perfiles a través de la información obtenida en cada mensaje realizado para comunicarse. A través de un evaluador de atributos y un buscador (InfoGain y Ranker) fue posible detectar cuales son los atributos determinados que generan más peso en cada rol. De esta forma se analizó individualmente como afectaba cada uno de los atributos seleccionados en la toma de decisiones de cada rol. Para esto se utilizaron las instancias pertenecientes al rol a analizar.

6.1.1 Roles sociales

Comenzando con el grupo más presente dentro de los roles auto percibidos, se encuentran los roles sociales, donde los rankings específicos de cada tipo de rol muestran una correlación en las tres primeras conductas IPA 1-3 a diferencia del resto de las categorías, esto se encuentra reflejado con las características de las mismas, ya que este conjunto específico de conductas se distinguen por pertenecer al área socio-emocional y reacciones positivas.

En la tabla 6.1 se pueden observar estas relaciones y comparar estos resultados, analizando los atributos obtenidos por los evaluadores para definir a la categoría.

Coordinador	Colaborador	Investigador
Conducta IPA 6	Conducta IPA 2	Conducta IPA 3
Cantidad de mensajes	Conducta IPA 6	Conducta IPA 4
Tipo Conducta IPA 1	Conducta IPA 8	Conducta IPA 9
Área de mensajes 1	Reacción del tipo 1	Conducta IPA 2
Área de mensajes 2	Reacción del tipo 4	Conducta IPA 7
Reacción del tipo 1	Conducta IPA 4	Reacción 4
Reacción del tipo 4	Conducta IPA 5	Conducta IPA 6
Conducta IPA 3	Reacción del tipo 3	Reacción del tipo 1
Conducta IPA 2	Conducta IPA 9	Conducta IPA 5

Tabla 6.1 Ranking atributos sociales.

Dentro de los coordinadores se destaca la cantidad de mensajes que generan a lo largo de sus tareas, otro indicador positivo que se lo puede ver relacionado a la actividad en sí mismo y a su categoría. Para entrar más en profundidad se procede a realizar un análisis individual de cada uno.

Coordinador (Social):

El coordinador destaca sus conductas para dar información, con una media del 45% de sus mensajes correspondientes al tipo de conducta IPA 6 dando información, seguido por una muestra de acuerdo y aprobación dado por la conducta IPA 3 en el 25% de sus conversaciones. Esto refleja su

tendencia a liderar, agradeciendo a todos los posibles aportes, con el objetivo de llevar a cabo la actividad con la menor cantidad de problemas posibles.

Sus horarios de actividad suelen estar mayormente en las dos primeras franjas horarias, mientras que relegan en la última etapa.

Es un rol que aparece frecuentemente y genera conflictos con otros del mismo tipo, por lo tanto, aquellos integrantes que lo posean, se deberá tener muy en cuenta su rol secundario para que pueda tener libertad de expresarlo en caso de que no se le su rol principal de forma natural. Además, tienen a enfrentarse con los Impulsores por sus diferentes estilos de gestión.

En los casos que se presentó este rol principal, normalmente los compañeros lo supieron identificar. Además, dentro de todos los roles es aquel que más cantidades de mensajes realizó según el rol de autopercepción.

Colaborador (Social):

Luego, dentro del grupo social, como referente intermedio se encuentran los colaboradores, reconocidos como buenos cooperadores. Se los reconoce por su muestra de relajación o moderación en cada uno de sus comentarios, presente en la conducta IPA 2, donde se muestran expresiones de placer, gusto o felicidad. Como por ejemplo:

¡Este trabajo está resultando realmente bueno!

Esta conducta es en promedio una de las más altas, con una diferencia de presencia de un 30% más en promedio que el resto de las clases, y refleja su continuo apoyo a sus compañeros de grupo, su sociabilidad, y su preocupación por los demás.

Seguido a estas conductas lo caracterizan las conductas IPA 6 y 8, donde la primera conducta es dar información, mientras que la segunda conducta representa la solicitud de opiniones, ligado a los comentarios de su colaboración, como por ejemplo:

¿Creen que este resultado es correcto?

Generalmente participan en las primeras franjas horarias, reflejando su punto débil de que no funcionan bien bajo presión o en situaciones que generan confrontación.

Investigador (Social):

Por último dentro de los grupos sociales, se encuentra el rol con menor presencia, que son los investigadores, este al igual que su rol previo, muestra una identificación con la conducta IPA 2, siendo entre ambos los mayores comunicadores de esta conducta, aunque en su caso no tiene tanto peso, esto puede ser puntualmente por la cantidad de ocurrencias. Esta conducta refleja su característica de extrovertido, entusiasta y comunicativo.

Aquellas conductas más relacionadas con este tipo de rol se encuentran en las conductas IPA 3 y 4, encargadas de demostrar respectivamente acuerdos y sugerencias. Los investigadores suelen generar contactos fuera del grupo, captando ideas de otros y adaptándolas y sugiriendo al grupo en el que participan.

6.1.2 Roles De Acción

Continuando con el grupo intermedio en términos cuánticos de presencia en el conjunto, se encuentran aquellos destinados a la acción. Dentro de estos, tal como se podrá observar en la tabla 6.2, existen varios aspectos en común. Al igual que con la categoría anterior hay un conjunto de conductas que los destaca y diferencia con el resto, ellas son las conductas IPA entre 4-6.

Estas reflejan el área de tareas y reacción de respuestas.

Implementador	Finalizador	Impulsor
Conducta IPA 6	Conducta IPA 6	Conducta IPA 1
Conducta IPA 5	Reacción del Tipo 1	Conducta IPA 4
Conducta IPA 9	Reacción del Tipo 4	Conducta IPA 6
Reacción del tipo 1	Conducta IPA 3	Conducta IPA 3
Conducta IPA 3	Conducta IPA 11	Conducta IPA 2
Conducta IPA 2	Conducta IPA 1	Conducta IPA 5
Conducta IPA 1	Conducta IPA 2	Reacción del tipo 1
Conducta IPA 8	Conducta IPA 8	Conducta IPA 8

Tabla 6.2. Ranking atributos de acción

Implementador(Acción):

Aquellos integrantes con un rol de implementador, se destacaron por sus reacciones en forma de respuesta en cada uno de sus comentarios, y por pedir sugerencias u orientaciones representado por la conducta IPA 9, como por ejemplo:

“¿Y ahora dónde seguimos?”

Donde luego se ve caracterizado por dar opiniones y ofrecer información al resto de los integrantes a través de una combinación de las conductas IPA 5 y 6.

Esto refleja su característica de transformar las ideas en acciones, solicitando sugerencias y adaptando esas ideas en el trabajo, dando respuestas.

Finalizadores (Acción):

Seguido en el mismo conjunto de tipo de rol se encuentran los finalizadores.

Este rol se lo encuentra relacionado principalmente con la conducta IPA 6, que describe aquellos comentarios en los cuales se otorga información sobre el contenido realizado por el grupo y obteniendo así una atención específica del resto de los integrantes del grupo.

Las reacciones en cada uno de sus mensajes también forman parte de una gran descripción de este rol, donde sus comentarios se realizan de forma positiva y en forma de respuesta, reflejando una de sus principales características, ser reacios a delegar. Esto quiere decir que raramente piden sugerencia u orientación, prefieren realizar todas las tareas ellos mismos.

Seguido se encuentra la conducta IPA 3, donde se muestra un acuerdo o aprobación en respuesta a cualquier actividad solicitada por el grupo o respecto a una observación o análisis.

En menor medida pero aun representativa, se encuentra la conducta IPA 11, en la cual se muestra desacuerdo, tensión o molestia, relacionada con su característica negativa de ser intransigentes para pasar por alto los detalles, es decir, no aceptan opiniones cuando se quiere evitar darle importancia a ciertos puntos, llevando su perfeccionismo al extremo.

Este tipo de conducta es importante para identificar los posibles casos de conflicto respecto a los roles con los cual se comparte grupo.

Impulsor (Acción):

Los roles impulsores se caracterizan por su iniciativa, conducción y soslayados ante diferentes obstáculos, y de la siguiente forma lo caracterizan sus conductas.

Sus rasgos principales están dados por su muestra de solidaridad, representado por la conducta IPA 1, donde se demuestra aliento, elogio y apoyo al resto de los integrantes. Seguido se encuentra la conducta IPA 4, que representa los comentarios donde se ofrece sugerencias u orientación al resto de los integrantes.

Ambas conductas se las asocia con el perfil de conducción e iniciativa que este representa.

Seguido a estas se encuentran las conductas IPA 6 y 3 donde se da información y acuerdo de lo que sucede, lo cual también refleja su principal característica de conducción.

En los datos analizados sobre este dataset, no se observan que sobresalgan conductas o reacciones negativas, es decir no hubo casos en el que los impulsores hirieron sentimientos de los demás o provocaron a alguien, el cual es uno de sus puntos débiles. Igualmente, se detectaron pocos impulsores en los grupos analizados, existiendo pocas probabilidades de conductas negativas.

6.1.3 Roles Mentales

Como última categoría se encuentran los Mentales, grupo minoritario, aunque aun así permite obtener características determinadas que lo diferencian del resto, como la presencia de las Conductas IPA distribuidas entre los dos últimos grupos, entre las conductas IPA 7-12. Si bien se destaca también la conducta 3, se resaltan los dos últimos grupos de conducta ya que el resto de categorías no tiene semejante presencia, lo cual hace más identificable a este tipo de rol. Estas conductas son de áreas de Tarea y Socio Emocionales, con una reacción de pregunta y negativa respectivamente, como se presenta en la Tabla 6.3

Cerebro	Especialista	Monitor
Conducta IPA 3	Conducta IPA 10	Reacción del tipo 4

Conducta IPA 6	Conducta IPA 3	Conducta IPA 3
Reacción del tipo 1	Conducta IPA 5	Conducta IPA 9
Reacción del tipo 4	Conducta IPA 9	Reacción del tipo 1
Conducta IPA 5	Conducta IPA 6	Conducta IPA 6
Conducta IPA 10	Conducta IPA 2	Conducta IPA 5
Conducta IPA 11	Reacción del tipo 1	Conducta IPA 1
Reacción del tipo 3	Reacción del tipo 3	Conducta IPA 2

Tabla 6.3. Ranking atributos mentales

Cerebro (Mentales):

El cerebro al ser un rol mental, la conducta que más lo diferencia es la IPA 5, donde su forma de expresarse es a través de opiniones con reacciones positivas y de respuesta. Un ejemplo que lo respalda, sería del siguiente tipo:

“Creo que está bien ya que el Teorema de Thales nos respalda”.

Donde cumple con todas las características identificadas en el rol, de dar información en una respuesta sumado a una aprobación. Esto es una característica esencial ya que su propósito es generar ideas y además posee ese librepensador que se expresa a partir de opiniones.

Por otra parte se observa la presencia de conductas IPA 10, las cuales se tratan de mostrar desacuerdo u orientación. Esto refleja su dificultad para comunicarse, debido a su individualismo y su distancia que generan con los otros miembros del grupo.

Especialista (Mentales):

El especialista suele aportar sus conocimientos claves a partir de sus muestras de acuerdo y desacuerdo, reflejado especialmente en las conductas IPA 3 y 10 respectivamente. La primera de estas conductas, ya mencionada anteriormente, refleja comentarios del siguiente estilo:

“Si. Concuero contigo”

La conducta 10 refleja su característica de falta de interés por los demás, centrándose en su propio progreso y actividad, lo cual puede generar conflictos en el grupo.

Además se detecta una muestra de opiniones dadas por las conductas IPA 5, la cual sumada a la conducta 3, permite detectar la característica principal de este rol, aportar habilidades y conocimientos.

Monitor (Mentales):

El rol de monitor es reconocido principalmente por sus reacciones de respuestas combinado con conductas de sugerencias u orientación y muestras de acuerdo o aprobación, contribuidas a las

conductas IPA 9 y 3. Según las reacciones que se aprecian en su comportamiento suele mostrar reacciones positivas acorde a sus conductas.

Aun así la presencia de las conductas de respuestas como las IPA 5 y 6, reflejan su característica de evaluador, donde evalúan las ideas y sugerencias que reciben, dando muy buenos consejos.

En este caso no se detectaron conductas negativas, por lo que se puede observar que los Monitores detectados no fueron excesivamente críticos acerca de lo que realizaban sus compañeros.

6.2. Resultados de experimentación con técnicas de aprendizaje de máquina

Debido a que el tipo de aprendizaje automático utilizado en este trabajo es de tipo supervisado, se contaba con un conjunto de datos previamente etiquetado, es decir, se tenía un conjunto de muestra, el cual ya se sabía a qué valor de clase pertenece cada registro. Por esto, comparando el resultado de las clasificaciones hechas sobre este dataset, con los valores originales que contenía el mismo, se realizó la primer experimentación, obteniendo un conjunto de precisiones.

En esta sección se van a presentar los resultados obtenidos de los distintos clasificadores, poniendo foco en aquellos que mejor precisión lograron. Se va a realizar un análisis general, y luego se los va a analizar individualmente explicando las causas de su resultado.

Los principales aspectos a tener en cuenta son la precisión y recall. Antes de definirlos, se deben dar a conocer algunos conceptos, que forman parte de su estructura:

- **True Positives (TP)** para la clase C: son instancias pertenecientes a la clase C que se clasifican correctamente en la clase C.
- **True Negatives (TN)** para la clase C: son instancias no pertenecientes a la clase C y que no se clasifican como clase C.
- **False Positives (FP)** para la clase C: son instancias no pertenecientes a la clase C pero que se clasifican como clase C.
- **False Negatives (FN)** para la clase C: son instancias pertenecientes a la clase C pero que no se clasifican como clase C.

Una vez definidos estos conceptos, la precision y recall se calculan de la siguiente manera:

- Precisión para la clase C: es un valor entre 0 y 1. Su valor aumenta cuando hay pocos falsos positivos. Mide que las instancias clasificadas como clase C sean realmente de la clase C, aunque haya instancias de la clase C que se clasifiquen como otra clase.

$$P(C) = TP / (TP + FP)$$

- Recall para la clase C: es un valor entre 0 y 1. Su valor aumenta cuando hay pocos falsos negativos. Mide que las instancias de la clase C se clasifiquen como clase C, aunque otras instancias también se clasifiquen como clase C sin serlo.

$$R(C) = TP / (TP + FN)$$

Para graficar estos conceptos, se presentan las figuras 6.5 y 6.6:




Figura 6.5. Dominio de datos



Figura 6.6. Precisión/recall dentro del dominio

6.2.1 Análisis general clasificadores

En este capítulo se describen los resultados de las pruebas realizadas sobre los enfoques propuestos en la sección 3 (Enfoques Propuestos) dentro del capítulo 3, “Solución Propuesta”, y se analiza el desempeño general. Además, se compara los resultados obtenidos en la solución final, con los resultados obtenidos anteriormente en otros enfoques, donde no se logró buena precisión.

Previo a las clasificaciones realizadas, ya sea directa o por fases, se realiza parte de la clasificación de conductas IPA[ref. mineo], donde a partir de estas se obtienen nuevos atributos que permiten el realizamiento de las fases consiguientes. A partir del resultado de las mismas, también, desencadena parte de la performance de los siguientes clasificadores. Este efecto, obviamente, sucederá con cada fase posterior.

Se probaron diferentes algoritmos de clasificación, utilizando 10-fold cross validation sobre el conjunto de datos de entrenamiento. En un principio, se clasificaron los datasets sin aplicar ningún

procesamiento, siguiendo los pasos explicados en la sección anterior. La Tabla 6.4 muestra la precisión obtenida de los principales clasificadores utilizados en el procesamiento directo, tanto en el contexto de grupos como el general, con el rol autopercebido.

Clasificador	Kstar	SMO	Bayes net	LMT
General	30.62%	32.65%	23.80%	24.53%
Grupos	18.63%	19.55%	21.21%	16.05%

Tabla 6.4. Precisión de diferentes clasificadores en procesamiento directo

Como se observa, con estos datasets y sin preprocesamiento, las precisiones obtenidas son bajas. La principal razón es que las features no logran ser lo suficientemente descriptivas del conjunto de datos, provocando en fin, que no se encuentre una correlación entre ellas y obteniendo así una muy mala clasificación.

Además, como se presentó anteriormente, existe un desbalance de las clases, que produce que aquellas que presentan más repeticiones tengan mayor peso para el clasificador al momento de decidir. Entonces, si un clasificador debe decidir entre dos valores de una clase, siempre se va a inclinar por el que presente mayores apariciones, ya que tiene más probabilidad de acierto.

A su vez, se observa un menor porcentaje de precisión al momento de clasificar el dataset de grupos, ya que los clasificadores se inclinan preferentemente por los roles Coordinador e Implementador debido a que son los que más ocurrencias presentan, como se puede observar en la Figura 6.7.




Figura 6.7. Distribución de rol percibido por compañeros

Este mismo comportamiento, se vió reflejado también en los clasificadores entrenados para el procesamiento en fases. En la Tabla 6.5 y 6.6, se presentan las precisiones obtenidas por los clasificadores de la fase 2 y 3 respectivamente.

Clasificador	Kstar	SMO	Bayes net	LMT
General	48.69%	50.55%	39.36%	42.72%
Grupos	41.88%	42.98%	43.54%	40.22%

Tabla 6.5. Precisión de diferentes clasificadores en procesamiento Fase 2.

La Fase 3 aumenta levemente la precisión ya que los clasificadores tienen que filtrar solo entre tres valores de clase, ya que se cuenta con el Tipo de Rol calculado anteriormente, por lo que solo tiene que decidir entre los tres roles pertenecientes al conjunto en cuestión.

Clasificador	Kstar	SMO	Bayes net	LMT
General	55.22%	59.14%	53.35%	55.22%
Grupos	47.97%	49.44%	42.61%	40.03%

Tabla 6.6. Precisión de diferentes clasificadores en procesamiento Fase 3.

En esta fase, a pesar de lo mencionado, sigue existiendo en su mayoría el problema del desbalance de repeticiones, que hace que los clasificadores elijan aquellos de mayor ocurrencia.

En el enfoque propuesto, para mejorar las precisiones obtenidas hasta el momento, se realizó un pre procesamiento de los datos donde se incluye un filtro de Weka llamado Resample. Este filtro permite hacer un nuevo muestreo del conjunto de datos originales para un balanceo de clases, agregando instancias de la clase que tiene pocas ocurrencias varias veces para el conjunto de datos de resultados. Con esto se logra un mayor peso para aquellos valores de clase que menos presentan. Aun así se aplicaron varios filtros sobre las variables para que estas trabajen mejor de forma conjunta con los distintos clasificadores, tales como discretizados y normalizadores que permiten a los valores tender a valores entre 0 y 1, o dividirlos por franjas a aquellos valores numéricos. En fin, todos los filtros aplicados sufrieron la misma cantidad de test, y si los mismos obtenían menor rendimiento que los anteriores eran retirados del proceso.

Las Tablas 6.7 y 6.8 muestra la precisión obtenida luego de aplicar los filtros, comparadas con las obtenidas anteriormente para el procesamiento directo.

Clasificador	Kstar	SMO	Bayes net	LMT
Sin resample	30.62%	32.65%	23.80%	24.53%
Con resample	67.15%	46.31%	31.18%	66.97%

Tabla 6.7. Precisión de clasificadores con resample en procesamiento directo general.

Clasificador	Kstar	SMO	Bayes net	LMT
--------------	-------	-----	-----------	-----

Sin resample	18.63%	19.55%	21.21%	16.05%
Con resample	62.73%	31.73%	28.59%	65.12%

Tabla 6.8. Precisión de clasificadores con resample en procesamiento directo por grupos.

Como se puede observar, se logró una mejora notoria en la precisión de todos los clasificadores tanto en el procesamiento general, como en el de grupos, debido a que los roles que presentaban menor peso lograron ganarlo gracias a esta técnica. Los clasificadores entonces, al momento de decidir entre dos valores, ya no se inclinan por los que más ocurrencias tienen ya que las mismas se igualaron.

Por esta misma razón, los clasificadores de fases también mejoraron sus precisiones. En las Tablas 6.9 y 6.10 se presentan las mejoras observadas en la fase 2.

Clasificador	Kstar	SMO	Bayes net	LMT
Sin resample	48.69%	50.55%	39.36%	42.72%
Con resample	71.08%	50.18%	45.33%	73.69%

Tabla 6.9. Precisión de clasificadores con resample en procesamiento general Fase 2.

Clasificador	Kstar	SMO	Bayes net	LMT
Sin resample	41.88%	42.98%	43.54%	40.22%
Con resample	70.66%	48.15%	43.35%	73.80%

Tabla 6.10. Precisión de clasificadores con resample en procesamiento por grupo Fase 2.

En este caso se puede observar que mejoraron todos los clasificadores excepto Bayes Net en el procesamiento por grupo, que no varió con respecto a su anterior precisión en el caso del procesamiento por grupo.

Por último, en las Tablas 6.11 y 6.12 se presentan los resultados de la Fase 3 aplicando resample.

Clasificador	Kstar	SMO	Bayes net	LMT
Sin resample	55.22%	59.14%	53.35%	55.22%
Con resample	78.73%	65.29%	61.38%	71.08%

Tabla 6.11. Precisión de clasificadores con resample en procesamiento general Fase 3.

Clasificador	Kstar	SMO	Bayes net	LMT
Sin resample	47.97%	49.44%	42.61%	40.03%
Con resample	71.77%	55.71%	51.66%	72.14%

Tabla 6.12. Precisión de clasificadores con resample en procesamiento por grupos Fase 3.

Un comportamiento general que se puede observar es que los clasificadores que más aumentaron su precisión son aquellos del tipo Árbol (J48 o LMT), los cuales utilizan la técnica de árbol de decisión. Esto se da debido a que se basan en probabilidades, por lo que en un principio obtenían mayoritariamente el atributo con más ocurrencias, ya que era el que más probabilidades presentaba. Luego con el balanceo de clases, se balancean también las probabilidades de los distintos valores.

Como último enfoque dentro del proceso de clasificaciones, se encuentra la independización de tipos de roles, donde el clasificador solo trabaja con un máximo de tres roles del mismo tipo. De esta forma se esperan mejores resultados, ya que debería haber menos confusión a la hora de clasificar.

Para ello se promedió el resultado del clasificador en cada una de las instancias que clasificó a los roles de un mismo tipo.

Clasificador	Kstar	SMO	Bayes net	LMT
Sin resample	55.57%	65.40%	63.72%	62.33%
Con resample	80.14%	79.96%	68.47%	79.74%

Tabla 6.13. Precisión de clasificadores con resample por tipos en procesamiento general Fase 3.

Clasificador	Kstar	SMO	Bayes net	LMT
Sin resample	46.43%	54.04%	46.45%	50.67%
Con resample	69.21%	62.77%	56.89%	75.59%

Tabla 6.14. Precisión de clasificadores con resample por tipos en procesamiento por grupos Fase 3.

Como se puede observar en ambos casos, ya sea por grupos o general, se obtuvo resultados más performantes a los ya obtenidos. Esto comprueba de que esta independización de los roles y los clasificadores en un dominio más acotado les permite discernir con mayor performance que los clasificadores de los enfoques anteriores.

A continuación se presentan la actuación individual de cada uno de los clasificadores que lograron la mayor precisión a la hora de clasificar a qué clase pertenece un determinado conjunto de datos. Para ello se propuso indicar las diferentes columnas TP Rate, FP Rate, Precision, Recall, F-Measure, MCC, ROC Area y RPC Area. Si bien cada una de estas columnas representa valiosa información acerca de las decisiones tomadas, el análisis se centrará principalmente en la Precisión, el Recall y F-

Measure, ya que se considera, en conjunto a la matriz de confusión, que se da de forma sencilla y rápida un paneo general acerca de los resultados.

Este análisis en profundidad se realizará únicamente en aquellos clasificadores cuyo modelo fue el más exitoso, mientras que con los modelos clasificadores restantes solo se ilustrara los resultados obtenidos.

6.2.2 Análisis individual clasificadores entrenamiento directo

En las siguientes tablas se encuentran detallados los detalles de las clasificaciones iniciales. Como se puede observar, los resultados si bien poseen una precisión baja, al ser directos y sin ningún tipo de aplicaciones de filtro sobre los datos, apenas reflejan de que existen ciertas correlación entre los datos. Debido a esto, se finalizó de detectar que las variables seleccionadas para representar el modelo debían mejorarse, con el objetivo de obtener mejores resultados.

Como primer algoritmo a presentar se encuentra el SMO, el cual obtuvo alrededor de un 6% de asertividad mayor que el promedio de los clasificadores y un 2% del siguiente mejor clasificador, el K-Star. Este algoritmo dentro de la librería se encuentra implementado para utilizar con conjuntos de datos multiclase, resolviendo cada clase como 1-vs-1, más conocido como “*clasificación pairwise*”, como puede analizarse en la Figura 6.8.




Figura 6.8. Clasificación pairwise

De esta forma el algoritmo separa las diferentes clases y realiza a qué clase pertenece cada caso. Donde para calcular esta clasificación utiliza el método estadístico de acoplamiento de *Hastie y Tibshirani*, obteniendo los siguientes resultados presentados en la Tabla 6.13:

TP Rate	FP Rate	Precisión	Recall	F-Measure	MCC	ROC Area	PRC Área	Clase
0,000	0,015	0,000	0,000	0,000	-0,045	0,551	0,154	Finalizador
0,000	0,000	0,000	0,000	0,000	0,000	0,575	0,030	Impulsor
0,129	0,061	0,237	0,129	0,167	0,088	0,604	0,173	Cerebro
0,613	0,312	0,323	0,613	0,423	0,247	0,671	0,289	Colaborador
0,305	0,062	0,375	0,305	0,336	0,266	0,689	0,223	Especialista
0,352	0,107	0,268	0,352	0,304	0,218	0,708	0,200	Implementador

0,000	0,004	0,000	0,000	0,000	-0,018	0,710	0,149	Monitor
0,000	0,000	0,000	0,000	0,000	0,000	0,552	0,041	Investigador
0,606	0,252	0,377	0,606	0,465	0,303	0,700	0,332	Coordinador
0,327	0,139	0,237	0,327	0,265	0,164	0,656	0,225	Avg.

Tabla 6.13. Clasificador SMO Autopercepción Directo

Como se puede ver al igual que el porcentaje de clasificación los resultados obtenidos a partir de las mediciones también son bajos, ya que están altamente relacionados con el proceso y resultados de selección del clasificador.

Aun así, aquel valor que resalta respecto al resto es el ROC Area, en los casos como por ejemplo el coordinador donde fue una clase con mayor acierto que el resto, dado en parte a la cantidad de casos que posee. En la Figura 6.9 se presenta una vista el Treshold de esta clase.




Figura 6.9. Treshold de la clase Coordinador (ROC = 0,7)

Prosiguiendo con los resultados obtenidos por el clasificador, dentro de la matriz de confusión de la Tabla 6.14 se puede observar reflejado la precisión, el recall y F-Measure obtenido anteriormente. Más precisamente las clases de Finalizador, Impulsor, Monitor e Investigador que obtuvieron 0% de instancias acertadas. Las clases de Colaborador y Coordinador por su parte obtuvieron la mayor de las clasificaciones, dado a su peso por cantidad de instancias en el conjunto de datos.

a	b	c	d	e	f	g	h	i	Clase
0	0	4	34	7	9	0	0	20	a = Finalizador
0	0	1	2	1	6	0	0	3	b = Impulsor
1	0	9	32	8	7	0	0	13	c = Cerebro
3	0	8	65	4	4	0	0	22	d = Colaborador
2	0	2	24	18	1	0	0	12	e = Especialista
0	0	0	9	3	19	0	0	23	f = Implementador
0	0	8	12	2	12	0	0	11	g = Monitor

1	0	0	5	0	1	0	0	5	h = Investigador
0	0	6	18	5	12	2	0	66	i = Coordinador

Tabla 6.14. Matriz de confusión de la tabla 6.13

En el caso de la percepción por grupos se observa información totalmente diferente a la anterior, debido principalmente a que el algoritmo utilizado es de un tipo diferente, Red de Bayes. Este algoritmo se encuentra implementado con algoritmo de búsqueda local y estimadores provistos por Weka. Los resultados son ampliamente nulos excepto por dos clases que son el Implementador y Coordinador, nuevamente las clases mayoritarias desviando los resultados del resto de las clases, como se presenta en la Tabla 6.15.

TP Rate	FP Rate	Precisión	Recall	F-Measure	MCC	ROC Area	PRC Área	Clase
0,000	0,000	0,000	0,000	0,000	0,000	0,522	0,132	Finalizador
0,000	0,000	0,000	0,000	0,000	0,000	0,459	0,085	Impulsor
0,000	0,000	0,000	0,000	0,000	0,000	0,487	0,055	Cerebro
0,000	0,000	0,000	0,000	0,000	0,000	0,454	0,081	Colaborador
0,000	0,000	0,000	0,000	0,000	0,000	0,510	0,105	Especialista
0,947	0,915	0,180	0,947	0,303	0,046	0,503	0,171	Implementador
0,000	0,000	0,000	0,000	0,000	0,000	0,494	0,122	Monitor
0,000	0,002	0,000	0,000	0,000	-0,009	0,496	0,042	Investigador
0,255	0,038	0,595	0,255	0,357	0,312	0,576	0,348	Coordinador
0,212	0,167	0,139	0,212	0,118	0,064	0,509	0,156	Avg.

Tabla 6.15. Clasificador Bayes-Net Autopercepción por Grupos Directo

En la matriz de confusión de la Tabla 6.16 se puede observar como claramente todos los casos impactan únicamente en los Coordinadores e Implementadores, y un único caso donde un Impulsor fue confundido con un Investigador. He aquí el 0,002 de porcentaje en Falsos Positivos de esta clase.

a	b	c	d	e	f	g	h	i	Clase
0	0	0	0	0	69	0	0	1	a = Finalizador
0	0	0	0	0	47	0	1	3	b = Impulsor
0	0	0	0	0	32	0	0	0	c = Cerebro
0	0	0	0	0	43	0	0	5	d = Colaborador
0	0	0	0	0	57	0	0	0	e = Especialista
0	0	0	0	0	90	0	0	5	f = Implementador
0	0	0	0	0	65	0	0	3	g = Monitor
0	0	0	0	0	23	0	0	0	h = Investigador
0	0	0	0	0	73	0	0	25	i = Coordinador

Tabla 6.16. Matriz de confusión de la tabla 6.15

6.2.3 Análisis individual clasificadores entrenamiento fases

Retomando a lo que son las clasificación por fases, estas tienden a lucir más prometedoras. Si bien en este caso principalmente dependen de tan solo tres clases, esto ayuda a mejorar la performance del clasificador notablemente. Dado al tener un dominio mucho menor, el clasificador pasa de tener que seleccionar entre nueve clases a tan solo tres, haciendo así su tarea mucho más sencilla, ya que lo más posible es que estas clases difieran mucho más entre ellas.

Aunque no son el resultado definitivo del clasificador, el resultado final de la 3era fase en la categorización de las clases dependerá también de la precisión con la que se realice este proceso de clasificación de 2da Fase. Por lo tanto mucho de los resultados obtenidos aquí pueden verse posiblemente arrastrados hacia la siguiente fase.

Para comenzar, se va a analizar la precisión del clasificador SMO, presentado en la Tabla 6.17.

TP Rate	FP Rate	Precisión	Recall	F-Measure	MCC	ROC Area	PRC Area	Clase
0,819	0,590	0,493	0,819	0,616	0,242	0,612	0,481	Social
0,402	0,163	0,543	0,402	0,462	0,262	0,618	0,425	Mental
0,142	0,051	0,500	0,142	0,221	0,153	0,588	0,321	Acción
0,506	0,310	0,511	0,506	0,462	0,225	0,607	0,421	Avg.

Tabla 6.17. Clasificador 2da Fase SMO Autopercepción

Nuevamente se nota una mejora en la distribución de las clases, aunque el rol Social, obtiene la mayor de las clasificaciones a su favor.

Social	Mental	Acción	Clase
181	28	12	Social
96	70	8	Mental
90	31	20	Acción

Tabla 6.18. Matriz de confusión de la tabla 6.17

La percepción de los grupos llevó a que el clasificador por Bayes Net no reconozca a ninguna instancia como clase de aquellos con un rol mental, distribuyendo sus clasificaciones al par restante.

TP Rate	FP Rate	Precisión	Recall	F-Measure	MCC	ROC Area	PRC Area	Clase
0,172	0,040	0,659	0,172	0,272	0,223	0,546	0,431	Social
0,000	0,000	0,000	0,000	0,000	0,000	0,518	0,295	Mental
0,958	0,893	0,416	0,958	0,580	0,118	0,510	0,396	Acción
0,435	0,368	0,371	0,435	0,316	0,116	0,524	0,378	Avg.

Tabla 6.19. Clasificador 2da Fase BayesNet Autopercepción por Grupos

En el caso de la percepción obtenida por los grupos se puede observar que el rol social obtiene la mayoría de las clasificaciones a comparación de aquellos por autopercepción. Esto se debe principalmente a que lo percibido por los compañeros no siempre es lo mismo que uno se autopercebe, ya sea porque es otra visión o por el contexto en el que se desarrolla la actividad.

Social	Mental	Acción	Clase
29	0	140	Social
6	0	151	Mental
9	0	207	Acción

Tabla 6.20. Matriz de confusión de la tabla 6.19

Como tabla final en la clasificación sin filtros y por fases se presenta la Tabla 6.21, donde se muestra que se obtienen mucho mejores resultados que los anteriores y se puede detectar que el algoritmo de SMO presenta buena precisión en esta etapa de clasificación, mejorando en casi todos los aspectos a comparación de los resultados obtenidos en la clasificación directa. A pesar de esto, el rol de Impulsor continúa siendo una clase difícil de detectar y fácilmente confundible.

TP Rate	FP Rate	Precisión	Recall	F-Measure	MCC	ROC Area	PRC Area	Clase
0,635	0,050	0,671	0,635	0,653	0,599	0,950	0,622	Finalizador
0,000	0,000	0,000	0,000	0,000	0,000	0,873	0,092	Impulsor
0,486	0,099	0,425	0,486	0,453	0,366	0,887	0,399	Cerebro
0,698	0,063	0,733	0,698	0,715	0,647	0,928	0,656	Colaborador
0,542	0,059	0,533	0,542	0,538	0,480	0,930	0,487	Especialista
0,630	0,077	0,479	0,630	0,544	0,491	0,928	0,443	Implementador
0,311	0,041	0,412	0,311	0,354	0,308	0,916	0,367	Monitor
0,000	0,000	0,000	0,000	0,000	0,000	0,801	0,054	Investigador
0,796	0,088	0,683	0,796	0,735	0,670	0,928	0,639	Coordinador
0,591	0,067	0,566	0,591	0,576	0,515	0,921	0,523	Avg.

Tabla 6.21. Clasificador 3ra Fase SMO Auto percepción

Más concretamente dentro de la matriz de confusión de la Tabla 6.22 se observa que los únicos Impulsores que se encontraban en el dataset fueron confundidos por Implementadores, al igual que gran parte de los Finalizadores. Aun así en la diagonal se observa una buena distribución y acierto de las clases, dando una señal positiva del camino en la clasificación por fases.

a	b	c	d	e	f	g	h	i	Clase
47	0	0	0	0	27	0	0	0	a = Finalizador
3	0	0	0	0	10	0	0	0	b = Impulsor
0	0	34	0	21	0	15	0	0	c = Cerebro
0	0	0	74	0	0	0	0	32	d = Colaborador
0	0	22	0	32	0	5	0	0	e = Especialista
20	0	0	0	0	34	0	0	0	f = Implementador
0	0	24	0	7	0	14	0	0	g = Monitor

0	0	0	6	0	0	0	0	6	h = Investigador
0	0	0	21	0	0	0	0	82	i = Coordinador

Tabla 6.22. Matriz de confusión de la tabla 6.20

Continuando con la última tabla en este proceso de clasificación se encuentra la autopercepción por grupos (Tabla 6.23), notando nuevamente que varias clases no percibieron ningún tipo de clasificación correcta al igual que la clasificación del algoritmo SMO en los roles de autopercepción. En este caso no se obtuvo ninguna instancia clasificada como Finalizadores, Impulsores y Cerebros, mientras que en la autopercepción sucede con los Impulsores y Investigadores. Si bien no son exactamente los mismos roles, ya que las percepciones de los usuarios fueron distintas, lo que se destaca es el comportamiento similar del algoritmo en ambos casos, dejando valores de clase totalmente excluidos en el proceso de clasificación.

TP Rate	FP Rate	Precisión	Recall	F-Measure	MCC	ROC Area	PRC Area	Clase
0,000	0,006	0,000	0,000	0,000	-0,029	0,840	0,321	Finalizador
0,000	0,000	0,000	0,000	0,000	0,000	0,831	0,236	Impulsor
0,000	0,000	0,000	0,000	0,000	0,000	0,880	0,213	Cerebro
0,083	0,024	0,250	0,083	0,125	0,099	0,876	0,281	Colaborador
0,509	0,066	0,475	0,509	0,492	0,430	0,916	0,419	Especialista
0,979	0,268	0,437	0,979	0,604	0,553	0,863	0,437	Implementador
0,721	0,099	0,510	0,721	0,598	0,539	0,924	0,489	Monitor
0,000	0,000	0,000	0,000	0,000	0,000	0,859	0,136	Investigador
0,949	0,135	0,608	0,949	0,741	0,696	0,928	0,606	Coordinador
0,494	0,094	0,323	0,494	0,378	0,341	0,884	0,399	Avg.

Tabla 6.23. Clasificador 3ra Fase SMO por Grupos

Nuevamente los Impulsores fueron confundidos por el clasificador por los Implementadores, al igual que en la clasificación por autopercepción individual, esto se puede ver relacionada a que ambos roles presentan características similares, y es difícil para el algoritmo desasociar entre ellos. Por lo tanto, será necesario que estas clases minoritarias ganen mayor peso para lograr esta diferenciación. Aun así se sigue presentando cierta diagonal aunque de mucho menor performance respecto a su competidora por fases, reflejados en el resultado final de performance en precisión de los clasificadores.

a	b	c	d	e	f	g	h	i	Clase
0	0	0	0	0	70	0	0	0	a = Finalizador
1	0	0	0	0	50	0	0	0	b = Impulsor
0	0	0	0	13	0	19	0	0	c = Cerebro
0	0	0	4	0	0	0	0	44	d = Colaborador
0	0	0	0	29	0	28	0	0	e = Especialista

2	0	0	0	0	93	0	0	0	f = Implementador
0	0	0	0	19	0	49	0	0	g = Monitor
0	0	0	0	7	0	0	0	16	h = Investigador
0	0	0	0	5	0	0	0	96	i = Coordinador

Tabla 6.24. Matriz de confusión de la tabla 6.23

Resumen de análisis individual de los clasificadores

En resumen a los algoritmos y tablas analizadas, si bien en promedio las precisiones no fueron óptimas, se logró obtener ciertos resultados que permitieron indicar distintos puntos a atacar para mejorarlos, como por ejemplo el esperado desbalance de clases. Por parte de los algoritmos, sólo se mostraron aquellos basados en Bayes, o funciones logísticas (SMO), dejando de lado a los algoritmos de árboles, como el J48 o LMT, o aquellos basados en reglas, como por ejemplo JRIP.

Una vez finalizado el análisis de toda la información sobre la primera etapa, donde todavía no se aplicó ningún tipo de filtro a los datos, continuaremos con un nuevo conjunto de datos y nuevos algoritmos, ya que la alteración de la información resaltó la performance de variados clasificadores que antes no habían obtenido el mayor porcentaje de clasificaciones correctas.

6.2.3 Análisis individual clasificadores con filtros entrenamiento directo

Comenzando con el nuevo proceso de clasificación, nos encontramos con un nuevo algoritmo ganador, el K-Star. Este algoritmo es un clasificador basado en instancias, donde la clase de rol con la que se va a clasificar a la instancia, se obtiene a partir de la similitud de ella con todas las clases de roles. Para ello se compara con ejemplos anteriormente clasificados correctamente provenientes del conjunto de datos de entrenamiento. Luego la función de medición se basa en la entropía.

A primera vista lo que se puede observar es que todos los valores obtenidos a partir de la información de la clasificación han mejorado un 205% en promedio cada una de las columnas a comparación a la tabla de esta misma instancia pero sin las nuevas características agregadas a la información, lo cual todos los filtros aplicados han ayudado potencialmente a mejorar la solución de nuestro problema, otorgando mayor información sobre los datos a diferencia de los valores crudos.

Como se puede observar a partir del Recall y la Precisión, se obtuvieron buenos resultados, aunque lo preferible es basarse en el F-Measure, ya que otorga un valor más limpio de estas dos características mencionadas sobre aquellas clases que se desempeñaron mejor y luego visualizar el TP/FP Rate correspondiente.

Específicamente los Colaboradores y Especialistas obtuvieron el mejor desempeño en lo que abarca a clasificación, cabe recordar que estos dos roles suman un total de casi un tercio del conjunto de datos disponibles. Aun así entre estos existe una ligera diferencia, ya que aunque el F-Measure es similar, los Colaboradores obtuvieron mayor Precisión y menor Recall respecto a los Especialistas.

Esto quiere decir que de la cantidad de verdaderos positivos que seleccionó en su total había tan solo un 21% de falsos positivos. Un número que si bien es bueno se quisiera que sea un promedio en todas las clases de roles y no únicamente en una. Por otra parte, para los Especialistas, se obtuvo un valor similar pero con el Recall, donde fue la mayor clase en obtener este resultado, esto quiere

decir que de todos los Especialistas posibles, un 77% fue elegido correctamente. Estos resultados están reflejados en la tabla 6.25.

TP Rate	FP Rate	Precisión	Recall	F-Measure	MCC	ROC Area	PRC Area	Clase
0,639	0,051	0,657	0,639	0,648	0,595	0,828	0,555	Finalizador
0,571	0,006	0,571	0,571	0,571	0,566	0,704	0,579	Impulsor
0,597	0,056	0,639	0,597	0,617	0,557	0,814	0,545	Cerebro
0,690	0,049	0,788	0,690	0,736	0,674	0,832	0,719	Colaborador
0,773	0,060	0,674	0,773	0,720	0,674	0,876	0,666	Especialista
0,724	0,054	0,618	0,724	0,667	0,626	0,870	0,533	Implementador
0,610	0,024	0,676	0,610	0,641	0,614	0,835	0,528	Monitor
0,615	0,011	0,571	0,615	0,593	0,583	0,959	0,696	Investigador
0,663	0,070	0,640	0,663	0,651	0,584	0,826	0,619	Coordinador
0,672	0,052	0,676	0,672	0,672	0,619	0,840	0,613	Avg.

Tabla 6.25. Clasificador directo K-Star con Filtros y Autopercepción

Como se puede observar, los resultados de las clases más chicas mejoro mucho más respecto a los resultados sin filtros, donde absolutamente todos los Impulsores estaban correctamente asignados, mientras que en estos nuevos datos podemos observar de que aunque el conjunto de datos es chico, se pudo obtener un gran porcentaje de precisión.

a	b	c	d	e	f	g	h	i	Clase
46	0	2	5	7	4	1	1	6	a = Finalizador
0	4	0	1	1	0	0	0	1	b = Impulsor
7	1	46	3	7	4	4	1	4	c = Cerebro
5	0	6	78	3	7	2	2	10	d = Colaborador
3	0	3	2	58	2	2	0	5	e = Especialista
3	2	2	3	4	42	0	0	2	f = Implementador
1	0	3	2	1	4	25	1	4	g = Monitor
0	0	3	1	1	0	0	8	0	h = Investigador
5	0	7	4	4	5	3	1	57	i = Coordinador

Tabla 6.26. Matriz de confusión de la tabla 6.25

Para esta nueva muestra de clasificación se utilizó el algoritmo LMT (Logistic model trees), el cual es un árbol de clasificación con funciones de regresión logística en sus hojas. El algoritmo propiamente puede trabajar con multi-clases, variables numéricas y nominal, como también con valores ausentes.

Tanto en la inferencia de grupos como en la autopercepción, nuevamente los filtros resaltan su presencia mejorando los resultados obtenidos, aunque aún así hay clases como los Colaboradores que tienen una actuación bastante pobre la cual hace bajar en promedio el resultado general, como se muestra en la Tabla 6.27.

TP Rate	FP Rate	Precisión	Recall	F-Measure	MCC	ROC Area	PRC Area	Clase
0,654	0,041	0,736	0,654	0,693	0,644	0,771	0,521	Finalizador
0,558	0,031	0,659	0,558	0,604	0,568	0,774	0,466	Impulsor
0,686	0,030	0,615	0,686	0,649	0,624	0,794	0,404	Cerebro
0,426	0,038	0,513	0,426	0,465	0,422	0,687	0,310	Colaborador
0,604	0,047	0,558	0,604	0,580	0,538	0,779	0,373	Especialista
0,755	0,092	0,643	0,755	0,695	0,624	0,815	0,547	Implementador
0,672	0,036	0,726	0,672	0,698	0,658	0,851	0,589	Monitor
0,619	0,004	0,867	0,619	0,722	0,724	0,775	0,542	Investigador
0,710	0,085	0,635	0,710	0,670	0,598	0,831	0,523	Coordinador
0,651	0,054	0,655	0,651	0,650	0,600	0,794	0,491	Avg.

Tabla 6.27. Clasificador directo LMT con Filtros por Grupos

Como se puede observar hay una buena distribución de los datos, donde a pesar de haber un clasificador de árboles, donde la tendencia es hacia las clases mayoritarias, aquí las clasificaciones se encuentran distribuidas dentro de todos los valores de roles, lo cual representa un avance positivo, ya que en el caso de que se optara por este modelo para clasificar las instancias futuras, si bien el algoritmo se equivocaría, no se equivocaría siempre con la misma clase, permitiendo mejoras más detalladas. La matriz de confusión de la Tabla 6.28 refleja este comportamiento.

a	b	c	d	e	f	g	h	i	Clase
53	3	1	0	9	5	3	0	7	a = Finalizador
1	29	1	7	4	7	0	0	3	b = Impulsor
2	1	24	1	3	0	2	0	2	c = Cerebro
0	3	1	20	2	9	1	0	11	d = Colaborador
2	1	2	2	29	5	1	2	4	e = Especialista
6	1	3	4	0	74	4	0	6	f = Implementador
3	1	5	2	2	4	45	0	5	g = Monitor
1	2	1	1	0	1	2	13	0	h = Investigador
4	3	1	2	3	10	4	0	66	i = Coordinador

Tabla 6.28. Matriz de confusión de la tabla 6.27

6.2.4 Análisis individual clasificadores con filtros entrenamiento fases

En el caso de la segunda fase con filtros nuevamente LMT obtuvo el mayor rendimiento. Además se pudo observar en la Tabla 6.29 que la Precisión y Recall dieron justamente el mismo porcentaje en promedio, lo que quizás para algunos sea muy difícil obtener.

De entre todos las clases, los roles de tipo acción tuvieron el menor promedio de performance, lo cual puede ser un detalle para la clasificación de la siguiente fase.

TP Rate	FP Rate	Precisión	Recall	F-Measure	MCC	ROC Area	PRC Area	Clase
0,738	0,142	0,764	0,738	0,751	0,599	0,775	0,690	Social
0,774	0,125	0,739	0,774	0,756	0,641	0,809	0,624	Mental
0,698	0,128	0,702	0,698	0,700	0,570	0,790	0,588	Acción
0,737	0,133	0,737	0,737	0,737	0,604	0,790	0,638	Avg.

Tabla 6.29. Clasificador 2da Fase LMT con filtros y Auto percepción

Nuevamente los resultados obtenidos siguen mejorando respecto a lo obtenido con los datos crudos sin aplicar ningún tipo de filtro ni modelado adicional. Igualmente, aún se conserva la distribución en los errores de clasificación, como se observa en la Tabla 6.30.

Social	Mental	Acción	Clase
152	24	30	Social
20	130	18	Mental
27	22	113	Acción

Tabla 6.30. Matriz de confusión de la tabla 6.29

En comparación a lo que se venía obteniendo la percepción por grupos no hizo la diferencia, ya que se obtuvieron buenos resultados y muy similares a los de autopercepción por usuario. A diferencia de la autopercepción los roles sociales pasaron a ser la clase que menor performance obtuvo. Esto puede observarse en la Tabla 6.31.

TP Rate	FP Rate	Precisión	Recall	F-Measure	MCC	ROC Area	PRC Area	Clase
0,671	0,084	0,771	0,671	0,718	0,613	0,773	0,626	Social
0,713	0,128	0,682	0,713	0,697	0,578	0,785	0,552	Mental
0,801	0,193	0,755	0,801	0,777	0,604	0,780	0,683	Acción
0,738	0,142	0,740	0,738	0,737	0,599	0,779	0,630	Avg.

Tabla 6.31. Clasificador 2da Fase LMT con filtros por Grupos

La matriz de confusión de este clasificador se ilustra en la Tabla 6.32:

Social	Mental	Acción	Clase
108	18	35	Social
18	107	25	Mental
14	32	185	Acción

Tabla 6.32. Matriz de confusión de la tabla 6.31.

Como fase final, y ya ingresando en los últimos resultados de clasificación se encuentra nuevamente el algoritmo K-Star, donde su desempeño fue el mejor respecto al resto por varios puntos, como se muestra en la Tabla 6.33. A comparación de la clasificación de SMO en los datos crudos y 3era fase, se mejoró en un 25% el promedio de cada una de las características presentadas.

TP Rate	FP Rate	Precisión	Recall	F-Measure	MCC	ROC Area	PRC Area	Clase
0,864	0,027	0,864	0,864	0,864	0,837	0,966	0,871	Finalizador
0,875	0,010	0,737	0,875	0,800	0,796	0,990	0,794	Impulsor
0,723	0,034	0,746	0,723	0,734	0,698	0,955	0,677	Cerebro
0,854	0,046	0,815	0,854	0,834	0,794	0,972	0,861	Colaborador
0,790	0,040	0,721	0,790	0,754	0,721	0,955	0,663	Especialista
0,759	0,023	0,800	0,759	0,779	0,753	0,965	0,693	Implementador
0,659	0,020	0,730	0,659	0,692	0,669	0,959	0,674	Monitor
0,583	0,008	0,636	0,583	0,609	0,601	0,817	0,572	Investigador
0,769	0,038	0,805	0,769	0,787	0,744	0,957	0,846	Coordinador
0,787	0,033	0,787	0,787	0,787	0,754	0,960	0,774	Avg.

Tabla 6.33. Clasificador 3ra Fase K-Star con filtros y Autopercepción

Estos resultados dejan a la alternativa de aplicar los modelos de datos directos totalmente nula, ya que se posee buen F-Measure en promedio. El ROC Área se elevó potencialmente a lo que se obtuvo previamente, como también el MCC. Por parte del rol Investigador, obtuvo la peor performance dentro de las clases de esta clasificación, mientras que el rol de Finalizador obtuvo muy buenas métricas, clase que tiene gran parte del conjunto, lo cual representa información muy positiva para seleccionar este clasificador como final.

Si se quisiera observar el threshold a comparación de lo que se obtenía inicialmente con los primeros clasificadores se puede observar en la Figura 6.10:




Figura 6.10. Threshold de la clase Finalizador (ROC = 0.966)

En comparación al primer threshold obtenido se puede apreciar la mejora dentro de los datos donde se llega más rápido a la cumbre de los positivos verdaderos, lo cual permite que más datos sean clasificados correctamente.

Si se observa la matriz de confusión de la Tabla 6.34, la cantidad de errores se ha reducido notablemente y aquellas clases donde se obtienen falsos positivos son determinadas y apenas distribuidas. En este caso los Coordinadores y Colaboradores muestran cierta similitud entre ellos, ya que ambas clases han sido incorrectamente clasificadas entre ellas, en alrededor de un 15% de las instancias pertenecientes a ambas clases. Esto mismo sucede entre Cerebros y Monitores, y por otra parte, entre Implementadores y Finalizadores.

a	b	c	d	e	f	g	h	i	Clase
76	3	0	0	0	9	0	0	0	a = Finalizador
0	14	0	0	0	2	0	0	0	b = Impulsor
0	0	47	0	13	0	5	0	0	c = Cerebro
0	0	0	88	0	0	0	2	13	d = Colaborador
0	0	8	0	49	0	5	0	0	e = Especialista
12	2	0	0	0	44	0	0	0	f = Implementador
0	0	8	0	6	0	27	0	0	g = Monitor
0	0	0	1	0	0	0	7	4	h = Investigador
0	0	0	19	0	0	0	2	70	i = Coordinador

Tabla 6.34. Matriz de confusión de la tabla 6.33

Como tablas finales del proceso de clasificación, se encuentra la del clasificador LMT por autopercepción en grupo utilizando el algoritmo basado en árboles de clasificación detallado anteriormente.

Si bien se lograron buenos resultados, aquellos obtenidos por la autopercepción lograron una menor performance en el resultado final y en promedio de métricas. En esta ocasión el rol de Colaborador fue el que mas sufrió esta baja de performance y obtuvo el peor puesto de métricas con 0,518 puntos en F-Measure, dando una breve descripción de su comportamiento general como información. Esto está ilustrado en la Tabla 6.35:

TP Rate	FP Rate	Precisión	Recall	F-Measure	MCC	ROC Area	PRC Area	Clase
0,765	0,030	0,816	0,765	0,790	0,755	0,837	0,639	Finalizador
0,558	0,022	0,725	0,558	0,630	0,603	0,771	0,498	Impulsor
0,714	0,030	0,625	0,714	0,667	0,644	0,828	0,444	Cerebro
0,468	0,032	0,579	0,468	0,518	0,480	0,710	0,372	Colaborador
0,729	0,030	0,700	0,729	0,714	0,686	0,844	0,531	Especialista
0,827	0,090	0,669	0,827	0,740	0,681	0,848	0,610	Implementador
0,731	0,017	0,860	0,731	0,790	0,767	0,879	0,736	Monitor
0,667	0,008	0,778	0,667	0,718	0,710	0,836	0,554	Investigador
0,796	0,062	0,725	0,796	0,759	0,707	0,899	0,628	Coordinador
0,721	0,043	0,726	0,721	0,719	0,681	0,838	0,582	Avg.

Tabla 6.35. Clasificador 3ra Fase LMT con filtros por Grupos

Dentro de la matriz de confusión de la Tabla 6.36, la distribución se mantiene muy similar en los errores obtenidos en la misma matriz de confusión por el clasificador SMO en la 3era fase por la inferencia por grupo. Esto quiere decir que ciertamente, independiente del algoritmo que se utilice, hay ciertas características compartidas entre las clases, como por ejemplo las de Finalizador e Impulsor con los Implementadores, ya que esta misma distribución se obtiene en la tabla anterior sin la utilización de ningún filtro.

a	b	c	d	e	f	g	h	i	Clase
62	3	0	0	1	13	0	0	2	a = Finalizador
3	29	0	0	2	17	0	0	1	b = Impulsor
1	0	25	1	5	0	3	0	0	c = Cerebro
0	0	0	22	1	5	0	1	18	d = Colaborador
0	1	8	0	35	0	4	0	0	e = Especialista
8	5	1	2	0	81	0	0	1	f = Implementador
1	1	6	2	5	2	49	0	1	g = Monitor
0	0	0	2	0	0	0	14	5	h = Investigador
1	1	0	9	1	3	1	3	74	i = Coordinador

Tabla 6.36. Matriz de confusión de la tabla 6.35.

Hasta lo ya observado, los modelos que mejor se desempeñaron terminaron siendo aquellos por fases, debido a la contextualización del modelo, dado que primero se obtiene un contexto donde las clases a predecir son los tipos de roles que luego serán utilizados para obtener la predicción de las clases definitivas que son los roles de los usuarios. Este proceso, que presenta una similitud al método *Dividir y Conquistar*, permitió definitivamente obtener mejores resultados a diferencia de los modelos directos, donde no se encuentra presente la división del contexto.

Como era de esperar, lo mismo sucede con los modelos con filtros, estos trabajan fuertemente sobre los datos mejorando ampliamente todos los resultados, en las matrices de confusión se ve como la variación de pesos se corrige y se clasifica ampliamente mejor que los modelos predecesores.

En la segunda fase del clasificador con filtros, se puede observar que comienzan a mejorar los resultados, con una baja cantidad de falsos positivos, y una distribución similar en aquellos casos en los que se ha clasificado incorrectamente, demostrando que una clase no tiende a solo dos clases sino que su relación con el resto de las clases está distribuida.

Lo mismo sucede con la cantidad de errores por clase, obteniendo así un promedio de 18 errores de clasificación.

En lo que respecta a la clasificación en grupos y las de percepción, si bien a la hora de realizar el modelo de la segunda fase los grupos obtuvieron una mejor performance, luego esta se ve reducida en la tercera fase, donde este contexto de percepción en grupo sobre el rol percibido por el compañero toma aún más efecto aunque con menor performance que la autopercepción de los usuarios.

En ambos casos se persevero el incremento en la precisión de los clasificadores. Como se puede ver, se obtuvo casi un 78% de clasificaciones correctas, lo cual da mayor seguridad para seleccionar un modelo final, que pueda predecir con resultados aceptables.

6.2.5 Análisis colectivo de clasificadores con filtros y entrenamiento fases

Como último análisis de clasificación, se presenta el enfoque final, donde para esta etapa, a diferencia de las fases anteriores, se procedió a seleccionar diferentes clasificadores para roles de un mismo tipo, independientemente del que se haya utilizado para clasificar a otro tipo de rol. Esto nos

permite llegar a una granularidad más baja de contexto seleccionando un único clasificador por tipo de rol, eligiendo siempre aquel que obtenga la mejor performance.

En la Tabla 6.37, se puede observar los resultados independientes de los tres clasificadores, uno por cada tipo de rol, que obtuvieron las mejores precisiones. Estos vendrían a ser, LMT para los sociales, KStar para los mentales y SMO para los de acción.

TP Rate	FP Rate	Precisión	Recall	F-Measure	MCC	ROC Area	PRC Area	Clase
0,855	0,111	0,856	0,855	0,855	0,743	0,908	0,878	Colaborador Investigador Coordinador
0,747	0,139	0,747	0,747	0,744	0,615	0,879	0,808	Cerebro Especialista Monitor
0,837	0,146	0,836	0,837	0,836	0,699	0,852	0,771	Finalizador Impulsor Implementador
0,813	0,132	0,813	0,813	0,811	0,685	0,879	0,819	Avg.

Tabla 6.37. Clasificador por tipo de rol autopercebido en 3era Fase con filtros

En promedio se obtienen mejores resultados que aquellos obtenidos en las fases anteriores. Lo único que cabe resaltar es el trade off con el porcentaje de falsos positivos que incrementa unos ligeros puntos y una reducción del ROC Área, aunque se obtiene una mejor performance en el resto de los atributos.

Si se observa la matriz de confusión de la Tabla 6.38 se mantiene la distribución de errores, donde solo se confunde en aquellos casos donde pertenecen al mismo tipo de rol, acotando el contexto de error.

a	b	c	d	e	f	g	h	i	Clase
69	1	0	0	0	8	0	0	0	a = Finalizador

2	12	0	0	0	0	0	0	0	b = Impulsor
0	0	58	0	8	0	4	0	0	c = Cerebro
0	0	0	81	0	0	0	3	10	d = Colaborador
0	0	15	0	30	0	6	0	0	e = Especialista
11	1	0	0	0	37	0	0	0	f = Implementador
0	0	7	0	4	0	42	0	0	g = Monitor
0	0	0	3	0	0	0	6	2	h = Investigador
0	0	0	12	0	0	0	2	102	i = Coordinador

Tabla 6.38. Matriz de confusión de la tabla 6.37.

A lo que respecta a la percepción por los grupos, también se obtuvo una mejoría en los resultados, acercándose a los auto percibidos del enfoque presentado anteriormente, como se presenta en la Tabla 6.39. Nuevamente se obtuvo un tradeoff de puntos entre el ROC Área y MCC contra el F-Measure, lo cual da un acierto mayor al que se venía obteniendo.

TP Rate	FP Rate	Precisión	Recall	F-Measure	MCC	ROC Area	PRC Area	Clase
0,763	0,178	0,768	0,763	0,764	0,582	0,840	0,793	Colaborador Investigador Coordinador
0,745	0,153	0,745	0,745	0,745	0,594	0,801	0,700	Cerebro Especialista Monitor
0,759	0,128	0,763	0,759	0,761	0,629	0,832	0,717	Finalizador Impulsor Implementador
0,755	0,153	0,758	0,755	0,756	0,601	0,824	0,736	Avg.

Tabla 6.39. Clasificador por tipo y grupos en 3ra Fase con filtros

A diferencia de la misma tabla en la fase anterior, esta se encuentra atada a errores solo en los mismos tipos de roles, ya que al separar al clasificador a un solo tipo, reduce la distribución de roles a equivocarse. Por lo tanto, no se delega esta propiedad al algoritmo clasificador sino a la metodología de clasificación. Estos detalles son presentados en la matriz de confusión de la Tabla 6.40.

a	b	c	d	e	f	g	h	i	Clase
57	9	0	0	0	8	0	0	0	a = Finalizador

7	29	0	0	0	7	0	0	0	b = Impulsor
0	0	21	0	4	0	5	0	0	c = Cerebro
0	0	0	35	0	0	0	2	15	d = Colaborador
0	0	5	0	37	0	12	0	0	e = Especialista
14	7	0	0	0	78	0	0	0	f = Implementador
0	0	5	0	9	0	59	0	0	g = Monitor
0	0	0	3	0	0	0	15	2	h = Investigador
0	0	0	10	0	0	0	8	79	i = Coordinador

Tabla 6.40. Matriz de confusión de la tabla 6.39

Utilizando este último enfoque se logró llevar los resultados a un 2,6% más efectivo que los enfoques previamente obtenidos en lo que respecta a las clasificaciones por autopercepción y alrededor de un 3% para aquellos por grupos. Estos puntajes que si bien, pueden sonar diminutos, a este nivel de complejidad y dificultad para subir su precisión, terminan siendo grandes avances.

La metodología de llevar el contexto a una granularidad menor, sumado a la selección de aquellos algoritmos que performan de mejor forma, reciben la mayor atribución de este avance. Estos resultados, a pesar de su trade-off entre falsos positivos y Roc Área con el F-Measure, logran una mejor performance globalmente a lo que se venía observando. Por lo tanto, ambos modelos son los candidatos a ser utilizados en la herramienta final.

6.3 Aplicación y evaluación de la herramienta resultante

En esta sección se evalúa la herramienta desarrollada en un caso de experimentación real, en el cual se toman como muestra 27 alumnos divididos en 5 grupos de 5 y 6 participantes, los cuales debieron realizar una actividad colaborativa con una asignación aleatoria por parte de un profesor, y luego otra actividad con grupos recomendados por la aplicación. Ambas actividades fueron similares a aquellas de las cuales se extrajeron los datasets de entrenamiento para el desarrollo de la solución propuesta, es decir bajo el entorno colaborativo de Google Docs, comunicándose a través de Hangouts.

Comenzada la primer actividad, se pudo obtener el rol principal y secundario de los alumnos que formaban los grupos aleatorios, proveniente de la encuesta de autopercepción que completaron los mismos. Esto permite tener una vista de cómo estaban distribuidos estos roles en los grupos, según los resultados del cuestionario, lo cual se presenta en la Tabla 6.41.

Grupo 1	Grupo 2	Grupo 3	Grupo 4	Grupo 5
Especialista/ Implementador	Investigador/ Coordinador	Implementador/ Coordinador	Implementador/ Especialista	Monitor/ Implementador

Coordinador/ Implementador	Colaborador/ Finalizador	Impulsor/ Monitor	Cerebro/ Implementador	Coordinador/ Impulsor
Colaborador/ Especialista	Implementador/M onitor	Especialista/ Coordinador	Especialista/ Monitor	Colaborador/ Implementador
Monitor/ Coordinador	Cerebro/ Finalizador	Finalizador/ Coordinador	Monitor/ Coordinador	Especialista/ Implementador
Finalizador/ Coordinador	Coordinador/ Implementador	Coordinador/ Colaborador	Colaborador/ Implementador	Finalizador/ Monitor
			Colaborador/ Investigador	Finalizador/ Colaborador

Tabla 6.41. Distribución de grupos primer actividad.

Como se puede observar, asumiendo que la autopercepción es correcta, se presenta un aceptable balance de los roles, aunque no el ideal. Se cuenta con dos grupos que contienen 6 de los 9 roles definidos por Belbin, y otros tres grupos que presentan 7.

Una vez finalizada la primer actividad, se pudieron obtener los chats de la misma para inferir los roles de usuario utilizando la herramienta desarrollada en el actual trabajo, siguiendo los pasos presentados en el manual de usuario que se encuentra en el Capítulo 9. Con los roles obtenidos se calcularon automáticamente grupos, dando como resultado los presentados en la Tabla 6.42.

Grupo 1	Grupo 2	Grupo 3	Grupo 4	Grupo 5
Colaborador/ Implementador	Impulsor/ Implementador	Finalizador/ Monitor	Especialista/ Finalizador	Finalizador/ Monitor
Finalizador/ Coordinador	Finalizador/ Coordinador	Cerebro/ Implementador	Monitor/ Implementador	Cerebro/ Especialista
Cerebro/ Impulsor	Especialista/ Monitor	Especialista/ Finalizador	Cerebro/ Coordinador	Coordinador/ Implementador
Especialista/ Monitor	Cerebro/ Implementador	Coordinador/ Coordinador	Colaborador/ Monitor	Colaborador/ Implementador
Coordinador/ Investigador	Colaborador/ Monitor	Colaborador/ Finalizador	Monitor/ Monitor	Especialista/ Monitor
Monitor/ Monitor	Investigador/ Implementador			

Tabla 6.42. Distribución de grupos segunda actividad.

Con la herramienta se logró obtener dos grupos balanceados, es decir con los 9 roles de Belbin distribuidos en sus participantes, mientras que los restantes sufren la falta de los roles investigador e impulsor, los cuales son pocos comunes en las predicciones debido a que son los que menos ocurrencias presentan en las autopercepciones. A pesar de esto, se puede determinar que se mejoró

el balance con respecto a la primer actividad, solo queda por definir si la aplicación infirió correctamente los roles, y si supera a la autopercepción extraída de las encuestas SYMLOG.

Para evaluar la herramienta, se definieron una serie de métricas provenientes de la opinión de los alumnos sobre su grupo de trabajo, extraídas de J.M. Alberola et al. (2016). Para esto, los integrantes al finalizar la actividad, debieron completar un cuestionario acerca de diferentes aspectos del equipo de trabajo, como la comunicación, coordinación, dinámica de equipo, entre otros. Esta encuesta refleja los diferentes niveles de satisfacción usando la escala de Likert, la cual cuenta con cinco niveles de respuesta: totalmente en desacuerdo, en desacuerdo, neutral, de acuerdo y totalmente de acuerdo. Las preguntas fueron organizadas de acuerdo a dos categorías principales: dinamica de grupo (coordinación, cooperación, balance de trabajo, comportamiento, toma de decisiones, entre otros) y la satisfacción del estudiantes, como puede observarse en la Tabla 6.43.

Coordinación y cooperación	
1. Nuestro equipo ha sido bien coordinado	Escala Likert
2. Nuestro equipo creó un ambiente cooperativo	Escala Likert
3. Establecimos normas y tareas específicas para todos	Escala Likert
4. Cada miembro hizo su parte del trabajo	Escala Likert
5. Nuestro equipo pasó su tiempo bien	Escala Likert
Comportamiento del miembro del equipo	
6. Las actitudes de los miembros del equipo fueron positivas	Escala Likert
7. Los miembros del equipo se tratan de una manera respetuosa	Escala Likert
8. Los miembros del equipo aceptaron sugerencias de una manera positiva	Escala Likert
9. Nuestro equipo escuchó las opiniones de todos los miembros	Escala Likert
10. Fue difícil para mi equipo llegar a una decisión	Escala Likert
Satisfacción del estudiante	
11. ¿Cómo fue su experiencia en este equipo?	Escala Likert
12. Me sentí cómodo trabajando en mi equipo	Escala Likert
13. Sentí que contribuí a este equipo	Escala Likert
14. Nuestro proyecto es aceptable para todos en el equipo	Escala Likert
15. Evalúe su equipo con un grado de 0 a 10	Puntaje entre 0 y 10

Tabla 6.43. Cuestionario de opinión sobre los grupos

Una vez definidas las métricas, realizó una comparación de los cuestionarios obtenidos de la primer y segunda actividad. Para analizar la escala Likert, se combinaron las categorías en acuerdo y desacuerdo, donde la primera incluye los valores “Muy acuerdo” y “Acuerdo”, mientras que la

segunda abarca “Neutral”, “Desacuerdo” y “Muy desacuerdo”. En la Tabla 6.44 se pueden observar los resultados obtenidos.

		Actividad 1	Actividad 2
Coordinación y cooperación	P1	A: 18 D: 9	A: 24 D: 3
	P2	A: 14 D: 13	A: 22 D: 5
	P3	A: 11 D: 16	A: 20 D: 7
	P4	A:14 D:13	A: 21 D: 6
	P5	A: 16 D: 11	A: 20 D: 7
Comportamiento del miembro del equipo	P6	A: 25 D: 2	A: 24 D: 3
	P7	A: 27 D: 0	A: 26 D: 1
	P8	A: 25 D: 2	A: 24 D: 3
	P9	A: 24 D: 3	A: 25 D: 2
	P10	A:6 D: 21	A: 3 D: 24
Satisfacción del estudiante	P11	A: 12 D:15	A: 21 D: 6
	P12	A: 23 D: 4	A: 24 D: 3
	P13	A: 25 D: 2	A: 25 D: 2
	P14	A: 22 D: 5	A: 24 D: 3
	P15	7,33	8,46

Tabla 6.44. Resultados de los cuestionarios.

De las 14 preguntas del cuestionario analizadas mediante la escala Likert, 10 obtuvieron mejores resultados en la actividad desarrolladas por los grupos formados por la herramienta, una mantuvo la misma opinión, mientras las otras 3 bajaron levemente la cantidad de acuerdos.

Todos las preguntas acerca de la coordinación y colaboración mejoraron notablemente los resultados, lo que marca la buena performance de la herramienta propuesta, que tiene como objetivo reducir los conflictos colaborativos y mejorar la eficacia del grupo en general. Por su parte, en el área de comportamiento del miembro del equipo, prácticamente se mantuvieron los resultados, observándose leves mejoras o bajas, pero insuficientes para determinar un cambio brusco de opinión, reflejando que los alumnos mantuvieron un trato respetuoso en ambas actividades.

Por último, la opinión acerca de cómo fue su experiencia en el equipo mejoró de 12 a 21 acuerdos, dando a entender que la nueva distribución de los roles hizo sentir más cómodos a los participantes. Las preguntas 12, 13 y 14 se mantuvieron estables, mientras que el puntaje promedio asignado por los alumnos mejoró considerablemente la satisfacción con el grupo 1,33 puntos.

En resumen, se puede llegar a la conclusión de que la herramienta permitió obtener una buena distribución de roles, los cuales balancearon los grupos asignados en un principio y mejoraron el desempeño reflejado en las opiniones de los alumnos. El experimento sugiere que los equipos formados por aplicación recibieron respuestas más positivas con respecto a los aspectos de satisfacción de los estudiantes. En general, un mayor porcentaje de estudiantes evaluó la experiencia del equipo como positiva, se sintió más cómodo trabajando con sus compañeros de equipo, percibió el trabajo realizado en el equipo como satisfactorio y los evaluó de mejor manera.

6.4 Análisis de métricas de usuarios

Con el fin de reconocer los usuarios que se contienen dentro del conjunto de datos, se procedió a obtener diferentes métricas respecto a ellos. Esto, permite indagar más profundamente acerca de la información que se tiene disponible y apuntar a detalles más específicos que no se hayan tenido en cuenta a la hora de tomar decisiones sobre las clasificaciones.

En la Figura 6.11 se puede observar que dentro de los perfiles detectados por los clasificadores se encuentran mayormente colaboradores y coordinadores. Muchas de estas repeticiones también son intercaladas, ya que el clasificador no cuenta con un 100% de efectividad, por lo tanto, se puede visualizar que en algunos casos la clasificación de rol de un usuario puede ser de entre uno o más roles.




Figura 6.11. Visualización de sampleo de clasificaciones.

En lo que respecta a los tipos de roles clasificados, como era de esperarse, el principal tipo más calificados son aquellos de los roles sociales, que a lo largo de todos los análisis marcaron gran predominancia y manteniendo una gran cantidad de repeticiones a lo largo de los usuarios, como se presenta en la Figura 6.12.




Figura 6.12. Visualización de sampleo tipos de rol en clasificaciones.

Como se puede observar en ambas imágenes, algunas de las repeticiones pueden llegar a ser mucho menores que el resto, ya que es posible que un usuario participe de algunos trabajos que se realicen y no esté presente en el resto. Por lo tanto, el radio de tamaño de participación no será equitativo con el resto de los participantes que hayan estado en cada etapa del proceso.

Similar a la autopercepción, un común con los grupos es que en ambos se encuentran muy presentes los coordinadores, lo cual no solo es un aspecto que surge a partir de la encuesta que se le realiza al usuario, sino que sucede con grandes posibilidades de que el resto de los compañeros presentes en el grupo sientan de que sus compañeros cumplen el rol de coordinadores al ejecutar o dar algún tipo de orden o acción social. Contrario es el caso de los colaboradores, ya que dentro del mundo de la autopercepción se da con gran frecuencia mientras que los grupos no visualizan tanto estas cualidades en su compañero y esto se ve reflejado en las tomas de decisiones del clasificador. Esta, es entre ambos clasificadores, la mayor diferencia que hay entre ellos, ya que luego si bien para la autopercepción las clasificaciones están más concentradas en dos roles, luego están distribuidas similarmente en el conjunto de datos. En la Figura 6.13 se puede observar la distribución de los roles asignados por los grupos.




Figura 6.13. Visualización de sampleo rol percepción por grupos en clasificaciones.

Como es de esperarse, los roles sociales nuevamente tienen la mayor presencia dentro de la clasificación de los tipos, seguidos por aquellos de acción y por último los mentales. En contraste a los de autopercepción, estos se diferencian que en aquellos hay mayor presencia de los roles mentales, mientras que en los percibidos por el grupo predominan los de acción por sobre los mentales. Esta distribución puede observarse en la Figura 6.14




Figura 6.14. Visualización de sampleo tipo de rol percepción por grupos en clasificaciones.

Si se observa más específicamente el rol de los usuarios, se puede observar que a partir de su autopercepción, el rol que se obtuvo es estático, ya que la encuesta la realiza una sola vez y es aquel rol que se le define a lo largo de los diferentes trabajos que va realizando.

Por lo tanto, en la Figura 6.15 se puede observar tal cualidad, donde el rol autopercebido es una línea recta estática.




Figura 6.15. Visualización de sampleo autopercepción de rol de un usuario.

En cambio si se analiza aquellos resultados obtenidos para el mismo usuario utilizando la herramienta, se puede observar una variación en la predicción del rol, comenzando erróneamente con un rol que el usuario no se autopercibe, aunque luego ya para la siguiente etapa se logró obtener el rol correcto, el cual luego se mantuvo. En la Figura 6.16 se presenta como el rol clasificado converge hacia aquel que el usuario autopercibe a partir de los datos obtenidos de su participación en las distintas etapas de los grupos.




Figura 6.16. Visualización de muestreo de rol clasificado por herramienta en autopercepción para un usuario.

6.5 Resumen

Como se pudo observar, a partir de un análisis inicial de los datos, se efectivizó la detección de posibles inconveniente o desperformantes para la clasificación, como por ejemplo, el desbalance de clases. Este trabajo inicial, permitió poder identificar de antemano estos futuros problemas, que luego de haber afirmado las hipótesis con métodos cuantitativos, tales como la matriz de confusión y las tablas de rendimiento individual de los clasificadores, fue posible aplicar correctamente los filtros necesarios. A su vez, estos resultados, proporcionan nuevos conocimientos acerca de la información con la que se contaba, por lo tanto, fue posible agregar nuevos filtros sobre la misma para obtener mejores clasificaciones.

La puesta en prueba de distintos métodos de aplicación de los algoritmos de aprendizaje de máquina, ya sea directo o por fases, demostró la diferencia entre cada una de las opciones. A su vez se pudieron analizar varios algoritmos de forma paralela, otorgando la libertad de elegir a aquellos que obtuvieron las mejores clasificaciones.

Los algoritmos que obtuvieron los mejores resultados en definitiva fueron los modelos de árboles logísticos, lo cual resulta muy positivo, ya que su performance para crear los modelos es bastante veloz y también permite realizar un único enfoque en un solo clasificador para futuras mejoras.

Por otra parte, además de las precisiones de los clasificadores, se pudo realizar un experimento con la herramienta en una situación real, cuyos resultados arrojaron que la misma puede mejorar la opinión de los integrantes con respecto a los grupos, y la eficacia de los mismos.

Por último, se visualizaron los perfiles de los usuarios y grupos identificados comparándolos con los datasets iniciales con los cuales se contaban para entrenar la herramienta.

Luego en el próximo capítulo se analizará más en profundidad sobre las conclusiones y limitaciones globales sobre todo el proyecto.

7. Conclusiones

El objetivo fundamental de esta tesis era el de abordar la falta de automatización en el proceso de modelado de usuarios, más específicamente los roles de los mismos, para el armado de grupos eficientes y con nula presencia de conflictos colaborativos. Después de la clasificación realizada por Meredith Belbin de los roles que debe poseer un equipo, se puede definir el equipo perfecto como aquel en el que sus integrantes logran suplir los defectos que se generan en la formación de un equipo, como por ejemplo el Cerebro proporciona gran cantidad de ideas pero es incapaz de distinguir cual es la más adecuada, en cambio el Monitor Evaluador realiza ese juicio crítico con el objetivo de obtener la idea más correcta. A su vez el Monitor Evaluador es incapaz de evitar confrontaciones en el equipo a su pensamiento crítico y su falta de entusiasmo, y ese aspecto lo corrige el Colaborador, y así continuamente. Esta afirmación conduce a pensar que es imposible que un individuo por sí sólo pueda ejercer los nueve roles, por lo que para optimizar al máximo el trabajo, será necesaria la constitución de un equipo bien coordinado.

Es por esto que el aporte principal de este trabajo consiste en una herramienta que permite inferir roles de usuario a partir de las conductas de la persona en un entorno de trabajo colaborativo digital. Este entorno digital fue Google Docs, donde los alumnos debieron desarrollar una serie de actividades, comunicándose a través de Hangouts, lo cual permite recolectar gran cantidad de información. Otra de las ventajas de extraer información a partir una herramienta como Hangouts, es que el usuario demuestra su comportamiento en un escenario real, el cual puede ser muy diferente a lo definido según su autopercepción. Además, ese comportamiento puede ser registrado de forma más certera que si lo realizara una persona encargada, ya que todas sus interacciones quedan almacenadas.

Se considera que este trabajo contribuye una gran ayuda al área de análisis de interacciones, debido a que se encuentran muchos estudios sobre la lengua inglesa, pero pocos estudios trabajan con el lenguaje español y con la clasificación de roles de equipo.

Para el desarrollo de la herramienta se implementaron distintas técnicas de Inteligencia Artificial, mediante la Minería de Datos, partiendo de un conjunto de datos no estructurados, es decir, de un conglomerado masivo y desorganizado de varios objetos que no tenían valor hasta que se identificaron y almacenaron de manera organizada. Los avances tecnológicos, principalmente en este campo son de gran utilidad para elaborar herramientas que ayuden a detectar asuntos de interés, como en este caso los roles de usuario.

La Minería de Datos utiliza en su análisis métodos del aprendizaje automático, el cual puede clasificarse en Aprendizaje supervisado, no supervisado, o semi supervisado, dependiendo del tipo de salida que se produzca y de cómo se aborde el tratamiento de los ejemplos. En el actual trabajo se implementó el de tipo supervisado, ya que utiliza ejemplos de los que se conoce su clasificación correcta, aprovechando las encuestas de auto percepción de los usuarios para extraer su rol, y utilizarlo como variable objetivo. Por otra parte, se concluyó que es importante aplicar el contexto en el que se desarrolló la actividad, mediante el uso de los roles inferidos por sus compañeros de grupo al finalizar cada actividad, lo cual permite establecer una mejor relación entre el rol y las conductas adoptadas.

Se propusieron diferentes enfoques, un enfoque directo en el que se infiere el rol a partir de distintos features sin ningún filtro de datos intermedio, y otros dos en fases, que mejoran las precisiones de los clasificadores, debido a que primero detecta el tipo de rol, para a partir del mismo predecir el rol del individuo. El enfoque que mejores resultados arrojó cuenta con un clasificador para cada tipo de rol en la última fase, que permite elegir entre solo tres valores de la clase rol, ya que son los únicos que el mismo va a conocer debido a que no hay otros presentes en el conjunto de datos (fueron descartados junto con el tipo de rol).

Para analizar estos enfoques, se buscó utilizar una variedad importante de clasificadores, de distintos tipos, como bayes, árboles, funciones, basados en reglas, lazy y meta. La puesta en prueba de distintos métodos de aplicación de los algoritmos de aprendizaje de máquina, ya sea directo o por fases, demostró la diferencia entre cada una de las opciones.

Se obtuvieron resultados variados, los cuales fueron analizados observando patrones que se repetían según cada tipo de rol, lo que permitió obtener mayor información acerca de cómo los clasificadores juzgan y de lo que se busca predecir. En un inicio los mismos eran bajos, sin embargo, mediante el aplicado de filtros como discretizado y resample, se logró obtener hasta casi un 79% de precisión, por lo cual se considera que se logró cumplir con el objetivo de obtener un modelo eficaz para la inferencia de roles. Los destacados fueron los modelos de árboles logísticos, lo cual resulta muy positivo, ya que su performance para crear los modelos es bastante veloz y también permite realizar un único enfoque en un solo clasificador para futuras mejoras, evaluando nuevos features que incrementen las precisiones, acercándose al ideal.

Por otra parte, se detectó que los cuestionarios y los roles resultantes de la herramienta no siempre coinciden, resultando más representativos aquellos roles detectados por la aplicación. Esto resalta aún más la importancia de la misma, debido a que caracteriza mejor al usuario de acuerdo a su entorno, la cual no necesariamente se asemeja a la visión que las personas tienen de uno mismo.

Adicionalmente se desarrolló un prototipo funcional, donde los administradores pueden ingresar los chats que quieren clasificar, y siguiendo simples pasos obtener una salida para analizar, que colabore en el armado de grupos. El mismo fue desarrollado con una arquitectura Cliente - Servidor, con el fin de evitar a los usuarios el trabajo de instalación, y para lograr la portabilidad de la aplicación. Utilizando este prototipo, se realizó un experimento para analizar la performance de la herramienta en una situación real. A partir de esto se concluyó que la misma puede mejorar la opinión de los integrantes con respecto a los grupos, y la eficacia sus acciones, aumentando la calidad de los trabajos colaborativos.

La herramienta se implementó de manera tal que pueda ser extensible para trabajos futuros, lo cual es muy importante para este área de software, ya que constantemente aparecen nuevas características a analizar, o relaciones con nuevos casos de estudio. Los hallazgos de nuestro estudio podrán ser utilizados como evidencia en trabajos futuros de la necesidad de trabajar complementando las interacciones con un asistente que detecte conflictos en la misma, y actúe de acuerdo al rol que se halle faltante.

Por último, se debe resaltar la importancia de lo aprendido durante estos años de carrera, los conocimientos acumulados que ayudaron a diseñar una solución que cumplió con el objetivo de este trabajo. Se pudieron aplicar distintas arquitecturas aprendidas como Cliente - Servidor, técnicas de Inteligencia Artificial recolectadas de distintas materias optativas, y modelaron clases adecuadamente, aplicando distintos lenguajes de programación.

7.1 Limitaciones

En líneas generales, los recursos otorgados para la construcción de la herramienta como los datasets de las encuestas y los chats de Hangouts de diferentes grupos de trabajo, permitieron llevar a cabo un desarrollo exitoso de la funcionalidad propuesta. Sin embargo se encontraron algunas limitaciones:

- Al utilizarse la librería Freeling, la cual no está implementada para ser utilizada en Java y Windows, se tuvo que construir la API siguiendo algunos pasos que se encuentran en la documentación oficial. Los mismos no estaban muy claros, por lo que costó mucho tiempo poder construirla. Además la misma cuenta con muchas dependencias que debieron descargarse para el correcto funcionamiento de la librería.
- Al principio se contaba con un dataset amplio de chats, de aproximadamente 40.000 mensajes, pero luego de pre procesarlo y prepararlo para el entrenamiento, como se calculaba un promedio de conductas, participación y atributos SYMLOG por cada alumno, solo se obtuvieron 542 registros para ser analizados. En un futuro, a medida que se vayan recolectando más chats, se pueden volver a entrenar los modelos con un dataset más amplio para optimizarlos aún más.
- Se debió confiar en que los alumnos llenaron los cuestionarios a conciencia y no solo por obligación. Esto se propone como una limitación ya que los roles que se utilizaron para entrenar los modelos provienen de las encuestas, entonces si algunos alumnos no llenaron de forma correcta las mismas, es probable de que eso afecte al entrenamiento.

7.2 Trabajos futuros

En la implementación de los distintos enfoques, se trabajaron diferentes niveles semánticos de la información a partir del texto. En estos niveles semánticos se detectó que se abarcan implícitamente acciones específicas que pueden observarse en plataformas de otro formato, por ejemplo acciones en un trabajo de edición colaborativa en Google Drive, o acciones de evolución de código en repositorio y proceso de desarrollo en GitHub.

Con Google Drive, los estudiantes aprenden a resolver juntos los problemas, desarrollando las habilidades de liderazgo, comunicación, confianza, toma de decisiones y solución de conflictos, las cuales fueron algunas de las cuestiones analizadas indirectamente a través de las conductas IPA y los atributos SYMLOG. Las sugerencias sobre el documento pueden relacionarse con las conductas IPA que dan sugerencia u orientación, al igual que los comentarios expuestos sobre el mismo. Estos últimos a su vez pueden mapearse a todas las áreas IPA, mediante el correcto análisis su contenido.

A su vez se puede extraer la cantidad de intervenciones de cada usuario sobre el editor, lo cual puede ser mapeado con el porcentaje de participación analizado para la inferencia de los roles. También, se puede detectar en qué momento de la edición del documento participó mayoritariamente un determinado participante, también de gran importancia para los roles.

Google Docs integra diferentes formas de estar en contacto, ya que todos los participantes pueden comunicarse de forma sincrónica través de una línea de chat o de forma asincrónica mediante debates o el historial de registro de las modificaciones. Adicionalmente, al permitir la edición al mismo tiempo de varios integrantes a la vez, la hace una herramienta totalmente colaborativa, aumentando la comunicación entre los usuarios activos.

A través de GitHub por su parte, se puede extraer la participación de cada programador a través de los commits realizados, el momento en el que participó, los cambios que hizo sobre el código y si los

mismo produjeron conflictos o no, si se debieron deshacer cambios hechos por una determinada persona, y el tiempo entre un aporte y otro. Mientras que a través de su plataforma de reporte de issues, es posible analizar textualmente cuál es su comportamiento frente a diferentes problemas que surgen a lo largo del ciclo de vida dentro del desarrollo.

Otra herramienta de la que se puede extraer información valiosa es Slack, donde se pueden compartir mensajes, archivos, conectarse con herramientas y servicios que se utilizan a menudo, trayendo la información necesaria, entre otras cosas.

La herramienta del presente trabajo posibilita el ingreso de esta meta información y la adaptación para incorporarla al proceso de detección de perfiles. Para esto, se debe contar con los datasets correspondientes para que puedan ser procesados y organizados mediante la aplicación. Una vez obtenidos los valores de los nuevos features, el usuario ya se encuentra en condiciones de entrenar a los clasificadores y luego predecir con los modelos obtenidos normalmente, utilizando Weka.

Por otra parte, queda pendiente el desarrollo de un Asistente Inteligente completo, que utilizando roles calculados anteriormente, junto con conductas IPA que puede ir calculando en tiempo real, actúe de conductor a medida que se va desarrollando el trabajo detectando conflictos colaborativos e interviniendo enviando mensajes para ofrecer posibles soluciones de los mismos. El asistente puede intervenir en caso de que se detecte a partir de las conductas que un determinado participante no está actuando de acuerdo a su rol o algún conflicto colaborativo, mediante distintos mensajes que ayuden a mantener la eficiencia del grupo. También puede proponer cambios de participantes entre grupos, inserción de otro rol para lograr mejor equilibrio, o asistencia para lograr que la falta de determinados roles no afecte el resultado final.

7.3 Implicancias

En el presente trabajo se desarrollaron dos herramientas para la inferencia de roles, una de entrenamiento y otra de predicción. Ambas pueden ser utilizadas tanto en ambiente académico como ambiente corporativo, utilizando los modelos ya aportados o creando nuevos. En uno de los atributos de calidad que se hizo hincapié fue en la usabilidad, para lograr que otras entidades que no sean la facultad puedan usar las aplicaciones con facilidad.

Para utilizarlas es importante que los equipos de trabajo se agrupen y se comuniquen mediante Hangouts, para luego con la información de esos chats inferir los roles de usuarios y formar nuevos grupos. Conocer el perfil de las personas de interés permite formar grupos balanceados en base a las responsabilidades que se deben asumir. Si se quisiera migrar hacia otro canal de comunicación, se podría utilizar un adaptador para obtener las conversaciones entre los usuarios y adaptar al formato utilizado actualmente por la herramienta.

Por otra parte, la labor de análisis de las interacciones por parte de una persona encargada insume tiempo y esfuerzo significativos. Estas herramientas van a permitir reducir carga en estas personas, debido a que los mismos van a poder tener un visión general de cómo se comportaron los integrantes y armar grupos automáticamente.

También, el armado de grupos con estas herramientas se espera que reduzca el número de conflictos que se pueden presentar por la presencia de dos o más personas con las mismas características. Por ejemplo, dos integrantes que se inclinan al rol cerebro es muy probable que generen conflictos, ya que van a querer desarrollar la actividad de acuerdo a sus ideas, y no van a delegar fácilmente, provocando un problema entre ellos. Lo mismo sucede con aquellos roles de liderazgo, donde ambos quieren posicionarse en un lugar que normalmente es planteado por un integrante, llevando a disconformidad y pérdida de gran parte del tiempo entre los participantes.

Por otra parte, en el ambiente académico, se puede lograr reemplazar a los feedbacks que los alumnos deben completar para la detección de sus roles, lo cual es tedioso tanto para ellos como para la persona encargada de analizarlos, nuevamente permitiendo a todos los afectados invertir este tiempo en otros aspectos relacionadas a la actividad.

Si todas estas tareas mencionadas, se debieran realizar a mano, siguiendo el control y personalización de cada una de ellas, el tiempo consumido superaría ampliamente al uso y aprendizaje de la herramienta.

8. Anexos

8.1 Relación Teoría de Roles de Belbin con modelos IPA y SYMLOG

El primer estudio de interacciones grupales, planteado a fines de la década de 1940 por el psicólogo estadounidense Robert Bales, llevó el nombre de “Interaction Process Analysis” (abreviado IPA). IPA divide a las interacciones en 12 categorías de acuerdo a 2 tipos: socioemocionales (referidas a relaciones entre miembros) y orientadas a la tarea (focalizadas en el trabajo que se espera del grupo)(Bales, 1950), como se muestra en la Tabla 8.1.

ÁREA	REACCIÓN	CONDUCTAS
Socio-emocional	Positiva	C1. Muestra solidaridad
		C2. Muestra relajamiento o moderación
		C3. Muestra acuerdo o aprueba
Tarea	Respuestas	C4. Da sugerencias u orientación
		C5. Da opiniones
		C6. Da información
	Preguntas	C7. Pide información
		C8. Pide opinión
		C9. Pide sugerencias u orientación
Socio-emocional	Negativa	C10. Muestra desacuerdo o desaprobación
		C11. Muestra tensión o molestia
		C12. Muestra antagonismo o agresividad

Tabla 8.1. Áreas, reacciones y conductas IPA

Bales también diferenció una serie de fases sucesivas y típicas por las que pasa cualquier grupo que desarrolla una tarea colaborativa, desde su principio hasta su final. Dichas fases son tres: Fase de orientación , Fase de evaluación , y Fase de control. Además, identificó seis tipos de problemas o conflictos que pueden producirse durante estas fases de la dinámica grupal: problemas de comunicación, de evaluación, de control, de decisión, de reducción de tensiones y de reintegración. Según la propuesta de Bales, cada uno de los problemas de colaboración se manifiestan mediante cantidades inapropiadas de los distintos tipos de interacciones en las distintas fases. Para poder detectar que una cantidad de cierto tipo de interacción en una fase es inapropiada, se considera cada interacción de cada tipo sobre un total de interacciones. Para definir qué porcentaje de interacciones de cada tipo hay en un grupo o una persona; Bales define rangos máximos y mínimos de cada interacción durante cada fase, y los valores que se observen fuera de esos rangos son los que se notan como cantidades inapropiadas, lo cual se puede observar en la Tabla 8.2.

CONFLICTOS	CONDUCTAS	LÍMITE SUPERIOR	LÍMITE INFERIOR
Comunicación	C6. Da información	30 %	14 %
	C5. Da opiniones	40 %	21 %
Evaluación	C4. Da sugerencias u orientación	11 %	4 %
	C3. Muestra acuerdo o aprueba	20 %	6 %
Control	C2. Muestra relajamiento	14 %	3 %
	C1. Muestra solidaridad	5 %	0 %
Decisión	C12. Muestra antagonismo	7 %	0 %
	C7. Pide información	11 %	2 %
Reducción de tensión	C8. Pide opinión	9 %	1 %
	C9. Pide sugerencias u orientación	5 %	0 %
Reintegración	C10. Muestra desacuerdo	13 %	3 %
	C11. Muestra tensión o molestia	10 %	1 %

Tabla 8.2. Conflictos colaborativos

Luego, Bales continuó refinando el modelo y modificándolo, obteniendo como resultado de esta investigación el modelo SYMLOG ("System for the Multiple Level Observation of Groups"). Este sistema, introducido en 1979, fue creado con el propósito de entender fenómenos tales como el liderazgo, la mecánica de grupos y las diferencias en eficiencia en el trabajo grupal. Como resultado, propone una clasificación de factores claves de personalidad que impactan en el desempeño grupal y un conjunto de herramientas para medirlos, generando en base a las mediciones para cada persona una medida en una escala correspondiente a los factores analizados. Del estudio de estas evaluaciones también pueden surgir valores óptimos en los que cada factor es deseable, y medidas que pueden implementarse para mejorar la efectividad del trabajo grupal. El análisis SYMLOG puede aplicarse a personas individualmente o a nivel de grupo (Bales, 1983).

Una evaluación de SYMLOG da como resultado un conjunto de valores numéricos que considera tres dimensiones, cada una con un lado positivo y un lado negativo ("Upward/Downward", "Positive/Negative" y "Forward/Backward"), que indican la presencia de ciertos rasgos distintos que resultan relevantes para el desempeño grupal. Cada dimensión se define de la siguiente manera:

- U/D Upward/Downward (Dominante vs. Sumiso). Un individuo caracterizado como U es activo y dominante en sus acciones. Un individuo caracterizado como D es relativamente callado y sumiso a los miembros dominantes.
- P/N Positive/Negative (Amistoso vs. No Amistoso). Un individuo caracterizado como P acuerda con otros miembros y sonríe al escuchar. Un individuo caracterizado como N es crítico, no sonríe, y no está habituado a escuchar a los demás.

- F/B Forward/Backward (Instrumentalmente controlado vs. Emocionalmente expresivo). Un individuo clasificado como F es controlado y tiene su atención puesta en la tarea grupal. Un individuo caracterizado como B expresa emociones y no está directamente interesado en la tarea principal del grupo.

Los autores de SYMLOG codificaron los Roles de Belbin dentro de las dimensiones SYMLOG. Los resultados revelaron que el cuestionario usado por Belbin para determinar el rol de equipo está enfocado principalmente en el comportamiento orientado a tareas. El comportamiento socio-emocional está representado solo por 10 de 70 items posibles en el cuestionario de Belbin. Por otra parte, ocho de los nueve roles se encuentran en la dimensión Forward del espacio SYMLOG, solo el Cerebro está en la dimensión Backward.

8.2 Freeling

Freeling es una librería de código abierto para el procesamiento multilingüe, que proporciona una amplia gama de funcionalidades de análisis para varios idiomas. En este trabajo fue utilizada para llevar a cabo el pre procesamiento del dataset.

El proyecto FreeLing se inició desde el centro TALP de la UPC (UPC Universitat Politècnica de Catalunya - Barcelona) para avanzar hacia la disponibilidad general de recursos y herramientas básicos de Procesamiento del Lenguaje Natural (PLN). Esta disponibilidad debería posibilitar avances más rápidos en proyectos de investigación y costes más reducidos en el desarrollo de aplicaciones industriales de PLN.

La herramienta se estructura como una librería que puede ser llamada desde cualquier aplicación de usuario que requiera servicios de análisis del lenguaje.

La arquitectura de la librería se basa en un enfoque de dos capas cliente-servidor: una capa básica de servicios de análisis lingüísticos (morfológico, morfosintáctico, sintáctico, etc) y una capa de aplicación que, actuando como cliente, realiza las peticiones deseadas a los analizadores y usa su respuesta según la finalidad de la aplicación. La arquitectura interna de la librería se estructura en dos tipos de objetos: los que almacenan datos lingüísticos con los análisis obtenidos y los que realizan el procesamiento en sí.

La naturaleza de código abierto del proyecto ha hecho también posible, junto con su arquitectura modular, incorporar el código de otros proyectos similares, como el módulo de desambiguación del sentido de las palabras. La versión actual soporta (a diferentes niveles de completitud) las siguientes lenguas: asturiano, catalán, castellano, galés, gallego, inglés, italiano, portugués, y ruso. Las funcionalidades existentes para cada idioma se resumen en la tabla de la Figura 8.1.

	as	ca	cy	en	es	gl	it	pt	ru
Tokenization	X	X	X	X	X	X	X	X	X
Sentence splitting	X	X	X	X	X	X	X	X	X
Number detection		X		X	X	X	X	X	X
Date detection		X		X	X	X		X	X
Morphological dictionary	X	X	X	X	X	X	X	X	X
Affix rules	X	X	X	X	X	X	X	X	
Multiword detection	X	X	X	X	X	X	X	X	
Basic named entity detection	X	X	X	X	X	X	X	X	X
B-I-O named entity detection				X	X	X			
Named Entity Classification				X	X				
Quantity detection		X		X	X	X		X	X
PoS tagging	X	X	X	X	X	X	X	X	X
WN sense annotation		X		X	X				
UKB sense disambiguation		X		X	X				
Shallow parsing	X	X		X	X	X		X	
Full/dependency parsing	X	X		X	X	X			
Coreference resolution					X				

Figura 8.1. Funcionalidades Freeing según idioma.

8.3 Weka

Weka es una plataforma de software para el aprendizaje automático y la minería de datos escrito en Java y desarrollado en la Universidad de Waikato. Weka es software libre distribuido bajo la licencia GNU-GPL. Esta es la librería utilizada para entrenar a los clasificadores y luego predecir los roles.

Weka soporta varias tareas estándar de minería de datos, especialmente, preprocesamiento de datos, clustering, clasificación, regresión, visualización, y selección. Todas las técnicas de Weka se fundamentan en la asunción de que los datos están disponibles en un fichero plano (flat file) o una relación, en la que cada registro de datos está descrito por un número fijo de atributos (normalmente numéricos o nominales, aunque también se soportan otros tipos).

La herramienta cuenta con un gran número de clasificadores, a los que se puede utilizar y entrenar, obteniendo modelos de predicción a partir de cualquier entrada que cumpla con el formato arff. A su vez, posee salidas claras que pueden ser analizadas para mejorar el entrenamiento y la precisión de los clasificadores (Frank et al., 2016).

Weka está diseñado como una herramienta orientada a la extensibilidad por lo que una de las propiedades más interesantes de este software, es su facilidad para añadir extensiones, modificar métodos etc. A su vez esta herramienta posee una versión GUI que a través de diferentes opciones permite analizar y profundizar el conocimiento del conjunto de datos, de esta forma es posible aplicar diferentes algoritmos tales como los rankeadores de atributos previo a la clasificación.

Nativamente Weka trabaja con un formato denominado arff, acrónimo de Attribute-Relation File Format. Este formato está compuesto por una estructura claramente diferenciada en tres partes:

1. Cabecera. Se define el nombre de la relación. Su formato es el siguiente:

relation <nombre-de-la-relación>

Donde <nombre-de-la-relación> es de tipo String. Si dicho nombre contiene algún espacio será necesario expresarlo entrecomillado.

2. Declaraciones de atributos. En esta sección se declaran los atributos que compondrán nuestro archivo junto a su tipo. La sintaxis es la siguiente:

@attribute <nombre-del-atributo>

Donde <nombre-del-atributo> es de tipo String teniendo las mismas restricciones que el caso anterior. Weka acepta diversos tipos:

- NUMERIC Expresa números reales .
- INTEGER Expresa números enteros.
- DATE Expresa fechas, para ello este tipo debe ir precedido de una etiqueta de formato entrecomillada. La etiqueta de formato está compuesta por caracteres separadores (guiones y/o espacios) y unidades de tiempo:
 - dd Día.
 - MM Mes.
 - yyyy Año.
 - HH Horas.
 - mm Minutos.
 - ss Segundos.
- STRING Expresa cadenas de texto.
- ENUMERADO El identificador de este tipo consiste en expresar entre llaves y separados por comas los posibles valores (caracteres o cadenas de caracteres) que puede tomar el atributo. Por ejemplo, si tenemos un atributo que indica el tiempo podría definirse:

@attribute tiempo {soleado,lluvioso,nublado}

3. Sección de datos. Declaramos los datos que componen la relación separando entre comas los atributos y con saltos de línea las relaciones:

@data

4,3.2

8.4 Equipo de trabajo

Según dice Belbin “Un equipo no es un conjunto de personas adscritas a determinados puestos de trabajo, sino una congregación de personas donde cada uno de ellos desempeña un rol que es comprendido por el resto de miembros. Los miembros de un equipo negocian entre sí el reparto de roles y desempeñan de manera más eficaz aquellos que les son más naturales” (Belbin, 1993).

El trabajo en equipo requiere en primer lugar, la existencia de una actividad u objetivo para cuya consecución forzosamente deben concurrir diferentes personas. Por esta razón, los equipos se configurarán con personas con habilidades complementarias, que están comprometidas con un propósito común.

Trabajar en equipo es asumir un conjunto de valores, y un espíritu que anima a un nuevo modelo de relaciones entre las personas, basado en la confianza, la comunicación, la sinceridad y el apoyo mutuo. Se privilegia la interdependencia activa, consciente y responsable de sus miembros, lo cual les integra en asumir la misión del equipo como propia.

Se puede concretar que un equipo tiene las siguientes características:

- Existe un liderazgo compartido. Aunque en todos los equipos siempre actúa alguien como líder, existe una cooperación entre todos los integrantes del grupo a la hora de gestionarlo.
- El equipo decide, discute y realiza el trabajo en conjunto.
- Responsabilidad individual y grupal compartida.
- El producto del trabajo es grupal, es decir, el equipo entiende que el trabajo conseguido es gracias a la unión de todos los integrantes.
- El equipo soluciona los problemas en conjunto.
- En el equipo de trabajo cada miembro domina una faceta, por lo que los integrantes del equipo son complementarios.
- Es necesaria la coordinación de todos los componentes del equipo, por lo que debe existir una buena comunicación.

Por otra parte, se puede establecer una diferencia con grupo de trabajo donde se observan otro tipo de características:

- Hay un sólo líder.
- Es el propio líder el que discute, decide y delega a los integrantes del grupo.
- Responsabilidad individual.
- El producto del trabajo es individual.
- Las reuniones son propuestas por el líder.
- En el grupo de trabajo, no cooperan entre ellos, por lo que los integrantes del grupo normalmente no se complementan ya que tienen una manera particular de funcionar.
- Simplemente interactúan entre ellos, pero no cooperan

No siempre resulta fácil, delimitar los “equipos” de las unidades tradicionales. Si bien no existe una respuesta clara en cuanto a la composición ideal de los equipos, pero varios autores coinciden en que los equipos compuestos por miembros heterogéneos, generalmente son más eficaces que los grupos compuestos por individuos similares al reunir una mayor diversidad de habilidades e información (Goodman et al., 1986). Además debe existir interdependencia entre los miembros.

A su vez, el tamaño ideal del equipo es una variable que depende del contexto, pero que afecta significativamente tanto al proceso como la efectividad del grupo. Generalmente, se coincide en que los equipos tienen que tener un tamaño pequeño, para poder optimizar todo su potencial, cuyo número fluctúa entre 5 y 12 miembros.

Algunos autores justifican el tamaño en base a los siguientes argumentos:

- El equipo pequeño involucra más, quizás porque las acciones de cada uno de los miembros son visibles y tienen impacto todo el tiempo. Una persona puede ocultarse o ausentarse durante algún tiempo en el equipo grande, mientras que en un equipo pequeño, se nota de inmediato.
- Los grupos más grandes están asociados con una menor satisfacción. A medida que aumenta el tamaño, se reducen las oportunidades de participación e interacción social, así como las habilidades de los miembros para identificarse con los logros del grupo.
- La coordinación es mucho más difícil en equipos grandes. Los equipos grandes, por tanto, son los que probablemente continúan necesitando gente que desempeñe funciones de liderazgo.
- El tamaño del grupo está relacionado inversamente con el desempeño individual.

9. Documentación de las herramientas

9.1. Herramienta de entrenamiento

9.1.1 Requisitos e instalación

La herramienta de entrenamiento está desarrollada bajo el lenguaje de programación Java, por lo que el único requisito necesario es contar con la Máquina Virtual de Java para poder ejecutarlo. En caso de no poseerla, el link de descarga es <https://www.java.com/es/download/>.

Una vez cumplidos todos los requisitos, se debe ejecutar el archivo JAR mediante la consola, a través del script “java -jar <jar-file-name>.jar”, ubicándose previamente en el Path donde se encuentra almacenado el mismo, como se observa en la Figura 9.1 (en ese caso el JAR se encuentra en C:\Users\franc).

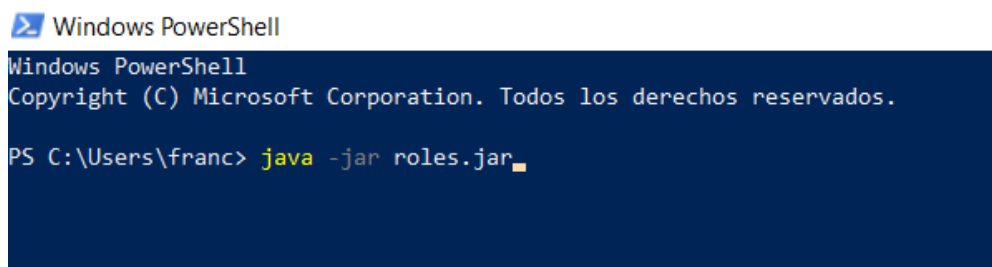


Figura 9.1. Ejecución herramienta entrenamiento

9.1.2 Manual de uso

a- Pre procesamiento de los datos

La herramienta cuenta con las opciones de pre procesar el conjunto de entradas requeridas o de ingresar archivos en caso de que el usuario cuente con los mismos de anteriores pre procesamientos.

Para seleccionar la opción se cuenta con un combo con las opciones “Preparar Dataset” o “Ingresar Arff” como se puede observar en la Figura 9.2.




Figura 9.2. Combo pre procesamiento

a.1- Pre procesar

Si se elige ingresar las entradas para pre procesar, el usuario inicialmente debe cargar el archivo que contiene las conversaciones con la cual desea entrenar al modelo, el cual debe ser de formato JSON,

similar al que se obtiene desde la página Google Takeout (<https://takeout.google.com/settings/takeout>).

Por otra parte, debe cargar las encuestas de autopercepción, en un archivo de formato xlsx (Excel) con la estructura presentada en la Figura 9.3.

	A	B	C	D
1	E-mail (cuenta personal de G-mail)	Id	Rol Natural	Rol Secundario
2	usuario@gmail.com	115867541511810988465	Colaborador;Monitor;Implementador;F Investigador de recursos;Especialista;	

Figura 9.3. Estructura excel encuestas autopercepción.

Como se observa, se requiere que el archivo cuente con cuatro columnas, la primera con el email del participante, la segunda con el ID de Google, la tercera con la lista de roles naturales separados por “;”, y la última con el rol secundario con el mismo formato que la anterior.

Por último, para finalizar con la carga de archivos, se deben cargar los feedbacks que los alumnos completan sobre sus compañeros de grupo al finalizar cada trabajo. Los mismos deben ser de formato xlsx con las columnas presentadas en la Figura 9.4.

	A	B	C	D	E	F	G	H	I	J	K
1	E-mail (cuenta personal de G-mail)	Id	Finalizador	Impulsor	Cerebro	Colaborador	Especialista	Implementado	Monitor	Investigador	Coordinador
2	usuario@gmail.com	115810		2			1			1	

Figura 9.4. Estructura excel feedbacks compañeros

En este caso el formato solicitado son once columnas, la primera con el email, la segunda con el ID de Google, y luego nueve columnas que van a constar de los roles de usuario ordenados de la siguiente manera: Finalizador, Impulsor, Cerebro, Colaborador, Especialista, Implementador, Monitor, Investigador y Coordinador. Las mismas deben contener la suma de las veces que sus compañeros de grupo lo caracterizaron según cada rol.

En la Figura 9.5 se presentan los botones encargados de la carga de archivos, junto con los nombre de los archivos cargados de ejemplo:




Figura 9.5. Carga de archivos pre procesamiento.

Como último paso previo a pre procesar las entradas, se requiere que el usuario ingrese la relación que van a tener las encuestas con los títulos de las conversaciones. Por ejemplo, si el *feedbacktp1_2016* forma parte de las conversaciones del TP1 (aquellas que en su nombre contengan TP1) se debe ingresar el nombre de la encuesta junto a TP1 (parte del título comunes a todas las conversaciones a la que pertenece la misma), tal como se demuestra en la Figura 6.




Figura 9.6. Relación encuestas con conversaciones

Luego, una vez seleccionado el tipo de procesamiento que desee, mediante el combo de la Figura 9.7, el usuario ya se encuentra en condiciones de pre procesar los archivos para obtener la entrada que se va a utilizar para entrenar. Cabe aclarar que el pre procesamiento para Fases y Fases Compuesto es el mismo, seleccionar una u otra opción toma importancia al momento del entrenamiento.



Figura 9.7. Tipo de procesamiento

En la Figura 9.8, se observa una visión general de la aplicación cuando se elige la opción de pre procesamiento, en la cual se encuentra el botón con la leyenda “Preprocesar” el cual envía a pre procesar todas las entradas.




Figura 9.8. Interfaz pre procesamiento

a.2- Ingreso directo de archivos

Si el usuario opta por la opción de ingresar directamente los archivos, la cantidad de los mismos varía según el tipo de procesamiento que elija. Si elige procesamiento Directo, debe ingresar dos archivos, uno para el entrenamiento del modelo general, y otro para el entrenamiento del modelo de grupo.

Si elige procesamiento en Fase o en Fase Compuesto en cambio, debe seleccionar cuatro archivos, dos por de la fase 2 (general y de grupo), y dos de la fase 3 (general y de grupo). En todos los casos, tanto directo como en fases, los mismos tienen que ser de formato arff.

Estos archivos pueden ser obtenidos de procesamientos previos, ya que los mismos se almacenan en el path donde está corriendo el ejecutable, con los nombres que se observa en la Figura 9.9.

 ResumenDirecto.arff	5/9/2018 11:46 p.	ARFF Data File	151 KB
 ResumenFase2.arff	6/9/2018 7:01 p. m.	ARFF Data File	144 KB
 ResumenFase2-viejo.arff	12/5/2018 5:44 p.	ARFF Data File	193 KB
 ResumenFase3.arff	6/9/2018 7:10 p. m.	ARFF Data File	156 KB
 ResumenFase3-viejo.arff	12/5/2018 5:44 p.	ARFF Data File	200 KB
 ResumenGrupoDirecto.arff	5/9/2018 11:39 p.	ARFF Data File	219 KB
 ResumenGrupoFase2.arff	6/9/2018 6:56 p. m.	ARFF Data File	142 KB
 ResumenGrupoFase3.arff	6/9/2018 7:05 p. m.	ARFF Data File	148 KB

Figura 9.9. Archivos para entrenar directo.

En la Figura 9.10 se observa la interfaz completa con la opción “Ingresar Arff” seleccionada, con los archivos cargados listos para entrenar al modelo.




Figura 9.10. Interfaz Ingresar Arff.

b- Entrenamiento de los modelos

Una vez obtenidos los archivos para entrenar a los modelos, el usuario debe seleccionar el clasificador que desea entrenar, mediante el combo presentado en la Figura 9.11.




Figura 9.11. Combo de clasificadores.

Cuando seleccione el clasificador deseado el usuario debe elegir la opción entrenar. Una vez que estén los resultados los mismos se presentan el para el usuario en el área de texto de la interfaz, como se observa en la Figura 9.12.




Figura 9.12. Presentación de resultados de entrenamiento.

A su vez, una vez que finaliza el entrenamiento, se almacenan los respectivos resultados en el path en el que está corriendo el ejecutable. En *pathEjecutable/results*, se crean las carpetas presentadas en la Figura 9.13.

procesamientoDirecto	23/4/2018 6:48 p.	Carpeta de archivos
procesamientoFases	23/4/2018 6:43 p.	Carpeta de archivos
procesamientoFasesCompuesto	24/9/2018 7:22 p.	Carpeta de archivos
procesamientoGrupos	25/9/2018 6:23 p.	Carpeta de archivos
resample_discretize	15/8/2018 6:21 p.	Carpeta de archivos

Figura 9.13. Carpetas de resultados

La carpeta *procesamientoDirecto* contiene dentro los resultados de la clasificación, junto con el modelo formado para el clasificador entrenado con el proceso directo. La carpeta *procesamientoFases* presenta un contenido similar a la anterior, solo que para la Fase 2 y Fase 3. Dentro de la carpeta *procesamientoGrupos* se encuentran dos carpetas iguales a las anteriores para el enfoque de grupo, es decir una para el procesamiento directo, y la restante para el de fases. A su vez, la carpeta *resample_discretize* posee las tres carpetas anteriores, pero con el resultado de aplicar los filtros de resample y discretize.

Por último se encuentra la carpeta *procesamientoFasesCompuesto*, la cual contiene los resultados y modelos de los tres clasificadores de la Fase 3 pertenecientes a cada tipo de rol. Esta carpeta también se encuentra dentro de *procesamientoGrupos*, y en *resample_discretize* con los resultados del aplicado de filtros.

9.2. Herramienta de predicción

9.2.1 Requisitos e instalación

Tanto el servicio como la aplicación van a estar contenidas en una imagen de Docker cada uno. Es por esto que el requisito principal para poder utilizar la herramienta es tener Docker instalado. El mismo puede ser descargado mediante la página oficial <https://www.docker.com/get-started>.

Dependiendo del sistema operativo, Docker brinda dos instaladores, el común o Docker Toolbox, que se utiliza para los SO más antiguos, donde instala todo lo necesario para configurar y utilizar el ambiente de la herramienta. Las mismas varían en la IP donde corren las imágenes, ya que la versión más reciente utiliza *localhost*, mientras que toolbox usa la IP *192.168.99.100*. Es por esto, que se cuenta con dos imágenes distintas de la aplicación de usuario, con las peticiones a la correspondiente dirección.

Para el uso de las imágenes se debe realizar la carga de las mismas mediante el comando *docker load --input image-name.tar*, tal como se muestra en las figuras 9.14 para el servicio de la aplicación y en la 9.15 para la interfaz de usuario.

```
Windows PowerShell
PS C:\Users\francod\Downloads> docker load --input tesis-services.tar
f1b91f8d903c: Loading layer [=====>] 103.9MB/103.9MB
d5ce7f246067: Loading layer [=====>] 15.87kB/15.87kB
5251addbe073: Loading layer [=====>] 14.85kB/14.85kB
41f50d293d3a: Loading layer [=====>] 5.632kB/5.632kB
b3c5147f2ed1: Loading layer [=====>] 3.072kB/3.072kB
24a1f607f8f2: Loading layer [=====>] 50.68MB/50.68MB
936cbcca9fe5: Loading layer [=====>] 1.696MB/1.696MB
0012b64eb25f: Loading layer [=====>] 466.8MB/466.8MB
ce3d2b6bf695: Loading layer [=====>] 19.84MB/19.84MB
6474d58d2cc3: Loading layer [=====>] 346.1kB/346.1kB
8f302d982a44: Loading layer [=====>] 346.6MB/346.6MB
ed523125e994: Loading layer [=====>] 201.5MB/201.5MB
bc83e9dd674c: Loading layer [=====>] 272.1MB/272.1MB
1947d1d79ce9: Loading layer [=====>] 33.79kB/33.79kB
5701962789b6: Loading layer [=====>] 267.1MB/267.1MB
cc448d37fa80: Loading layer [=====>] 11.2MB/11.2MB
313af9338395: Loading layer [=====>] 84.37MB/84.37MB
36e9a308d40e: Loading layer [=====>] 3.806MB/3.806MB
7b797937ec3e: Loading layer [=====>] 3.806MB/3.806MB
1456c1188820: Loading layer [=====>] 884.2kB/884.2kB
60de84088972: Loading layer [=====>] 884.2kB/884.2kB
4783410bba62: Loading layer [=====>] 1.555MB/1.555MB
4f5d3c2c7d27: Loading layer [=====>] 1.555MB/1.555MB
2a64b7151b7: Loading layer [=====>] 2.56kB/2.56kB
Loaded image: tesis-services:latest
```

Figura 9.14. Carga de imagen servicio de aplicación.

```
Windows PowerShell
PS C:\Users\francod\Downloads> docker load --input tesis-ui.tar
57bc50126946: Loading layer [=====>] 1.536kB/1.536kB
03e93ccdb6b: Loading layer [=====>] 3.072kB/3.072kB
626187769418: Loading layer [=====>] 258.6MB/258.6MB
cec8b7faca24: Loading layer [=====>] 211.8MB/211.8MB
Loaded image: tesis-ui:latest
```

Figura 9.15. Carga de imagen interfaz de usuario de aplicación.

Una vez cargadas las imágenes se procede a ejecutarlas, mediante el comando *docker run*. En el mismo se debe publicar el puerto expuesto en la imagen con algún puerto del host. En las siguientes figuras se detalla lo anterior:

```
Windows PowerShell
PS C:\Users\francod\Downloads> docker run -it -p 8080:8080 -p 9990:9990 tesis-services


JBoss Bootstrap Environment
JBoss_HOME: /opt/jboss/wildfly
JAVA: /usr/lib/jvm/java-8-openjdk-amd64/bin/java
JAVA_OPTS: -server -Xms64m -Xmx512m -XX:MetaspaceSize=96m -XX:MaxMetaspaceSize=256m -Djava.net.preferIPv4Stack=true -Djboss.modules.system.pkgs=org.jboss.byteman -Djava.awt.headless=true

18:13:51,881 INFO [org.jboss.modules] (main) JBoss Modules version 1.7.0.Final
18:13:53,684 INFO [org.jboss.msc] (main) JBoss MSC version 1.3.2.Final
18:13:53,736 INFO [org.jboss.threads] (main) JBoss Threads version 2.3.1.Final
18:13:54,214 INFO [org.jboss.as] (MSC service thread 1-3) WFLYSRV0049: WildFly Full 12.0.0.Final (WildFly Core 4.0.0.Final) starting
18:13:59,292 INFO [org.jboss.as.controller.management-deprecated] (Controller Boot Thread) WFLYCTL0028: Attribute 'security-realm' in the resource at address '/core-service=management/management-interface=http-interface' is deprecated, and may be removed in a future version. See the attribute description in the output of the read-resource-description operation to learn more about the deprecation.
18:13:59,292 INFO [org.jboss.as.controller.management-deprecated] (Controller Boot Thread) WFLYCTL0028: Attribute 'security-realm' in the resource at address '/subsystem=undertow/server=default-server/https-listener=https' is deprecated, and may be removed in a future version. See the attribute description in the output of the read-resource-description operation to learn more about the deprecation.
18:13:59,294 INFO [org.wildfly.security] (ServerService Thread Pool -- 17) ELY00001: WildFly Elytron version 1.2.2.Final
18:14:05,713 INFO [org.jboss.as.repository] (ServerService Thread Pool -- 3) WFLYDR0001: Content added at location /opt/jboss/wildfly/standalone/data/content/6b/614c499594cab1/a26bea3decf94b9e43f323d/content
18:14:05,909 INFO [org.jboss.as.server] (Controller Boot Thread) WFLYSRV0039: Creating http management service using socket-binding (management-http)
18:14:06,013 INFO [org.xnio] (MSC service thread 1-3) XNIO version 3.6.2.Final
18:14:06,026 INFO [org.xnio.nio] (MSC service thread 1-3) XNIO NIO Implementation Version 3.6.2.Final
18:14:06,222 WARN [org.jboss.as.txn] (ServerService Thread Pool -- 58) WFLYTX0013: The node-identifier attribute on the /subsystem=transactions is set to the default value. This is a danger for environments running multiple servers. Please make sure the attribute value is unique.
18:14:06,257 INFO [org.wildfly.extension.io] (ServerService Thread Pool -- 41) WFLYIO001: Worker 'default' has auto-configured to 4 core threads with 32 task threads based on your 2 available processors
18:14:06,265 INFO [org.jboss.as.jsf] (ServerService Thread Pool -- 48) WFLYJSF0007: Activated the following JSF Implementations: [main]
18:14:06,276 INFO [org.jboss.as.security] (ServerService Thread Pool -- 57) WFLYSEC0002: Activating Security Subsystem
18:14:06,299 INFO [org.jboss.as.jaxrs] (ServerService Thread Pool -- 43) WFLYRS0016: RESTEasy version 3.5.0.Final
18:14:06,328 INFO [org.jboss.as.naming] (ServerService Thread Pool -- 50) WFLYNAM0001: Activating Naming Subsystem
18:14:06,332 INFO [org.jboss.as.webservices] (ServerService Thread Pool -- 60) WFLYWS0002: Activating WebServices Extension
18:14:06,416 INFO [org.jboss.as.clustering.infinispan] (ServerService Thread Pool -- 42) WFLYCLINF0001: Activating Infinispan subsystem
```

Figura 9.16. Run imagen servicio de aplicación.

El comando *-it* permite ejecutar el contenedor interactivo, es decir, que al cancelar la ejecución mediante *ctrl + c*, se detiene el contenedor y el servidor Wildfly que se encuentra dentro del mismo. Por otra parte, el comando *-p* permite, como se dijo anteriormente, publicar el puerto expuesto en la imagen. En este caso el puerto 8080 del Docker, que es donde va a estar levantado el servicio, se

publica en el puerto 8080 de localhost, mientras que el puerto de la consola de administración del servidor, expuesta en el puerto 9990, también se publica localmente en el mismo.



```
PS C:\Users\francod\Downloads> docker run -it -p 3000:3000 tesis-ui_
```

Figura 9.17. Run imagen servicio de aplicación.

En el ejemplo de la Figura 9.17 de la interfaz de usuario se expone el puerto 3000 en el mismo puerto del host local, y también está siendo ejecutado interactivamente.

Una vez corriendo las imágenes, ya se puede utilizar la interfaz accediendo a localhost o a la IP de docker-machine según corresponda, como se muestra en las figuras 9.18, y 9.19.

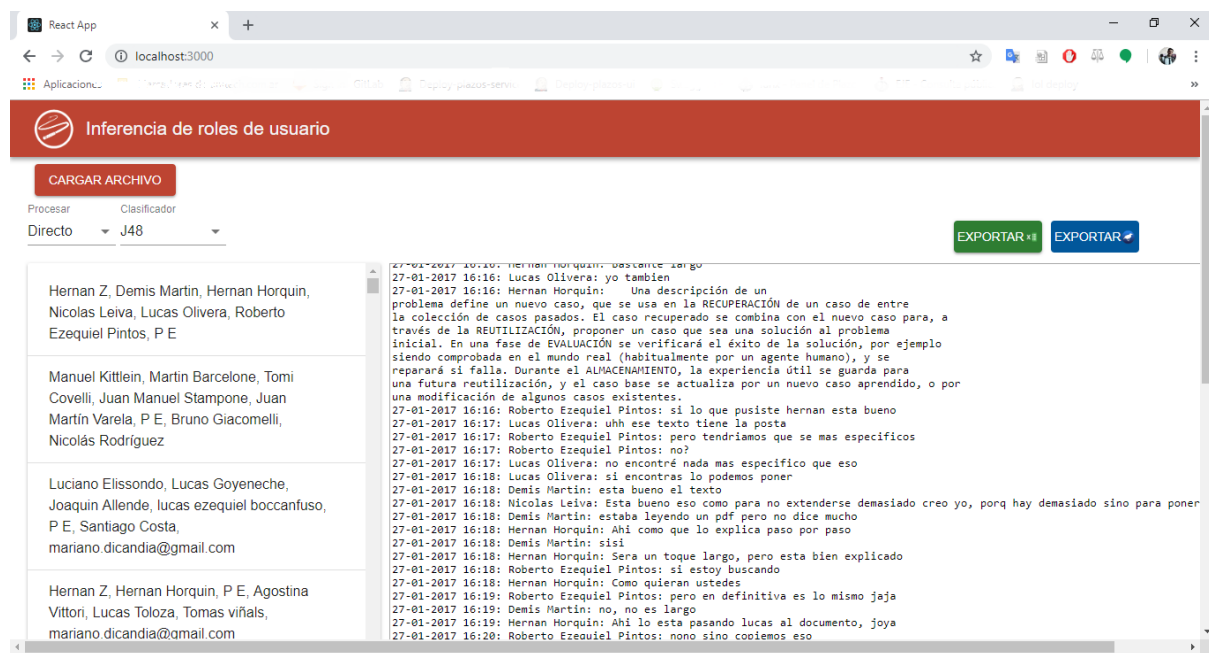


Figura 9.18. Aplicación ejecutándose en localhost.

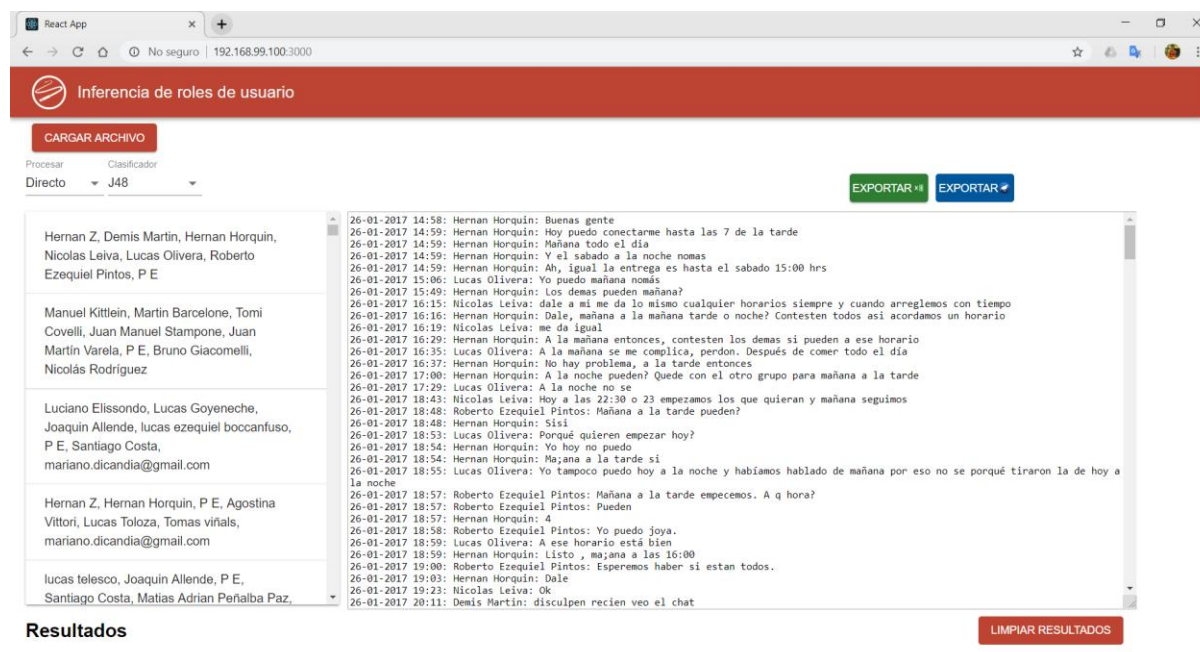


Figura 9.19. Aplicación ejecutándose en IP de docker machine.

9.2.2 Manual de uso

a- Ingreso de archivo

La aplicación web de modelado de usuario utiliza el mismo archivo que la herramienta de entrenamiento, obtenido de Google Takeout. La misma al iniciar contiene un pantalla con la explicación de donde obtener el archivo, como se observa en la Figura 9.20.




Figura 9.20. Carga de archivo

b- Modelado de usuarios

Una vez cargado el archivo, se presenta una pantalla con la lista de conversaciones que contiene el mismo, como se puede observar en la Figura 9.21, las cuales debe seleccionar para procesar.

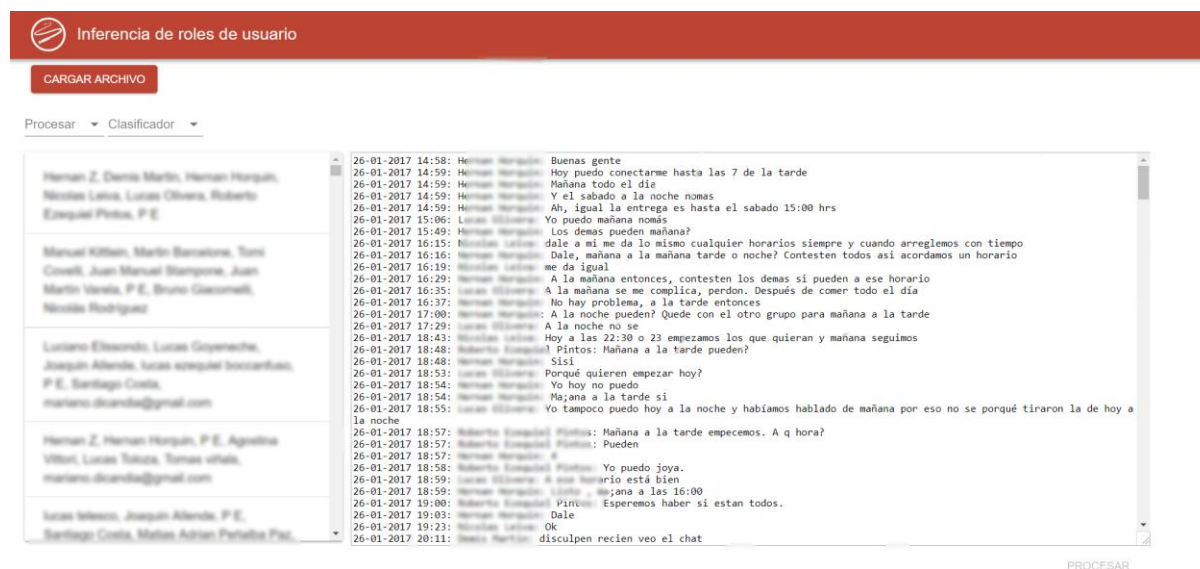


Figura 9.21. Pantalla inicial con conversación cargada

Como se puede ver en la Figura anterior, el botón *Procesar* está deshabilitado. Esto se debe a que el usuario para poder procesar la conversación debe elegir el tipo de procesamiento, es decir directo, en fases o en fases compuesto, y el clasificador con el que desea predecir. Para esto, debe utilizar los combos presentados en la Figura 9.22 en el caso de que seleccione procesar directo, en la Figura 9.23 en caso de que elija predecir en fases o en la Figura 9.24 para el procesamiento de fases compuesto.



Figura 9.22. Filtros procesamiento directo



Figura 9.23. Filtros procesamiento en fases




Figura 9.24. Filtros procesamiento en fases compuesto.

Una vez cargado todo lo requerido, el botón Procesar se habilita como se muestra en la Figura 9.25, y el usuario se encuentra en condiciones de modelar a los usuarios de la conversación que desee.

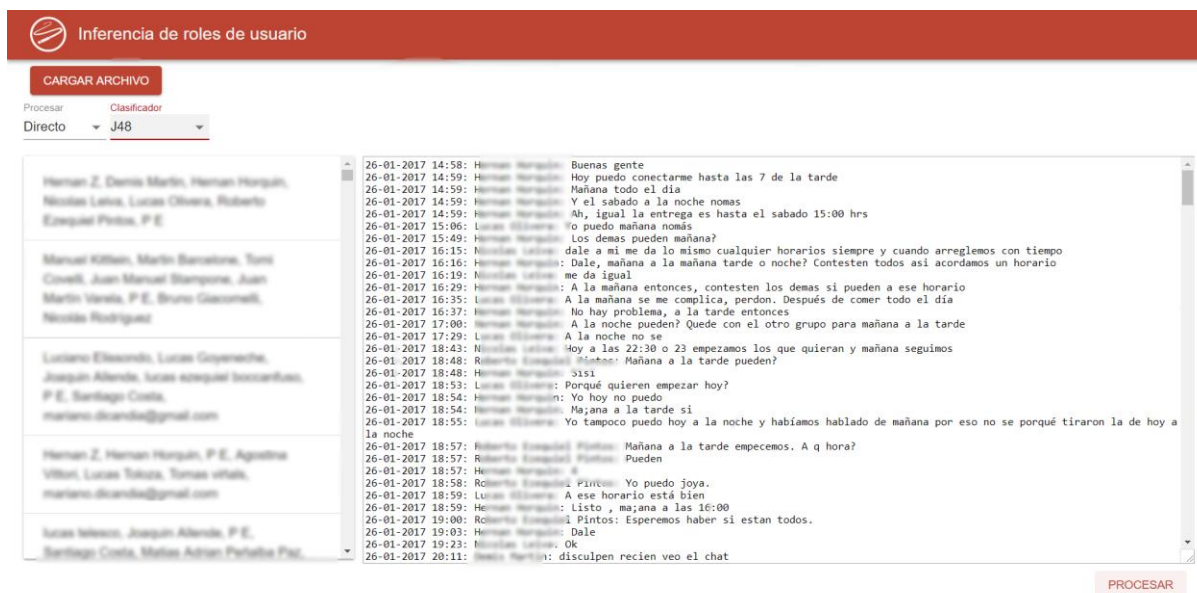


Figura 9.25. Pantalla con botón procesar activo.

Una vez realizada la predicción, se presentan los roles resultantes en una lista como se observa en la Figura 9.26.

Resultados

	Usuario 1 Colaborador
	Usuario 2 Finalizador
	Usuario 3 Cerebro
	Usuario 4 Impulsor
	Usuario 5 Monitor

Figura 9.26. Lista de resultados.

Si el usuario desea, puede observar los detalles del análisis individual de cada integrante, pulsando sobre el ítem de la lista de interés. Los mismos se presentan de acuerdo a como se muestra en la Figura 9.27.

Resultados

	Usuario 3 Cerebro
Rol asignado por compañeros: Impulsor Mensajes en introducción: 0.071429 Mensajes en desarrollo: 0.928571 Mensajes en finalización: 0 Dominante (SYMLOG): 0.035714 Sumiso (SYMLOG): 0.964286 Amistoso (SYMLOG): 0.464286 No amistoso (SYMLOG): 0.035714 Tarea (SYMLOG): 0.5 Socio emocional (SYMLOG): 0.5 Participación 0.08805	

Figura 9.27. Detalles del resultado.

c- Exportar

El usuario una vez que proceso al menos una conversación, se encuentra en condiciones de exportar los resultados. El mismo tiene la opción de exportar a Excel (un archivo.xlsx), o un archivo ARFF. En la Figura 9.28 se puede observar los botones correspondientes a estas funcionalidades.

Inferencia de roles de usuario

CARGAR ARCHIVO

Procesar Clasificador
Directo J48

EXPORTAR EXPORTAR

Resultados

LIQUIAR RESULTADOS

26-01-2017 14:58: Herman Horguin: Buenas gente
 26-01-2017 14:59: Herman Horguin: Hoy puedo conectarme hasta las 7 de la tarde
 26-01-2017 14:59: Herman Horguin: Mañana todo el día
 26-01-2017 14:59: Herman Horguin: Y el sábado a la noche nomás
 26-01-2017 14:59: Herman Horguin: Ah, igual la entrega es hasta el sábado 15:00 hrs
 26-01-2017 15:06: Herman Horguin: Yo puedo mañana nomás
 26-01-2017 15:49: Herman Horguin: Los demás pueden mañana?
 26-01-2017 16:15: Herman Horguin: Dale a mí me da lo mismo cualquier horarios siempre y cuando arreglemos con tiempo
 26-01-2017 16:16: Herman Horguin: Dale, mañana a la mañana tarde o noche? Contesten todos así acordamos un horario
 26-01-2017 16:19: Herman Horguin: Me da igual
 26-01-2017 16:29: Herman Horguin: A la mañana entonces, contesten los demás si pueden a ese horario
 26-01-2017 16:35: Herman Horguin: A la mañana se me complica, perdon. Después de comer todo el día
 26-01-2017 16:37: Herman Horguin: No hay problema, a la tarde entonces
 26-01-2017 17:00: Herman Horguin: A la noche pueden? Quede con el otro grupo para mañana a la tarde
 26-01-2017 17:29: Herman Horguin: A la noche no se
 26-01-2017 18:43: Herman Horguin: Hoy a las 22:30 o 23 empezamos los que quieran y mañana seguimos
 26-01-2017 18:48: Roberto Gonzalez: Mañana a la tarde pueden?
 26-01-2017 18:48: Herman Horguin: Sisi
 26-01-2017 18:53: Herman Horguin: Porqué quieren empezar hoy?
 26-01-2017 18:54: Herman Horguin: Yo hoy no puedo
 26-01-2017 18:54: Herman Horguin: Mañana a la tarde si
 26-01-2017 18:55: Herman Horguin: Yo tampoco puedo hoy a la noche y habíamos hablado de mañana por eso no se porqué tiraron la de hoy a la noche
 26-01-2017 18:57: Roberto Gonzalez: Mañana a la tarde empezemos. A q hora?
 26-01-2017 18:57: Herman Horguin: Pueden
 26-01-2017 18:57: Herman Horguin: 4
 26-01-2017 18:58: Roberto Gonzalez: Pasa: Yo puedo joya.
 26-01-2017 18:59: Herman Horguin: A ese horario está bien
 26-01-2017 18:59: Herman Horguin: Listo , mañana a las 16:00
 26-01-2017 19:00: Herman Horguin: Esperemos haber si estan todos.
 26-01-2017 19:03: Herman Horguin: Dale
 26-01-2017 19:23: Herman Horguin: Ok
 26-01-2017 20:11: Juan Martin: disculpen recién veo el chat

Figura 9.28. Botones de exportar.

Si el usuario selecciona la opción de exportar a Excel, obtiene un archivo como el de la Figura 9.29:

Archivo Inicio Insertar Diseño de página Fórmulas Datos Revisar Vista Ayuda ¿Qué desea hacer?												
G8												
1	Rol	Nombre	Rol Companeros	Participacion Intro	Participacion Desa	Participacion Fin	Dominante	Sumiso (SYM	Amistoso (SY	No-amistoso (SY	Tarea (SYM)	Socio-Emocional (S
2	colaborador	Usuario1	implementador	0.185567	0.793814	0.020619	0.051546	0.948454	0.505155	0	0.494845	0.505155
3	finalizador	Usuario2	coordinador	0.093023	0.906977	0	0	0.232558	0.767442	0	0.232558	0.767442
4	cerebro	Usuario3	impulsor	0.071429	0.928571	0	0.035714	0.964286	0.464286	0.035714	0.5	0.5
5	impulsor	Usuario4	implementador	0.068966	0.873563	0.057471	0.045977	0.954023	0.62069	0.034483	0.344828	0.655172
6	monitor	Usuario5	monitor	0.111111	0.857143	0.031746	0.095238	0.904762	0.396825	0.079365	0.52381	0.47619
7												
8												

Figura 9.29. Archivo.xlsx exportado.

En cambio, si se opta por exportar a ARFF, se descarga un archivo como el que se muestra en la Figura 9.30:

```
@relation 'chat-weka.filters.unsupervised.attribute.Remove-R1-3,5-5'

@attribute class_rol {finalizador,impulsor,cerebro,colaborador,especialista,implementador,monitor,investigador,coordinador}
@attribute nombre string
@attribute class_rol_companeros {finalizador,impulsor,cerebro,colaborador,especialista,implementador,monitor,investigador,coordinador}
@attribute C1 numeric
@attribute C2 numeric
@attribute C3 numeric
@attribute C4 numeric
@attribute C5 numeric
@attribute C6 numeric
@attribute C7 numeric
@attribute C8 numeric
@attribute C9 numeric
@attribute C10 numeric
@attribute C11 numeric
@attribute C12 numeric
@attribute R1 numeric
@attribute R2 numeric
@attribute R3 numeric
@attribute R4 numeric
@attribute A1 numeric
@attribute A2 numeric
@attribute Honorio1 numeric
@attribute Honorio2 numeric
@attribute Honorio3 numeric
@attribute dominante_symlog numeric
@attribute sumiso_symlog numeric
@attribute amistoso_symlog numeric
@attribute no_amistoso_symlog numeric
@attribute tarea_symlog numeric
@attribute socio_emocional_symlog numeric
@attribute cant_mensajes numeric

@data
colaborador,'Usuario1',implementador,0.154639,0.010309,0.340206,0.041237,0.113402,0.28866,0.041237,0.010309,0,0,0,0.505155,0.0.051546,
0.443299,0.505155,0.494845,0.185567,0.793814,0.020619,0.051546,0.948454,0.505155,0.494845,0.505155,0.305031
finalizador,'Usuario2',coordinador,0.023256,0.046512,0.162791,0.162791,0.116279,0.488372,0,0,0,0.232558,0,0,0.767442,0.232558,
0.767442,0.093023,0.906977,0,0,1,0.232558,0.767442,0.232558,0.13522
cerebro,'Usuario3',impulsor,0.035714,0.107143,0.321429,0.107143,0.392857,0,0,0.035714,0,0,0.464286,0.035714,0.5,0.5,0.5,0.071429,
0.928571,0,0.035714,0.964286,0.464286,0.035714,0.5,0.5,0.08885
impulsor,'Usuario4',implementador,0.091954,0.057471,0.471264,0.011494,0.057471,0.264368,0,0.011494,0,0.022989,0.011494,0.62069,
0.034483,0.011494,0.333333,0.655172,0.344828,0.068966,0.873563,0.057471,0.045977,0.954023,0.62069,0.034483,0.344828,0.655172,0.273585
monitor,'Usuario5',monitor,0.190476,0.047619,0.15873,0.142857,0.063492,0.301587,0,0.015873,0,0.063492,0.015873,0.396825,0.079365,0.015873,0.507937,
0.47619,0.52381,0.111111,0.857143,0.031746,0.095238,0.904762,0.396825,0.079365,0.52381,0.47619,0.198113
```

Figura 9.30. Archivo ARFF exportado.

d- Armado de grupos

Para que se habilite la opción de armado de grupos, el usuario debe haber procesado al menos tres conversaciones, ya que se considera un número óptimo de participantes para distribuirlos en grupos. En la Figura 9.31 se muestra la visibilidad del botón encargado de esta funcionalidad.

Figura 9.32. Botón armar grupos.

Una vez que se selecciona la opción, se presenta un modal como el de la Figura 9.33 en el que se solicita al usuario que ingrese la cantidad de personas que quiere que conformen a los grupos.




Figura 9.33. Modal tamaño de grupos.

Una vez calculados los grupos, se presenta la lista de los mismos, la cual se puede ver en la Figura 9.34.

Grupos	
Integrantes:	Usuario1 (colaborador, implementador), Usuario2 (finalizador, coordinador), Usuario3 (cerebro, impulsor), Usuario4 (especialista, monitor), Usuario5 (impulsor, investigador).
Integrantes:	Usuario6 (impulsor, implementador), Usuario7 (finalizador, coordinador), Usuario8 (especialista, monitor), Usuario9 (cerebro, implementador), Usuario10 (colaborador, monitor).
Roles faltantes:	investigador.
Integrantes:	Nicolas Rodriguez (finalizador, monitor), Joaquin Allende (coordinador, implementador), Matias Adrian Penabaz Paz (colaborador, impulsor), Juan Martin Varela (especialista, finalizador), Agustin Freiburger (cerebro, monitor).
Roles faltantes:	investigador.
Integrantes:	Mariano diandio@gmail.com (especialista, monitor), Franco Oliva (cerebro, coordinador), Desconocido (finalizador, finalizador), Lucas Goyenache (especialista, monitor), Lucas Olivera (monitor, monitor).
Roles faltantes:	implementador, colaborador, investigador, impulsor.
Integrantes:	Santiago Costa (especialista, monitor), Alan Hase (coordinador, coordinador), Nicolas Laugas (cerebro, monitor), Lucas Goyenache (especialista, monitor), Lucas Olivera (monitor, monitor).
Roles faltantes:	implementador, colaborador, finalizador, investigador, impulsor.

EXPORTAR CERRAR

Figura 9.34. Lista de grupos.

Como se puede observar, se cuenta con la opción de exportar la información de los mismos. Si se elige realizarlo, se descarga un archivo TXT como el de la Figura 9.35.

```

Grupo 1:
Integrantes: Usuario1 (colaborador, implementador), Usuario2 (finalizador, coordinador), Usuario3 (cerebro, impulsor),
Usuario4 (especialista, monitor), Usuario5 (impulsor, investigador).
-----
Grupo 2:
Integrantes: Usuario6 (impulsor, implementador), Usuario7 (finalizador, coordinador), Usuario8 (especialista, monitor),
Usuario9 (cerebro, implementador), Usuario10 (colaborador, monitor).
Roles faltantes: investigador.
-----

```

Figura 9.35. Archivo de grupos exportado.

Referencias

Agrawal, R.; Mannila, H.; Srikant, R.; Toivonen, H.; and Verkamo, I. (1996). Fast Discovery of Association Rules. In *Advances in Knowledge Discovery and Data Mining*, eds. U. Fayyad, G. Piatetsky-Shapiro, P. Smyth, and R. Uthurusamy, 307–328.

Albert Simón Mira (2015). Estudio de los roles de equipo en el sector de la auditoría contable.

Aritzeta, A., & Ayestarán, S. (2003). “Aplicabilidad de la Teoría de los Roles de Equipo de Belbin: un estudio longitudinal comparativo con equipos de trabajo”. *Rev. Psicología Gral y Aplic.*

Bales, R. F. (1950). Interaction process analysis; a method for the study of small groups.

Bales, R.F (1983). Overview of the SYMLOG System: Measuring and Changing Behavior in Groups.

Beck, Dieter, and Rudolf Fisch.(2005) Dynamics of Group Role Diversity in Work Teams: Belbin’s Team Role Approach. In *Analysis of Social Interaction Systems*, Hare, A.P., Sjovold, E., Baker, H.G., and Powers, J. (Eds.). Lanham, Maryland: University Press of America, Inc., pp. 17-34.

BELBIN, R.M (1993). Roles de equipo en el trabajo. Londres: William Heinemann Ltd.

Berdun, F., Armentano, M. G., & Amandi, A. (2016, November). Inferencia de roles de equipo a partir de conductas colaborativas detectadas en interacciones textuales. In *Simposio Argentino de Inteligencia Artificial (ASAI 2016)-JAIIO 45* (Tres de Febrero, 2016).

Brodahl, C., Hadjerrouit, S., & Hansen, N. K. Collaborative writing with Web 2.0 technologies: education students' perceptions (2011).

Cireşan, Dan Claudiu; Meier, Ueli; Gambardella, Luca Maria; Schmidhuber, Jürgen (21 de septiembre de 2010). «Deep, Big, Simple Neural Nets for Handwritten Digit Recognition». *Neural Computation*.

Cortez Vásquez, A., Pariona Quispe, J., & Huayna, A. M. (2014). Procesamiento de Lenguaje Natural. *Revista de investigación de Sistemas e Informática*, 6(2), 45-54.

Dubiau, L. (2013). Procesamiento de Lenguaje Natural en Sistemas de Análisis de Sentimientos.

Eibe Frank, Mark A. Hall, and Ian H. Witten (2016). The WEKA Workbench. Online Appendix for "Data Mining: Practical Machine Learning Tools and Techniques", Morgan Kaufmann, Fourth Edition.

F.D. Berdun et al., Classification of collaborative behavior from free text interactions, *Computers and Electrical Engineering* (2017).

Finholt, T.A. & Teasley, S.D. (1998). Psychology: The Need for Psychology in Research on Computer-Supported Cooperative Work. *Social Science Computer Review*, 16, 40-52.

Francisco Serrano, Franco D. Berdun, Marcelo G. Armentano (2017). Identificación automática de usuarios conflictivos en grupos de Facebook.

Franco D. Berdun , Marcelo G. Armentano , Luis S. Berdun , Matías Cincunegui , Building SYMLOG profiles with an online collaborative game, *International Journal of Human-Computer Studies* (2018).

GLINZ, P.E. (2005) Un acercamiento al trabajo colaborativo. En: *Revista Iberoamericana de Educación*. De los lectores, Nº 35/2.

Goodman, P.S., Ravlin, E. C., & Argote, L. (1986). Current Thinking About Groups: Setting the stage for new ideas. In P. S Goodman, Designing Effective Work Groups. San Francisco, CA: Jossey-Bass.

Henry Fernando Vallejo Ballesteros a ; Edelmira Guevara Iñiguez b ; Segundo Rafael Medina Velasco c (2018). Minería de Datos Revista Científica Mundo de la Investigación y el Conocimiento. Vol. 2 núm., especial, mayo, ISSN: 2588-073X, pp. 339-349.

Ian H. Witten, Eibe Frank. Morgan Kaufmann (1999). Introducción a la minería de datos. J. Hernández, J. Ramírez . Data Mining: Practical Machine Learning Tools and Techniques.

Jeria, V. H. (2007). Minería web de uso y perfiles de usuario: aplicaciones con lógica difusa. Granada

Fischer, Gerhard (2001), «User Modeling in Human-Computer Interaction», User Modeling and User-Adapted Interaction 11: 65-68.

J.M. Alberola et al., An artificial intelligence tool for heterogeneous team formation in the classroom, Knowledge-Based Systems (2016), <http://dx.doi.org/10.1016/j.knosys.2016.02.010>

Joan Anton Ros Guasch (2006). Análisis de Roles de Trabajo en Equipo: Un enfoque centrado en comportamientos.

Johnson, Addie; Taatgen, Niels (2005), «User Modeling», Handbook of human factors in Web design, Lawrence Erlbaum Associates, pp. 424-439.

José Manuel Molina López, Jesús García Herrero (2006). Técnica de análisis de datos. Aplicaciones prácticas utilizando Microsoft Excel y Weka.

Kieser, A. L. & Ortiz-Golden, F. (2009). Using Online Office Applications: Collaboration Tools for Learning. Distance Learning, 6, (1), 41-46.

Laura Dabbish, Colleen Stuart, Jason Tsay y Jim Herbsleb. Social coding in GitHub. En ACM 2012 conference on Computer Supported Cooperative Work, páginas 1277–1286, New York, New York, USA, 2012. ACM Press, ISBN 9781450310864.

Leight Tharp, T. (2010). —Wiki, Wiki, Wiki—WHAT?|| Assessing Online Collaborative Writing. English Journal, 99.5, 40-46.

Luis M. de Campos, Juan M. Fernández-Luna and Juan F. Huete (2004). «Bayesian networks and information retrieval: an introduction to the special issue». Information Processing & Management (Elsevier).

Mansilla, P. S., Costaguta, R., & Missio, D. (2012). Habilidades de E-tutores en Grupos Colaborativos. Experiencias Innovadoras en Investigación Aplicada. Ediciones DASS-UCSE, Jujuy, 687-704.

Matías Nicoletti, José María Balmaceda, Silvia Schiaffino, Daniela Godoy. II Congresso Brasileiro de Informática na Educação (CBIE 2013). Influencia de estilos de aprendizaje y roles de equipo en el aprendizaje colaborativo soportado por computadoras.

Montaner, Miguel; López, Beatriz; De La Rosa, Josep Lluís (2003), «A Taxonomy of Recommender Agents on the Internet,», Artif. Intell. Rev. 19: 285-330.

Schmidhuber, J. (2015). «Deep Learning in Neural Networks: An Overview». Neural Networks 61: 85-117.

Weiss, S. H., & Indurkha, N. (1998). *Predictive Data Mining: A Practical Guide*. San Francisco, CA: Morgan Kaufmann Publishers.

Zhou, W., Simpson, E., & Domizi, D. P. (2012). Google Docs in an Out-of-Class Collaborative Writing Activity. *International Journal of Teaching and Learning in Higher Education*, 24(3), 359-375.