

**UNIVERSIDAD NACIONAL DEL CENTRO DE LA
PROVINCIA DE BUENOS AIRES**



**FACULTAD DE CIENCIAS EXACTAS
TESIS DE GRADO - INGENIERÍA DE SISTEMAS**

**HelpMePublish - Una herramienta de soporte para la selección de
revistas científicas**

Alumnos: Elizalde, Federico
Leiva, Nicolas Guillermo

Directores: Armentano, Marcelo Gabriel
Alonso, Diego Gabriel.

Agradecimientos

Agradecemos en primer lugar a nuestras familias que nos apoyaron y ayudaron en cada momento de este camino. También a nuestros directores Dr Marcelo Armentano y Dr Diego Alonso, además de amigo, por acercarnos esta propuesta de tesis y compartir el mismo entusiasmo que nosotros en la realización de este proyecto, con predisposición y paciencia. También queremos hacer llegar nuestro agradecimiento a todos los profesionales que formaron parte de nuestro ciclo académico, sin su vocación docente no podríamos haber realizado este logro. A todos ellos, muchas gracias.

1. Introducción

En este capítulo, se describe de manera general el contexto, la motivación y el objetivo del presente trabajo. Además, se presenta la estructura del documento para una mejor comprensión del resto de los capítulos.

1.1. Contexto

La comunicación científica es un eje fundamental en la generación de conocimiento. Debido al uso generalizado de las nuevas tecnologías, los canales de difusión tradicionales y electrónicos se han diversificado, al tiempo que han incrementado su cantidad. De entre los múltiples canales que existen para comunicar el conocimiento, las revistas científicas son consideradas el principal medio de difusión entre generadores de conocimientos.

Las revistas científicas son publicaciones periódicas pertenecientes a una editorial en particular que, entre otras funciones, registran los avances e innovaciones en diversas áreas de la ciencia. En consecuencia, los científicos publican para contribuir al progreso de la ciencia y, además, atribuir autoría o participación respecto a dichos avances en su área de estudio [1].

Para los científicos, elegir la revista adecuada donde publicar no es tarea fácil y son varios los criterios que se han de tener en cuenta. Uno de los principales criterios considerados por los científicos es el alcance de la revista. El alcance de una revista es fundamental para corroborar que la contribución de su investigación concuerda con el área de interés de la misma [2]. Sin embargo, existen otros aspectos que también deben ser tenidos en cuenta como, quiénes son los lectores, cuál es el impacto de la revista, cuáles son los plazos de revisión y de publicación, cuál es la periodicidad y el número de artículos por edición, entre otros.

Además del canal de recepción principal, cada revista puede abrir canales alternativos como ediciones especiales (*special issues*) o abrir convocatorias a contribución de artículos (*call for papers*) [3]. Los *special issues* se enfocan sobre temas específicos dentro del alcance de la revista y, en ocasiones, están asociados a un evento científico como una conferencia o *workshop*. Los *call for papers* son llamados abiertos a recepción de trabajos académicos durante un determinado tiempo sobre un tema en particular. La diferencia fundamental entre ambos radica en que los *special issues* son administrados por editores invitados, mientras que, los *call for papers* son administrados por el grupo de editores estable de la revista. Usualmente, las editoriales no cuentan con servicios de suscripción o notificación sobre la apertura de estos canales de recepción alternativos. Por ende, los interesados deben ingresar regularmente a cada website particular para consultar la existencia de *special issues* o *call for papers*.

Algunas editoriales proporcionan sistemas de búsqueda¹ donde es posible, a través del título y/o resumen de una investigación, encontrar las diferentes revistas en las cuáles se podría publicar dicha investigación. Algunos de ellos, permiten refinar las búsquedas a través de aspectos como palabras claves, factor de impacto, entre otros. No obstante, debido a que cada editorial trabaja en forma independiente a las demás, los científicos deben aprender a usar múltiples sistemas de búsqueda y, una vez obtenidos los resultados, deben compararlos manualmente [4].

Por los motivos mencionados anteriormente, se observa que es necesario proveer de herramientas y aplicaciones que faciliten el procesamiento del gran número de editoriales y revistas disponibles, y que sirvan a su vez como soporte a los investigadores a la hora de seleccionar la revista que mejor se adecúe a su investigación.

1.2. Motivación

La divulgación del conocimiento científico es una responsabilidad de todo aquel que investiga, en breve, involucra comunicar resultados a la comunidad formada por los especialistas en la materia.

Uno de los principales retos del investigador a la hora de escribir un artículo es encontrar la revista indicada para su publicación. En ocasiones, es necesario buscar en diversos repositorios ya que uno solo no es suficiente para encontrar los recursos que el investigador necesita, esto puede tomar demasiado tiempo y dificultar el objetivo.

La publicación en revistas de impacto genera un doble beneficio. En primer lugar y de manera individual, al investigador. Un científico que publique asiduamente en estas revistas destacará en su carrera científica, y probablemente será reconocido como un experto en su campo. Por otro lado, a nivel institucional ya que la universidad o centro de investigación también se verá beneficiado si cuenta con una planta de investigadores que publique en este tipo de revistas. Por dichos motivos, es necesario conocer las características, los requerimientos y los mecanismos propios de estas revistas con el objetivo de publicar en ellas.

En muchos casos, la imposibilidad de lograr la publicación deseada no se debe a cuestiones relacionadas con la investigación, el estudio o la calidad de los mismos, sino a la incorrecta elección de la revista, a errores y descuidos en la presentación formal del manuscrito, a la adopción de un enfoque erróneo en el planteamiento del trabajo, o a la impericia al momento de contestar a las propuestas y sugerencias de editores y evaluadores [3].

En la actualidad, una gran cantidad de científicos optan por publicar en revistas especializadas, tanto del ámbito académico como del profesional. Para esto, el autor debe conocer previamente dónde es posible o más adecuado publicar un determinado artículo. En este punto cabe destacar que, el gran número de

¹ Por ejemplo, sistema de búsqueda de Springer
<https://link.springer.com/search?facet-discipline=%22Engineering%22>

editoriales y revistas existentes entre las cuales los científicos deben decidir, hace necesario un sistema que brinde soporte a esta decisión.

Para hacer frente a esta sobrecarga de información, resultan de particular interés los sistemas de recuperación de la información y sistemas de recomendación. Un sistema de recuperación de la información, consiste en presentar al usuario la información que satisfaga su necesidad, satisfacer no necesariamente se refiere a mostrar toda la información sobre un tema específico, sino mostrar los suficientes textos que puedan ser relevantes y útiles para el usuario [5]. Los sistemas de recomendación tratan de ser un paso adelante en el contexto de la recuperación de información tradicional, los mismos buscan predecir la importancia o preferencia que un usuario daría a un determinado ítem o grupo de ítems. Estos sistemas se han popularizado en aplicaciones de comercio electrónico y entretenimiento, pero también han sido utilizados en diferentes sistemas expertos, educativos, citas en línea y redes sociales [6].

La mayoría de sistemas de recomendación se pueden clasificar como basados en contenido o de filtrado colaborativo [7]. Los sistemas de recomendación basados en contenido le brindarán al usuario información similar a la que ha mostrado interés, es decir, mostrará ítems similares, independientemente de lo que opinen otros usuarios [8]. En cambio, los sistemas de recomendación que utilizan filtrado colaborativo realizan predicciones automáticas sobre los intereses de un usuario (filtrado) mediante la recopilación de las preferencias o intereses de otros usuarios similares (colaborativo) [9].

En este contexto, surge la necesidad de diseñar y desarrollar herramientas de recomendación que contemple las diversas editoriales y factores de análisis para ayudar al científico con la tarea de selección del canal de publicación más apropiado para un artículo particular.

1.3. Propuesta

En este trabajo final se propone un enfoque denominado "HelpMePublish", cuyo objetivo general es brindar soporte en la tarea de selección de la revista más apropiada a aquellas personas interesadas en publicar un artículo científico.

Para lograr este objetivo se propone desarrollar un sistema de búsqueda y recomendaciones de revistas multi-editorial que, a partir de información de un artículo científico (título, palabras claves, resumen, etc.) sugiera las revistas científicas en las que el contenido del artículo científico sea relevante para el alcance de dichas revistas.

Mediante la información provista por el usuario, el sistema busca y compara con una base de datos que contiene información relativa a revistas y editoriales. Luego, sugerirá las opciones que mejor se adapten a las características provistas.

El enfoque propuesto se implementará como una plataforma web que permite fácilmente a los usuarios realizar búsquedas sobre revistas en base a diferentes

criterios. Además, el sistema proveerá una interfaz que facilita la comparación entre diversas revistas para asistir en el proceso de selección.

La calidad del sistema de recomendación será evaluado mediante dos perspectivas. En la primera de ellas, denominada Perspectiva Automática, se procederá a utilizar artículos ya publicados y analizar si la revista recomendada coincide con la revista donde fue publicada. La segunda perspectiva está centrada en el usuario. En este caso particular, los usuarios finales serán investigadores del área de Computación y Sistemas de la UNICEN. Se buscará comparar las recomendaciones del enfoque con las obtenidas por los buscadores existentes de las editoriales. En particular, los investigadores evaluarán la calidad de la recomendación según diferentes aspectos cualitativos.




Figura 1.1: Diagrama general de la aplicación.

1.4. Estructura

En la presente sección se detalla la estructura del documento. En particular, el documento se divide en capítulos y secciones que se describen brevemente a continuación.

En el Capítulo 2, se presenta el marco teórico, donde se presentan los fundamentos teóricos utilizados en la presente tesis. Además, se describen cuestiones acordes a lo difícil que es hoy en día identificar la revista correcta al trabajo relacionado. También, se describe el estado del arte actual donde se analizan diversos trabajos relacionados a la problemática estudiada en el proyecto.

Una vez presentados los conceptos teóricos más importantes se procede a explicar de manera detallada el enfoque propuesto desde un punto de vista abstracto en el Capítulo 3 del informe. Los aspectos principales de la solución propuesta se describen en este capítulo, analizando de forma general las cuestiones necesarias en el algoritmo de recomendación y la utilidad del mismo.

Luego, una vez establecido el enfoque, en el Capítulo 4 se describe la implementación del proyecto mostrando el diseño, las técnicas y los algoritmos utilizados, y la arquitectura principal para el desarrollo de la plataforma web propuesta.

En el Capítulo 5, se presenta el caso de estudio, mediante el cual se evalúa el enfoque propuesto en términos de cantidad de aciertos en las recomendaciones considerando dos perspectivas, automática y centrada en el usuario. Todos los análisis experimentales se describen en este capítulo.

Por último, el Capítulo 6 muestra las conclusiones establecidas, analizando ventajas y limitaciones del enfoque, como así también trabajos futuros y mejoras a realizar.

2. Marco teórico

En este capítulo, se describe el marco teórico en el que se desarrolla la presente tesis. En particular, se mencionan detalladamente los conceptos teóricos utilizados y se analiza el estado del arte actual de los tópicos relacionados a este trabajo final.

El capítulo se organiza de la siguiente manera:

- La sección 2.1 se basa en la captura de información y los diferentes factores que actúan para lograr lo mencionado.
- En la sección 2.2 se presentan las características más importantes acerca de la recuperación de la información.
- La sección 2.3 contiene información acerca de los sistemas de recomendación.
- La sección 2.4 se enfoca en describir el proceso de evaluación de un sistema de recomendación.
- En la sección 2.5 se analizan trabajos relacionados.

2.1. Captura de la Información

En esta sección, se presentan los principales conceptos que se utilizan para lograr capturar la información a utilizar de manera adecuada. Dicha información se obtiene a partir de los sitios web de las revistas mediante un crawler y con un web scraping se captura el contenido necesario para el desarrollo de un sistema de recuperación de la información.

Los datos extraídos son procesados quitando información redundante y almacenados en una base de datos. Dicho procedimiento se realiza cada un tiempo determinado para tener siempre la base de datos actualizada.

El algoritmo de recomendación utiliza datos como el título, resumen, palabras claves, que son ingresados por el usuario para generar las recomendaciones que mejor se adapten a lo especificado.

2.1.1. Web Scraping

Podemos definir el Web Scraping como un conjunto de técnicas que nos permiten, de forma automática, extraer datos de sitios web.

También conocido como Web harvesting o Web data extraction, es el proceso de rastreo y descarga de información de sitios web y la extracción de datos no estructurados o poco estructurados a un formato estructurado. Para lograrlo, se simula la exploración humana de la World Wide Web, ya sea por implementación de bajo nivel del protocolo de transferencia de hipertexto, o la incorporación de ciertas plataformas web.

Para realizar scraping se utiliza un programa, conocido como *orquestador*, que organiza y ejecuta las peticiones al browser. Se deben tener bien definidos los elementos a buscar, y que se indique el estado de la búsqueda a realizar (búsqueda exitosa, errores en la búsqueda, sin resultados).

El proceso de web scraping se realiza en dos etapas, la primera es la etapa de extracción, en la cual se realiza una consulta de datos hacia un sitio y se guardan de manera local y, después, en la segunda etapa, se realiza el análisis de estos datos para obtener información.

2.1.2. Técnicas para la extracción de información

- **Web bot, Spider, Crawler, Arañas y Rastreadores**[10]: Inspeccionan las páginas web de internet de forma metódica y automatizada. Se usan para rastrear la red. Lee la estructura de hipertexto y accede a todos los enlaces referidos en el sitio web. Son utilizadas la mayoría de las veces para poder crear una copia de todas las páginas web visitadas para que después puedan ser procesadas por un motor de búsqueda; esto hace que se puedan indexar las páginas, proporcionando un sistema de búsquedas rápido.
- **Plataformas de agregación verticales:** Existen plataformas que tienen el propósito de crear y controlar numerosos robots que están destinados para mercados verticales específicos. Mediante el uso de esta preparación técnica se realiza el establecimiento de la base de conocimientos destinada a la totalidad de plataformas verticales y luego a crearla automáticamente. Medimos nuestras plataformas por la calidad de la información que se obtiene. Esto asegura que la robustez de nuestras plataformas utilizadas consiga la información de calidad y no sólo fragmentos de datos inútiles.
- **Reorganización de anotación semántica:** El desarrollo de web scraping puede realizarse para páginas web que adoptan marcas y anotaciones que pueden ser destinadas a localizar fragmentos específicos semánticos o metadatos. Las anotaciones pueden ser incrustadas en las páginas y esto puede ser visto como análisis de la representación estructurada (DOM). Esto permite recuperar instrucciones de datos desde cualquier capa de páginas web.

2.1.3. Herramientas de Web Scraping

Existe una gran variedad de herramientas, algunas gratuitas y otras no. A continuación se enumeran algunas con una breve descripción:

- **Beautiful Soap:** Es una biblioteca de Python diseñada para proyectos de respuesta rápida como screen scraping o web scraping. Ofrece algunos métodos simples y modismos de Python para navegar, buscar y modificar un árbol de análisis: una herramienta para la disección de un documento y extraer lo que necesita, además de que no se necesita mucho código para escribir una aplicación. BeautifulSoup convierte automáticamente los documentos entrantes a Unicode y documentos salientes a UTF-8, también trabaja con analizadores de Python populares como lxml y html5lib y permite realizar el recorrido del DOM.
- **AngleSharp:** AngleSharp es una biblioteca .NET que brinda la capacidad de analizar hipertextos como HTML, SVG y MathML. XML sin validación también es compatible con la biblioteca. Un aspecto importante de AngleSharp es que CSS también se puede analizar. El analizador se basa en la especificación oficial del W3C, por lo que produce una perfecta representación portable del DOM HTML5 del código fuente dado y garantiza la compatibilidad con los resultados en los navegadores.
- **ScrapApi:** Esta herramienta se clasifica como herramienta para desarrolladores. Permite crear scrapers para analizar la web, gestionar proxies e incluso captcha. Provee una API, por lo que su uso es bastante sencillo. Eso sí, no es un servicio de datafiniti, es decir, no ofrecen datos ya procesados de forma estructurada a través de una API, sino que utiliza las APIs para controlar tus crawlers.
Es una herramienta bastante popular y goza de buen estatus en la comunidad de Código Abierto (Open Source), ya que colabora bastante. Tiene muy buena documentación disponible y fácil de encontrar. Permite iniciar sesión automáticamente con los servicios de Google y con las credenciales de GitHub.
- **Scrapy:** En el mundo de los desarrolladores, podemos considerar Scrapy como la librería por excelencia. Totalmente gratuita y extremadamente potente. Eso sí, es obligatorio saber Python para su utilización. [2].

2.1.4. Crawler

Un crawler es un software que, dada una URL base, escala poco a poco todo ese sitio guardando todas las URLs obtenidas para poder analizarlas posteriormente.

Este tipo de software es la clave de los mayores motores de búsqueda del mercado, que no solo analizan todas las URLs de un sitio web, sino que analizan, literalmente, toda la red mundial. Cuando encuentran un enlace nuevo, lo añaden a esa gran lista de enlaces.

Posteriormente, se procede a un análisis automatizado y a un etiquetado que permite obtener búsquedas adecuadas según lo introducido por el usuario en base a popularidad, porcentaje de coincidencia y todo lo que respecta.

Gracias a una correcta manipulación de las URLs de un sitio web, es posible no solo obtener información de una página o documento, sino escalar todo el sitio web en busca de todas sus URLs y, así, tener acceso a toda su información. Para hacer esto es necesario poder obtener las URLs absolutas de cada enlace y, por supuesto, debe controlarse hacia dónde se está navegando, para evitar salir fuera del dominio deseado.

Para un buen crawler es indispensable gestionar adecuadamente las URLs del sitio que se está analizando. La problemática no es muy amplia, pero sí conviene conocer cómo proceder en algunos casos. Cuando se trata de URLs absolutas no existe mayor problema que analizar adecuadamente el documento para extraer aquellas de verdadera relevancia, pero los problemas llegan cuando se trata de URLs relativas [2].

2.1.4.1 Herramientas de Crawling

Al igual que con las herramientas de scraping mencionadas anteriormente, existen varias opciones para realizar crawling. A continuación mencionaremos algunos ejemplos de ellas.

- **Heritrix:** Es una biblioteca de crawling web escrito en Java de código abierto con alta extensibilidad y también está diseñada para el archivo web. También proporciona una interfaz de usuario basada en web muy fácil de usar accesible con cualquier navegador web moderno que se puede usar para controles operativos y para monitorear los rastreos.
- **Web-Harvest:** También de código abierto y escrita en java. Ofrece la función de recopilar datos útiles de páginas web selectivas. Para lograrlo con éxito, se basa principalmente en XSLT, XQuery y expresiones regulares para buscar y filtrar contenido de sitios web basados en HTML y XML. También se puede integrar fácilmente con bibliotecas Java personalizadas para utilizar aún más sus capacidades de extracción.
- **Apache Nutch:** Es una herramienta única de rastreo web de Java que viene con una arquitectura altamente modular. Permite a los desarrolladores de Java crear complementos personalizados para aplicaciones como análisis de tipos de medios, recuperación de datos, consultas y agrupación. Debido a que es conectable y modular, Apache Nutch viene con una interfaz extensible para ajustar todas las implementaciones personalizadas.

2.2 Recuperación de la información

La Recuperación de Información (*Information Retrieval*, en inglés) no es un área nueva, ha pasado por un proceso de largo desarrollo e innovación [11], girando alrededor de un elemento importante, el valor de la información. Por lo tanto, para un usuario es de gran importancia disponer del contenido de un texto de manera precisa y que cubra la necesidad de este en el menor tiempo posible.

Actualmente se dispone de varios métodos y modelos para recuperar información, tales como, Modelo Booleano, Modelo Probabilístico, Modelo Vectorial [5], aplicados ampliamente en bases de datos documentales, bibliotecas, páginas web o todo aquel lugar donde haya grandes bases de información y por lo consiguiente gran necesidad de procesamiento y búsqueda.

Hoy en día la Recuperación de la Información apoya en diferentes áreas y se enfoca a una gran gama de aplicaciones como son: extracción de información, búsquedas Web, respuestas a preguntas, organización automática (clustering), clasificación, detección de novedades, entre otros, ofreciendo diferentes soluciones y desarrollando nuevas herramientas para cada situación.

El proceso de recuperación se ha regido mediante los siguientes conceptos fundamentales: almacenamiento, organización, acceso, búsqueda, recuperación, necesidad, precisión y relevancia, entonces la Recuperación de la Información puede ser concreta como un conjunto de tareas por las cuales un usuario puede localizar, acceder y recuperar los recursos informativos que previamente han sido almacenados, que son útiles y favorezcan a solucionar un determinado planteamiento o necesidad.

El mayor exponente de este hecho es Internet, que permite que millones de usuarios accedan a una fuente de recursos de información y conocimiento compartido a escala mundial, siendo el instrumento que está produciendo la mayor y más sorprendente revolución en el mundo de la información.

Este gran volumen de información provoca también grandes problemas. La capacidad de digerir la información por parte de los usuarios no ha ido pareja a su producción, y es importante descartar la que no interesa, o lo que es lo mismo, seleccionar la información pertinente para una necesidad informativa dada. Evidentemente, la necesidad informativa no está limitada a Internet, sino a cualquier tipo de sistema que soporte o almacene información. Los ordenadores pueden almacenar cada día más y más información, en varios formatos (texto, imágenes, vídeo, sonido, etc.), de usuarios locales o remotos, y con diferentes características y objetivos, y la necesidad de localizar y organizar rápidamente esa información se está convirtiendo en pieza clave de tales sistemas. Debido a esta necesidad las opciones de búsqueda están implementadas en prácticamente todas las aplicaciones actuales.

Los sistemas de recuperación de información son la pieza clave para resolver el problema de la búsqueda rápida y eficiente de información. De hecho, nos encontramos en un momento crucial para estos sistemas. Los más avanzados

tratan de agregar información semántica a las búsquedas, con una amplia actividad de investigación en torno a interfaces de usuario, nuevos métodos de búsqueda y nuevas formas de indización, para adelantarse a las necesidades de los usuarios. Hoy en día se debe tener la capacidad de encontrar información y datos de diversos tipos y formatos de manera flexible, libres de forma, que permitan realizar búsquedas requiriendo el mínimo esfuerzo posible.

En base al análisis de diferentes fuentes consideramos que, la RI es el conjunto de acciones, métodos y procedimientos para la representación, almacenamiento, organización y recuperación de información. El objetivo fundamental de la RI es, dada una necesidad de información y un conjunto de documentos, obtener los documentos relevantes para esa necesidad, ordenarlos en función del grado de relevancia, y presentarlos al usuario. Podemos definir relevancia como la medida de cómo un documento se ajusta a una consulta.

La Figura 2.1 presenta de forma esquemática un sistema de RI, que acepta documentos y consultas, y que obtiene una salida, que es el conjunto de documentos que satisfacen la consulta. Una consulta es la expresión formal de la necesidad informativa del usuario. El problema principal en este sistema es obtener representaciones homogéneas, tanto de los documentos como de la necesidad informativa del usuario, y procesar convenientemente estas representaciones para obtener la salida. Se aprecian dos actividades: representación y búsqueda. Tampoco debemos perder de vista la evaluación de la salida, para determinar si ésta coincide con las necesidades informativas del usuario.




Figura 2.1: Paradigma de la Recuperación de Información.

En el proceso de RI podemos distinguir las siguientes etapas:

1. Obtener la representación de los documentos. Generalmente los documentos se representan utilizando un conjunto más o menos grande de términos índice. La elección de dichos términos es el proceso más complicado.
2. Identificar la necesidad informativa del usuario. Se trata de obtener la representación de esa necesidad, y plasmarla formalmente en una consulta acorde con el sistema de recuperación.
3. Búsqueda de documentos que satisfagan la consulta. Consiste en comparar las representaciones de documentos y la representación de la necesidad informativa para seleccionar los documentos pertinentes.
4. Presentación de los resultados al usuario. Puede ser desde una breve identificación del documento hasta el texto completo.
5. Evaluación de los resultados. Para determinar si son acordes con la consulta.

Finalmente, mencionar que el objetivo principal de un sistema de recuperación, consiste en presentar al usuario la información que satisfaga su necesidad, satisfacer no necesariamente se refiere a mostrar toda la información sobre un tema específico, sino mostrar los suficientes textos que puedan ser relevantes y útiles para el usuario.

2.2.1 Indexación

Antes de continuar es conveniente indicar que es habitual utilizar el término indización cuando se habla de recuperación de información en entornos basados en documentos. Sin embargo, en entornos informáticos suele utilizarse más el término indexación. Ambos términos en realidad son sinónimos y utilizaremos uno u otro indistintamente.

Hoy en día con el incremento del número de documentos en formato electrónico se hace necesario contar con herramientas informáticas adecuadas para su recuperación. Actualmente los ordenadores hacen posible representar un documento utilizando su contenido completo, es lo que se denomina representación a texto completo. Efectivamente, es la forma más completa de representación, pero implica un coste computacional muy alto para colecciones grandes de documentos, por lo que se busca encontrar el equilibrio entre el número de términos utilizados para representar su contenido y el coste computacional asociado para obtener la salida en un tiempo razonable.

La mayoría de sistemas de RI utilizan términos índice para representar el contenido de los documentos como muestra la Figura 2.2. En sentido estricto, un término índice es una palabra (o grupo de palabras) que posee significado propio [12] y que se utiliza para representar un concepto [13]. Los sistemas de recuperación basados en términos índice se apoyan en la idea fundamental de que tanto el contenido de los documentos como la necesidad informativa del usuario pueden representarse utilizando el conjunto de términos índice. Esto es lo que se conoce como indexación (o indización). A continuación, se deja un ejemplo de diagrama




Figura 2.2: Diagrama de clasificación de documentos

Ahora bien, no todas las palabras de un documento poseen la misma utilidad para describir su contenido, y por tanto, de poder usarse como términos índice. Aunque existen palabras más importantes que otras en función de la categoría gramatical, no es tarea fácil decidir la importancia de cada una de ellas. Adverbios, artículos, preposiciones y conjunciones suelen ser palabras casi vacías de contenido semántico, y por tanto, poco útiles desde el punto de vista de la RI. No obstante, esto no está claro, pues muchas palabras de este tipo incorporan un nivel semántico adicional al nombre o verbo que acompañan, y por tanto debieran tenerse en cuenta. Asimismo, también resultan poco útiles para las tareas de recuperación aquellas palabras que se repiten con mucha frecuencia en la colección de documentos, pues llevan a términos índice poco discriminatorios en relación con una consulta dada.

En conclusión, los sistemas de recuperación no sólo intentan encontrar aquellos términos que mejor representen a los documentos, sino además aquellos que permitan diferenciar unos respecto de otros. Los diferentes modelos de recuperación se diferencian precisamente en el método elegido para representar los documentos y las consultas, y para realizar las búsquedas de información.

Así pues, el primer paso para la indización es analizar el texto del documento para determinar qué términos pueden utilizarse como términos índice. Es importante destacar que se parte de un documento a texto completo y se consigue al final del proceso un conjunto más o menos numeroso de términos índice que lo representan. Este proceso suele llevar la sucesión de los siguientes pasos:

2.2.2 Pre-procesamiento de la información

La representación del contenido de documentos es la transformación automática del texto en una forma que represente uno o más aspectos de su significado.

El pre-procesamiento de la información consiste en general en los siguientes pasos o etapas:

- Transformación a un formato ASCII (eliminando caracteres de formato, estilo, etc).
- Conversión del texto a minúscula.
- Identificación de palabras del texto (strings de caracteres contiguos delimitados por blancos).
- Eliminación de puntuación.
- Eliminación de Stopwords.
- Stemming.
- Asignación de pesos a términos.

2.2.2.1 Eliminación de StopWords

Son palabras que por su frecuencia y/o semántica no poseen valor discriminatorio alguno, no permiten distinguir un documento de otro en una colección. Generalmente, se trata de artículos, pronombres, preposiciones, verbos muy frecuentes, adverbios, etc.

Su alta frecuencia hace que cualquier función de asignación de pesos tienda a disminuir el impacto del resto de las palabras del documento considerando esto uno de los aspectos negativos. Además, consumen gran cantidad de tiempo de procesamiento improductivo.

Como efecto positivo se puede mencionar que la eliminación de este tipo de palabras reduce en más de un 30% el tamaño del documento. La eliminación de dichas palabras, se realiza chequeando el contenido del documento contra un listado disponible.

Las listas de stopwords pueden ser:

- Independientes de la colección, cada lenguaje posee listas estándares de stopwords de longitud variable
- Dependientes de la colección, palabras que para una determinada colección no poseen valor discriminante (por ejemplo, en computación la palabra “software”)

2.2.2.2 Stemming

Es un proceso de normalización lingüística en el cual las diferentes formas que puede adoptar una palabra son reducidos a una única forma común, a la cual se denomina stem o raíz. El stem conlleva el significado del concepto asociado a un grupo de palabras. A continuación se muestra un ejemplo:

- Palabras como: Computer, computers, compute, computes, computational, computationally, etc.
- Resultado: Comput

Como efecto positivo se puede mencionar que mejora la formulación de consultas, incrementando el recall y reduciendo la dimensión del espacio de términos en un porcentaje entre el 10% y el 50%. Para realizar esta transformación, se cuenta con un diccionario que posee el stem asociado a cada palabra. Términos como engineering, engineered o engineer tienen como único stem engineer.

Usualmente se emplea este método en conjunción con la eliminación de sufijos. Existen diversos algoritmos para la eliminación de sufijos y/o prefijos como:

- Algoritmo de Harman[14].
- Algoritmo de Lovins[15].
- Algoritmo de Porter[16].

De esta forma, atravesando las etapas descritas en las secciones anteriores y en la presente, se busca cumplir con el objetivo del enfoque. Como se ha enunciado con anterioridad, dicho objetivo se centra en la creación de un sistema de recomendación que sugiera los canales de publicación más apropiados para la publicación de un artículo.

2.3 Sistema de recomendación

Los sistemas de recomendación tratan de ser un paso adelante en el contexto de la recuperación de información tradicional, los mismos se encargan de recomendar o sugerir a los usuarios ítems o productos concretos basándose en sus preferencias.

Con la finalidad de reflejar los intereses de los usuarios y realizar recomendaciones, los sistemas de recomendación recopilan la información de los usuarios a través del proceso de retroalimentación. Este proceso es la pieza clave para el buen funcionamiento de un sistema de recomendación, porque sin la información recuperada por este, sería imposible conocer el interés de los usuarios y por esto, el sistema tampoco podría recomendarles contenidos interesantes.

La información que permite funcionar a estos sistemas se puede obtener de forma explícita, es decir, que los usuarios expresan de forma voluntaria y directa qué contenidos le gustan, normalmente a través de las valoraciones, ó de manera

implícita, donde los objetos son evaluados sin la intervención directa de los usuarios, o sea, que la evaluación se realiza sin que el usuario lo perciba, por ejemplo, a través de las acciones que el usuario realiza durante la interacción con el sistema.

2.3.1 Introducción

Los sistemas de recomendación tienen un papel cada vez más importante en el panorama actual. Si bien su uso en aplicaciones web viene siendo habitual desde hace algunos años, su utilización en otro tipo de dispositivos, como pueden ser los libros electrónicos, es un campo en el que todavía existe mucho por explorar.

Para las empresas un sistema de recomendación es un sistema que, de una manera muy cómoda, hace llegar a cada cliente información de su interés que probablemente no conozca. Obviamente, un sistema de recomendación competente y bien utilizado constituirá una herramienta de marketing muy potente: puede hacer llegar fácilmente a cada cliente la publicidad sobre los productos que le van a gustar concretamente a él sin necesidad de que el cliente haga un esfuerzo explícito para comunicar lo que le satisface y eliminando una gran cantidad de publicidad sobre temas que a ese cliente no le interesan [17].

Por este motivo, los sistemas de recomendación son ampliamente utilizados en páginas web de tiendas online, como por ejemplo Amazon, ya que además de hacer que la gente consuma más, permiten crear un escaparate virtual a la medida de cada cliente haciendo la experiencia del usuario mucho más atractiva. Esta filosofía de “crear una tienda personalizada para cada cliente” es lo que hizo triunfar a Amazon en el mundo de las ventas por Internet [18].

Los sistemas de recomendación también son muy utilizados en el ámbito de las redes sociales. Por ejemplo, YouTube se sirve de un sistema de recomendación para sugerir a los usuarios diferentes videos que pueden interesarles según su historial de navegación en el sistema, con lo que se pretende mejorar la experiencia del usuario. Por su parte, Facebook tiene un sistema de recomendación basado en filtrado colaborativo, que recomienda amigos en base a los amigos que tienen en común los usuarios, estos son algunos ejemplos de redes sociales, pero la gran mayoría de de redes sociales tienen su propio sistema de recomendación integrado.

También, existen servicios web dedicados a temas concretos que se sirven de sistemas de recomendación. Algunos ejemplos son: last.fm, una radio online que recomienda música, eventos y festivales en función de tus gustos musicales; y Strands, una red social dedicada a deportistas que permite que éstos compartan sus programas de entrenamiento y recomienda programas de otros usuarios [17].

Si bien se ha visto que los sistemas de recomendación son ampliamente utilizados en la web, su aplicación en otro tipo de entornos no está tan extendida. La tendencia de investigación actual en los sistemas de recomendación es intentar que el sistema llegue a conocer al usuario sin que éste le tenga que dar información explícita sobre sus gustos y preferencias. Esto se consigue estudiando y analizando

diferentes parámetros que entran en juego en la interacción del usuario con el dispositivo. Así, aspectos como el tiempo de lectura de un contenido, el número de clics, acciones como comentar un contenido o recomendar el contenido a otros usuarios puede determinar el interés de los usuarios.

Actualmente, se investigan sistemas de recomendación más efectivos, de carácter híbrido (combina técnicas de filtrado colaborativo y basadas en contenido), que recogen los datos necesarios para efectuar las recomendaciones de una manera totalmente transparente al usuario.

2.3.2 Alcance del estudio

En la actualidad, los sistemas de recomendación resultan muy útiles en la Web, estos ayudan a los usuarios a encontrar contenidos que son interesantes para ellos de forma fácil, ágil y sin mucho esfuerzo. Estos contenidos son seleccionados por los sistemas de recomendación de una gran cantidad de contenidos que están disponibles en la web.

El objetivo de este capítulo es disponer de un conjunto de referencias clasificadas y una comparativa de las mismas que permita definir de un modo más objetivo, completo y consistente los conceptos generales, características, funcionamiento, clasificación, ventajas e inconvenientes de los sistemas de recomendación. En este capítulo, se presenta un estudio general sobre los sistemas de recomendación, en el que se pretende:

1. Describir los conceptos generales de sistemas de recomendación.
2. Describir las diferentes formas de retroalimentación de la información en los sistemas de recomendación.
3. Describir las principales características y funcionamiento general de un sistema de recomendación.
4. Describir los diferentes tipos de sistemas de recomendación existentes.
5. Describir la importancia, ventajas y problemas de los sistemas de recomendación.
6. Describir ejemplos y casos de estudios de sistemas de recomendación.

2.3.3. Definiciones de sistemas de recomendación

A continuación, se presentan diferentes definiciones planteadas por algunos autores sobre sistemas de recomendación. Tras analizar la variedad de definiciones existentes, luego se establecerá una definición que servirá como marco conceptual para este trabajo.

- Un sistema de recomendación es un sistema que tiene como tarea principal, elegir ciertos objetos que cumplen con los requisitos de los usuarios, donde

cada uno de estos objetos están almacenados en un sistema informático y caracterizados por un conjunto de atributos. [19]

- Un sistema recomendador es una tecnología de filtrado de información personalizada, usada para predecir si a un usuario particular le gusta un ítem en particular (problema de predicción), o identificar un conjunto de N ítems que pueden interesarles a ciertos usuarios (problema de recomendación top-N.) [20]
- Los sistemas de recomendación son una serie de mecanismos y técnicas aplicadas a la recuperación de información para intentar resolver el problema de sobrecarga de datos en Internet. Estos ayudan a los usuarios a elegir los objetos que pueden ser de utilidad o de su interés, pudiendo estos objetos ser de cualquier tipo, tales como libros, películas, canciones, páginas Web, blogs.[21]

Cómo es posible apreciar, existen diversas definiciones que utilizan los términos «sistemas de recomendación» o «sistemas recomendadores», ambos términos son válidos.

2.3.4. Características de un sistema de recomendación

Un aspecto relacionado con los sistemas de recomendación es la “recuperación de información” o “búsqueda de información” (information retrieval). Ambos conceptos se asemejan en el hecho de que intentan proporcionar información relevante al usuario pero se distinguen por ciertas singularidades [21]:

- **Frecuencia de uso:** Los sistemas de búsqueda son enfocados por uso concreto y puntual del usuario mientras que los sistemas de recomendación están diseñados para un uso prolongado y de forma repetitiva.
- **Representación de las necesidades de información:** En sistemas de búsqueda la información requerida se expresa en forma de pregunta (query), mientras que en los sistemas de recomendación la información es descrita en los perfiles del usuario.
- **Objetivo:** Los sistemas de búsqueda seleccionan los ítems de la base de datos que coinciden con la pregunta (query) mientras que los sistemas de recomendación eliminan la información irrelevante de flujos de entrada de información y/o reúnen información relevante de diferentes repositorios de acuerdo al perfil del usuario.

- **Base de datos:** Los sistemas de búsqueda trabajan con bases de datos relativamente estáticas mientras que los sistemas de recomendación trabajan con información dinámica.
- **Tipos de usuarios:** En los sistemas de búsqueda no se tiene porque tener información sobre los usuarios que lo utilizan mientras que en los sistemas de recomendación se necesita saber o tener información sobre los usuarios.
- **Ámbito social:** Los sistemas de recomendación están interesados en aspectos sociales de modelado y privacidad del usuario mientras que los sistemas de búsqueda no.

2.3.5. Técnica de retroalimentación de información

Un sistema de recomendación debe proporcionar un mecanismo para recopilar la mayor cantidad posible de información relacionada al perfil de los usuarios con el fin de descubrir sus gustos e intereses por determinados objetos y posteriormente generar mejores recomendaciones. Este proceso se llama «retroalimentación». Según se muestra en [22], [23] y [24] el proceso de retroalimentación es clasificado en dos tipos: retroalimentación implícita y explícita.

La combinación entre las técnicas de retroalimentación explícita e implícita es otro paradigma para los sistemas de recomendación, a pesar de que estos presentan características diferentes acerca de las preferencias de los usuarios [25].

2.3.5.1. Retroalimentación implícita

Este proceso consiste en evaluar los objetos, sin las intervenciones de los usuarios. Es decir, esta evaluación se realiza sin conocimiento del usuario, a través de la captura de la información obtenida de las acciones realizadas por los usuarios en la aplicación. Por ejemplo, cuando el usuario accede a una noticia o lee un artículo en línea, de acuerdo con el tiempo que toma para la lectura, el sistema puede deducir si el contenido es de su interés.

Las técnicas de retroalimentación implícita se han utilizado para recuperar, filtrar y recomendar una variedad de artículos: películas, artículos de revistas, documentos de Web, artículos de noticias en línea, libros, programas de televisión, y otros. Estas técnicas aprovechan el comportamiento del usuario para comprender los intereses y preferencias del usuario [26].

2.3.5.2. Retroalimentación explícita

A través de un proceso de encuesta, el usuario valora los contenidos mediante la asignación de una puntuación. La retroalimentación explícita proporciona a los usuarios un mecanismo para expresar de manera inequívoca su interés en los objetos [25]. Por ejemplo, la tienda online Amazon, Film affinity, Movilens y otros, utilizan el sistema de puntuación de «cinco estrellas», que permite a los usuarios valorar los productos que son de su interés. Por otro lado, las redes sociales como Facebook, YouTube y otros, usan el sistema de valoración «Like» para calificar los contenidos.

Finalmente, Google +1 es una nueva funcionalidad que Google ha añadido a su motor de búsqueda para que los usuarios puedan evaluar de forma explícita los sitios web que les gustan y así recomendar estos sitios a los contactos del usuario que ha realizado la valoración.

2.4 Clasificación de los sistemas de recomendación

Los sistemas de recomendación pueden ser clasificados en diferentes tipos, de acuerdo al tipo de información que utilizan para realizar las recomendaciones. Tradicionalmente existen varios paradigmas de filtrado de información utilizados para la generación de recomendaciones, estos se clasifican en: **Basados en contenido**: tratan de recomendar productos similares a los que le ha gustado a un usuario determinado en el pasado; **Filtrado colaborativo**: que identifica a los usuarios cuyos gustos son similares a las de un usuario determinado y recomienda a este usuario los contenidos que les gustan a los demás usuarios; y **enfoque Híbrido**: que es una combinación entre el basado en contenido y el filtrado colaborativo [27][28].

2.4.1. Sistemas de recomendación basados en contenido

Este sistema trata de recomendar productos similares a los que le ha gustado a un usuario determinado en el pasado, también se lo conoce con el nombre de sistema de recomendación no colaborativo. Los productos han sido previamente valorados por el usuario y para determinar que un ítem es parecido a otro se buscan “palabras clave” del ítem que calificó el usuario. Esto puede presentar un problema ya que si siempre se recomiendan ítems similares a los vistos anteriormente se puede llegar a lo que se conoce como sobre-especialización. Un ejemplo de esto, es que si en un sistema de recomendación de películas, un usuario solo ha valorado películas del género acción, va a ser difícil que el sistema le recomiende películas de comedia o infantiles. Los sistemas de recomendación basados en contenido presentan las siguientes ventajas e inconvenientes [28]:

2.4.1.1. Ventajas

- Recomendación por contenido y no por opiniones subjetivas de otros usuarios.
- El sistema puede generar explicaciones sobre la recomendación que hizo en base al historial del usuario.
- No hay dispersión (Sparsity): Pues el modelado de la información está presente en las características del documento y no necesitan mostrarse otros usuarios.

2.4.1.2. Inconvenientes

- Necesita un modelo detallado de preferencias del usuario que es complejo de construir y mantener.
- Sobre-especialización: el usuario está limitado a que le recomienden ítems similares a los que recomendó.
- Subjetividad de los Contenidos: dificultad en dominios con contenido difícil de analizar (audio, gráficos, imágenes, vídeo).
- Problema del Usuario Nuevo: el usuario tiene que puntuar un número suficiente de ítems para que el sistema pueda realmente entender sus preferencias.
- Representación del Perfil del Ítem: para cada ítem se extraen ciertas características sobre las cuales se evalúa la similaridad.
- Efecto Portafolio: se da en dominios como recomendación de noticias, ya que es posible descartar noticias que pueden ser muy similares a otras previas, pero que al mismo tiempo presentan hechos nuevos e importantes.
- Problema de Estabilidad vs. Plasticidad: es difícil para el sistema aprender a adaptarse a los cambios en el perfil del usuario hasta no haber recolectado un número suficiente de valoraciones actualizadas.
- Tarea Onerosa de tener que valorar.

2.4.2. Sistemas de recomendación basados en filtrado colaborativo

Estos sistemas tienen como objetivo conocer las preferencias del usuario y hacer recomendaciones sobre la base de datos de los usuarios y la comunidad, también se los conoce con el nombre de sistemas de recomendación colaborativos. El sistema recomienda ítems de otros usuarios con “gustos” similares a los suyos. Por tanto, el sistema de recomendación calcula la similitud entre usuarios y crea lo que llaman “vecinos cercanos”, es decir, usuarios que tienen las mismas valoraciones o calificaciones en los mismos ítems. Por ejemplo, si un usuario calificó 20 ítems y hay otro usuario que coincide en 16 de esas calificaciones, éste sería un

“vecino” y es muy probable que los ítems del “vecino” (y que el usuario no valoró) le resulten interesantes. Los sistemas de recomendación basados en filtrado colaborativo presentan las siguientes ventajas e inconvenientes [29]:

2.4.2.1. Ventajas

- No necesita modelo detallado de preferencias; basta con un vector de valoración de objetos.
- Permite recomendar contenidos difíciles de analizar.
- Recomendar ítems basados en las preferencias del usuario.
- Realizar recomendaciones válidas pero no esperadas.
- Puede aplicarse a cualquier tipo de ítem o producto: documentos, música, películas, libros, etc.
- Permite introducir novedades respecto a la experiencia previa del usuario.
- Similar a popularidad global, pero personalizada al usuario (por afinidad con los “puntuadores”, siendo éstos otros usuarios).

2.4.2.2. Inconvenientes

- El coste computacional es elevado. Requiere mucho espacio de almacenamiento y tiempo de proceso para determinar usuarios parecidos.
- Es imprescindible conocer la valoración de algunos objetos para que el proceso pueda funcionar.
- Problema de Cold-Start: Problema del Usuario Nuevo (ó early rater) y Problema de Ítem Nuevo.
- Problema de Dispersión (Sparsity) : si el número de usuarios es pequeño en relación al volumen de información en el sistema, se corre el riesgo de que el cubrimiento de las valoraciones se vuelva muy disperso, disminuyendo la colección de ítems recomendables.
- Problema de Escalabilidad: a medida que la cantidad de usuarios y de ítems crece, también crece la cantidad de cálculos de vecinos más cercanos para la determinación de usuarios similares y, dado que los cálculos se hacen en tiempo real, el sistema puede colapsar.
- Problema de la Oveja Gris: existen usuarios donde sus perfiles encajan entre clases existentes de usuarios, haciendo difícil determinar para ellos una recomendación adecuada.
- Problema de la Sinonimia: se produce por la escasez de cualquier forma de interpretación semántica. Ítems similares no se tratarán de tal manera cuando se hagan las recomendaciones.

2.4.3. Sistemas de recomendación Híbridos

Dado que los sistemas colaborativos y los basados en contenido tienen un carácter complementario, ha surgido un nuevo grupo de sistemas que trata de aunar las ventajas de ambos para efectuar mejores recomendaciones.

Los sistemas híbridos explotan características de los sistemas basados en contenido y colaborativos, debido a la naturaleza complementaria de ambos. Lo que se busca es sobrellevar los inconvenientes de ambos sistemas para obtener mejores recomendaciones.

Para crear un sistema híbrido, los perfiles de usuario se mantienen según el análisis de los contenidos de los ítems y, directamente, se comparan esos perfiles para determinar la similaridad entre usuarios para una recomendación colaborativa.

2.4.4. Otras clasificaciones de sistemas de recomendación

En [30] se proponen otros tipos de sistemas de recomendación, aunque de una u otra forma están relacionados con los tipos de sistemas de recomendación antes mencionados:

- **Recomendaciones demográficas (Demographic):** Clasifican a los usuarios de acuerdo a su perfil y hacen las recomendaciones basándose en clases demográficas. Las recomendaciones demográficas son similares a las recomendaciones basadas en contenido con la excepción de que las similitudes están calculadas a partir de la utilización de información demográfica en lugar de valoraciones de los ítems.
- **Recomendaciones basadas en el conocimiento (Knowledge based):** Las sugerencias de los ítems se basan en inferencias sobre las necesidades de los usuarios y sus preferencias. Para ello, se utiliza conocimiento en donde se tiene información sobre cómo un ítem específico responde a una necesidad en particular del usuario y, por lo tanto, la razón sobre la relación entre la necesidad y una posible recomendación.
- **Recomendaciones basadas en la utilidad (Utility based):** Son sistemas de recomendación que crean una función de utilidad para cada ítem la cual interviene directamente en el proceso de recomendación. La ventaja de este método es que permite evaluar elementos no atribuibles al producto o ítem en sí. Aspectos como la fiabilidad de un proveedor o la disponibilidad de un ítem estarían representados en la función de utilidad.

Por otro lado, se encuentran los sistemas de recomendación semánticos que mejoran y enriquecen la representación de la información mediante la aplicación de tecnologías de Web Semántica. Se pueden clasificar en tres tipos [30]:

- **Sistemas basados en ontologías o esquemas de conceptos:** Las ontologías (esquemas conceptuales de la información correspondientes a un dominio en concreto) son utilizadas para representar la información o modelar los ítems así como para el modelado de usuarios o perfiles de usuario.
- **Sistemas adaptables al contexto:** Toman en consideración diferentes factores del usuario tales como temporales, de lugar, nivel de experiencia, dispositivo que se está utilizando en el momento de recibir la recomendación, para inferir el contexto en que se encuentra el usuario y adaptar la recomendación a esas circunstancias.
- **Sistemas basados en redes de confianza:** Añaden filtros de información adicionales a los sistemas adaptables al contexto. Estos sistemas están enfocados en garantizar la fiabilidad y precisión de las recomendaciones mediante la creación de redes de confianza entre las diferentes partes que componen el sistema. La confianza de los usuarios, además de aportar credibilidad a los resultados de las recomendaciones, implica un aumento de calidad y usabilidad del sistema.

2.4.5. Ventajas de los Sistemas de Recomendación

Los sistemas de recomendación ofrecen una amplia gama de ventajas tanto a los usuarios que utilizan Internet para buscar o compartir información, como a las instituciones que utilizan la Web para ofrecer sus servicios y tener presencia en la misma. A continuación, se indican una serie de ventajas que ayudan a los usuarios y a las empresas a optimizar el tiempo y lograr obtener u ofrecer la información deseada con un mínimo esfuerzo y dedicación gracias a los sistemas de recomendación:

- **Satisfacción del usuario:** mejoran la satisfacción de los usuarios porque le ayudan a descubrir nuevos contenidos de su interés de una forma fácil y con un mínimo esfuerzo.
- **Ahorro de tiempo:** reducción de tiempo por parte de los usuarios para encontrar cosas que le gusten o le parezcan interesantes.
- **Descubrimiento de información:** ayuda a los usuarios a encontrar cosas nuevas (productos, amigos, temas de interés, etc.) de una forma eficaz y fácil.
- **Personalización del cliente:** ofrecen recomendaciones personalizadas y acertadas relacionadas al perfil de los usuarios.

- **Forma efectiva de Marketing:** es una forma atractiva y eficiente de compra-venta ya que permite crear una experiencia de compra personalizada para cada cliente.
- **Mejora la retención del cliente:** como funciona como asesor personal de cada cliente, hace que el proceso de compra sea más fácil y más agradable.
- **Obtener una visión del cliente:** permite generar informes que ayudan a saber por qué y qué productos se están vendiendo y quién los está comprando. Esto, principalmente, gracias al mecanismo de retroalimentación.
- **Aumentar el promedio de las compras:** los sistemas de recomendación ayudan a las personas a encontrar lo que desean de manera fácil, lo que hace que la tendencia de compra sea mayor.

2.4.5.1. Sobrecarga de datos

El acceso al gran volumen de datos disponibles en Internet requiere de mecanismos y algoritmos de clasificación que permitan optimizar las búsquedas y el acceso a estos contenidos de una manera eficiente. Todos los días aumenta el volumen de información disponible en la Web, y esto se convierte en un problema de optimización para los sistemas de recomendación [32][33][34].

2.4.5.2. Implementación de un mecanismo eficiente de retroalimentación

En la mayoría de los casos, los mecanismos de retroalimentación están basados en la retroalimentación explícita, y esto puede causar inconvenientes a los usuarios porque típicamente no les gusta valorar los contenidos. Las valoraciones explícitas son los más comunes y evidentes indicadores del interés de los usuarios, porque le permiten identificar al sistema qué es lo que realmente piensan de los objetos a valorar. Por otro lado, estos pueden alterar la navegación normal y los patrones de lectura de los usuarios porque le obligan a detenerse a valorar los contenidos. Además, estos pueden dejar de valorar los objetos si no perciben algún beneficio [35].

Por lo tanto, es necesario obtener la mayor cantidad de información como sea posible sin la intervención directa de los usuarios, con la finalidad de determinar sus intereses y necesidades, e intentar implementar un mecanismo de retroalimentación más eficaz [31].

2.4.5.3. Arranque en frío en los sistemas de recomendación

Cuando el sistema de recomendación no dispone de suficiente información acerca de un usuario o contenido, es difícil poder realizar recomendaciones, y sobre todo, recomendaciones válidas o acertadas para el usuario en cuestión. El problema del arranque en frío, se debe a la existencia de contenidos que nadie ha valorado explícitamente o implícitamente, dentro de un conjunto de datos [29][36]. En general, si no se valoran los contenidos, no es posible hacer inferencia sobre el interés o gusto de los usuarios.

2.4.5.4. Coste de los sistemas de recomendación

Otro de los problemas de los sistemas de recomendación es el coste de realizar el mantenimiento del sistema. Es necesario pensar en modelos de negocio que se podrían usar para generar suficientes ingresos y así cubrir estos costes. Para [3], una posible solución sería que los usuarios registrados en el sistema de recomendación tengan que pagar una suscripción por pertenecer a él o incluir publicidad en el sistema de recomendación y recibir dinero a cambio.

2.4.5.5. Diseño de los sistemas de recomendación

El sistema de recomendación debe tener buenas técnicas de representación de las preferencias o recomendaciones de los usuarios para poder captar verdaderamente el concepto del objeto recomendado. Además, la interfaz del sistema de recomendación tiene que ser atractiva y debe mejorar la interacción de recomendación-usuario.


El sistema de recomendación no tiene que hacer solamente buenas recomendaciones sino que debe ser un entorno amigable. Es fundamental captar la atención de los usuarios ya que si no hay usuarios en el sistema de recomendación, no hay recomendaciones.

2.5 Ejemplos y casos de estudios de sistemas de recomendación

En la actualidad, existe una amplia gama de sistemas de recomendación que son usados en diferentes áreas, ya sea con fines comerciales, científicos o experimentales. A continuación, se resumen brevemente los más conocidos o usados para la selección de revistas científicas.

2.5.1. Elsevier Journal Finder

Elsevier Journal Finder, es uno de los sistemas de recomendación de revistas que cubre todos los dominios científicos y más de 2900 revistas de la editorial Elsevier. El sistema utiliza técnicas de procesamiento de lenguaje natural para la generación de características y Okapi BM25 para el algoritmo de recomendación. El procedimiento consiste en ingresar texto de búsqueda, como un resumen, y obtener una lista de revistas recomendadas y metadatos relevantes.[37]




The screenshot displays the Elsevier Journal Finder web interface. At the top, the Elsevier logo and 'JournalFinder' text are on the left, while 'Find journals', 'About', and 'FAQ' links are on the right. The main form is divided into several sections: 'Paper title' with a text input field containing 'Cases of autoimmune rippling muscles with myasthenia gravis'; 'Paper abstract' with a text input field containing 'We present six cases with iRMD (immune-mediated rippling muscle disease) and AChR-antibody positive myasthenia gravis.' and a 'Don't have an abstract?' link; 'Keywords' with two tags 'Neuromuscular Disease' and 'Neuromuscular Disorders'; and 'Field of research' with a 'Medicine' tag and a 'Select field of research' dropdown menu. A 'Maximum 5,000 characters' warning is visible near the abstract field. At the bottom left is a '+ Refine your search' link, and at the bottom right is a blue 'Find journals >' button.

Figura 2.1: Sitio Journal Finder

2.5.2. Springer Journal Suggester

Springer Journal Suggester es una herramienta de investigación académica que permite a los usuarios seleccionar la revista más adecuada para su investigación. Permite la selección de revistas de una base de datos de más de 2600 publicaciones de Springer. La herramienta provee de una lista de revistas relevantes, en función del título del manuscrito, el resumen y el modelo de publicación.



The image shows a web form titled "Journal suggester" from Springer Nature. The form is designed to help researchers find suitable journals for their work. It includes a header with the Springer Nature logo and the title "Journal suggester". Below the header, there is a brief instruction: "Enter your manuscript details to see a list of journals most suitable for your research." The form consists of three main input fields: "Manuscript title" (a single-line text box), "Manuscript text" (a large multi-line text area), and "Subject area" (a dropdown menu with "Please select" as the current option). Below the "Subject area" field, there is a link that says "+ Refine your recommendations". At the bottom of the form, there is a prominent blue button labeled "Suggest journals".

Figura 2.2: Sitio Journal Suggester

2.5.3. Google Scholar

Google Scholar es un motor de búsqueda de Google enfocado y especializado en la búsqueda de contenido y bibliografía científico-académica. El sitio indexa editoriales, bibliotecas, repositorios, bases de datos bibliográficas, entre otros; y entre sus resultados se pueden encontrar citas, enlaces a libros, artículos de revistas científicas, comunicaciones y congresos, informes científico-técnicos, tesis, tesinas y archivos depositados en repositorios.

3. Enfoque propuesto

El objetivo principal del proyecto de tesis es crear una herramienta que logre brindar soporte en la tarea de selección de la revista más apropiada a aquellas personas interesadas en publicar un artículo científico mediante recomendaciones basadas en el contenido de su investigación.

La estructura del capítulo se establece de la siguiente manera: En la sección 3.1 se desarrollará una introducción del enfoque que se propone, describiendo el esquema conceptual del sistema implementado. En la sección 3.2 se procederá a explicar y comentar el proceso de scraper, mencionando las editoriales seleccionadas para el trabajo. Luego, en la sección 3.3 del enfoque mencionaremos la importancia de la recuperación de información en la actualidad. En la sección 3.4 se explicará el concepto de indexación y procesamiento de datos.

3.1 Introducción

En el contexto introducido, surge la necesidad de diseñar y desarrollar una herramienta de búsqueda con recomendación que contemple las diversas editoriales y factores de análisis para ayudar al científico en la tarea de selección del canal de publicación más apropiado para un artículo particular.

El enfoque propuesto se desarrolla como una plataforma web que permite fácilmente a los usuarios realizar búsquedas sobre revistas en base a diferentes criterios.

Podemos dividir el enfoque propuesto en 4 etapas principales. La primera de ellas se basa en la recolección y extracción de la información de los sitios web de las distintas revistas y editoriales. Luego, una vez extraída y estructurada la información se procede a almacenar en una base de datos para su posterior procesamiento en la siguiente etapa. La etapa número tres, se encarga de procesar e indexar cada una de las revistas de forma tal que puedan luego ser consultadas mediante información provista por el usuario. La última etapa es en la cual el usuario ingresa los diferentes atributos del artículo que desea publicar y obtiene las recomendaciones. A continuación, en la figura 3.1 se ilustra un modelo conceptual del sistema, y sus diferentes etapas.




Figura 3.1: Modelo conceptual del enfoque propuesto.

HelpMePublish hace uso de técnicas de procesamiento de documentos, partiendo desde la recuperación de la información necesaria, y utiliza la función de clasificación de similitud BM25 para proporcionar recomendaciones basadas en el contenido como método principal.

3.2 Fase 1: Recolección de datos

La recolección de la información de las distintas revistas es llevada a cabo mediante técnicas de web scraping. Mediante un análisis de los sitios web de las diferentes editoriales, se llegó a la conclusión de que es necesario tener que desarrollar un scraper específico para cada uno de ellos, ya que cada uno tiene la información distribuida de distinta manera. Otro aspecto importante es que no todos proveen la misma información para cada una de las revistas, y no toda información provista es de utilidad para la recomendación.

Los sitios web de las editoriales no sólo poseen información acerca de sus revistas, algunos poseen información de los artículos, obras de referencia e incluso de libros. Por este motivo, los scrapers deberán filtrar y recolectar información sólo de las revistas, y por otro lado, el alcance de nuestra propuesta solo se basa en revistas que sean de la temática de Ciencias de la Computación, por lo que también deberán considerar este filtro.

A continuación, se detalla la estructura de las páginas web de cada una de las editoriales elegidas. Además, se puede observar cómo aplicar los filtros previamente mencionados y cuáles son los datos recolectados para las diferentes revistas.

3.2.1 Editorial Elsevier

En el buscador de publicaciones de Elsevier, cómo podemos visualizar en la figura 3.2, se aplica en primer lugar el filtro para poder obtener todos los documentos de tipo journals como se ve en 1. Luego, y como se observa en 2, se limita la búsqueda al área de ciencias de la computación. Una vez aplicados ambos filtros, el sitio lista cada una de las revistas que cumplen los requisitos. De esta sección, nos interesa la dirección URL de cada una de las revistas. En esta dirección URL se encuentra el detalle de la revista.




Figura 3.2: Buscador Elsevier

De la página de detalle de la revista (ver Figura 3.3) se extrae información acerca de: el título de la revista y su imagen de portada, objetivos y alcance (aims and scope), y métricas de la revista, como puede ser el factor de impacto, el tiempo de publicación, el tiempo de revisión, etc.

Home > Journals > IFAC Journal of Systems and Control


IFAC Journal of Systems and Control
 Publishing options: [OA](#) Open Access [S](#) Subscription [↗](#)
[↗](#) Guide for authors [Track your paper](#) [v](#)

ISSN: 2468-6018

Submit your paper

 With this journal indexed in 4 international databases, your published article can be read and cited by researchers worldwide

[View articles](#)

Editor-in-Chief > [Editorial board](#)

 Professor Robert Bitmead, PhD

IFAC Journal of Systems & Control publishes high-quality research papers containing generalizable, extensible and transferable innovations across all aspects of the field of control and automation. The journal will only consider submitted papers consisting of significant previously unpublished material germane to applicable
[Read full aims & scope](#)

ⓘ Top Readership [↗](#) ⓘ Publication Time
 CN US IN 1.5 weeks

Figura 3.3: Elsevier - Detalles de una revista.

3.2.2 Editorial Springer

En la editorial Springer, el listado y la forma de filtrar las revistas es similar al de Elsevier. Sin embargo, en la imagen 3.4 se puede observar que la página de detalle de la revista, posee la portada y título de la revista, sus métricas y un texto con información acerca de la revista, quién la publica, métodos de evaluación, etc. En este caso, la información acerca del aims and scope de la revista, se encuentra en otra página por lo que aquí se debe navegar una vez más para poder obtener toda la información relevante.





Computational Visual Media

[Editorial board](#)
[Aims & scope](#)
[Journal updates](#)

Computational Visual Media is a Single-Blinded peer-reviewed open access journal published quarterly by Tsinghua University Press and Springer. It publishes original high-quality research papers and significant review articles on novel ideas, methods, and systems relevant to visual media. — [show all](#)

Editor-in-Chief
Shi-Min Hu

Publishing model
Open Access. [Learn about publishing OA with us](#)

17 days Submission to first decision	44,855 (2020) Downloads
--	-----------------------------------

Figura 3.4: Springer - Detalles de una revista.



Computational Visual Media

[Journal home](#) > [Aims and scope](#)

Aims and scope

Computational Visual Media is a peer-reviewed open access journal. It publishes original high-quality research papers and significant review articles on novel ideas, methods, and systems relevant to visual media.

Computational Visual Media publishes articles that focus on, but are not limited to, the following areas:

- Editing and composition of visual media
- Geometric computing for images and video
- Geometry modeling and processing
- Machine learning for visual media

Figure 3.5: Springer - Aims and Scope

3.2.2 Editorial Wiley

En el caso de la editorial Wiley, el detalle cuenta con un atributo muy importante como son las keywords. A diferencia de las editoriales anteriores, Wiley cuenta con esta sección que será de mucha utilidad a la hora de realizar y refinar la búsqueda por los campos ingresados. Por otro lado, la sección general no presenta diferencias con respecto a las anteriores.




Figura 3.5: Wiley - Detalles de un artículo.

3.3 Fase 2: Almacenamiento y Estructuración de la Información

Una vez identificada y recolectada la información de las diferentes revistas para los diferentes editoriales, se propone definir una estructura en común y abstracta a todos las revistas que sea de rápido acceso, y pueda ser fácilmente actualizada en caso de ser necesario. La información almacenada contiene todos los campos en común, como título, about, aims and scope, keyboards, url de la página y la imagen de portada de la revista. Algunos de ellos de gran importancia para realizar el

filtrado basado en el contenido y alcance de las distintas revistas como el título, el aim and scope, keywords y about. Otros, de menor relevancia que se utilizan para mejorar la presentación de los resultados como la imagen de portada de la revista, la url para la redirección y métricas de cada revista.

3.4 Fase 3: Indexación de la información

Los campos anteriormente citados utilizarán un analizador personalizado para procesar el texto desestructurado almacenado de las revistas. Como resultado se tendrá una optimización de dicha estructura para realizar las búsquedas. El analizador tendrá 3 etapas, filtros de caracteres (char filters), tokenizadores (tokenizers) y filtro de token (token filters).

El filtrado de caracteres se encargará de transformar el texto, agregando, quitando o modificando el mismo. Es posible tener varios filtros.

Como la información es obtenida mediante el proceso de scraping, es posible que los campos almacenados contengan elementos html. Es por eso que se realizará un filtrado llamado *html_strip*. Este filtro nos permite eliminar los elementos HTML de un texto, y además reemplaza las entidades HTML con su valor decodificado. Por ejemplo, para un texto con el siguiente contenido “<p>I'm so happy!/</p>” el filtro producirá el siguiente texto “I’m so happy!”.

Luego del proceso de filtrado de caracteres se generarán los tokens, generalmente son palabras individuales. Para ello, se seleccionó el tokenizador *standard* que se adapta de la mejor manera a nuestra información. **Elasticsearch** provee diferentes tokenizadores que pueden ser utilizados para realizar esta función. El tokenizador *standard*, divide el texto en tokens en los límites de las palabras, según lo define el algoritmo de segmentación de texto Unicode. Además, elimina la mayoría de los símbolos de puntuación. A diferencia de la etapa anterior, un analizador sólo puede contener un único tokenizador.

Como etapa final, los tokens generados deberán ser optimizados para su utilización. Es por ello que se aplican filtros de tokens como *lowercase*, *stopwords*, *stemmer*, *synonym* y los que sean necesarios.

3.5 Fase 4: Presentación de la información

El primer paso a realizar para comenzar a utilizar la herramienta será la realización del proceso de login. Una vez dentro de la aplicación, el usuario tendrá la posibilidad de seleccionar los campos que quiere ingresar para la búsqueda. El formulario de búsqueda contará con los campos de título, abstract y keywords para poder ejecutar la consulta y obtener una lista de resultados. Además, se tendrá la posibilidad de refinar la búsqueda de manera que se pueda modificar los valores de

relevancia de los diferentes campos de búsqueda en los distintos atributos de los journals y sobre si se desea buscar en todos ellos o no.

Luego de realizada la búsqueda se presentará la información obtenida en forma de lista, en donde los primeros journals serán los de mayor relevancia con respecto a los datos ingresados. Cada ítem tendrá su propia información como el título, la editorial y la imagen de portada. En el caso de contar, se presentará información acerca de métricas como el impact factor, fecha de importancia, cantidad de descargas, entre otras. Además, al clickear sobre alguno de los resultados se redireccionará al usuario al sitio del journal.

4. Implementación

En este capítulo se describe la implementación de la herramienta HelpMePublish desde un punto de vista técnico, analizando su diseño y desarrollo. En la primera sección de este capítulo se muestra un diagrama que representa la vista de módulos del sistema. Se eligió la utilización de dicha vista con el objetivo de presentar la funcionalidad del sistema mediante unidades estáticas que proveen conjuntos de servicios y responsabilidades. Además, en las secciones siguientes se descomponen dichos módulos utilizando diagramas de clases. Estos permiten realizar un análisis de mayor profundidad sobre la implementación y el diseño.

En la última sección del presente capítulo se muestran capturas de la aplicación en funcionamiento bajo las distintas pantallas que pueden encontrarse. Entre ellas, se muestra la pantalla de login para ingresar a la aplicación. Una vez dentro, se observa el buscador con sus respectivos campos a ingresar. Por último, se encuentra la vista de resultados en donde se detalla un listado con información individual de cada revista recomendada.

Por otro lado, cabe destacar que el desarrollo de HelpMePublish se realizó en .NET, utilizando el entorno de desarrollo Visual Studio. El motivo de la utilización de .NET corresponde a la familiarización y experiencia con dicha tecnología. También es importante mencionar que existe una gran cantidad de bibliotecas que facilitan el trabajo básico necesario, permitiendo enfocarse en el objetivo real del proyecto.




Figura 4.1: Diagrama del módulo del sistema.

4.1 Scraper

Este módulo se encarga de llevar a cabo la captura de la información de las diferentes revistas en las distintas editoriales elegidas, para luego poder ser almacenada para su posterior procesamiento.

En la Figura 4.2, se ilustra la clase abstracta **Scraper**, la cuál provee un conjunto de propiedades, y métodos necesarios que deben ser implementados para poder realizar la extracción de los datos relevantes de las diferentes editoriales y revistas de interés.




Figura 4.2: Diagrama de clases

La propiedad llamada **browser**, es un objeto del tipo **IBrowsingContext** de la biblioteca **AngleSharp**². El mismo nos permite navegar y realizar peticiones de sitios web, modelando los mismos en objetos de la interfaz **IDocument**, los cuales nos servirán como punto de entrada para el contenido de la página web. Esta interfaz provee métodos para recorrer los diferentes elementos del DOM (Document Object Model, por sus siglas en Inglés) y poder acceder a ellos y manipularlos.

Por otro lado, la propiedad **editorial** del tipo **IEditorial**, representa la editorial del cual el scraper extraerá las diferentes revistas. Esta posee información acerca de la URL base de la editorial en cuestión, y un método para obtener las distintas páginas que contienen los listados de las revistas objetivo. Esta página de listado, como ya se mencionó en la sección 3.2, puede poseer paginación y/o algún filtro respecto a los tópicos que tratan las distintas revistas. En base a estos valores, la URL puede variar, por lo que este método nos ayudará a determinar la URL a utilizar. En la imagen 4.3, se puede observar que para la editorial *Elsevier* la URL varía según el tópico y el número de página.

² AngleSharp <https://github.com/AngleSharp/AngleSharp>

```

1 reference
public class ElsevierEditorial : IEditorial
{
    4 references
    public string Key { get; init; } = "Elsevier";
    9 references
    public string BaseUrl { get; init; } = "https://www.elsevier.com/";
    6 references
    public string GetListUrl(int subject, int page = 1)
    {
        return $"{BaseUrl}search-results?labels=journals&subject-0={subject}&page={page}";
    }
}

```

Figura 4.3: Clase ElsevierEditorial

Dentro del conjunto de métodos que la clase **Scraper** define, y que deben ser implementados si o si por los distintos scrapers que hereden de esta clase, se encuentran los métodos llamados: **GetListOfJournals** y **FillJournalDetails**. El primero de ellos deberá generar un listado con las diferentes revistas a procesar, mientras que el otro, es el encargado de extraer la información de la página web de la revista.

Por último, la clase **Scraper** define un método llamado **Run** que es en donde tiene lugar la acción del scraper y los métodos previamente mencionados genera un listado de objetos del tipo **Journal** que contendrá toda la información relevante extraída de las páginas web. La anatomía de este método se puede ver en la siguiente figura, en donde primero se obtiene el listado de revistas a procesar. Segundo, por optimización, se descargan en paralelo las páginas de detalle de cada una de las revistas. Tercero, por cada una de las páginas descargadas, se extrae y rellena el objeto **Journal** con la información extraída de la misma.

```

/// <summary>
/// Download all the detail pages in parallel.
/// </summary>
1 reference
protected Task<IDocument[]> DownloadDetailPages(ISet<Journal> journals) =>
    Task.WhenAll(journals.Aggregate(new List<Task<IDocument>>(), (tasks, journal) =>
    {
        //Open every page async, and add the task to the list of tasks to be waited.
        tasks.Add(GetDetailPage(journal));
        return tasks;
    }));

/// <summary>
/// Read all journals from the editorial website and return them as a list of Journal objects with full information
/// </summary>
6 references
public async Task<ISet<Journal>> Run()
{
    var journals = await GetListOfJournals(); 1
    var pages = await DownloadDetailPages(journals); 2

    foreach(var page in pages)
    {
        var journal = journals.First(j => editorial.IsJournalPage(j, page.Url));
        if (journal != null)
        {
            await FillJournalDetails(journal, page); 3
        }
    }

    return journals;
}

```

Figura 4.4: Método Run

En la siguiente sección se verá en detalle cuales son los diferentes datos extraídos de las revistas, y como estas son almacenadas.

4.2 Acceso de datos

El módulo de acceso de datos tiene como propósito, abstraer la base de datos utilizada y, además, proveer una interfaz clara para el resto de los módulos de cómo acceder y almacenar la información necesaria.

Este módulo hace uso de una biblioteca llamada **Dapper**³ para poder hacer el mapeo entre la base de datos y los objetos C#. El motor de base de datos seleccionado para este proyecto es PostgreSQL⁴, ya que es gratuito y libre, además de que ofrece una gran variedad de opciones avanzadas.

Los datos que se almacenan de las distintas revistas son los mismos indistintamente para las distintas editoriales. En la figura siguiente se observa un diagrama de entidad-relación de cómo las revistas se encuentran modeladas en la base de datos.




Figura 4.5: Diagrama entidad-relación

³ Dapper. <https://dapper-tutorial.net/dapper>

⁴ PostgreSQL. <https://www.postgresql.org/>

Como se puede observar, la entidad **journal** representa una revista de una editorial. Los atributos más importantes de dicha entidad son:

- Title: Es una cadena de caracteres que representa el título o nombre de la revista.
- About: Contiene información acerca de la revista en sí.
- Aims And Scope: Contiene información acerca de los objetivos y ámbitos de los temas que se hablan en dicha revista.
- Keywords: Conjunto de palabras claves acerca de cuál es la temática o tópicos sobre los que tratan los artículos que se difunden en la revista.
- Url: La dirección URL de la revista.
- ImgUrl: La portada de la revista.

Luego, existen otros atributos como *CreatedAt*, *ModifiedAt*, *CreatedBy* y *ModifiedBy*, que son utilizados para almacenar información acerca del usuario que ha creado el registro, y el último usuario que modificó el registro, además de indicar las fechas en que dichas operaciones ocurrieron.

El atributo *version* es un campo numérico que se incrementa cada vez que se ejecutan los scrapers. De esta manera, generamos un histórico de revistas. Este campo además es utilizado en el proceso de indexación con el objetivo de mantener actualizado el índice con la última información extraída. En la siguiente sección se describen más detalles acerca de este proceso.

La entidad **journal_metrics** se utiliza para almacenar las diferentes métricas de las revistas. Cada métrica tiene su propio identificador, un nombre (por ejemplo, Impact Factor, CiteScore, etc) y un valor. Una métrica pertenece únicamente a una revista, y una revista puede poseer muchas métricas. Por lo que la relación entre la entidad **journal** y **journal_metrics** es del tipo one-to-many.

Por último, se encuentran las entidades **user**, **role** y **user_role**. Las cuales modelan los usuarios del sistema y sus roles.

4.3 Motor de Búsqueda

Una vez extraída y almacenada la información de las diferentes revistas, el módulo de motor de búsqueda nos provee diferentes interfaces para realizar la indexación de dicha información y poder ejecutar consultas complejas sobre los diferentes datos de las revistas.

En este módulo se utiliza **Elasticsearch**⁵, el cual es un motor de búsqueda que está desarrollado a partir de **Lucene** por lo que es una buena alternativa para la búsqueda de texto completo.

En el centro de la arquitectura lógica de **Elasticsearch** se encuentra el concepto de Documento (Document) que contiene un conjunto de campos (Fields)

⁵ Elasticsearch <https://www.elastic.co/es/enterprise-search>

con sus correspondientes valores, estos valores pueden ser de diferentes tipos (String, Numbers, Dates, boolean, etc). Esta flexibilidad permite independizarse del formato del contenido a indexar. Durante el proceso de indexación, estos documentos son almacenados y se construye un índice invertido para optimizar la búsqueda de datos en dichos documentos.

Los documentos a indexar en nuestro caso, serán las revistas, pero vale mencionar que no todos los campos almacenados son de utilidad para realizar las búsquedas. Por ejemplo, las columnas utilizadas para auditoria de cuando se crearon las revistas en la base de datos.

A continuación se puede observar cuál es la estructura de los documentos indexados y los diferentes campos:

```
namespace SearchEngine.Indices;

99+ references
public class JournalDocument : ElasticBaseIndex
{
    [Text(Name = "title", Analyzer = "journals", Boost = 2)]
    99+ references
    public string? Title { get; set; }

    [Text(Name = "about", Analyzer = "journals", Boost = 1.5)]
    99+ references
    public string? About { get; set; }
    [Text(Name = "aims_and_scope", Analyzer = "journals", Boost = 1.75)]
    99+ references
    public string? AimsAndScope { get; set; }
    99+ references
    public string? Url { get; set; }
    99+ references
    public string? ImgUrl { get; set; }
    1 reference
    public string? Editorial { get; set; }
    99+ references
    public double? ImpactFactor { get; set; }
}
```

Figura 4.6: Clase JournalDocument

La clase JournalDocument cuenta con los campos más importantes a la hora de indexar un documento. Los primeros tres campos, title, about y aims and scope, comparten propiedades para la indexación. La propiedad analyzer especifica el analizador utilizado para la indexación, en nuestro caso "journals". Por otro lado, también cuentan con la propiedad boost. Esta propiedad hace referencia a la relevancia que tendrá dicho campo a la hora de realizar la búsqueda. Esto quiere decir, que title será el doble de relevante que Url, ImgUrl, Editorial e ImpactFactor.

Los diferentes campos utilizan un analyzer personalizado llamado **journals-analyzer**. El cual procesa el texto desestructurado que fue almacenado para las revistas y lo convierte en una forma estructurada optimizada para las búsquedas. Un analyzer se compone de tres etapas, filtros de caracteres (char filters), tokenizadores (tokenizers) y filtro de token (token filters).




Figura 4.7: Diagrama analyzer

El filtrado de caracteres recibe el texto original como una cadena de caracteres y lo transforma agregando, quitando o modificando los mismos. Un analizador puede tener o no varios filtrados de caracteres, los cuales son aplicados en orden.

La información de las revistas, como ya se mencionó, fue extraída de páginas web por lo que algunos de los campos almacenados poseen elementos HTML obtenidos por el proceso de scraping. Por este motivo, necesitamos realizar un filtrado de los elementos HTML, para ello se utilizó el filtro llamado *html_strip*, el cual elimina los elementos HTML del texto y reemplaza las entidades HTML con su respectivo valor decodificado (por ejemplo, reemplaza & con &).

Una vez que finaliza la etapa de filtrado de caracteres, se procede a dividir el texto en partes más pequeñas, llamados tokens. En la mayoría de los casos estos tokens son palabras individuales. **Elasticsearch** provee diferentes tokenizadores que pueden ser utilizados para realizar esta función. En nuestro caso, el tokenizer elegido se llama *standard* que utiliza el algoritmo de segmentación de texto de Unicode para dividir el texto, y además elimina los símbolos de puntuación. Vale destacar, que a diferencia de la etapa anterior, un analizador sólo puede contener un único tokenizador.

Por último, los diferentes token generados son enviados a la siguiente etapa, la cual puede modificar, e incluso eliminar o agregar tokens al resultado final. Esta etapa es útil para normalizar los términos, convirtiéndolos a todos en minúsculas o eliminar ciertos términos que no son importantes para la búsqueda. Los diferentes filtros de token que aplicamos son:

- *lowercase*: convierte todos los términos en minúscula.
- *stop*: elimina las stop words.
- *Stemmer*: reduce el token a su raíz.
- *synonym*: agrega los sinónimos de un token.

Journal Metrics: Si bien no se utilizan para la indexación de datos, es información útil para los investigadores-usuarios finales que se mostrará en la página de resultados. Ejemplo de algunas de estas métricas son, impact factor,

review time, entre otras. El motivo de porqué estas métricas no se indexan, se discutirá en la próxima sección.

4.4 Interfaz

En esta sección se muestra cómo fue realizada la UI de la aplicación. Como primer paso, mencionar que toda la interfaz fue desarrollada usando Vue 3. Vue.js⁶ es un proyecto de código abierto con licencia del MIT cuyo desarrollo continuo es posible gracias al apoyo de patrocinadores. Está diseñado desde cero para ser adoptado gradualmente y puede escalar fácilmente entre una biblioteca y un marco según los diferentes casos de uso. Consiste en una biblioteca central accesible que se enfoca solo en la capa de vista y un ecosistema de bibliotecas de soporte que permite abordar la complejidad de grandes aplicaciones de una sola página.

4.4.1 Login

La primera pantalla que nos encontramos al ingresar a HelpMePublish es la pantalla de login.





Figura 4.8: Pantalla de login.

Como se puede observar en la imagen, el servicio de login es sencillo. Solamente es necesario tener un usuario, ya sea con el rol de usuario o de administrador para ingresar a la aplicación.

⁶ Vue.js <https://vuejs.org/>

4.4.2 Buscador

Una vez dentro de la aplicación, en la parte superior izquierda, se observa el nombre de la aplicación con la finalidad de la misma. Para continuar se deberán ingresar datos para la búsqueda siendo todos los campos obligatorios.




The screenshot shows the 'Find journals' section of the HelpMePublish! application. It features a dark blue header with the text 'HelpMePublish! - Journal Finder' and a user icon. The main area is light gray and contains the following fields:

- Paper Title:** A text input field with the placeholder 'Enter your paper title'.
- Paper Abstract:** A larger text input field with the placeholder 'Enter your paper abstract'.
- Paper Keywords:** A text input field with the placeholder 'Enter relevant keywords for your paper'.
- A link labeled '+ Refine your search'.
- A 'Search Journals' button with a magnifying glass icon.

Figura 4.9: Pantalla del buscador.

El usuario deberá ingresar un título, un abstract y keywords para poder ejecutar la consulta y esperar su recomendación correspondiente. En la siguiente imagen se puede apreciar como se ve la vista rellena con información.



This screenshot shows the same 'Find journals' form as Figure 4.9, but it is populated with sample data:

- Paper Title:** 'A deep learning approach to automatic road surface monitoring and pothole detection'.
- Paper Abstract:** A detailed paragraph about road surface anomalies, driver safety, and the use of deep learning models (CNN, LSTM, Reservoir Computing) for pothole detection.
- Paper Keywords:** Three tags are displayed: 'Deep learning', 'Road surface monitoring', and 'Pothole detection'.
- The 'Search Journals' button is visible at the bottom right.

Figura 4.10: Pantalla completa de datos.

Por otro lado, el formulario provee la posibilidad de refinar la búsqueda para que el usuario pueda modificar los valores por defecto que trae HelpMePublish

sobre los atributos considerados más importantes para la recomendación de journals.

— Refine your search

Paper Title			Paper Abstract			Paper Keywords					
Journal Fields	Boost		Journal Fields	Boost		Journal Fields	Boost				
☒ Title	—	2.7	+	☒ Title	—	0.4	+	☒ Title	—	3.2	+
☒ About	—	4	+	☒ About	—	2.3	+	☒ About	—	3.2	+
☒ Aims and Scope	—	3	+	☒ Aims and Scope	—	0.4	+	☒ Aims and Scope	—	3.2	+
☐ Keywords	—	1	+	☐ Keywords	—	1	+	☐ Keywords	—	1	+

Search Journals

Figura 4.11: Pantalla refinamiento búsqueda.

4.4.3 Resultados

Por último, el usuario se encuentra con la pantalla de resultados que obtiene como producto de su consulta ingresada en la pantalla anterior.

HelpMePublish! - Journal Finder

Showing 10 journals matching your paper!

Edit Search New Search

	The Visual Computer Score 100.97691 Impact Factor 2.601 Five Year Impact Factor 2.081 Submission To First Decision 40 days Springer
	Journal of Computer Languages Score 65.94882 Impact Factor 1.271 5-year Impact Factor 1.271 Citescore 2.100 ELSEVIER
	Computational Visual Media Score 62.22988 Submission To First Decision 17 days Springer

Figura 4.12: Pantalla de resultados.

La vista resultante muestra en la parte superior la cantidad de journals con mayor relevancia con respecto a la información ingresada. La lista de resultados es mostrada en forma descendente según la valoración obtenida. Cada journal muestra el título, la editorial, la portada y cliqueando sobre él, será redirigido a su respectivo sitio web.

Además, para aquellos journals con los que se cuenta con información de métricas, como el impact factor, fecha de importancia, cantidad de descargas, entre otras son mostradas como información extra para ayudar a al investigador elegir el mejor journal.

4.5 Infraestructura/Docker

Para la implementación de toda la aplicación, utilizamos Docker Compose, una herramienta para definir y ejecutar aplicaciones Docker. Mediante un archivo YAML configuramos los servicios necesarios para el funcionamiento de nuestra app.

En docker-compose.yml se puede encontrar lo necesario para configurar postgres, pgadmin, elasticsearch, kibana y nuestro website, el cual fue subido al docker Hub como imagen pública.




Figura 4.13: Docker Desktop

4.5.1 Instalación del entorno.

El primer paso es levantar los containers con *docker-compose up -d* desde la carpeta donde se encuentre el archivo docker-compose.yml, también es necesario tener docker instalado.

Una vez descargadas todas las imágenes docker, se debe configurar la base de datos de las revistas. Para ello, dirigirse a <http://localhost:5050> contraseña

admin. Una vez dentro, hay que crear un nuevo server llamado *journals* y en la configuración de la conexión ingresar los siguientes valores:

- Hostname/address = postgres
- Port: 5432
- Username: journalsAdmin
- Password: JuanRomanRiquelme

El siguiente paso es crear la base de datos con el nombre *JournalsRecommender*. El siguiente paso es copiar el archivo de respaldo en el contenedor con el siguiente comando `docker cp SRC_FILE pgadmin_container:/tmp/JournalsRecommender.backup`. Donde SRC_FILE es la ubicación del archivo de backup, por ejemplo C:/temp/JournalsRecommender.backup.

Como último paso en la configuración, se debe restaurar la base de datos. Para ello, presionar clic derecho sobre la base de datos *JournalsRecommender*, seleccionar *Restore* y dirigirse a la ubicación del archivo */tmp/JournalsRecommender.backup* y restaurar.

Ahora, procedemos a la creación de los índices. Para ello, hay que abrir Swagger vía <http://localhost:5000/swagger/index.html>. Como primer paso, hay que dirigirse a `api/auth` para la generación del token con las credenciales del usuario, para este procedimiento se necesita que el usuario tenga el rol de administrador. Una vez generado el token, se debe agregar el mismo en el botón Authorize.

A continuación, es posible la creación de los índices en `api/index/create`, si todo fue realizado correctamente se mostrará un mensaje satisfactorio. Luego, ejecutar `api/index/fill` para completar el índice. La última versión en el archivo de backup es la v2. Por lo tanto, es posible utilizar 2 como número de versión.

Una vez realizados todos los procedimientos comentados, es posible ejecutar HelpMePublish! desde la siguiente url <http://localhost:5000/>.

5. Experimentación

El presente capítulo detalla todos los aspectos relacionados a los experimentos realizados, es decir, el análisis de todas las pruebas ejecutadas y las diferentes configuraciones que se experimentaron a lo largo del proyecto. En la sección 5.1, se describe y comenta el conjunto de datos utilizado y los aspectos más importantes del mismo. En la sección 5.2, se presentan los diferentes casos de estudio. La 5.3 menciona detalles a tener en cuenta en el análisis de resultados. En las secciones 5.4 y 5.5 se tratan los diferentes casos de estudios y sus resultados, primero el análisis uni-editorial y por último el análisis multi-editorial.

5.1 Dataset

Para comenzar la experimentación y análisis de resultados, contamos con un conjunto de datos descargado desde Open Academic Graph⁷ (OAG). OAG está compuesta por Microsoft Academic Graph (MAG) y Aminer, dos importantes grafos académicos. La versión inicial fue publicada a mediados de 2017 la cual contiene un aproximado de 160 millones de artículos de MAG (39 Gb) y 154 millones de Aminer (103 Gb), generando 64 millones de coincidencias entre ambas.

5.1.1 Refinamiento de datos

Para un correcto uso de la información, fue necesario analizar, procesar y seleccionar los artículos más valiosos para nuestro trabajo. Para ello, hubo que analizar y procesar cerca de 300 millones de artículos. Se filtraron en su mayoría, los artículos que no fueran en inglés y que no cuenten con los datos que nosotros considerábamos obligatorios como título, keywords, abstract entre otros.

Otro aspecto importante a la hora de realizar el filtrado fue que los papers debían haber sido publicados en alguna de las editoriales seleccionadas para el trabajo. Para ello, se analizó que en las urls presentes en los artículos estos contengan alguno de los *dos* prefijos pertenecientes a dichas editoriales.

Además, teniendo en cuenta que los artículos pueden tratarse de diferentes temas y tópicos, solo nos centramos en aquellos que fueron publicados en alguna de las revistas científicas procesadas e indexadas. Para poder realizar este último filtro, el dataset contiene información del venue de los artículos y con un archivo especial de venues de Aminer y MAG pudimos vincular la información. Es por ello que, no fue posible utilizar ningún artículo de MAG ya que no cumplía con las condiciones necesarias para el procesamiento.

⁷ Open Academic Graph <https://www.aminer.cn/open-academic-graph>

Por último, consideramos la fecha de publicación como un campo de relevancia, es por eso que no tuvimos en cuenta aquellos artículos publicados previos a 2005 para contar con un conjunto de datos actualizado.

Luego de todos estos filtros aplicados, el dataset fue reducido a un total de 12.865 papers, contando con 9.593 papers de la editorial Springer, 2.886 de Wiley y 382 de Elsevier.

5.1.2 Relevancia de los campos

Cada artículo debe contar con tres campos obligatorios, *título*, *abstract* y *keywords*, para ser incluido en el conjunto final utilizado para la experimentación. Sin embargo, que todos sean obligatorios no indica que tengan la misma relevancia e importancia a la hora de buscar una revista científica en la cual ser publicado.

Por lo general, en los títulos de los artículos se busca describir el contenido del mismo en forma específica, clara, breve y concisa. Se intenta transmitir los temas principales y atraer a los lectores. El resumen o abstract, es una síntesis completa, pero breve, del contenido de su artículo. Por otro lado, las keywords son términos que permiten identificar el campo o subcampo del área científica que trata la investigación. Por lo que es posiblemente uno de los campos de mayor relevancia a la hora de buscar una revista científica.

En los casos de estudios presentados, se realizaron diferentes ajustes en la ponderación de los campos en base a lo mencionado anteriormente y algún breve análisis teniendo en cuenta la información disponible en los diferentes journals. Estos ajustes son detallados en cada caso de estudio.

5.2 Casos de Estudios

Para llevar a cabo los experimentos, se definieron dos casos de estudio de interés. El primer caso de estudio, tiene una perspectiva automática en el cuál utilizando artículos científicos ya publicados, se analiza en qué posición HelpMePublish recomienda la revista científica en la que fue publicado. Además, se definió un enfoque uni-editorial, para el cual se dividió el dataset previamente generado por cada editorial y se configuró la herramienta para que evalúe y recomiende resultados utilizando solamente las revistas de la editorial objetivo.

En este primer caso de estudio, se busca evaluar la precisión de la recomendación de HelpMePublish de una manera objetiva teniendo en cuenta en qué posición se recomendó la revista científica. Se definieron 5 rangos para dividir las calificaciones obtenidas. En primer lugar el top 1, luego el top 5, top 10 y top 25 y fuera del top 25.

En el segundo caso de estudio, se busca analizar la calidad de la recomendación de una manera subjetiva y centrada en los usuarios finales. Para este caso de estudio, se seleccionaron 5 artículos científicos al azar y se obtuvieron

las 10 primeras recomendaciones para cada una de ellas. Luego, los usuarios finales, investigadores del área de computación y sistemas de la Universidad, evaluaron las diferentes recomendaciones para cada una de las revistas. El proceso de evaluación se llevó a cabo a través de una encuesta, en la cual cada usuario puntuaba las recomendaciones como Muy Relevante, Relevante, Poco Relevante o No Relevante. Una vez obtenidas las diferentes evaluaciones de los usuarios finales, se realizó un análisis cualitativo de las recomendaciones.

Para mostrar y comparar los resultados obtenidos, expondremos una serie de gráficos analizando los valores obtenidos y diferentes temas en cuestión, como los analizadores usados, el boosting de los atributos, los datos de cada editorial y/o revista, cómo impactan dichos datos en las búsquedas, entre otros aspectos de importancia para ambos casos de estudios.

5.3 Caso de Estudio 1: Análisis Uni-editorial

El presente caso de estudio tiene como objetivo mostrar el funcionamiento de la aplicación desarrollada para el caso uni-editorial. Se realiza una recomendación editorial por editorial basándonos en sus propios datos previamente obtenidos en la etapa scraper del enfoque propuesto.

Una vez realizado esto, primeramente se comentan cuestiones acerca de la información con la que cuenta cada editorial. Luego, se muestran y analizan los resultados obtenidos dejando un gráfico por cada editorial. Por último, se estudia si la recomendación obtenida es correcta, si no lo es, por qué sucede y si existe algún factor fundamental que impacte en la recomendación.

5.3.1 Springer

Analizaremos una recomendación uni-editorial sobre los documentos indexados de la editorial Springer. Para dicha prueba contamos con un total de 9593 documentos indexados que pertenecen a 56 journals.

Se realizaron 2 estudios acerca de dicha editorial. El primero de ellos fue con el dataset resultante comentado en la sección 5.1.1 luego del refinamiento de documentos que considerábamos que no eran de relevancia para nuestra herramienta. El segundo caso de estudio se realizó sobre un nuevo dataset generado ingresando los journals que habían sido eliminados en 5.1.2 por las cuestiones anteriormente comentadas.

5.3.1.1 Análisis de la información

Cada editorial cuenta con cierta información propia, la cual capturamos y comentamos en etapas anteriores. En el caso de Springer, todos los journals

cuentan con título y aims and scope. Por otro lado, la gran mayoría cuenta con información en el campo about, y para esta editorial en particular no se cuenta con keywords. Por lo que, a la hora de determinar las recomendaciones, la herramienta solo considerará el contenido de los campos title, about y aims and scope. Por otra parte, se le dio una gran ponderación a cómo impacta el contenido de las keywords del paper, sin importar en cuáles de los campos del editorial este contenido es similar. A continuación se puede apreciar cómo se configuró la herramienta en base a este análisis:

Paper Title				Paper Abstract				Paper Keywords						
Journal Fields		Boost		Journal Fields		Boost		Journal Fields		Boost				
☒	Title	-	2.7	+	☒	Title	-	0.4	+	☒	Title	-	3.2	+
☒	About	-	4	+	☒	About	-	2.3	+	☒	About	-	3.2	+
☒	Aims and Scope	-	3	+	☒	Aims and Scope	-	0.4	+	☒	Aims and Scope	-	3.2	+
☐	Keywords	-	1	+	☐	Keywords	-	1	+	☐	Keywords	-	1	+

Figura 5.1: Configuración Springer

Comenzamos la prueba con un total de 9593 papers que fueron quienes cumplieron todos nuestros requerimientos para ser tenidos en cuenta. La cantidad de documentos sin dichos filtros sería de 16545 papers publicados en los diferentes journals de la editorial Springer.

5.3.1.2 Análisis de resultados

Para la primera evaluación, se analizó y refinó la cantidad de documentos utilizados como se comentó previamente. Se trabajó con 6891 documentos de los cuales 1818 fue rankeado con la primera posición, esto equivale a un 26,4% del total de documentos. En cuanto al top 5, fueron 1967 los documentos ubicados allí que equivalen a 28,5%. Considerando ambas métricas, se pudo determinar que cerca del 55% de los documentos fueron seleccionados en los primeros 5 puestos del ranking.




Figura 5.2: Porcentaje dataset 1 Springer

Para la segunda iteración, se trabajó con 9593 documentos correspondientes al dataset #2 con la inclusión de los journals comentados. Se analizaron los journals con peores resultados para definir si eran valores atípicos o si el problema provenía de la herramienta. Se obtuvieron los resultados correspondientes como se puede apreciar en Figura 5.3 y se determinó que el problema provenía de los journals y no de la herramienta. Para esta segunda iteración, HelpMePublish recomendó un total de 1854 documentos en primer lugar, un 19,4% del total. Además, 2066 está en los primeros cinco lugares representando un 21.7%. Solamente considerando los primeros 5 puestos del ranking de recomendaciones se logró un 40% aproximadamente. Considerando que muchos de los journals utilizados pueden contener información contraproducente, consideramos que el porcentaje logrado es bueno.

Journal	Top 25	Top > 25	Total	Porcentaje
Scientometrics	430	827	1487	84.53%
The Journal of Supercomputing	236	688	998	92.59%
Frontiers of Computer Science	43	132	185	94.59%

Figura 5.3: Métricas negativas Springer




Figura 5.4: Gráficos comparativo Springer

Comparando ambas iteraciones, podemos apreciar que la primera obtuvo un 13% más en las recomendaciones en los primeros lugares como muestra la Figura 5.4. Otro dato a resaltar, fue el aumento de documentos fuera del top 25. En la primera ejecución era de un 12.3%, valor que se incrementó a 26,1%.

En la sección 5.4.4 analizaremos un caso en particular de los journals filtrados mostrando porqué se tomó dicha decisión comparándolo con un journal de los primeros puestos.

En la figura 5.5 se listan los journals para los cuales HelpMePublish produjo los mejores porcentajes de recomendación.

Journal	Top 1	Top 5	Total	Porcentaje
Photonic Network Communications	316	90	417	97.36%
Autonomous Agents and Multi-Agent Systems	198	44	258	93.80%
Real-Time Systems	118	55	186	93.01%
Genetic Programming and Evolvable Machines	92	37	142	90.85%
Distributed and Parallel Databases	81	57	153	90.20%
Constraints	98	19	134	87.31%
Machine Learning	193	123	403	78.41%

Figura 5.5: Ranking journals Springer

5.3.2 Wiley

A continuación, analizaremos los resultados obtenidos para la editorial Wiley. Esta vez contamos con un total de 2886 documentos indexados que pertenecen a 50 journals.

Al igual que en Springer, se realizaron 2 estudios para dicha editorial siguiendo la misma metodología de trabajo, generando en una primera instancia la

evaluación del dataset original y en una segunda iteración agregando los journals que habían sido quitados.

5.3.2.1 Análisis de la información

La información que proporciona la editorial Wiley es bastante completa. Si bien hay journals específicos en donde falta algún campo con datos, el gran porcentaje de documentos utilizados cuentan con todos los datos. Es por eso que la configuración de la herramienta usa todos los ítems ajustando los valores a pruebas previas.

— Refine your search

Paper Title

Journal Fields	Boost
☒ Title	— 5 +
☒ About	— 1 +
☒ Aims and Scope	— 1.5 +
☒ Keywords	— 1.5 +

Paper Abstract

Journal Fields	Boost
☒ Title	— 2.5 +
☒ About	— 1 +
☒ Aims and Scope	— 1 +
☒ Keywords	— 1 +

Paper Keywords

Journal Fields	Boost
☒ Title	— 5 +
☒ About	— 1 +
☒ Aims and Scope	— 1 +
☒ Keywords	— 5 +

Figura 5.6: Configuración Wiley

El dataset completo con el cual comenzamos a trabajar con la editorial Wiley fue de 5680. Siguiendo la misma lógica utilizada para Springer, se recortaron aquellos papers publicados antes de 2005. Una vez aplicado el filtro por año, se obtuvo un total de 4886 papers.

5.3.2.2 Análisis de resultados

A continuación, se muestra la primera recomendación de HelpMePublish basándose en el primer dataset. Se puede observar que para un 21.9%, equivalente a 696 documentos, la herramienta recomendó como en primera posición, y para un 37,4% representando 1186 entre los primeros 5 lugares. Nuevamente e igual con lo que sucedió con la editorial Springer, contamos con más de un 55% de las recomendaciones ubicadas en los primeros 5 lugares. Quizás la única diferencia que podemos notar entre las editoriales y mirando tanto la Figura 5.2 y 5.7 es que Springer contaba con prácticamente la misma cantidad de datos entre la posición uno y la quinta. Mientras que Wiley, cuenta con menos documentos en el top 1 pero más en el top 5 equiparando los porcentajes entre ambas editoriales.




Figura 5.7: Porcentaje dataset 1 Wiley

Al igual que con la editorial Springer, se analizaron los journals con peores resultados para definir si eran valores atípicos o si el problema provenía de la herramienta. Una vez definido que el funcionamiento de la herramienta era el correcto, se procedió a agregar los documentos previamente quitados del dataset. Comenzamos la segunda iteración con un total de 4886 documentos de los cuales se rankeo 726 en la primera posición, representando un 14,9% y 1308 entre los primeros cinco lugares que equivalen a un 26,8 % del total del conjunto de datos. Observando ambas métricas, se puede apreciar como ahora se redujo desde casi un 60% de los documentos en primeras posiciones que teníamos en la primera iteración a poco más del 40%.




Figura 5.8: Gráfico comparativo Wiley

Como se puede apreciar en Figura 5.8, la primera iteración logró una mejora aproximada del 17% generando un 59,3% del total de los documentos entre los primeros cinco lugares. Otra mejora a mencionar fue la reducción en los documentos que quedaron por fuera del top 25 y superior. Ambos lugares del ranking representan un 24,7% del total mientras que en la primera iteración equivalía a 45,5% del total del dataset utilizado.

En Figura 5.9, se puede observar un listado con los mejores journals que la herramienta recomendó para la editorial Wiley.

Journal	Top 1	Top 5	Total	Porcentaje
Archaeological Prospection	9	1	10	100.00%
Software Testing, Verification and Reliability	19	4	23	100.00%
Random Structures & Algorithms	10	3	14	92.86%
International Journal of Robust and Nonlinear Control	62	36	110	89.09%
Numerical Methods for Partial Differential Equations	50	31	95	85.26%
International Journal of Adaptive Control and Signal Processing	40	25	77	84.42%
System Dynamics Review	31	0	37	83.78%
Crystal Research and Technology	88	36	166	74.70%

Figura 5.9: Ranking journals Wiley

Como se comentó en un primer momento, algunos journals quedaron fuera del dataset original por ser considerados no representativos. Se pudo analizar en la segunda iteración que los mismos perjudicaron las recomendaciones.

En Figura 5.10, se muestran los journals más significativos negativamente que decidimos sacar del dataset con algunas de sus métricas.

Journal	Top 25	Top > 25	Total	Porcentaje
Biometrics	710	446	1329	86.98%
Communications on Pure and Applied Mathematics	73	67	189	74.07%
Mathematische Nachrichten	65	80	194	74.74%

Figura 5.10: Métricas negativas Wiley

5.3.3 Elsevier

La última editorial a analizar es Elsevier. Para dicha editorial contamos con el dataset más chico de todos. Es por esto que, a diferencia de las pruebas en las editoriales anteriores, para Elsevier solamente ejecutaremos una única iteración de recomendación.

Por otro lado, considerando que el tamaño del conjunto de datos no es muy grande, si quisiéramos filtrar información nos quedaría un dataset muy pequeño para realizar la ejecución de la herramienta.

5.3.3.1 Análisis de la información

Como se mencionó anteriormente, cada editorial cuenta con información propia y particular que no siempre la tienen todos los journals. En el caso de Elsevier, analizamos que el campo about, generalmente estaba vacío o con información redundante que no le aportaba nada a la herramienta para optimizar la recomendación. Es por esto que se optó por la siguiente configuración de búsqueda.

Paper Title			Paper Abstract			Paper Keywords		
Journal Fields		Boost	Journal Fields		Boost	Journal Fields		Boost
☒	Title	- 2 +	☒	Title	- 1 +	☒	Title	- 2 +
☐	About	- 1 +	☐	About	- 1 +	☐	About	- 1 +
☒	Aims and Scope	- 1.5 +	☒	Aims and Scope	- 2 +	☒	Aims and Scope	- 2 +
☒	Keywords	- 1.5 +	☒	Keywords	- 1.5 +	☒	Keywords	- 2 +

Figura 5.11: Configuración Elsevier

Sin aplicar refinamiento, se trabajó directamente con la totalidad del dataset, 382 papers que fueron publicados en la editorial de Elsevier. Siguiendo la lógica de las editoriales anteriores, lo que sí se realizó fue el recorte de documentos a partir del año 2005, ya que consideramos de vital importancia trabajar con un conjunto de datos actuales, además de que hayan sido publicados en revistas vigentes.

5.3.3.2 Análisis de resultados

Como ya comentamos anteriormente, esta vez realizamos una única iteración por nuestra herramienta HelpMePublish. La misma recomendó sobre un total de 194 documentos, que 59 de ellos estaban en primera posición. Además, también recomendó 65 journals entre las cinco primeras posiciones. Si vamos a los porcentajes que representan estos números sobre el total del dataset, estamos hablando de un 30,4% y un 33.5% respectivamente.




Figura 5.12: Porcentaje Elsevier

Analizando el gráfico anterior, podemos determinar que más de un 63% de las recomendaciones generadas por la herramienta están ubicadas en las primeras 5 posiciones. Es importante comentar que las tres editoriales obtuvieron un porcentaje muy similar con respecto a las primeras posiciones del ranking.

Podemos determinar que pese a la editorial utilizada o la configuración elegida para cada una de ellas, como también el tamaño del dataset, la herramienta se mantiene en un rango de valores similares para cada una de las editoriales utilizadas.

A continuación, y pese a la poca cantidad de documentos utilizados, listamos los mejores journals de Elsevier recomendados por la herramienta.

Journal	Top 1	Top 5	Totals	Porcentaje
Medical Image Analysis	23	3	26	100.00%
Artificial Intelligence in Medicine	7	0	7	100.00%
Computer Networks	11	7	20	90.00%
Fuzzy Sets and Systems	6	1	9	77.78%

Figura 5.13: Ranking journals Elsevier

5.3.4 Análisis conjunto de las recomendaciones

En esta sección hablaremos acerca de la importancia de los datos dentro de los journals, cuáles son clave para una recomendación de calidad y en qué nos basamos para considerar que un journal es relevante o no.

Para ejemplificar y analizar por qué HelpMePublish recomendó journals en baja posición y otros en los primeros lugares, hemos decidido mostrar 2 ejemplos claros de journals que contienen información útil para la herramienta mientras otros no tanto. Para dicho análisis, tomaremos a la editorial Springer como primer caso y luego haremos lo mismo con Wiley. En dichas editoriales se realizaron dos iteraciones con la herramienta para poder comparar los resultados. A continuación comentaremos porque se decidió a quitar journals con poca relevancia que perjudicaban los resultados finales.

5.3.4.1 Contenido Springer

Para el siguiente análisis, tomaremos dos documentos al azar de los comentados en la sección anterior en las tablas de listado de recomendaciones. Luego, analizamos cuál fue la información que hizo que ese journal sea relevante o no para la herramienta entre otros aspectos.

Seleccionamos como un journal de relevancia a [Genetic Programming and Evolvable Machines](#) para comparar con [Scientometrics](#) que fue uno de los peores journals rankeados.




Figura 5.14: Sección aims and scope Scientometrics

Comenzaremos el análisis haciendo énfasis en la sección Aims and scope del journal. En este caso, se puede apreciar cómo la sección no cuenta con una división clara de la información, solamente contiene 3 párrafos en donde resume, sin mucho detalle, el contenido del journal. Otro aspecto importante a resaltar es el título, el cual solamente contiene una palabra general que no describe lo que contiene.



Autonomous Agents and Multi-Agent Systems

[Journal home](#) > [Aims and scope](#)

Aims and scope

The journal provides a leading forum for disseminating significant original research results in the foundations, theory, development, analysis, and applications of autonomous agents and multi-agent systems. Specific topics of interest include, but are not restricted to:

- Agent decision-making architectures and their evaluation, including deliberative, practical reasoning, reactive/behavioural, plan-based, and hybrid architectures.
- Cooperation and teamwork, including organizational structuring and design for multi-agent systems, self-organization, emergent functionality and swarm intelligence.
- Multi-agent planning and planning for multi-agent systems, and the coordination of multi-agent plans and activities.
- Computational auction systems, computational market systems, algorithmic/automated mechanism design, automated negotiation, computational aspects of game theory (cooperative and non-cooperative), and computational social choice theory.
- Knowledge representation and reasoning for, and logical foundations of, autonomous agents and multi-agent systems.
- Agent programming languages - their implementation, semantics, and evaluation.
- Distributed constraint processing and distributed constraint optimization.
- Multi-agent argumentation and dialogue, conflict detection and resolution.
- Multi-agent learning, co-learning, and evolutionary approaches in multi-agent systems.
- Learning agents, including: computational architectures for learning agents; evolution, adaptation; multi-agent learning.
- Agent communication languages, their semantics, pragmatics, and implementation, and agent communication protocols and conversations.
- Conventions, commitments, norms, obligations, and social laws in multi-agent systems, and models of trust and reputation.
- Believable and synthetic agents and characters, and human-agent interaction.
- Environments, testbeds, and programming languages for experimentation with, and analysis of, agent systems.
- Ontologies for agent systems, agents and the semantic web, agents and semantic web services, Grid-based systems, and service-oriented computing.
- Robotic agents, including: integrated perception, cognition, and action; cognitive robotics; robot planning (including action and motion planning); multi-robot systems.
- Agents as a software engineering paradigm, including agent system development, specification and verification of agent systems, methodologies for autonomous agents

Figura 5.15: Sección aims and scope Genetic Programming and Evolvable Machines

En comparación con el journal anterior, en la Figura 5.15 se puede apreciar como luego de un breve resumen introductorio se comienza a listar información relevante acerca del contenido del journals. Implícitamente, cada ítem listado contiene palabras claves que por más que no aparezcan en una sección individual como “keywords” es fácil reconocerlas. Otro aspecto de importancia como se mencionó anteriormente es el título, en este caso el journal cuenta con un título como Genetic Programming and Evolvable Machines que describe de forma clara y específica de qué se trata el documento. También, se destaca la longitud de la sección aims and scope, la Figura 5.15 muestra solo una parte de la misma.

5.3.4.2 Contenido Wiley

A diferencia de la editorial de Springer y como se comentó anteriormente donde la sección aims and scope era de vital importancia, los journals provenientes de Wiley contienen, además, la sección de keywords la cual es de gran relevancia a la hora procesar la información.

Para el siguiente análisis hemos seleccionado los journals de [Testing, Verification and Reliability](#) que es uno de los documentos completos y listados por la herramienta en los primeros lugares para describir su contenido, con el journal [Biometrics](#) que fue el quitado del conjunto de datos en la segunda iteración por su bajo nivel de relevancia.

El Journal de Biometrics está compuesto por 3 secciones (véase Figura 5.16). La primera de ellas es Overview, en donde se resume acerca de qué trata el documento y cuales son los objetivos. Luego aparece la sección Aims and Scope, la cual analizamos anteriormente con los journals de Springer y en donde no haremos énfasis esta vez. Por último, aparece el apartado Keywords en donde se listan las palabras que consideraron de relevancia para describir el journal. Como se puede observar, dichas palabras carecen de importancia ya que son muy genéricas en su mayoría y no aportan mucho potencial para calificar al documento.

Overview

Published on behalf of the [International Biometric Society](#), **Biometrics** emphasizes the role of statistics and mathematics in the biosciences. Its objectives are to promote and extend the use of statistical and mathematical methods in the principal disciplines of biosciences by reporting on the development and application of these methods. A centerpiece of most Biometrics articles is scientific application that sets scientific or policy objectives, motivates methods development, and demonstrates the operations of new methods.

Aims and Scope

Published on behalf of the [International Biometric Society](#), **Biometrics** emphasizes the role of statistics and mathematics in the biosciences. Its objectives are to promote and extend the use of statistical and mathematical methods in the principal disciplines of biosciences by reporting on the development and application of these methods. A centerpiece of most Biometrics articles is scientific application that sets scientific or policy objectives, motivates methods development, and demonstrates the operations of new methods.

Papers in the journal appear in one of four sections. The Biometric Methodology section presents papers that focus on the development of new methods and results of use in the biosciences. The Biometric Practice section contains papers involving innovative applications of methods and providing practical contributions and guidance, biological insight, and/or significant new findings. Reader Reaction papers refer directly to articles previously published in the journal, and Letters to the Editors provide comments and suggestions on the journal and its content. The Book Review section intends to offer timely reviews of newly published books, including statisticians and people from other disciplines, who are interested in theoretical and methodological development and evolution in Biometrics.

Keywords


biometrics, journal, international, society, IBS, biology, theory, mathematics, science, analysis, data, environments, biological, journal, article, periodical, analysis, research, effects, methods, policy

Figura 5.16: Journal Biometrics

En el caso del journal, Software Testing, Verification and Reliability, que la herramienta seleccionó como relevante, podemos apreciar fácilmente como la distribución de la información es más prolija y detallada. Comienza como es habitual con un resumen y sigue el aims and scope. Aquí, nuevamente se percibe lo hablado acerca del ejemplo anterior sobre cómo además de texto que describe la sección, utiliza una serie de ítems para listar puntos de relevancia.

Además, este journal cuenta con la sección Readership que resulta muy útil para identificar el tipo de usuario a quien podría interesarle el contenido del documento.

Por último, está la sección de keywords que si bien contiene algunas palabras redundantes como el ejemplo anterior, también contiene palabras muy calificadas y descriptivas que permiten identificar fácilmente el contenido.



Journal of Software: Testing, Verification and Reliability

[HOME](#) | [ABOUT](#) | [CONTRIBUTE](#) | [BROWSE](#)

Overview

Software Testing, Verification and Reliability (STVR) is an international journal, publishing 8 issues per year. It publishes papers on theoretical and practical issues of software testing, verification and reliability. The goal of the journal is to publish high-quality papers that help researchers, educators and practitioners understand cutting edge results.

Aims and Scope

The journal is the premier outlet for research results on the subjects of testing, verification and reliability. Readers will find useful research on issues pertaining to building better software and evaluating it.

The journal is unique in its emphasis on theoretical foundations and applications to real-world software development. The balance of theory, empirical work, and practical applications provide readers with better techniques for testing, verifying and improving the reliability of software.

The journal targets researchers, practitioners, educators and students that have a vested interest in results generated by high-quality testing, verification and reliability modeling and evaluation of software. Topics of special interest include, but are not limited to:

- New criteria for software testing and verification
- Application of existing software testing and verification techniques to new types of software, including web applications, web services, embedded software, aspect-oriented software, and software architectures
- Model based testing
- Formal verification techniques such as model-checking
- Comparison of testing and verification techniques
- Measurement of and metrics for testing, verification and reliability
- Industrial experience with cutting edge techniques
- Descriptions and evaluations of commercial and open-source software testing tools
- Reliability modeling, measurement and application
- Testing and verification of software security
- Automated test data generation
- Process issues and methods
- Non-functional testing

Types of contributions include:

- *Research Papers* reporting original work, either theoretical or practical, which increase knowledge, understanding or practice in software testing, verification or reliability. Refereed prior to publication.
- *Survey Papers* that detail all the current knowledge in a specific area. Refereed.

Each scientific paper will be thoroughly reviewed by at least three reviewers.

Readership

Software engineers and designers · software researchers · software tool vendors · information technology practitioners

Keywords

Software, software testing, verification, software reliability, software metrics and metrology, software standards, programming, object oriented, policy, software tools, practical, fault coupling/exposure behaviour, fault-based testing, journal, online journal, Wiley Online Library

Figura 5.17: Journal Software Testing, Verification and Reliability

5.4 Caso de estudio 2: Análisis Multi-editorial

El presente caso de estudio tiene como objetivo mostrar el funcionamiento de la aplicación desarrollada para el caso Multi-editorial. El mismo se llevó a cabo seleccionando 5 papers al azar con sus respectivas recomendaciones y generando un formulario. Como muestra la Figura 5.18, las recomendaciones estaban compuestas por 10 journals obtenidos de la herramienta para ese paper en particular. Los encargados de recibir el formulario fueron investigadores del área de computación y sistemas de la universidad.

Managing the constraints of boundary spanning in emergency management

Stakeholders tasked with boundary spanning in emergency management are fundamental in facilitating multi-agency coordination. However, there is a scarcity of research investigating the characteristics of emergency management boundary spanners and how they achieve this function in the complex environment of emergency operation centres. An exploratory case study approach was adopted and applied in a strategic-level emergency operations centre. The study used three very different but interrelated qualitative research techniques based upon the Core-Task Analysis framework to categorize the work of stakeholders fulfilling a boundary spanning role in this setting. The data identified that stakeholders performing boundary spanning activities in a strategic-level emergency operations centre face a number of constraints. These can include unfamiliarity with the work domain, its personnel, and structure which can lead to temporal, cultural and information challenges. In order to manage these constraints, boundary spanners working in a strategic-level emergency operations centre need to adopt certain characteristics in order to accomplish their activities. A significant outcome from the data was the necessity to engage in these important undertakings in the pre-response phase in an effort to facilitate successful multi-agency coordination in an actual emergency event

Boundary spanning, Emergency operations centre, Multi-agency coordination, Liaison officer, Emergency management, Disaster management

<https://link.springer.com/article/10.1007/s10111-014-0285-z>

Journal #1

Cognition, Technology & Work

<https://link.springer.com/journal/10111>

Journal #2

Engineering Analysis with Boundary Elements

<https://www.journals.elsevier.com/engineering-analysis-with-boundary-elements>

Journal #3

Constraints

<https://link.springer.com/journal/10601>

Journal #4

Journal of Network and Systems Management

<https://link.springer.com/journal/10922>

Journal #5

International Journal of Information Management Data Insights

<https://www.journals.elsevier.com/international-journal-of-information-management-data-insights>

Journal #6

Telematics and Informatics

<https://www.journals.elsevier.com/telematics-and-informatics>

Journal #7

Autonomous Agents and Multi-Agent Systems

<https://link.springer.com/journal/10458>

Journal #8

AI & SOCIETY

<https://link.springer.com/journal/146>

Journal #9

Requirements Engineering

<https://link.springer.com/journal/766>

Journal #10

Computers & Fluids

<https://www.journals.elsevier.com/computers-and-fluids>

Figura 5.18: Formulario

Para evaluar los resultados obtenidos se optó por utilizar la métrica Ganancia Acumulada Descontada Normalizada o más conocida como NDCG, por sus siglas en inglés. NDCG es una de las métricas más utilizadas para medir la precisión en sistemas de recomendación y premia la colocación de los documentos de gran relevancia en los primeros lugares de las listas recomendadas.

Dicha métrica, valora que los resultados de gran relevancia se encuentren en los primeros lugares de las listas recomendadas, valorando el hecho de que algunos documentos son “más” relevantes que otros. Los elementos muy relevantes deben ir antes que los elementos de relevancia media, que deben ir antes que los elementos no relevantes.

$$\text{nDCG}_p = \frac{DCG_p}{IDCG_p}$$

Figura 5.19: Ecuación NDCG

A cada revista se le asignó un grado de relevancia, el cual proviene de la suma de las valoraciones de los expertos en el formulario mostrado anteriormente. En este mismo, se solicitó a los encuestados que califiquen la recomendación (Muy relevante, relevante, poco relevante, no relevante) con el fin de poder hacer un análisis en base a los conocimientos y experiencias de los investigadores sobre las recomendaciones obtenidas por la herramienta. Cada calificación tuvo asociado un valor para la utilización de la métrica NDCG como se puede observar en Figura 5.21.

	Muy Relevante	Relevante	Poco Relevante	No Relevante
Journal #1	☐	☐	☐	☐
Journal #2	☐	☐	☐	☐
Journal #3	☐	☐	☐	☐
Journal #4	☐	☐	☐	☐
Journal #5	☐	☐	☐	☐
Journal #6	☐	☐	☐	☐
Journal #7	☐	☐	☐	☐
Journal #8	☐	☐	☐	☐
Journal #9	☐	☐	☐	☐
Journal #10	☐	☐	☐	☐

Figura 5.20: Calificación de papers.

Calificación	Valor
Muy Relevante	2
Relevante	1
Poco Relevante	0.5
No Relevante	0

Figura 5.21: Valores NDCG

5.4.1 Experimento y Análisis de Resultados

El primer paso para el análisis fue la captura de las calificaciones realizadas por los expertos en el formulario enviado. Cada experto valoró a su parecer los 10 papers obtenidos por la herramienta. El valor de cada calificación se puede observar en Figura 5.21 y la relevancia final del paper se obtiene de la sumatoria de cada valoración del experto multiplicado por el valor correspondiente. En Figura 5.22 ejemplificamos la situación, en este caso, 2 expertos lo calificaron como muy relevante, otros 3 como relevante y otros 2 como poco relevante y no relevante. En este caso la relevancia final se calcula como $2*2 + 3*1 + 1*0,5 + 1*0$, obteniendo como valor final 7.5.

	Muy Relevante	Relevante	Poco relevante	No Relevante
Journal 1	2	3	1	1

Figura 5.22: Valoración journal #1

Cada investigador calificó a su criterio los distintos journals recomendados por la herramienta. En algunos casos, las valoraciones de los expertos eran muy diferentes, no había unanimidad. Por ejemplo, algunos expertos califican como muy relevante una recomendación mientras que otros la califican como no relevante.

Tomaremos el Paper 4 para mostrar las relevancias indicadas por los expertos y cómo se realiza el cálculo posterior mediante la ecuación de la Figura 5.19. El primer paso fue separar las valoraciones de cada experto por journal. Mediante los valores indicados en Figura 5.22 calculamos la columna Real para conocer la valoración total de ese journal y a su vez, generamos otra columna más con el valor Ideal.

El valor ideal se calcula en base a que los journals de mayor relevancia deberían estar al inicio de los resultados. Para esto, se ordena la distribución real de mayor a menor, y se genera una nueva distribución con los valores ideales. En el siguiente ejemplo, se puede observar que para los journals en la posición 2 y 3, se obtiene un valor de 6.5 pero el valor ideal para estas posiciones es de 7, ya que

contamos con al menos 2 journals que obtuvieron una mayor puntuación en posiciones peores.

	Muy Relevante	Relevante	Poco relevante	No Relevante	Real	Ideal
Journal 1	6	1	0	0	13	13
Journal 2	1	4	1	1	6.5	7
Journal 3	2	1	3	1	6.5	7
Journal 4	1	4	1	1	6.5	6.5
Journal 5	1	3	3	0	6.5	6.5
Journal 6	0	3	3	1	4.5	6.5
Journal 7	1	4	2	0	7	6.5
Journal 8	1	4	2	0	7	4.5
Journal 9	0	0	3	4	1.5	2
Journal 10	0	1	2	4	2	1.5

Figura 5.23: Esquema de valoraciones

Con los valores reales e ideales ya calculados, procedimos a separar las valoraciones de los expertos individualmente para posteriormente separarlos en vectores que utilizamos para el cálculo de los valores finales del NDCG.

	Experto 1	Experto 2	Experto 3	Experto 4	Experto 5	Experto 6	Experto 7
Journal 1	2	2	2	2	2	1	2
Journal 2	2	0.5	1	1	1	0	1
Journal 3	2	0.5	0.5	1	2	0.5	0
Journal 4	1	1	1	0.5	1	0	2
Journal 5	2	0.5	1	1	1	0.5	0.5
Journal 6	1	0.5	1	1	0	0.5	0.5
Journal 7	2	0.5	1	1	0.5	1	1
Journal 8	2	0.5	1	1	0.5	1	1
Journal 9	0.5	0	0	0.5	0.5	0	0
Journal 10	0.5	0.5	0	0	1	0	0

Figura 5.24: Esquema de valoraciones individuales

Los vectores de cada experto según sus valoraciones quedaron de la siguiente manera:

- Experto 1 = [2,2,2,1,2,1,2,2,0.5,0.5]
- Experto 2 = [2,0.5,0.5,1,0.5,0.5,0.5,0.5,0,0.5]
- Experto 3 = [2,1,0.5,1,1,1,1,1,0,0]
- Experto 4 = [2,1,1,0.5,1,1,1,1,0.5,0]

- Experto 5 = [2,1,2,1,1,0,0.5,0.5,0.5,1]
- Experto 6 = [1,0,0.5,0,0.5,0.5,1,1,0,0]
- Experto 7 = [2,1,0,2,0.5,0.5,1,1,0,0]

En Figura 5.25 se muestran los resultados finales arrojados por NDCG utilizando los valores anteriormente mencionados a las calificaciones generadas por los expertos.

Se puede apreciar como en los papers 3 y 4 los expertos coincidieron en gran medida las valoraciones de forma positiva. En cambio, en los papers 2 y 5 las valoraciones variaron generando valores extremos tanto positiva como negativamente. El paper 1 obtuvo valoraciones positivas en su mayoría, salvo un experto que asignó un valor extremo.

Interpretamos que este comportamiento, donde las valoraciones de los expertos variaba mucho para un mismo resultado, se debe a que los papers seleccionados trataban de diferentes y variados campos de estudio, y probablemente los expertos conozcan más de un área de estudio que de otra por lo cual en algunos casos les puede resultar difícil tomar una decisión en cuanto a qué valoración darle a un journal determinado.

	Paper 1	Paper 2	Paper 3	Paper 4	Paper 5
Persona 1	0.951	0.810	0.989	0.974	0.656
Persona 2	0.813	0.891	0.834	0.974	0.850
Persona 3	0.507	0.609	0.783	0.981	0.944
Persona 4	0.825	0.851	0.926	0.989	0.701
Persona 5	0.911	0.837	0.841	0.953	0.799
Persona 6	0.832	0.568	0.863	0.827	0.637
Persona 7	0.815	0.803	0.936	0.905	0.649
Todos	0.889	0.634	0.861	0.998	0.529

Figura 5.25: Resultados NDCG

6. Conclusiones

En la actualidad, no existe un medio de búsqueda de calidad en el cual un investigador pueda basarse para encontrar la revista indicada para su publicación. En ocasiones, es necesario buscar en diversos repositorios ya que uno solo no es suficiente para encontrar los recursos que el investigador necesita, esto puede tomar demasiado tiempo y dificultar el objetivo. Lograr ese medio significa un avance importante en todo lo relacionados al análisis y recomendación de publicaciones en revistas de impacto.

6.1 Contribuciones

Como contribución principal, la herramienta HelpMePublish, desarrollada como proyecto de tesis, permite la recomendación de revistas multi-editorial que, a partir de información de un artículo científico (título, palabras claves, resumen, etc.), sugiere los canales de publicación más apropiados.

Resulta importante resaltar que la información es obtenida automáticamente de los sitios web de las revistas más reconocidas a nivel mundial.

Para esto, se provee una interfaz gráfica para buscar la revista más adecuada considerando los atributos antes mencionados, generando así una lista de los resultados mejores rankeados para la publicación.

En base a los resultados obtenidos de la experimentación, se concluye que la herramienta permite realizar una recomendación acertada en el 60% por ciento de los casos. La contribución concreta de la tesis es una herramienta multi-editorial para ayudar a los investigadores a encontrar revistas dónde publicar sus trabajos.

6.2 Limitaciones

Una limitación que posee la herramienta surge de la dependencia con las descripciones con las que cuentan las revistas. Un caso en particular fue el de Scientometrics, el cual no fue recomendado por la herramienta pese a la cantidad de publicaciones con las que contaba. Una posible solución para esto podría ser que en lugar de analizar la descripción de la revista, se analicen los artículos que se encuentran publicados en ella.

Por otro lado, la herramienta captura la información desde las interfaces web de las editoriales. En el caso de que la página modifique su interfaz, la herramienta tiene la limitación de no actualizarse automáticamente y se deberá actualizar el crawler con las nuevas direcciones.

6.3 Futuras mejoras

La aplicación ha sido diseñada y desarrollada de tal manera que pueda ser escalada con facilidad.

Como se mencionó en la sección de la propuesta, la búsqueda y la recomendación se centra en la categoría de ciencias de la computación. Esto significa que una de las primeras y mejores ampliaciones que se podrían realizar sería escalar hacia áreas como ciencias económicas, veterinarias, humanas entre muchas otras. También, es posible fácilmente agregar más editoriales a las anteriores mencionadas (Springer, Elsevier y Wiley).

A continuación mencionaremos algunas posibles funcionalidades a agregar que serían beneficiosas para el futuro:

- **Sistema de valoración:** sería de utilidad después de realizar una búsqueda con su posterior recomendación, poder calificar de alguna manera si el resultado devuelto es exitoso o no para el usuario.
- **Criterios de búsqueda:** agregar más criterios según para mejorar las búsquedas, quizás dependiendo del área a buscar.
- **Ranking histórico:** elaborar un registro histórico de las revistas más buscadas y recomendadas.
- **Interacción entre usuarios:** agregar la posibilidad de comentar o debatir acerca de recomendaciones.
- **Recordador de publicaciones:** almacenar las publicaciones del usuario para posibles recomendaciones.
- **Ranking en base a Similitud Semántica:** en lugar de utilizar BM25 se podrían crear representaciones vectoriales (embeddings) de los campos y calcular, por ejemplo, la distancia del coseno u otra métrica.

Referencias

1. Eduardo Aguado López, Rosario Rogel-Salaza(1999-2006). Las revistas multidisciplinares como medios de exposición del trabajo en colaboración: CIENCIA ergo sum.
2. Espinosa Santos, V. (2010). Difusión y divulgación de la investigación científica. *Idesia* (Arica), 28(3), 5-6.
3. Torres-Salinas, Daniel y Cabezas-Clavijo, Álvaro. (2013). Cómo publicar en revistas científicas de impacto: consejos y reglas sobre publicación científica. EC3 Working Papers, N° 13
4. Campanario, J. M. (2003). Cómo escribir y publicar un artículo científico. Cómo estudiar y aumentar el impacto. *Revista española de documentación científica*, 26(4), 461-463.
5. BAEZA-YATES, Ricardo, et al. *Modern information retrieval*. New York: ACM press, 1999.
6. Bobadilla, J., Ortega, F., Hernando, A., & Gutiérrez, A. (2013). Recommender systems survey. *Knowledge-Based Systems*, 46, 109-132.
7. Wang, Y. Y., Luse, A., Townsend, A. M., & Mennecke, B. E. (2015). Understanding the moderating roles of types of recommender systems and products on customer behavioral intention to use recommender systems. *Information Systems and e-Business Management*, 13(4), 769-799.
8. Pazzani, M. J., & Billsus, D. (2007). Content-based recommendation systems. In *The adaptive web* (pp. 325-341). Springer Berlin Heidelberg.
9. Molina Crespo, M. Á. (2016). Sistema de recomendación híbrido para la predicción de calificaciones en Yelp. com (Doctoral dissertation, ETSI_Informatica).
10. Schrenk, M.: Webbots, spiders, and screen scrapers, a guide to developing internet agent with PHP/CUR, 2nd edition (2012)
11. Kowalski, Gerald. *Information retrieval architecture and algorithms*. Springer Science & Business Media, 2010.
12. Kautz, H., Selman, B., and Shah, M. (1997). Referral web: combining social networks and collaborative filtering.
13. Doug Cutting Apache Foundation's Jakarta. Apache Lucene: Overview [on-line]. <http://lucene.apache.org/java/docs/> (mayo 2006). [visit. 15/12/2006] URL: <http://lucene.apache.org/java/docs/>.
14. Ricardo Baeza-Yates y Berthier Ribeiro-Neto. *Modern Information Retrieval*. Addison-Wesley, Harlow, England (1999).
15. AENOR, editor. *Documentación*. Tomo 2. Normas Fundamentales, tomo 56 de Recopilación de normas UNE. AENOR, Madrid, Segunda edición (1997).
16. D. Harman. How effective is suffixing? *JA-SIS*, 42(1):7–15, 1991.

17. Villanueva Rodríguez, U. J. (2019). Investigación y desarrollo de técnicas de scraping.
18. Carrero, F. and Cortizo, J. C. (2009). Sistemas de recomendación.
19. JoseK (2009). De la búsqueda a los sistemas de recomendación.
20. Wang, P. (1998). Why recommendation is special? In Workshop on Recommender Systems, part of the 15th National Conference on Artificial Intelligence, volume 15, pages 111–113, Madison, Wisconsin, EUA). AAAI-98.
21. Karypis, G. (2001). Evaluation of item-based top-n recommendation algorithms. In Proceedings of the tenth international conference on Information and knowledge management, CIKM '01, pages 247–254, New York, NY, USA.
22. Belkin, N. J. and Croft, W. B. (1992). Information filtering and information retrieval: two sides of the same coin?
23. Resnick, P. and Varian, H. R. (1997). Recommender systems.
24. Adomavicius, G., Sankaranarayanan, R., Sen, S., and Tuzhilin, A. (2005). Incorporating contextual information in recommender systems using a multidimensional approach
25. Ziegler, C.-N., McNee, S. M., Konstan, J. A., and Lausen, G. (2005). Improving recommendation lists through topic diversification. In Proceedings of the 14th international conference on World Wide Web
26. Jawaheer, G., Szomszor, M., and Kostkova, P. (2010). Comparison of implicit and explicit feedback from an online music recommendation service. In Proceedings of the 1st International Workshop on Information heterogeneity and Fusion in Recommender Systems
27. Kelly, D. and Teevan, J. (2003). Implicit feedback for inferring user preference: a bibliography.
28. Balabanovic, M. and Shoham, Y. (1997). Fab: content-based, collaborative recommendation
29. Adomavicius, G. and Tuzhilin, A. (2005). Toward the next generation of recommender systems: A survey of the state-of-the-art and possible extensions.
30. Burke, R. (2002). Hybrid recommender systems: Survey and experiments.
31. Del Castillo; J. A. Delgado-López, E. P. J. M. M. (2008). Semantic recommender systems. analysis of the state of the topic.
32. Nuñez Valdéz, E. R., Sanjuán Martínez, O., Cueva Lovelle, J. M., Ordoñez de Pablos, P., and Montenegro Marín, C. E. (2012b). Implicit feedback techniques on recommender systems applied to electronic books.
33. O'Donovan, J. and Smyth, B. (2005). Trust in recommender systems.
34. Resnick, P., Iacovou, N., Suchak, M., Bergstrom, P., and Riedl, J. (1994). Grouplens: an open architecture for collaborative filtering of netnews.

35. González Crespo, R., Sanjuán Martínez, O., Cueva Lovelle, J. M., Pelayo García-Bustelo, B. C., Gayo, J. E. L., and nez de Pablo, P. O. (2010). Recommendation system based on user interaction data applied to Computers in Human Behavior. intelligent electronic books.
36. Claypool, M., Brown, D., Le, P., and Waseda, M. (2001). Inferring user interest.
37. Kang, N., Doornenbal, M. A., & Schijvenaars, R. J. (2015, September). Elsevier journal finder: recommending journals for your paper. In *Proceedings of the 9th ACM Conference on Recommender Systems* (pp. 261-264).